



FUNDAÇÃO EDSON QUEIROZ
UNIVERSIDADE DE FORTALEZA - UNIFOR
CENTRO DE CIÊNCIAS TECNOLÓGICAS
CURSO DE GRADUAÇÃO EM CIÊNCIA DA COMPUTAÇÃO

COMPRESSÃO SEMÂNTICA NA GERAÇÃO DE MODELOS BPMN 2.0
POR MODELOS DE LINGUAGEM: DSL E TRANSPILAÇÃO DETERMINÍSTICA

RAFAEL MARINS FLORENZANO

FORTALEZA – CEARÁ

2026

RAFAEL MARINS FLORENZANO

COMPRESSÃO SEMÂNTICA NA GERAÇÃO DE MODELOS BPMN 2.0
POR MODELOS DE LINGUAGEM: DSL E TRANSPILAÇÃO DETERMINÍSTICA

Trabalho de Conclusão de Curso apresentado ao Curso de Graduação em Ciência da Computação do Centro de Ciências Tecnológicas da Universidade de Fortaleza, como requisito parcial à obtenção do grau de bacharel em Ciência da Computação.

Orientador: Prof. Caio Marques

FORTALEZA – CEARÁ

2026

A ficha catalográfica deve ser gerada no site da biblioteca da Unifor através do link <https://goo.gl/XYUWSC> (link encurtado).

Preencha o formulário com as informações solicitadas e ao final será gerado um arquivo PDF da ficha catalográfica a ser anexada na versão final do TCC.

O arquivo PDF deve ser renomeado para "ficha-catalografica.pdf" (sem aspas) e colocado no diretório "elementos-pre-textuais" (sem aspas) do modelo de TCC da Unifor.

Ficha catalográfica da obra elaborada pelo autor através do programa de geração automática da Biblioteca Central da Universidade de Fortaleza

Batista, Bruno .
TEORIA DA RELATIVIDADE: SUBTÍTULO / Bruno Batista, Sandra
Lima. - 2017
40 f.

Trabalho de Conclusão de Curso (Graduação) - Universidade
de Fortaleza. Curso de Ciência da Computação, Fortaleza, 2017.
Orientação: Liadina Camargo.

1. FÍSICA. 2. RELATIVIDADE. 3. TEMPO. 4. ESPAÇO. I. Lima,
Sandra. II. Camargo, Liadina. III. Título.

ERRATA

Elemento opcional da (ABNT, 2011, 4.2.1.2). Exemplo:

**FERRIGNO, C. R. A. Tratamento de neoplasias ósseas apendiculares com reim-
plantação de enxerto ósseo autólogo autoclavado associado ao plasma rico em plaquetas:**
estudo crítico na cirurgia de preservação de membro em cães. 2011. 128 f. Tese (Livre-Docência)
- Faculdade de Medicina Veterinária e Zootecnia, Universidade de São Paulo, São Paulo, 2011.

Folha	Linha	Onde se lê	Leia-se
1	10	auto-conclavo	autoconclavo

RAFAEL MARINS FLORENZANO

COMPRESSÃO SEMÂNTICA NA GERAÇÃO DE MODELOS BPMN 2.0
POR MODELOS DE LINGUAGEM: DSL E TRANSPILAÇÃO DETERMINÍSTICA

Trabalho de Conclusão de Curso apresentado ao
Curso de Graduação em Ciência da Computação
do Centro de Ciências Tecnológicas da Univer-
sidade de Fortaleza, como requisito parcial à
obtenção do grau de bacharel em Ciência da
Computação.

Aprovada em:

BANCA EXAMINADORA

Prof. Caio Marques (Orientador)
Centro de Ciências Tecnológicas - CCT
Universidade de Fortaleza - UNIFOR

Membro da Banca Dois
Centro de Ciências e Tecnologia - CCT
Universidade do Membro da Banca Dois - SIGLA

Membro da Banca Três
Centro de Ciências e Tecnologia - CCT
Universidade do Membro da Banca Três - SIGLA

Membro da Banca Quatro
Centro de Ciências e Tecnologia - CCT
Universidade do Membro da Banca Quatro - SIGLA

Este trabalho é dedicado às crianças adultas que,
quando pequenas, sonharam em se tornar cien-
tistas.

AGRADECIMENTOS

Recuo de parágrafo.

Primeiramente a Deus que permitiu que tudo isso acontecesse, ao longo de minha vida, e não somente nestes anos como universitária, mas que em todos os momentos é o maior mestre que alguém pode conhecer.

Aos meus pais, pelo amor, incentivo e apoio incondicional.

Obrigada meus irmãos e sobrinhos, que nos momentos de minha ausência dedicados ao estudo superior, sempre fizeram entender que o futuro é feito a partir da constante dedicação no presente!

A esta universidade, seu corpo docente, direção e administração que oportunizaram a janela que hoje vislumbro um horizonte superior, eivado pela acendrada confiança no mérito e ética aqui presentes.

Agradeço a todos os professores por me proporcionar o conhecimento não apenas racional, mas a manifestação do caráter e afetividade da educação no processo de formação profissional, por tanto que se dedicaram a mim, não somente por terem me ensinado, mas por terem me feito aprender. a palavra mestre, nunca fará justiça aos professores dedicados aos quais sem nominar terão os meus eternos agradecimentos.

“É melhor lançar-se à luta em busca do triunfo mesmo expondo-se ao insucesso, que formar fila com os pobres de espírito, que nem gozam muito nem sofrem muito; E vivem nessa penumbra cinzenta sem conhecer nem vitória nem derrota.”

(Franklin Roosevelt)

RESUMO

Espaçamento simples. (1cm) e palavras-chave são separadas por ponto e vírgula, finalizando com ponto.

Segundo a (ABNT, 2003, 3.1-3.2), o resumo deve ressaltar o objetivo, o método, os resultados e as conclusões do documento. A ordem e a extensão destes itens dependem do tipo de resumo (informativo ou indicativo) e do tratamento que cada item recebe no documento original. O resumo deve ser precedido da referência do documento, com exceção do resumo inserido no próprio documento. (...) As palavras-chave devem figurar logo abaixo do resumo, antecedidas da expressão Palavras-chave:, separadas entre si por ponto e finalizadas também por ponto.

Palavras-chave: latex. abntex. editoração de texto.

ABSTRACT

In this on the radio waves: popular culture, peasants and the Basic Education Movement we analyze the participation of peasants of the Brazilian northeastern region in the Basic Education Movement. The focus of this thesis is to demonstrate how the labors involved with broadcast schools have elaborated actions for maintaining and spreading the schools in their communities, in order to achieve the necessary means to improve their way of life. Peasants of the Basic Education Movement have been coadjuvant of the modernizing catholic proposition of the early 1960s, by means of quite peculiar political and cultural representations. Some of these representations were: a meaning for the school, a role for the union and for the political participation, precepts of the land use rights and labor rights, and the multiple meanings of the radio as a mass communication, information and leisure medium. This study intends to stress that the actions – and the political enrollment – of the northeastern peasant could not ever be separated from the modernizing process. The connection can be observed in different social movements of the period, such as the Basic Education Movement, rural unions, the Catholic Agrarian Youth and the MCP. In this sense, we consider that, if the Brazilian modernization was a guideline for the institutions, political organisms and parties for the social movement, such a modernization was a guideline of demands based on elements of material life. Those elements included, by that time, the agrarian reform, the educational issue and labor urgencies.

Keywords: Adult education. Community schools. Peasants. Popular culture

LISTA DE ILUSTRAÇÕES

LISTA DE TABELAS

Tabela 0	– Fontes do conjunto de dados e partições	38
Tabela 1	– Braços experimentais	46
Tabela 2	– Distribuição do corpus por partição	50
Tabela 3	– Fidelidade topológica por versão do conversor	52

LISTA DE QUADROS

LISTA DE ALGORITMOS

LISTA DE CÓDIGOS-FONTE

Código-fonte 1 – Exemplo de processo na BPMN-DSL: decisão exclusiva com laço de repetição via referência. Rótulos em inglês conforme a Seção 4.4.5 41

LISTA DE SÍMBOLOS

A_e	Área efetiva da antena
B	Largura de faixa em que o ruído é medido em Hertz
d	Distância em metros
E	Campo elétrico
FA	Fator da antena
Gr	Ganho de recepção
h	Altura efetiva ou comprimento efetivo de uma antena
I	Corrente elétrica
k	Constante de Boltzmann's
K	Eficiência de irradiação
M	Variação do patamar de ruído em função da RBW
N	Condutor de neutro
NF	Figura de ruído
N_i	Potência do ruído na entrada
N_o	Potência do ruído na saída
P	Potência
R	Resistência
S_i	Potência do sinal na entrada
S_o	Potência do sinal na saída
t	Tempo
V	Tensão
Z_L	Impedância da antena
Z_o	Impedância de referência (50Ω)
λ	Comprimento de onda
Γ	Coefficiente de reflexão

SUMÁRIO

1	INTRODUÇÃO	20
1.1	MOTIVAÇÃO	21
1.2	OBJETIVOS	22
1.2.1	Objetivo Geral	22
1.2.2	Objetivos Específicos	22
2	FUNDAMENTAÇÃO TEÓRICA	23
2.1	MODELAGEM DE PROCESSOS DE NEGÓCIO E A NOTAÇÃO BPMN 2.0	23
2.1.1	Gerenciamento de Processos de Negócio	23
2.1.2	A Notação BPMN 2.0	24
2.1.3	Representação XML e Verbosidade	24
2.2	MODELOS DE LINGUAGEM DE GRANDE ESCALA	25
2.2.1	Arquitetura Transformer	25
2.2.2	Tokenização e o Custo de Sequências Longas	25
2.2.3	Geração de Saídas Estruturadas	26
2.3	LINGUAGENS DE DOMÍNIO ESPECÍFICO E COMPRESSÃO SEMÂNTICA	26
2.3.1	Linguagens de Domínio Específico	26
2.3.2	Compressão Semântica como Estratégia de Geração	27
2.4	ADAPTAÇÃO DE MODELOS DE LINGUAGEM A TAREFAS ESPECÍFICAS	27
2.4.1	Supervised Fine-Tuning	27
2.4.2	Ajuste com Eficiência de Parâmetros: LoRA e QLoRA	28
2.4.3	Aprendizado por Reforço com GRPO	28
2.5	EXTRAÇÃO DE PROCESSOS A PARTIR DE TEXTO NATURAL	29
2.5.1	Caracterização do Problema	29
2.5.2	Recursos e Datasets Disponíveis	29
2.6	AVALIAÇÃO DE GERAÇÃO DE ARTEFATOS ESTRUTURADOS	30
2.6.1	Validação por Esquema	30
2.6.2	Métricas Sintáticas e Semânticas	30
2.6.3	Distância de Edição em Grafos	30
2.6.4	Eficiência: Razão de Compressão de Tokens	31
2.6.5	Função de Recompensa Composta	31
2.7	SÍNTESE DO CAPÍTULO	31

3	TRABALHOS RELACIONADOS	32
3.1	GERAÇÃO DE MODELOS DE PROCESSO COM LLMS	32
3.2	REPRESENTAÇÕES COMPACTAS DE PROCESSOS	32
3.3	COMPRESSÃO DE <i>TOKENS</i> : ENTRADA <i>VERSUS</i> SAÍDA	33
3.4	MODELOS PEQUENOS ESPECIALIZADOS	34
3.5	GARANTIA DE VALIDADE SINTÁTICA	34
4	METODOLOGIA	36
4.1	DELIMITAÇÃO DO PROBLEMA	36
4.2	PRÉ-REGISTRO DO PROTOCOLO EXPERIMENTAL	37
4.3	VISÃO GERAL DO PROTOCOLO	37
4.4	CONSTRUÇÃO DO CONJUNTO DE DADOS	38
4.4.1	Fontes e Curadoria	38
4.4.2	Pré-processamento com LLM	39
4.4.3	Seleção do Modelo Gerador	39
4.4.4	Geração do JSON BPMN Canônico	39
4.4.5	Idioma dos Artefatos	40
4.4.6	Partições e Prevenção de Contaminação	40
4.5	A BPMN-DSL	41
4.6	TRANSPILAÇÃO DETERMINÍSTICA	42
4.6.1	JSON para DSL	42
4.6.2	DSL para XML BPMN 2.0	43
4.7	PROTOCOLO DE AVALIAÇÃO	43
4.7.1	Eixo 1: Validade Sintática	43
4.7.2	Eixo 2: Equivalência Topológica	43
4.7.2.0.1	<i>Definição.</i>	44
4.7.2.0.2	<i>Justificativa.</i>	44
4.7.2.0.3	<i>Proveniência e delimitação.</i>	44
4.7.3	Eixo 3: Fluxos de Mensagem	45
4.7.4	Eixo 4: Compressão	45
4.7.5	Referências Múltiplas e Ambiguidade de Modelagem	46
4.7.6	Desenho dos Braços Experimentais	46
4.7.7	Parâmetros Congelados e Análise Estatística	47
4.8	ESPECIALIZAÇÃO DO MODELO	48

4.8.1	Ajuste Supervisionado	48
4.8.2	Etapa Opcional: Aprendizado por Reforço com Recompensa Verificável	48
4.9	INFRAESTRUTURA E REPRODUTIBILIDADE	49
5	RESULTADOS	50
5.1	COMPOSIÇÃO DO CORPUS	50
5.2	EIXO 1: VALIDADE SINTÁTICA	51
5.3	EIXO 2: FIDELIDADE TOPOLÓGICA	51
5.3.1	Trajetória entre Versões	51
5.3.2	Análise do Resíduo	52
5.4	EIXO 4: COMPRESSÃO DE <i>TOKENS</i>	52
5.5	CONJUNTO DE REFERÊNCIA	53
5.6	AVALIAÇÃO COMPARATIVA DOS BRAÇOS	53
6	CONCLUSÕES E TRABALHOS FUTUROS	55
6.1	CONTRIBUIÇÕES DO TRABALHO	55
6.2	LIMITAÇÕES	55
6.3	TRABALHOS FUTUROS	56
	REFERÊNCIAS	57
	GLOSSÁRIO	59
	APÊNDICES	60
	APÊNDICE A – Lorem Ipsum	61
	APÊNDICE B – Modelo de Capa	62
	APÊNDICE C – Termo de Fiel Depositário	63
	ANEXOS	64
	ANEXO A – Exemplo de Anexo	65
	ANEXO B – Dinâmica das classes sociais	66
	Índice	67

1 INTRODUÇÃO

Organizações dependem de processos documentados para operar de forma previsível, treinar pessoas e cumprir exigências regulatórias. A notação BPMN 2.0, padronizada pela Object Management Group (2011), tornou-se a linguagem de referência para essa documentação, com uso consolidado tanto na indústria quanto na literatura de gestão de processos (WESKE, 2019; DUMAS *et al.*, 2018). Na prática, porém, a maior parte do conhecimento sobre processos permanece registrada em linguagem natural: manuais internos, descrições de procedimentos e documentos de política. A conversão desse material em modelos formais continua sendo uma tarefa manual, lenta e dependente de especialistas (FRIEDRICH; MENDLING; PUHLMANN, 2011; AA *et al.*, 2018).

O avanço dos modelos de linguagem de grande porte (VASWANI *et al.*, 2017; BROWN *et al.*, 2020) tornou plausível automatizar essa conversão. A dificuldade está na forma de saída. A serialização XML da BPMN foi concebida para intercâmbio entre ferramentas, não para ser escrita diretamente por pessoas ou por modelos. Ao solicitar que um modelo produza XML BPMN completo, transfere-se a ele uma responsabilidade pouco adequada ao seu funcionamento: reproduzir com precisão um grande volume de marcação técnica, ainda que boa parte dessa marcação possa ser derivada de maneira determinística. O custo aparece em duas frentes. A primeira é econômica, pois cada *token* de marcação repetitiva consome contexto, tempo e dinheiro. A segunda é de confiabilidade, já que qualquer inconsistência estrutural invalida o documento inteiro.

A redução do número de *tokens* em sistemas baseados em modelos de linguagem tem sido atacada principalmente do lado da entrada. Na pesquisa, o LLMLingua (JIANG *et al.*, 2023) comprime o contexto antes que ele alcance o modelo, com ganhos expressivos e pouca perda de desempenho. Na indústria, ferramentas como o Headroom (Headroom Labs, 2026) aplicam a mesma ideia a saídas de ferramentas, registros e trechos recuperados, relatando reduções entre 60% e 95% em conteúdo estruturado. Essas abordagens confirmam que a economia de *tokens* é uma preocupação concreta e que boa parte dela vem da remoção de repetição estrutural. Nenhuma delas, entretanto, atua sobre o lado da geração: fazer com que o próprio modelo emita nativamente uma representação compacta, cuja expansão determinística produza um artefato válido segundo um esquema formal.

Duas linhas de trabalho se aproximam desse objetivo por caminhos distintos. A decodificação restrita, discutida por Poesia *et al.* (2022), garante conformidade sintática durante

a geração, mas não reduz o volume que o modelo precisa emitir. Já o ProMoAI, de Kourani *et al.* (2024), gera modelos de processo por meio de uma representação intermediária expandida deterministicamente em BPMN, demonstrando que a estratégia é viável. O trabalho de Kourani *et al.* (2024) apoia-se, contudo, em um modelo de fronteira operado por *prompt* e não trata a representação intermediária como um problema de compressão com taxa medida. É exatamente nesse espaço que esta monografia se posiciona.

A escolha do modelo também é parte do problema. Belcak *et al.* (2025) argumentam que modelos pequenos e especializados, e não modelos de fronteira genéricos, tendem a ser a base adequada para tarefas agênticas repetitivas, por razões de custo, latência e previsibilidade. Uma representação intermediária suficientemente compacta e regular torna essa especialização viável: reduz o que o modelo precisa aprender a emitir e permite que um modelo de sete bilhões de parâmetros, como o Qwen2.5-Coder (HUI *et al.*, 2024), seja ajustado para a tarefa.

Este trabalho propõe, portanto, um protocolo de compressão semântica para geração de BPMN. Um modelo de linguagem produz uma descrição concisa do processo em uma linguagem de domínio específico projetada para esse fim, e um transpilador baseado em gramática EBNF expande essa descrição em XML BPMN 2.0 validado contra o esquema oficial. A separação de responsabilidades traz um efeito colateral útil para a depuração: quando ocorre uma falha, ela fica localizada na geração da DSL, no transpilador ou na validação, em vez de diluída em um documento XML extenso. Medições preliminares sobre 1021 processos, usando o tokenizador do Qwen2.5-Coder, indicam que a representação proposta é cerca de cinco vezes mais compacta que o XML lógico correspondente, o que equivale a uma redução de aproximadamente 80% no número de *tokens* que o modelo precisa emitir.

1.1 MOTIVAÇÃO

A modelagem de processos permanece cara justamente onde é mais necessária. Organizações que já documentam seus procedimentos em texto raramente dispõem de tempo especializado para convertê-los em modelos formais, e o resultado é uma base documental que não pode ser analisada, simulada ou automatizada. Reduzir o custo dessa conversão amplia o acesso à modelagem formal para além das organizações que podem manter analistas dedicados.

Há ainda uma motivação técnica. Se a hipótese central se confirmar, o ganho não se limita à BPMN. O padrão de separar a geração de uma representação compacta da expansão determinística em um artefato validável é aplicável a qualquer domínio em que a saída precise

obedecer a um esquema formal e a serialização oficial seja verbosa. A BPMN oferece um caso de teste favorável para essa investigação porque possui esquema oficial, conjuntos de dados públicos com modelos de referência e métricas estruturais bem definidas, o que permite verificação objetiva em vez de avaliação subjetiva.

Por fim, a economia de *tokens* deixou de ser detalhe de implementação. Em fluxos que geram modelos em escala, o custo de emitir marcação redundante é recorrente, e a alternativa de depender continuamente de modelos de fronteira concentra esse custo em um fornecedor externo. Um modelo pequeno ajustado para emitir uma representação comprimida é, nesse cenário, uma resposta de engenharia e não apenas um exercício acadêmico.

1.2 OBJETIVOS

1.2.1 Objetivo Geral

Investigar se a geração de uma representação intermediária comprimida, seguida de expansão determinística, produz modelos BPMN 2.0 válidos de forma mais confiável e mais econômica em *tokens* do que a geração direta de XML por modelos de linguagem.

1.2.2 Objetivos Específicos

- a) projetar uma linguagem de domínio específico para descrição de processos BPMN, com gramática EBNF formalmente especificada;
- b) implementar um transpilador determinístico que expanda essa linguagem em XML BPMN 2.0 validado contra o esquema oficial;
- c) construir um conjunto de dados de pares formados por descrição textual e representação na linguagem proposta, a partir de fontes públicas de descrições de processos;
- d) realizar o ajuste fino supervisionado de um modelo de linguagem de pequeno porte para emitir a representação comprimida;
- e) quantificar a compressão obtida e a fidelidade estrutural dos modelos gerados, comparando a abordagem proposta com a geração direta de XML sob protocolo de avaliação definido previamente à execução dos experimentos.

2 FUNDAMENTAÇÃO TEÓRICA

O ponto de partida deste trabalho é uma dificuldade prática: gerar XML BPMN 2.0 completo por meio de Modelos de Linguagem de Grande Escala (LLMs, do inglês *Large Language Models*) tende a ser custoso, verboso e sujeito a erros estruturais. Para discutir esse problema, este capítulo reúne os conceitos necessários à proposta de um protocolo de compressão semântica voltado à geração de *markup* XML. A fundamentação começa pela modelagem de processos de negócio e pela notação BPMN 2.0, passa pelos princípios de funcionamento dos LLMs e pelos desafios da geração estruturada, e então discute Linguagens de Domínio Específico (DSLs, do inglês *Domain-Specific Languages*) como mecanismo de mediação entre descrição semântica e representação XML. Em seguida, são apresentados os métodos de adaptação de modelos que sustentam a etapa experimental do projeto, especialmente SFT, LoRA, QLoRA e GRPO. Por fim, o capítulo aborda recursos disponíveis para extração de processos a partir de texto natural e métricas adequadas à avaliação de artefatos estruturados.

2.1 MODELAGEM DE PROCESSOS DE NEGÓCIO E A NOTAÇÃO BPMN 2.0

2.1.1 Gerenciamento de Processos de Negócio

O Gerenciamento de Processos de Negócio (BPM, do inglês *Business Process Management*) trata processos organizacionais como objetos que podem ser descritos, analisados, executados e aperfeiçoados de forma sistemática (DUMAS *et al.*, 2018). Essa área aproxima contribuições da administração, da engenharia de software e da pesquisa operacional, sobretudo quando o processo precisa deixar de ser apenas uma prática informal e passar a funcionar como um artefato verificável (WESKE, 2019).

Essa formalização é importante porque iniciativas de automação, auditoria e conformidade dependem de uma representação compartilhada do processo. Ao mesmo tempo, a notação adotada precisa equilibrar dois requisitos que nem sempre caminham juntos: ser compreensível para analistas e gestores, sem exigir domínio técnico profundo, e preservar precisão suficiente para permitir análise computacional ou execução automatizada. A BPMN se consolidou justamente nesse espaço, oferecendo uma linguagem visual relativamente acessível, mas apoiada por uma especificação formal.

2.1.2 A Notação BPMN 2.0

A *Business Process Model and Notation*, em sua versão 2.0, é mantida pelo *Object Management Group* e é uma das principais referências para a representação de processos de negócio (Object Management Group, 2011). Seu papel é duplo: por um lado, define símbolos gráficos usados por analistas de processo; por outro, estabelece uma serialização XML descrita por um *XML Schema Definition* (XSD). Essa combinação permite que um mesmo modelo seja lido visualmente por pessoas e processado por ferramentas.

Segundo a especificação da BPMN 2.0, os elementos da notação são agrupados em categorias principais Object Management Group (2011):

- **Objetos de fluxo** (*flow objects*): eventos (*events*), atividades (*activities*) e *gateways*, que representam os principais nós do processo;
- **Objetos de conexão** (*connecting objects*): fluxos de sequência, fluxos de mensagem e associações, responsáveis por explicitar relações entre elementos;
- **Raias** (*swimlanes*): *pools* e *lanes*, usadas para indicar participantes, setores ou responsabilidades;
- **Artefatos** (*artifacts*): grupos, anotações textuais e objetos de dados, empregados para acrescentar informação complementar ao modelo.

Com esses elementos, a BPMN permite representar padrões comuns de processos, como decisões exclusivas, execuções paralelas, eventos intermediários e interações entre participantes. A expressividade da notação, no entanto, cobra seu preço: quanto mais completa é a representação, maior tende a ser a complexidade para quem modela, valida ou gera o artefato. Dumas *et al.* (2018) observam que essa riqueza da BPMN exige aprendizado, tanto do analista humano quanto de qualquer sistema que tente manipulá-la automaticamente.

2.1.3 Representação XML e Verbosidade

Na prática, um modelo BPMN 2.0 interoperável costuma ser armazenado em XML conforme o esquema oficial. Essa escolha favorece o intercâmbio entre ferramentas e reduz ambiguidades de implementação, mas produz documentos consideravelmente maiores do que a descrição conceitual do processo. Em um exemplo simples, o XML precisa declarar *namespaces*, identificadores, elementos de diagrama, coordenadas, fluxos, referências cruzadas e atributos previstos pela especificação.

Essa verbosidade não é um problema grave quando o XML é gerado por uma

ferramenta de modelagem. A situação muda quando o alvo de geração passa a ser um LLM. Nesse caso, o modelo precisa emitir uma sequência longa, com muitos trechos repetitivos e com baixa tolerância a pequenos desvios. Uma *tag* ausente, um identificador trocado ou uma referência inconsistente pode invalidar o documento inteiro, mesmo que a estrutura geral do processo tenha sido compreendida corretamente. Esse descompasso entre conteúdo semântico e representação textual motiva a busca por uma camada intermediária mais curta e mais controlável.

2.2 MODELOS DE LINGUAGEM DE GRANDE ESCALA

2.2.1 Arquitetura Transformer

A arquitetura Transformer, proposta por Vaswani *et al.* (2017), marcou uma mudança importante na modelagem de sequências. Em vez de processar a entrada de forma recorrente, o Transformer usa mecanismos de *self-attention* para relacionar diretamente diferentes posições da sequência. Esse desenho favoreceu paralelização em larga escala e abriu caminho para os modelos de linguagem atuais.

Os LLMs mais utilizados seguem, em geral, uma formulação autorregressiva: a cada passo, o modelo estima o próximo *token* a partir dos anteriores. Quando treinados sobre grandes coleções de texto, esses modelos passam a apresentar capacidade de generalização para tarefas variadas, inclusive tarefas que não aparecem explicitamente como objetivos de treinamento (BROWN *et al.*, 2020). Essa flexibilidade explica seu interesse para geração de código, consultas, marcações e outros formatos estruturados.

2.2.2 Tokenização e o Custo de Sequências Longas

LLMs não operam diretamente sobre palavras completas. A entrada e a saída são decompostas em *tokens*, frequentemente obtidos por técnicas como *Byte-Pair Encoding* (SENNRICH; HADDOW; BIRCH, 2016). Essa estratégia funciona bem para texto natural, mas pode ser pouco econômica para formatos como XML. Identificadores longos, nomes de atributos, símbolos de marcação e padrões repetidos tendem a ser fragmentados em vários *tokens*.

O aumento no número de *tokens* tem consequências diretas. O mecanismo de atenção cresce em custo com o comprimento da sequência, o que afeta memória, tempo de treinamento e latência de inferência. Em um ambiente acadêmico com recursos limitados, gerar XML BPMN completo significa gastar parte relevante do orçamento computacional em trechos que

são necessários para a conformidade do arquivo, mas não necessariamente para a descrição semântica do processo.

2.2.3 Geração de Saídas Estruturadas

A geração de artefatos estruturados por LLMs, como código-fonte, consultas e linguagens de marcação, tornou-se uma linha de pesquisa relevante a partir de trabalhos como o de Chen *et al.* (2021). O desafio central é que a geração probabilística não garante, por si só, validade sintática nem conformidade a um esquema externo. Em linguagem natural, um pequeno desvio pode ser tolerável; em XML, uma inconsistência local pode tornar todo o documento inválido.

Poesia *et al.* (2022) discutem esse problema no contexto de geração de código e defendem a combinação entre modelos probabilísticos e mecanismos determinísticos de restrição. A ideia é simples, mas importante para este trabalho: quando a saída precisa obedecer a regras formais, a geração livre do modelo deve ser complementada por alguma forma de controle. Esse controle pode aparecer durante a decodificação, em uma etapa posterior de validação ou por meio de uma representação intermediária projetada para ser mais simples de gerar e de verificar.

2.3 LINGUAGENS DE DOMÍNIO ESPECÍFICO E COMPRESSÃO SEMÂNTICA

2.3.1 Linguagens de Domínio Específico

Para Fowler (2010), uma Linguagem de Domínio Específico é uma linguagem computacional criada para um domínio particular, com escopo e expressividade intencionalmente limitados. Essa limitação não é uma deficiência. Pelo contrário, ela permite que a linguagem se aproxime dos conceitos do problema e reduza detalhes que seriam necessários em uma linguagem de propósito geral. Mernik, Heering e Sloane (2005) apontam benefícios recorrentes das DSLs, entre eles a elevação do nível de abstração, a redução de código repetitivo e a maior facilidade para realizar análises estáticas.

No caso da BPMN, a serialização XML já é uma linguagem formal, mas não foi pensada para ser escrita diretamente por pessoas ou por modelos de linguagem. Ela foi concebida principalmente para intercâmbio entre ferramentas. Por isso, quando se pede a um LLM que produza XML BPMN completo, transfere-se ao modelo uma responsabilidade pouco adequada ao seu funcionamento: repetir com precisão uma grande quantidade de marcação técnica, ainda

que parte dessa marcação possa ser gerada de maneira determinística.

2.3.2 Compressão Semântica como Estratégia de Geração

Neste trabalho, compressão semântica designa a redução da representação textual de um artefato sem perda do conteúdo essencial, desde que a forma completa possa ser reconstruída por uma etapa determinística. A compressão, portanto, não é tratada como objetivo isolado. Seu papel é separar duas responsabilidades: o LLM deve produzir uma descrição concisa do processo, enquanto o transpilador deve expandir essa descrição para XML BPMN 2.0 válido.

A proposta segue três etapas. Primeiro, o LLM gera uma representação intermediária em uma DSL voltada à descrição de processos BPMN. Em seguida, um transpilador baseado em gramática EBNF e regras de enriquecimento converte essa representação em XML BPMN 2.0. Por fim, o XML gerado é validado contra o XSD oficial. Quando ocorre erro, a falha tende a ficar mais localizada: pode estar na geração da DSL, no transpilador ou na validação do XML. Esse desenho facilita a depuração quando comparado à geração direta de um documento XML longo.

A motivação para essa estratégia combina três aspectos. O primeiro é computacional, pois uma saída mais curta reduz o número de *tokens* e pode baratear treinamento e inferência. O segundo é de aprendizado, já que uma representação menos redundante pode concentrar melhor o sinal supervisionado no que realmente descreve o processo. O terceiro é metodológico: a separação entre modelo e transpilador permite avaliar de forma mais clara o que foi aprendido pelo LLM e o que foi garantido por regras determinísticas.

2.4 ADAPTAÇÃO DE MODELOS DE LINGUAGEM A TAREFAS ESPECÍFICAS

2.4.1 Supervised Fine-Tuning

O ajuste supervisionado, ou *Supervised Fine-Tuning* (SFT), é uma das formas mais diretas de adaptar um LLM a uma tarefa específica. O procedimento continua o treinamento do modelo sobre pares de entrada e saída esperada, deslocando a distribuição gerada na direção do comportamento desejado (OUYANG *et al.*, 2022). Neste projeto, cada exemplo associa uma descrição textual de processo a uma representação na DSL proposta.

A qualidade do SFT depende fortemente do corpus. Em tarefas muito específicas, como gerar uma DSL nova para processos BPMN, não há um conjunto público pronto que

resolva o problema de forma direta. Isso torna necessária a construção de dados por meio de conversões, curadoria e aumento de dados. Modelos mais capazes podem atuar como apoio nessa etapa, gerando pseudoexemplos que depois precisam ser filtrados e validados.

2.4.2 Ajuste com Eficiência de Parâmetros: LoRA e QLoRA

O ajuste completo de modelos com bilhões de parâmetros costuma ser inviável em computadores de uso acadêmico. Hu *et al.* (2022) propuseram o método *Low-Rank Adaptation* (LoRA) como uma alternativa mais econômica: em vez de atualizar todos os pesos do modelo, treinam-se matrizes de baixa dimensão acopladas a camadas específicas. Os pesos originais permanecem congelados, e apenas os parâmetros adicionais são ajustados.

O método reduz a quantidade de parâmetros treináveis e, consequentemente, o consumo de memória. O QLoRA, apresentado por Dettmers *et al.* (2023), amplia essa economia ao quantizar os pesos congelados do modelo base para 4 *bits*, mantendo as adaptações em maior precisão. Essa combinação é especialmente relevante para o presente estudo, pois o projeto considera treinamento em uma estação local com 12 GB de memória dedicada de GPU.

2.4.3 Aprendizado por Reforço com GRPO

Embora o SFT ensine o modelo a imitar exemplos, ele não otimiza diretamente métricas externas de qualidade. Para uma tarefa como esta, algumas propriedades importantes são verificáveis por código: validade sintática, conformidade ao XSD, fidelidade semântica, coerência topológica do grafo e economia de *tokens*. Essas propriedades podem ser usadas como sinais de recompensa em uma etapa posterior de treinamento.

Shao *et al.* (2024) introduziram o *Group Relative Policy Optimization* (GRPO) no contexto de modelos voltados a raciocínio matemático. O método deriva do PPO, mas evita manter um modelo crítico separado. Para cada *prompt*, gera-se um grupo de respostas, e a vantagem de cada resposta é estimada em relação à média do próprio grupo. Essa simplificação reduz custo de memória, característica importante em cenários com restrição de hardware.

Neste trabalho, o GRPO é previsto como uma segunda etapa após o SFT. A função de recompensa combina dimensões diferentes da qualidade esperada: sintaxe, semântica, topologia e eficiência da DSL gerada. A composição ponderada dessas dimensões permite transformar critérios de avaliação em um sinal de treinamento, sem reduzir a qualidade do processo a uma única métrica isolada.

2.5 EXTRAÇÃO DE PROCESSOS A PARTIR DE TEXTO NATURAL

2.5.1 Caracterização do Problema

A extração automática de modelos de processo a partir de texto natural é anterior ao uso recente de LLMs. Friedrich, Mendling e Puhlmann (2011), por exemplo, já investigavam a geração de modelos BPMN com apoio de técnicas tradicionais de Processamento de Linguagem Natural (PLN), como análise sintática, resolução de correferências e regras de mapeamento. Os resultados indicavam potencial, mas também deixavam claro que textos de processo podem conter ambiguidades e informações implícitas.

Aa *et al.* (2018) organizam esses desafios em dimensões como ambiguidade lexical e estrutural, variação de granularidade, lacunas de informação e possibilidade de múltiplos modelos válidos para uma mesma descrição. Essa última questão é particularmente importante: em muitos casos, não existe apenas uma modelagem correta. O que existe são representações mais ou menos adequadas a uma interpretação do texto, ao nível de detalhe escolhido e ao objetivo da modelagem.

2.5.2 Recursos e Datasets Disponíveis

O domínio ainda possui poucos *benchmarks* consolidados. Bellan *et al.* (2023) apresentaram o *Process Extraction from Text* (PET), composto por 45 descrições textuais anotadas com atividades, *gateways*, atores e relações de fluxo. O PET é relevante por oferecer anotações em granularidade fina, úteis tanto para treinamento quanto para avaliação de tarefas de extração.

Outro recurso importante é o *PMo Dataset*, disponibilizado por Brissard, Cuppens e Zouaq (2025a). O conjunto reúne 55 modelos de processo com descrições textuais correspondentes e diferentes representações de modelo, incluindo BPMN, Mermaid, Graphviz, POWL code e XML simplificado. A presença de uma representação BPMN padronizada como referência torna o conjunto especialmente útil para avaliação. Já o dataset de Mangler e Klievtsova (2023) oferece 24 descrições textuais acompanhadas de múltiplos modelos BPMN possíveis, com pontuações atribuídas por especialistas, o que ajuda a observar a ambiguidade natural da modelagem de processos.

Além desses conjuntos especializados, o projeto pode recorrer a textos procedurais não anotados, como trechos públicos de documentação organizacional, para etapas de aumento de dados. A distinção entre essas fontes é metodologicamente relevante: datasets anotados

servem como referência e avaliação, enquanto textos abertos podem alimentar a construção de pares sintéticos, desde que passem por validação.

2.6 AVALIAÇÃO DE GERAÇÃO DE ARTEFATOS ESTRUTURADOS

2.6.1 Validação por Esquema

A validação por esquema é o primeiro critério para avaliar XML BPMN. No caso da BPMN 2.0, o XSD oficial define se o documento respeita a estrutura esperada pela especificação. O resultado é binário: o XML é válido ou inválido. Esse critério é necessário, mas não suficiente. Um arquivo pode ser válido em termos de esquema e ainda assim representar um processo diferente daquele descrito no texto de entrada.

2.6.2 Métricas Sintáticas e Semânticas

Para avaliar a fidelidade ao processo de referência, métricas como precisão, revocação e F1 podem ser calculadas sobre elementos extraídos do modelo gerado. Atividades, atores, *gateways* e arestas podem ser comparados com os elementos presentes no modelo esperado. A medida F1 é útil nesse contexto porque resume precisão e revocação, evitando uma leitura baseada apenas em acertos brutos.

2.6.3 Distância de Edição em Grafos

Como modelos BPMN podem ser interpretados como grafos, a comparação estrutural também é necessária. A *Graph Edit Distance* (GED), associada ao trabalho de Sanfeliu e Fu (1983), mede a distância entre grafos a partir do custo mínimo de operações de edição, como inserção, remoção e substituição de vértices e arestas. Em formulações gerais, o cálculo exato é computacionalmente difícil, razão pela qual aproximações são frequentemente usadas em aplicações práticas (GAO *et al.*, 2010).

Para este estudo, a GED é interessante porque considera a organização topológica do processo, não apenas a presença ou ausência de elementos individuais. Ainda assim, sua utilidade depende do modelo de custo adotado. Esse modelo precisa refletir o que, no contexto da BPMN, deve ser tratado como diferença relevante entre dois processos.

2.6.4 Eficiência: Razão de Compressão de Tokens

A Razão de Compressão de Tokens (TCR, do inglês *Token Compression Ratio*) é usada para medir a eficiência da representação intermediária. A métrica compara a quantidade de *tokens* necessária para representar o processo em XML BPMN com a quantidade necessária para representá-lo na DSL proposta, usando o mesmo tokenizador. Valores superiores a um indicam que a DSL é mais compacta que o XML correspondente.

Essa métrica, sozinha, não mede qualidade. Uma representação pode ser muito curta e ainda assim perder informação relevante. Por isso, a TCR precisa ser analisada junto às métricas de validade, fidelidade semântica e estrutura topológica. O interesse do trabalho está exatamente nesse equilíbrio: reduzir a saída gerada pelo LLM sem comprometer a reconstrução determinística do BPMN.

2.6.5 Função de Recompensa Composta

No treinamento por GRPO, as métricas anteriores podem ser combinadas em uma função de recompensa composta. Essa função precisa equilibrar critérios diferentes: validade sintática, adequação semântica ao texto, plausibilidade topológica e eficiência em *tokens*. Uma formulação ponderada facilita a interpretação dos resultados, pois permite identificar que dimensão da qualidade está contribuindo mais ou menos para o comportamento do modelo.

2.7 SÍNTESE DO CAPÍTULO

A discussão apresentada neste capítulo delimita o problema e justifica a estratégia proposta. A BPMN 2.0 oferece uma representação rica para processos de negócio, mas sua serialização XML é longa e sensível a erros. LLMs são capazes de gerar texto estruturado, porém não garantem conformidade formal por si mesmos. DSLs oferecem uma alternativa intermediária: descrevem o conteúdo essencial em uma forma mais curta, enquanto um transpilador assume a expansão para XML válido. As técnicas de SFT, LoRA, QLoRA e GRPO fornecem o caminho para adaptar o modelo à tarefa, e as métricas discutidas permitem avaliar a solução sob diferentes aspectos.

Com essa base, o Capítulo de Metodologia pode especificar de maneira operacional a gramática da DSL, o funcionamento do transpilador, a construção dos dados, os parâmetros de treinamento e o protocolo de avaliação.

3 TRABALHOS RELACIONADOS

Este capítulo situa o trabalho em relação a quatro linhas de pesquisa que o tangenciam: geração de modelos de processo por modelos de linguagem, representações compactas de processos, compressão de *tokens* em sistemas com LLMs, e garantia de validade sintática na geração de linguagens formais. O critério de organização é a proximidade com a pergunta desta pesquisa — o custo de gerar marcação hierárquica verbosa —, e não a cronologia ou a autoria.

3.1 GERAÇÃO DE MODELOS DE PROCESSO COM LLMs

A referência mais próxima em objetivo é o ProMoAI (KOURANI *et al.*, 2024), que emprega um LLM de fronteira, guiado por *prompt*, para produzir código POWL executável, posteriormente traduzido para BPMN. A estratégia compartilha com este trabalho a premissa central de **não** pedir XML diretamente ao modelo, interpondo uma representação intermediária mais adequada às capacidades do gerador.

As diferenças são de natureza e de escopo. O ProMoAI depende de um modelo de fronteira em tempo de inferência, o que mantém o custo por geração no patamar que este trabalho procura reduzir; a representação intermediária é código Python, escolhida por familiaridade do modelo com tarefas de programação, e não projetada para minimizar *tokens* emitidos; e a compressão obtida não é medida nem tratada como objetivo. Aqui, ao contrário, a compressão é métrica de primeira classe, a representação é projetada para isso, e o gerador-alvo é um modelo pequeno especializado por ajuste supervisionado. A reexecução do ProMoAI está fora do escopo desta versão, de modo que ele é tratado como referência qualitativa; comparar com números publicados sob protocolo distinto seria metodologicamente indefensável.

3.2 REPRESENTAÇÕES COMPACTAS DE PROCESSOS

Diversas notações alternativas ao XML BPMN foram propostas com objetivos que se sobrepõem parcialmente ao deste trabalho. A representação *JSON branches* (KÖPKE; SAFAN, 2024) foi introduzida explicitamente para reduzir contagem de *tokens* e favorecer aderência a esquema na geração por LLMs. A representação *Process Model Elements* (VÖLTER; HAKE; FETTKE, 2024) organiza o modelo em listas planas de elementos, facilitando contagem e comparação. Somam-se a elas notações de visualização como Mermaid e Graphviz, e simplificações do próprio XML.

O trabalho de Brissard, Cuppens e Zouaq (2025b) é o que mais se aproxima em objeto empírico: realiza análise comparativa de nove representações de modelos de processo para geração com LLMs, sobre o mesmo conjunto de dados aqui utilizado como *holdout*. É, por isso, o antecedente que exige posicionamento mais cuidadoso.

A distinção é de **pergunta de pesquisa**, e não de artefato. Aquele trabalho pergunta qual representação produz os melhores modelos de processo quando um LLM é instruído por *prompt* — uma pergunta sobre adequação de notação à tarefa de modelagem. Esta pesquisa pergunta se a estratégia de comprimir a saída e expandi-la deterministicamente torna economicamente viável a geração de marcação hierárquica verbosa por modelos pequenos, usando BPMN como caso de estudo instrumentado. Disso decorrem três diferenças operacionais:

- a) **o gerador**: representações avaliadas por *prompt* em modelos de fronteira, contra um modelo pequeno especializado por ajuste supervisionado, cujo custo por inferência é ordens de grandeza menor;
- b) **a garantia sintática**: notações comparadas quanto à qualidade do modelo produzido, contra uma cadeia em que a validade perante o esquema é assegurada por construção, deixando de ser variável aleatória;
- c) **a métrica de custo**: compressão medida e reportada como resultado de primeira ordem, e não como propriedade qualitativa da notação.

Que representações compactas de BPMN já existam não é objeção a este trabalho — é evidência de que o problema é reconhecido. A contribuição pretendida não é a notação em si, mas a demonstração empírica de que a combinação entre compressão medida, expansão determinística verificável e especialização de modelo pequeno desloca a fronteira de custo da tarefa. Registre-se ainda que a DSL proposta cobre construções que algumas dessas notações não representam — múltiplos eventos de início e fim, fluxos de mensagem e raias —, embora essa maior expressividade seja consequência do desenho, e não sua justificativa.

3.3 COMPRESSÃO DE *TOKENS*: ENTRADA *VERSUS* SAÍDA

A redução do consumo de *tokens* em sistemas com LLMs é problema ativo, e a literatura predominante trata do lado da **entrada**. O LLMLingua (JIANG *et al.*, 2023) comprime *prompts* removendo conteúdo de baixa informação segundo um modelo de linguagem auxiliar, preservando o desempenho na tarefa a jusante. Trabalhos de gestão de contexto perseguem objetivo análogo por seleção e sumarização do que entra na janela.

Este trabalho ataca o lado oposto e complementar: o custo da **saída**. A assimetria é relevante e raramente explicitada. *Tokens* de entrada podem ser processados em paralelo e beneficiam-se de mecanismos de cache; *tokens* de saída são gerados sequencialmente, dominam a latência percebida e são tipicamente tarifados a preço superior. Em tarefas cuja saída é marcação verbosa, o gargalo econômico está na geração, não na leitura — e comprimir o *prompt* não o alivia. As duas famílias de técnica são, portanto, ortogonais e combináveis, e não concorrentes.

3.4 MODELOS PEQUENOS ESPECIALIZADOS

A viabilidade da proposta depende de que um modelo de pequeno porte, especializado, alcance desempenho competitivo em tarefa estreita. Essa premissa é sustentada por evidência recente sobre o papel de modelos pequenos em sistemas agênticos (BELCAK *et al.*, 2025), que argumenta serem eles suficientes — e economicamente preferíveis — para subtarefas repetitivas e bem delimitadas, reservando modelos de fronteira para as etapas que exigem generalidade.

A geração de marcação estruturada a partir de descrição textual é exatamente uma dessas subtarefas: formato fixo, vocabulário restrito, critério de sucesso verificável. Métodos de ajuste eficiente em parâmetros (HU *et al.*, 2022), especialmente em sua variante quantizada (DETTMERS *et al.*, 2023), tornam a especialização exequível com recursos computacionais modestos, o que é condição para que o argumento econômico se sustente.

3.5 GARANTIA DE VALIDADE SINTÁTICA

Há uma alternativa à estratégia adotada que precisa ser reconhecida: a **decodificação restrita**, que impõe a gramática do formato-alvo durante a amostragem, impedindo por construção a emissão de sequências inválidas (POESIA *et al.*, 2022). Aplicada ao XML BPMN, garantiria validade sintática sem representação intermediária alguma.

Duas considerações delimitam a comparação. A primeira é que a decodificação restrita resolve a validade, mas **não** o custo: o modelo continua emitindo cada *token* da marcação verbosa, de modo que a economia perseguida aqui permanece inalcançada — e, com efeito, as duas técnicas são combináveis, podendo a decodificação restrita ser aplicada sobre a própria DSL. A segunda é que restringir a decodificação a uma gramática garante boa formação sintática, mas não coerência estrutural: um documento pode respeitar o esquema e ainda referenciar identificadores inexistentes ou descrever um grafo desconexo, classe de erro que a expansão

determinística elimina por não permitir que ela seja expressa.

A avaliação empírica da decodificação restrita como braço experimental está fora do escopo desta versão, e é registrada como trabalho futuro derivado.

4 METODOLOGIA

Este capítulo descreve o protocolo de compressão semântica proposto e o desenho experimental usado para avaliá-lo. Trata-se de uma pesquisa aplicada, de natureza experimental e abordagem quantitativa: todos os critérios de qualidade adotados são computáveis por código, e todos os artefatos intermediários são persistidos e versionados para permitir a reprodução integral dos resultados.

4.1 DELIMITAÇÃO DO PROBLEMA

O objeto deste trabalho não é a modelagem de processos em si, mas um problema mais geral do qual ela é um caso concreto: o **custo de geração de linguagens de marcação hierarquicamente complexas e verbosas por modelos de linguagem**. Formatos como XML impõem ao modelo gerador um ônus que é, em grande parte, sintático e não semântico — abertura e fechamento de dezenas de elementos aninhados, declaração de *namespaces*, identificadores de serialização, atributos obrigatórios de referência cruzada. Cada um desses *tokens* é cobrado, aumenta a latência e oferece uma nova oportunidade de erro estrutural, sem acrescentar informação sobre o que o documento significa.

A hipótese de trabalho é que essa carga pode ser deslocada do componente probabilístico para um componente determinístico. Ao modelo cabe emitir apenas o conteúdo semântico, em uma representação intermediária compacta; a expansão para o formato verbossintático é feita por um transpilador que não erra sintaxe por construção. O ganho esperado é duplo e mensurável: **econômico**, pela redução do número de *tokens* gerados, e de **confiabilidade**, pela transferência da validade sintática do domínio estatístico para o domínio algorítmico.

A BPMN 2.0 é adotada como **caso de estudo** por reunir as propriedades que tornam o problema difícil e a avaliação possível: é um XML normativo com esquema oficial (permitindo verificação binária de validade), é hierárquico e verboso ao ponto de a marcação dominar o conteúdo, e possui uma semântica de grafo bem definida (permitindo comparação objetiva entre modelos). As conclusões que dependerem apenas dessas três propriedades — e não de particularidades da BPMN — são as candidatas naturais à generalização, e o texto sinaliza explicitamente quando é o caso.

Essa delimitação distingue o trabalho de investigações sobre *qual* representação de processo é a melhor para modelagem com LLMs, como a de Brissard, Cuppens e Zouaq (2025b), discutida no Capítulo 3. Aqui a pergunta não é qual notação produz o modelo de processo

mais fiel, e sim se a estratégia de comprimir a saída e expandi-la deterministicamente torna a geração de marcação verbosa economicamente viável em modelos pequenos. Sobreposição de artefatos com esses trabalhos é esperada e desejável — inclusive porque permite reaproveitar seus conjuntos de referência.

4.2 PRÉ-REGISTRO DO PROTOCOLO EXPERIMENTAL

Uma decisão metodológica antecede as demais e condiciona a leitura de todo o capítulo. Métricas de comparação entre modelos de processo admitem muitos graus de liberdade — o que conta como nó equivalente, como tratar *gateways*, qual referência usar quando há várias válidas. Escolher esses parâmetros *depois* de observar os resultados permitiria, ainda que involuntariamente, selecionar a configuração que favorece a hipótese defendida.

Para eliminar esse grau de liberdade, o protocolo de avaliação foi **integralmente especificado e congelado antes da primeira execução** dos braços experimentais, em documento versionado com *hash* de *commit* datado. O congelamento cobre: definição operacional de cada métrica, número de amostras por item, regra de agregação, testes estatísticos, contrastes planejados e critérios de aceitação do próprio *harness*. Hipóteses foram registradas com direção esperada, e ficou consignado que **resultado contrário às hipóteses é resultado publicável** e deve ser reportado como tal.

Qualquer alteração posterior é registrada como emenda datada, com o motivo e a indicação explícita de se ocorreu antes ou depois da observação dos resultados. Essa prática é incomum em trabalhos de conclusão de curso da área, e é adotada aqui por uma razão prática: as métricas propostas envolvem escolhas de projeto suficientes para que a ausência de pré-registro tornasse os resultados difíceis de defender.

4.3 VISÃO GERAL DO PROTOCOLO

O protocolo separa a geração de um modelo BPMN 2.0 em uma etapa probabilística curta e uma etapa determinística verificável. Na fase de construção do conjunto de dados, o fluxo completo é:

1. **Pré-processamento:** a descrição textual bruta do processo é reestruturada por um LLM de fronteira em um formato padronizado em linguagem natural (atores, fluxo principal, decisões e paralelismos);
2. **Extração estruturada:** um segundo LLM de fronteira converte o texto padroni-

zado em um JSON canônico de BPMN, contendo elementos, fluxos de sequência e *gateways*, sem informação de leiaute;

3. **Compressão:** um conversor determinístico (*json_to_dsl*) lineariza o grafo do JSON na DSL proposta, com garantia formal de preservação topológica;
4. **Expansão:** um transpilador determinístico (*dsl_to_xml*) expande a DSL para XML BPMN 2.0 completo;
5. **Validação:** o XML é validado contra o XSD oficial da especificação BPMN 2.0 e comparado topologicamente com o JSON de origem.

Os pares (descrição textual, DSL) resultantes constituem o corpus de treino. Na fase de avaliação, um modelo de linguagem de pequeno porte especializado gera a DSL diretamente do texto, e as etapas 4–5 reconstituem e verificam o XML. O modelo probabilístico nunca é responsável pela sintaxe do documento final — apenas pelo conteúdo semântico da representação intermediária.

4.4 CONSTRUÇÃO DO CONJUNTO DE DADOS

4.4.1 Fontes e Curadoria

Não existe conjunto público em escala que associe descrições textuais de processos a modelos BPMN em formato de intercâmbio. A estratégia adotada foi coletar apenas o lado de entrada (descrições textuais) de fontes heterogêneas e sintetizar o lado de saída pelo pipeline da Seção 4.3. As fontes utilizadas são apresentadas na Tabela 0.

Tabela 0 – Fontes do conjunto de dados e partições

Fonte	N	Partição	Papel
GitLab Handbook (seções curadas)	728	<i>sft</i>	treino supervisionado
GitLab Handbook (seções lineares)	172	<i>grpo</i>	etapa opcional de reforço
PET (BELLAN <i>et al.</i> , 2023)	44	<i>sft</i>	treino supervisionado
PMo (BRISSARD; CUPPENS; ZOUAQ, 2025a)	53	<i>holdout</i>	avaliação (nunca treino)
Zenodo (MANGLER; KLIEVTSOVA, 2023)	24	<i>holdout</i>	avaliação (nunca treino)

Fonte: Elaborado pelo autor

Nota: De 1.047 amostras coletadas, 26 foram excluídas por degradação identificada durante a validação topológica, resultando em 1.021 amostras ativas.

A principal fonte de volume é o *handbook* público da empresa GitLab, um manual operacional aberto com milhares de seções procedurais. As seções foram coletadas por *web scraping* e submetidas a uma curadoria automática que atribui um escore procedural (presença

de passos, decisões e atores) e classifica cada seção em quatro categorias: *ideal* (passos, decisões e atores), *good* (passos e decisões ou atores), *linear* (apenas passos) e *marginal* (sem passos, descartada). Seções *ideal* e *good* compõem a partição de treino supervisionado; seções *linear*, por não exigirem estrutura de decisão, são reservadas como *prompts* para a etapa opcional de aprendizado por reforço.

4.4.2 Pré-processamento com LLM

Cada descrição bruta é reestruturada por um LLM de fronteira em um formato padronizado que explicita nome do processo, atores, fluxo principal numerado, decisões com os dois caminhos (sim/não) e ações paralelas. O *prompt* instrui o modelo a apenas reorganizar e limpar o texto, sem inventar informação, e a separar blocos independentes quando a descrição contém múltiplos processos. Essa etapa normaliza a variação estilística das fontes e aproxima o texto do vocabulário estrutural do BPMN sem ainda impor formato de máquina.

4.4.3 Seleção do Modelo Gerador

O modelo responsável pelos dois estágios de construção do corpus foi escolhido por experimento-piloto, e não por preferência. Três configurações candidatas foram executadas sobre uma amostra estratificada de 50 itens, e a seleção considerou taxa de conversão bem-sucedida até o XML válido, preservação topológica e custo. A configuração vencedora — o modelo *glm-5.2* em ambos os estágios — está registrada em documento de decisão versionado.

Duas limitações desse procedimento merecem registro. Primeiro, o provedor utilizado não oferece *tags* datadas para os modelos empregados, apenas um apelido móvel; a data de acesso é registrada e o banco de dados do projeto é o registro autoritativo dos artefatos gerados, uma vez que a reexecução bit-idêntica não é garantida. Segundo, verificou-se empiricamente que temperatura zero **não** produz saídas determinísticas nesses modelos — execuções idênticas divergiram —, o que motivou a adoção de múltiplas amostras por item na fase de avaliação (Seção 4.7.7).

4.4.4 Geração do JSON BPMN Canônico

O texto padronizado é convertido em um JSON canônico que descreve o processo como grafo: nós tipados (eventos de início e fim, tarefas por tipo, *gateways* exclusivos, paralelos e inclusivos), arestas de fluxo de sequência com condições, e raias de responsabilidade. O JSON

não contém leiaute nem identificadores de serialização — apenas a estrutura lógica do processo. Esse artefato cumpre dois papéis: é a fonte da qual a DSL é derivada deterministicamente e é a referência contra a qual a equivalência topológica do XML final é verificada (Seção 4.7).

4.4.5 Idioma dos Artefatos

Todos os artefatos de máquina — rótulos do JSON canônico, da DSL e do XML gerado — são produzidos em **inglês**, enquanto esta monografia é redigida em português. A decisão foi tomada após se constatar que *prompts* redigidos em português, sem diretiva explícita de idioma, produziam corpus com rótulos em idioma inconsistente entre amostras. Como o modelo base escolhido é orientado a código e treinado predominantemente em inglês, e como a consistência de rótulos é pré-requisito para que a métrica de fidelidade topológica — que usa o rótulo como identidade de nó (Seção 4.7.2) — não penalize diferenças meramente linguísticas, o corpus foi integralmente regenerado com diretiva de idioma explícita nos dois estágios.

Cabe registrar uma limitação assumida: o "gabarito" estrutural de cada amostra é a interpretação do processo feita por um LLM de fronteira, não uma anotação humana. Essa escolha é o que torna viável a escala do corpus, e seu risco é mitigado pela avaliação final contra o conjunto PMo, cujos modelos de referência são curados por especialistas.

4.4.6 Partições e Prevenção de Contaminação

As amostras são particionadas em *sft* (772), *grpo* (172) e *holdout* (77). Duas regras protegem a integridade da avaliação:

- a) o conjunto PMo é exclusivamente de avaliação: nenhum artefato derivado dele participa de qualquer etapa de treino;
- b) as 24 descrições da fonte Zenodo (MANGLER; KLIEVTSOVA, 2023) provêm da mesma origem dos itens 25–48 do PMo (com pré-processamento distinto). Para evitar contaminação indireta do *holdout* — treinar com versões alternativas dos mesmos processos usados na avaliação — essa fonte foi igualmente excluída do treino e alocada à partição *holdout*, onde suas múltiplas modelagens de referência com pontuação de especialistas apoiam a análise de ambiguidade.

4.5 A BPMN-DSL

A representação intermediária é uma DSL projetada neste trabalho, uma vez que não há linguagem consolidada para descrição textual compacta de BPMN. Seu desenho segue princípios explícitos: cada conceito BPMN tem exatamente uma forma sintática; nomes são legibilidade e identificadores são referência (elementos referenciados recebem sufixo #id estável); raias são escopos que envolvem o fluxo (bloco @lane), eliminando a dupla declaração de atividades; ramos vazios de decisão são explícitos (()); e propriedades adicionais usam sintaxe única de pares chave-valor. A gramática é formalizada em EBNF e implementada com o *parser* Lark¹.

A DSL cobre os elementos essenciais da BPMN 2.0 — eventos (com gatilhos de mensagem, temporizador, erro, sinal e escalonamento), oito tipos de tarefa, *gateways* exclusivos, paralelos, inclusivos e baseados em eventos, subprocessos, raias, *pools*, colaborações com fluxos de mensagem e anotações — e mapeia cada construção para o elemento XML correspondente. Conceitos avançados (eventos de borda, compensação, multi-instância) ficam explicitamente fora do escopo desta versão. O Código 1 ilustra um processo com decisão e repetição.

Código-fonte 1 – Exemplo de processo na BPMN-DSL: decisão exclusiva com laço de repetição via referência. Rótulos em inglês conforme a Seção 4.4.5

```

1 process "Order Processing with Retry" {
2   start
3   -> service "Fetch data" #fetch
4   -> service "Validate"
5   -> xor "Valid?" {
6     ["yes"] -> service "Process" -> end
7     ["no"]  -> xor "Retry?" {
8               ["yes"] -> #fetch
9               ["no"]  -> end:error "Invalid"
10            }
11  }
12 }
```

¹ <<https://github.com/lark-parser/lark>>

O exemplo evidencia a propriedade que motiva a DSL: o laço de repetição, que em XML BPMN exigiria a declaração de dois *gateways* com identificadores próprios e quatro elementos *sequenceFlow* referenciando-os cruzadamente, é expresso por uma única referência `#fetch`. A razão de compressão obtida empiricamente sobre o corpus é reportada no Capítulo 5.

4.6 TRANSPILAÇÃO DETERMINÍSTICA

4.6.1 JSON para DSL

O conversor *json_to_dsl* lineariza o grafo do JSON canônico em texto DSL. O componente central é o linearizador, que deve satisfazer um único invariante:

Todo nó alcançável do grafo é emitido exatamente uma vez; qualquer reencontro posterior com um nó já emitido é serializado como referência (`#id`), nunca como nova emissão.

Esse invariante é o que garante que estruturas não estritamente aninhadas — caudas compartilhadas entre ramos, laços com arestas de retorno e convergências múltiplas — sejam representáveis sem duplicação de nós nem perda de lógica. A implementação final sustenta o invariante com três mecanismos: (i) um conjunto único de nós emitidos, compartilhado por referência em toda a travessia recursiva, de modo que cada ramo enxerga o que os demais já emitiram; (ii) detecção determinística de pontos de convergência por pós-dominador imediato, em substituição a heurísticas de busca de junção; e (iii) uma rede de segurança que, ao final da travessia, compara o conjunto de nós alcançáveis a partir do início com o conjunto efetivamente emitido — qualquer diferença é emitida em um apêndice conectado por referências e sinalizada com um aviso rastreável, transformando qualquer perda silenciosa em falha visível.

O conversor foi desenvolvido iterativamente em dez versões, cada uma executada contra o corpus completo e registrada em banco com estado, avisos e erros por amostra, o que permite auditar regressões entre versões. A versão final converte 100% das 1.021 amostras ativas com preservação topológica verificada.

O processo iterativo é, ele próprio, um resultado metodológico: duas classes de defeito só se tornaram visíveis porque a verificação topológica era executada sobre o corpus inteiro a cada versão, e não por inspeção amostral. A primeira foi a perda silenciosa de arestas de convergência em estruturas não estritamente aninhadas, que reduzia a equivalência exata sem produzir erro algum — o XML permanecia válido no esquema, apenas descrevia um processo diferente. A segunda foi a divisão implícita: nós não-*gateway* com mais de uma aresta de saída

no JSON de origem, cuja semântica de bifurcação se perdia na linearização. A correção adotada normaliza esses casos inserindo um *gateway* sintético — exclusivo quando todas as arestas de saída portam condição, paralelo caso contrário —, tornando explícito no grafo aquilo que estava implícito.

4.6.2 DSL para XML BPMN 2.0

O transpilador *dsl_to_xml* expande a DSL para o XML BPMN 2.0 explícito, sem reinterpretar o processo: cada conexão gera um `sequenceFlow`; blocos de *gateway* geram os nós de divisão e, quando há continuação, de convergência; escopos `@lane` materializam `laneSet`, `lane` e `flowNodeRef`; colaborações geram participantes e `messageFlow`. Um contexto global de alocação garante unicidade de identificadores em documentos com múltiplos processos. O XML resultante é validado com a biblioteca `lxml` contra o XSD oficial da OMG versionado no repositório; a validação por esquema é tratada como critério binário obrigatório de aceitação, e não como métrica.

4.7 PROTOCOLO DE AVALIAÇÃO

A avaliação é organizada em eixos independentes, para que se possa atribuir cada tipo de falha ao componente responsável.

4.7.1 Eixo 1: Validade Sintática

Todo XML produzido — na construção do corpus ou na inferência do modelo — deve ser bem formado e válido contra o XSD BPMN 2.0. Para a saída do modelo especializado, mede-se adicionalmente a taxa de DSL sintaticamente válida (aceita pela gramática Lark).

4.7.2 Eixo 2: Equivalência Topológica

A validade por esquema não garante que o XML represente o mesmo processo de origem: um documento pode ser impecável perante o XSD e descrever outro processo. O segundo eixo mede fidelidade estrutural pela métrica **DF-F1**, definida a seguir e usada tanto na verificação interna do corpus (contra o JSON de origem) quanto na avaliação final (contra os modelos de referência).

4.7.2.0.1 Definição.

Cada processo é projetado no multiconjunto de pares ordenados (a, b) tais que a atividade a é **diretamente seguida** pela atividade b , percorrendo-se e descartando-se os *gateways* de roteamento. A identidade de um nó é o seu rótulo; eventos anônimos colapsam para uma categoria derivada do tipo (`<start>`, `<end>`), neutralizando os nomes padrão que o serializador atribui. Sendo R o multiconjunto da referência e C o do candidato, define-se

$$P = \frac{|R \cap C|}{|C|}, \quad R_c = \frac{|R \cap C|}{|R|}, \quad \text{DF-F1} = \frac{2P \cdot R_c}{P + R_c}, \quad (4.1)$$

com interseção sobre multiconjuntos, de modo que arestas repetidas contam com sua multiplicidade. Candidato vazio contra referência não vazia recebe precisão zero, e não um; documento que não é sequer bem formado recebe falha total em todas as métricas, jamais linha ausente.

4.7.2.0.2 Justificativa.

Comparar dois XML BPMN por igualdade textual é inviável: identificadores, ordem de elementos, espaçamento e coordenadas diferem sempre, mesmo entre documentos semanticamente idênticos. A relação *directly-follows* é a abstração canônica de mineração de processos — é sobre ela que se constrói o algoritmo α (AALST; WEIJTERS; MARUSTER, 2004) e o grafo que alimenta os mineradores subsequentes (AALST, 2016). Descartar os *gateways* é deliberado: um *gateway* é roteamento, não trabalho, e dois modelos que codifiquem a mesma decisão com estilos diferentes de bifurcação não devem ser penalizados por isso. O que a métrica mede é a **ordem do trabalho**, não a escolha de codificação.

4.7.2.0.3 Proveniência e delimitação.

A métrica não é original deste trabalho, e é importante não apresentá-la como tal. Medir similaridade entre modelos de processo por pares de tarefas adjacentes tem precedente direto na similaridade por *transition adjacency relations* (ZHA *et al.*, 2010), e abordagens correlatas incluem perfis comportamentais (WEIDLICH; MENDLING; WESKE, 2011) e distância de edição de grafos (DIJKMAN *et al.*, 2011). A contribuição aqui é de **operacionalização**: projeção estrutural sobre BPMN com descarte de *gateways*, agregação por F1 sobre multiconjuntos e regra de máximo sobre múltiplas referências.

Dessa operacionalização decorre uma limitação que precisa ser declarada. A projeção adotada é **estrutural**, ao passo que Zha *et al.* (2010) e Weidlich, Mendling e Weske (2011) derivam suas relações do **comportamento** do modelo. A diferença é observável em blocos paralelos: em $A \rightarrow \{B, C\} \rightarrow D$ com bifurcação paralela, as execuções admitem B e C em qualquer ordem, e uma métrica comportamental registraria os pares (B, C) e (C, B) ; a projeção estrutural aqui empregada não os registra. A escolha é intencional — dispensa conversão para rede de Petri sã, é determinística e de custo linear, e mede se o candidato reproduziu a estrutura que a referência especifica, sem premiar intercalações equivalentes —, mas implica que os valores reportados não são diretamente comparáveis a números publicados sob formulação comportamental.

4.7.3 Eixo 3: Fluxos de Mensagem

Fluxos de mensagem entre participantes (messageFlow) são comunicação, não ordem de execução. Fundi-los à relação *directly-follows* produziria casamento espúrio — uma mensagem no candidato satisfazendo uma sequência na referência. São, por isso, medidos por uma métrica separada, **MF-F1**, de formulação idêntica à do Eixo 2 aplicada ao multiconjunto de pares (origem, destino) dos fluxos de mensagem, e **reportada ao lado, nunca somada** ao DF-F1.

A separação também torna visível uma assimetria real entre as abordagens comparadas: embora a DSL e o transpilador suportem fluxos de mensagem, nenhuma das 1.021 amostras do corpus os contém, de modo que contá-los no DF-F1 conferiria vantagem estrutural às configurações que emitem XML diretamente. Nos modelos de referência a construção aparece em 2 dos 53 itens de avaliação. Um candidato que omita todas as mensagens preserva DF-F1 igual a 1 e obtém MF-F1 igual a 0 — perda que, sem a separação, seria invisível.

4.7.4 Eixo 4: Compressão

A razão de compressão de *tokens* (TCR) é definida como

$$\text{TCR} = \frac{\text{tokens}(\text{XML BPMN lógico})}{\text{tokens}(\text{DSL})}, \quad (4.2)$$

medida com o tokenizador do modelo pequeno especializado, fixado no protocolo. O numerador é o XML **lógico** — sem a seção de diagrama (BPMNDI) — por definição normativa, e não por

conveniência: a informação de leiaute é gerada deterministicamente por pós-processamento e nenhuma das abordagens comparadas exige que o modelo a produza. Incluí-la no numerador inflaria artificialmente o ganho atribuído à DSL, e por isso o XML com leiaute nunca é materializado na mesma coluna do XML lógico no banco de dados, eliminando a possibilidade de medição contra o artefato errado.

4.7.5 Referências Múltiplas e Ambiguidade de Modelagem

Uma mesma descrição textual admite múltiplas modelagens corretas (AA *et al.*, 2018), e tratar uma delas como única verdade penalizaria candidatos legítimos. A porção do *holdout* derivada de Mangler e Klietsova (2023) oferece, para 24 dos 53 itens de avaliação, vários modelos por descrição, cada um com nota de especialista de 0 a 5.

A regra congelada é: pontuar o candidato contra **todas** as referências com nota maior ou igual a 4 e reter o **máximo**. Isso mede a alegação correta — o candidato equivale a ao menos uma modelagem que um especialista aprovou — e descarta as variantes reprovadas. Modelos sem nota atribuída são excluídos do conjunto de referência por ausência de evidência de aprovação, assim como referências que não produzam nenhuma aresta, por serem degeneradas. O número de referências admitidas por item é reportado junto aos resultados: a ambiguidade de modelagem é achado, não ruído.

4.7.6 Desenho dos Braços Experimentais

O desenho é fatorial, cruzando **modelo** e **formato de saída**, sobre os mesmos 53 itens de avaliação, com comparação pareada por item (Tabela 1).

Tabela 1 – Braços experimentais

ID	Modelo	Saída	Papel
A1	LLM de fronteira independente	XML direto	<i>baseline</i> externo
A2	LLM de fronteira independente	DSL	isola o efeito da DSL
A1g	LLM gerador do corpus	XML direto	leitura de destilação
A2g	LLM gerador do corpus	DSL	teto do método
A3	Modelo pequeno base	DSL	piso do modelo pequeno
A4	Modelo pequeno especializado	DSL	a proposta

Fonte: Elaborado pelo autor

Cabe explicitar um ponto de leitura: os braços A2 e A2g **não são abordagens concorrentes**, e sim o método proposto executado com um modelo de alto custo — o teto que

A4 procura alcançar a custo muito menor. O único *baseline* externo é A1/A1g, que representa a prática corrente de gerar o XML diretamente. Os contrastes planejados decorrem dessa estrutura: A2 contra A1 mantém o modelo fixo e varia apenas o formato, separando o efeito da representação do efeito da capacidade do modelo; A2g contra A1g replica o contraste com outro modelo, de modo que um efeito que apareça em um e não no outro seja atribuível ao modelo e não à DSL; e A4 contra A2 responde se a especialização de um modelo pequeno alcança o modelo de fronteira. Sem o par A2/A1, um bom resultado de A4 seria ambíguo entre o mérito da DSL e o do ajuste supervisionado.

O emprego de dois modelos de fronteira é deliberado. Como um deles gerou o corpus de treino, utilizá-lo como *baseline* único tornaria A4 uma destilação sua — leitura legítima, porém que confunde "a DSL ajuda" com "o aluno imita o professor". O segundo modelo é independente do corpus e fornece o *baseline* limpo, enquanto o primeiro permanece para que a leitura de destilação seja reportável.

4.7.7 Parâmetros Congelados e Análise Estatística

A temperatura é fixada em zero para reduzir variância, sem que se alegue determinismo — o oposto foi verificado empiricamente (Seção 4.4.3). Em consequência, cada item é gerado $k = 3$ vezes e a **unidade de análise é a mediana por item**; adota-se a mediana, e não a média, porque saídas ocasionalmente degeneradas deslocariam a média de forma desproporcional. A dispersão entre as três execuções é reportada, por constituir a evidência empírica do não determinismo.

Os limites de *tokens* são deliberadamente distintos por braço, calibrados por medição prévia sobre o *holdout*: os braços que emitem XML recebem teto substancialmente maior que os que emitem DSL, porque um teto único estrangularia o *baseline* que o trabalho pretende superar. O orçamento equalizado entre braços é o **modelo**, não o teto de saída. Truncamento é registrado por amostra e reportado separadamente de erro de modelo. Não há reexecução em caso de falha de análise sintática no número principal: a taxa de falha é resultado, não obstáculo a contornar.

Os dois braços executados com o modelo pequeno (A3 e A4) usam configuração de inferência **idêntica**: pesos quantizados em 4 *bits* no formato NF4 com dupla quantização, tipo de computação em ponto flutuante de 16 *bits* e implementação de atenção *scaled dot-product*. A escolha do tipo de computação e da implementação de atenção é imposta pelo hardware — a arquitetura Turing da GPU utilizada precede o suporte nativo a *bfloat16*, e as versões correntes

de FlashAttention-2 não a contemplam. A identidade de configuração entre A3 e A4 é o que preserva a interpretação do contraste entre eles: quantizações distintas fariam a comparação medir precisão numérica somada ao efeito da especialização.

Registre-se que a quantização de **treino** e a de **inferência** são parâmetros independentes, e que a restrição de memória que motiva a primeira não se aplica à segunda no cenário adotado, uma vez que o ajuste supervisionado é executado em infraestrutura de nuvem e apenas a inferência ocorre na estação local.

A comparação estatística usa teste de Wilcoxon pareado por postos com sinal, ao nível de 5%, sobre a métrica primária, restrito aos três contrastes planejados e com correção de Holm sobre eles; qualquer outro par é exploratório e reportado como tal. Intervalos de confiança de 95% são obtidos por *bootstrap* pareado com 10.000 reamostragens. Como o conjunto de avaliação tem 53 itens, reportam-se tamanho de efeito e intervalo de confiança, e não apenas o valor-*p*.

4.8 ESPECIALIZAÇÃO DO MODELO

4.8.1 Ajuste Supervisionado

O modelo base é o Qwen2.5-Coder-7B (HUI *et al.*, 2024), um modelo aberto de 7 bilhões de parâmetros orientado a código — perfil adequado a uma tarefa de emissão de linguagem formal. A especialização usa ajuste supervisionado com adaptação de baixo posto (LoRA) (HU *et al.*, 2022) sobre pesos quantizados em 4 *bits* (QLoRA) (DETTMERS *et al.*, 2023), viabilizando o treino em GPU de 12 GB na fase exploratória, com o treinamento final executado em infraestrutura de nuvem. Os exemplos de treino são os pares (descrição textual bruta, DSL) da partição *sft* com equivalência topológica exata verificada pelo Eixo 2 — o texto de entrada é a descrição original, e não o texto pré-processado, de modo que o modelo especializado absorva também a etapa de estruturação e o sistema final dependa de uma única inferência.

4.8.2 Etapa Opcional: Aprendizado por Reforço com Recompensa Verificável

Como extensão opcional ao escopo deste trabalho, prevê-se uma etapa de *Group Relative Policy Optimization* (SHAO *et al.*, 2024) sobre o modelo ajustado, usando como *prompts* as seções da partição *grpo* e as amostras sem equivalência exata (que não exigem DSL de referência). A recompensa composta é definida como

$$r = 0,35r_{\text{sint}} + 0,30r_{\text{sem}} + 0,25r_{\text{topo}} + 0,10r_{\text{comp}}, \quad (4.3)$$

em que r_{sint} (validade da DSL e do XML), r_{topo} (coerência topológica) e r_{comp} (economia de tokens) são integralmente verificáveis por código, enquanto r_{sem} (adequação semântica ao texto) requer sinal aproximado e é o componente metodologicamente mais frágil. Por essa razão, e por restrição de cronograma, essa etapa é tratada como trabalho futuro caso não seja concluída no prazo do TCC.

4.9 INFRAESTRUTURA E REPRODUTIBILIDADE

Todo o pipeline é implementado em Python 3.12, com dependências gerenciadas por *uv*, testes automatizados com *pytest* e análise estática com *ruff*. Os artefatos de todas as etapas — texto bruto, texto pré-processado, JSON canônico, DSL, XML e métricas de avaliação — são persistidos em um banco SQLite único, com cada execução de conversor registrada com número de versão, estado e diagnósticos, o que permite auditar e reproduzir qualquer resultado intermediário. A fase exploratória utiliza uma estação com GPU NVIDIA RTX 2080 Ti (12 GB), e o treinamento final, aceleradores de nuvem. Ao término do trabalho, o conjunto de dados e o modelo especializado serão disponibilizados publicamente na plataforma Hugging Face, juntamente com o código-fonte do protocolo.

5 RESULTADOS

Este capítulo reporta os resultados obtidos até o momento. Eles se dividem em duas partes de maturidade distinta: a **verificação do protocolo determinístico** sobre o corpus completo, concluída e reproduzível, e a **avaliação comparativa dos braços experimentais** contra os modelos de referência, ainda pendente de execução. A separação é explícita para que nenhum número parcial seja lido como resultado final.

Todos os valores desta seção são recuperáveis do banco de dados do projeto, no qual cada execução de conversor é registrada com versão, estado e diagnósticos por amostra.

5.1 COMPOSIÇÃO DO CORPUS

Foram coletadas 1.047 amostras, das quais 26 foram excluídas por degradação identificada durante a validação, resultando em **1.021 amostras ativas**. A distribuição por partição é apresentada na Tabela 2.

Tabela 2 – Distribuição do corpus por partição

Partição	N	Uso
<i>sft</i>	772	treino supervisionado
<i>grpo</i>	172	etapa opcional de reforço
<i>holdout</i>	77	avaliação exclusivamente
Total	1.021	

Fonte: Elaborado pelo autor

Nota: A partição *holdout* agrega os 53 itens do PMo e as 24 descrições da fonte Zenodo, esta última excluída do treino por compartilhar origem com parte do PMo.

Registra-se uma ameaça à validade externa: 900 das 944 amostras de treino (95,3%) provêm de uma única fonte, o *handbook* da GitLab. O modelo especializado é, portanto, treinado predominantemente sobre o estilo redacional de uma única organização e avaliado contra o PMo, de domínio distinto. Essa assimetria é reconhecida como limitação, e a consequência prática é que aumento de volume só reduz o risco se vier de **fontes novas**, não de mais seções do mesmo *handbook*.

5.2 EIXO 1: VALIDADE SINTÁTICA

As 1.021 amostras ativas produzem DSL aceita pela gramática e XML válido contra o XSD oficial da BPMN 2.0: **1.021/1.021 (100%)** em ambos os critérios. O resultado é esperado por construção — a validade sintática do XML final é responsabilidade do transpilador determinístico, não do modelo probabilístico — e sua função aqui é confirmar que o transpilador cumpre a garantia que o protocolo lhe atribui.

O valor desse número está no contraste que ele permite: nos braços que geram XML diretamente, a validade passa a ser uma variável aleatória dependente do modelo, e a diferença entre 100% garantido e a taxa observada é precisamente o que a hipótese H2 afirma.

5.3 EIXO 2: FIDELIDADE TOPOLÓGICA

Sobre a base ativa, a comparação entre o JSON canônico de origem e o XML reconstituído pela cadeia DSL apresenta **1.017 de 1.021 amostras (99,6%) com equivalência exata de arestas** e DF-F1 médio de **0,9999** (mínimo observado 0,9545). A contagem de nós por categoria coincide em **1.021/1.021 (100%)** das amostras.

Por partição: *sft* 768/772, *grpo* 172/172 e *holdout* 77/77 com equivalência exata. O subconjunto de 768 pares da partição *sft* com equivalência exata constitui o conjunto de treino supervisionado de alta confiança.

5.3.1 Trajetória entre Versões

O desenvolvimento iterativo do linearizador foi verificado executando-se a comparação topológica sobre o corpus **inteiro** a cada versão, e não por inspeção amostral. A Tabela 3 apresenta a trajetória.

Dois achados metodológicos emergem da tabela. O primeiro é o salto de v7 para v8, que corrigiu a perda silenciosa de arestas de convergência em estruturas não estritamente aninhadas: 891 para 1.015 amostras exatas, com as 127 amostras que perdiam arestas indo a zero. Essa classe de defeito é particularmente perigosa porque não produz erro observável — o XML permanece válido no esquema e apenas descreve um processo diferente.

O segundo é a **regressão introduzida pela regeneração em inglês**: a versão v8 aplicada ao corpus regenerado voltou a apresentar 20 amostras com arestas perdidas, apesar de a mesma versão do conversor ter atingido zero na base anterior. O conteúdo novo expôs

Tabela 3 – Fidelidade topológica por versão do conversor

Versão (DSL / XML)	Idioma	Exatas	DF-F1	Com arestas perdidas
v7 / v3	pt	891	0,9939	127
v8 / v3	pt	1.015	0,9999	0
v8 / v3	en	998	0,9970	20
v9 / v3	en	1.015	0,9998	1
v10 / v4	en	1.016	0,9998	1
v10 / v5	en	1.017	0,9999	0

Fonte: Elaborado pelo autor

Nota: N = 1.021 em todas as versões. "Com arestas perdidas" conta amostras em que ao menos uma aresta da referência não aparece no candidato.

defeitos latentes que o corpus antigo não exercitava — notadamente a divisão implícita descrita na Seção 4.6.1. As versões v9 e v10 eliminaram a regressão. O episódio sustenta uma escolha metodológica do trabalho: verificação sobre o corpus completo a cada versão, com resultado persistido, é o que torna regressões detectáveis; amostragem manual não as teria revelado.

5.3.2 Análise do Resíduo

As quatro amostras sem equivalência exata na base ativa compartilham uma propriedade relevante: em todas, o conjunto de arestas ausentes é **vazio**. O resíduo consiste exclusivamente em arestas *excedentes* — uma ou duas por amostra — e não em lógica perdida. Em termos práticos, a cadeia determinística nunca descarta uma relação de precedência presente no processo de origem; nos quatro casos remanescentes, ela introduz uma relação adicional decorrente da serialização de convergências. Sendo a preservação da lógica do processo o objetivo do componente determinístico, essa assimetria do erro é favorável: o modo de falha residual é conservador.

5.4 EIXO 4: COMPRESSÃO DE *TOKENS*

Medida com o tokenizador do modelo base sobre as 1.021 amostras, a razão de compressão é de **6,01** (IC95% [5,96; 6,06], mediana 5,99), correspondente a uma **redução de 83,4%** no número de *tokens* que o modelo precisa emitir em relação ao XML BPMN lógico equivalente.

Cabe explicitar o que o número **não** é. O denominador é o XML lógico, sem a seção de diagrama. Medindo-se contra o XML com informação de leiaute, a razão triplicaria — e seria um artefato de medição, já que o leiaute é gerado deterministicamente por pós-processamento e

nenhuma das abordagens comparadas exige que o modelo o produza. Essa distinção é registrada aqui porque uma medição preliminar contra o artefato errado chegou a indicar cerca de 91% de redução, valor que foi descartado ao se identificar a inconsistência; a definição normativa da métrica foi então fixada no protocolo, e o XML com leiaute deixou de ser materializado na mesma coluna do XML lógico no banco, tornando o erro irreproduzível.

Registra-se ainda que a meta de projeto inicialmente estipulada era de 85% de redução, e o valor medido (83,4%) ficou abaixo dela. Como a meta havia sido fixada antes de qualquer medição e sem base empírica, e como o protocolo de avaliação foi congelado com a definição normativa da métrica, opta-se por reportar o valor obtido e registrar a divergência, em vez de reajustar a meta *a posteriori*.

5.5 CONJUNTO DE REFERÊNCIA

O conjunto de avaliação reúne **53 modelos de referência primários** do PMo, um por item, e **172 referências alternativas** da fonte Zenodo distribuídas sobre 24 desses itens (de 4 a 11 por item), admitidas segundo a regra de nota mínima da Seção 4.7.5.

A curadoria descartou referências por dois motivos declarados: um modelo sem nota de especialista atribuída, por ausência de evidência de aprovação, e três modelos que, apesar de nota suficiente, não produzem nenhuma aresta na projeção adotada — referência degenerada não serve de referência. O mapeamento entre as duas fontes é verificado como bijeção no momento da carga, falhando explicitamente caso a propriedade não se sustente, em vez de gravar correspondência parcial.

5.6 AVALIAÇÃO COMPARATIVA DOS BRAÇOS

Esta seção será preenchida após a execução dos braços experimentais descritos na Seção 4.7.6. O protocolo encontra-se congelado; nenhum resultado comparativo havia sido observado até a redação deste capítulo.

Serão reportados, por braço: taxa de validade sintática (DSL e XSD), DF-F1 e MF-F1 contra os modelos de referência sob a regra de máximo, TCR sobre as saídas efetivamente geradas, taxa de truncamento, e a dispersão entre as três execuções por item. Os três contrastes planejados serão submetidos a teste de Wilcoxon pareado com correção de Holm, acompanhados de tamanho de efeito e intervalo de confiança por *bootstrap*.

Reitera-se o compromisso registrado no pré-registro: resultado contrário às hipóteses

é resultado publicável e será reportado como tal.

6 CONCLUSÕES E TRABALHOS FUTUROS

Nam dui ligula, fringilla a, euismod sodales, sollicitudin vel, wisi. Morbi auctor lorem non justo. Nam lacus libero, pretium at, lobortis vitae, ultricies et, tellus. Donec aliquet, tortor sed accumsan bibendum, erat ligula aliquet magna, vitae ornare odio metus a mi. Morbi ac orci et nisl hendrerit mollis. Suspendisse ut massa. Cras nec ante. Pellentesque a nulla. Cum sociis natoque penatibus et magnis dis parturient montes, nascetur ridiculus mus. Aliquam tincidunt urna. Nulla ullamcorper vestibulum turpis. Pellentesque cursus luctus mauris. Nullam eleifend justo in nisl. In hac habitasse platea dictumst. Morbi nonummy. Aliquam ut felis. In velit leo, dictum vitae, posuere id, vulputate nec, ante. Maecenas vitae pede nec dui dignissim suscipit. Morbi magna. Vestibulum id purus eget velit laoreet laoreet. Praesent sed leo vel nibh convallis blandit. Ut rutrum. Donec nibh. Donec interdum. Fusce sed pede sit amet elit rhoncus ultrices. Nullam at enim vitae pede vehicula iaculis.

6.1 CONTRIBUIÇÕES DO TRABALHO

Nulla malesuada porttitor diam. Donec felis erat, congue non, volutpat at, tincidunt tristique, libero. Vivamus viverra fermentum felis. Donec nonummy pellentesque ante. Phasellus adipiscing semper elit. Proin fermentum massa ac quam. Sed diam turpis, molestie vitae, placerat a, molestie nec, leo. Maecenas lacinia. Nam ipsum ligula, eleifend at, accumsan nec, suscipit a, ipsum. Morbi blandit ligula feugiat magna. Nunc eleifend consequat lorem. Sed lacinia nulla vitae enim. Pellentesque tincidunt purus vel magna. Integer non enim. Praesent euismod nunc eu purus. Donec bibendum quam in tellus. Nullam cursus pulvinar lectus. Donec et mi. Nam vulputate metus eu enim. Vestibulum pellentesque felis eu massa.

6.2 LIMITAÇÕES

Quisque ullamcorper placerat ipsum. Cras nibh. Morbi vel justo vitae lacus tincidunt ultrices. Lorem ipsum dolor sit amet, consectetur adipiscing elit. In hac habitasse platea dictumst. Integer tempus convallis augue. Etiam facilisis. Nunc elementum fermentum wisi. Aenean placerat. Ut imperdiet, enim sed gravida sollicitudin, felis odio placerat quam, ac pulvinar elit purus eget enim. Nunc vitae tortor. Proin tempus nibh sit amet nisl. Vivamus quis tortor vitae risus porta vehicula.

6.3 TRABALHOS FUTUROS

Fusce mauris. Vestibulum luctus nibh at lectus. Sed bibendum, nulla a faucibus semper, leo velit ultricies tellus, ac venenatis arcu wisi vel nisl. Vestibulum diam. Aliquam pellentesque, augue quis sagittis posuere, turpis lacus congue quam, in hendrerit risus eros eget felis. Maecenas eget erat in sapien mattis porttitor. Vestibulum porttitor. Nulla facilisi. Sed a turpis eu lacus commodo facilisis. Morbi fringilla, wisi in dignissim interdum, justo lectus sagittis dui, et vehicula libero dui cursus dui. Mauris tempor ligula sed lacus. Duis cursus enim ut augue. Cras ac magna. Cras nulla. Nulla egestas. Curabitur a leo. Quisque egestas wisi eget nunc. Nam feugiat lacus vel est. Curabitur consectetur.

REFERÊNCIAS

- AA, H. van der *et al.* Challenges and opportunities of applying natural language processing in business process management. In: *Proceedings of the 27th International Conference on Computational Linguistics*. Santa Fe, New Mexico, USA: Association for Computational Linguistics, 2018. p. 2791–2801. Disponível em: <<https://aclanthology.org/C18-1236/>>.
- AALST, W. M. P. van der. **Process Mining: Data Science in Action**. 2. ed. Berlin, Heidelberg: Springer, 2016.
- AALST, W. M. P. van der; WEIJTERS, T.; MARUSTER, L. Workflow mining: Discovering process models from event logs. **IEEE Transactions on Knowledge and Data Engineering**, v. 16, n. 9, p. 1128–1142, 2004.
- ASSOCIAÇÃO BRASILEIRA DE NORMAS TÉCNICAS. **NBR 6028**: Resumo - apresentação. Rio de Janeiro, 2003. 2 p.
- ASSOCIAÇÃO BRASILEIRA DE NORMAS TÉCNICAS. **NBR 14724**: Informação e documentação — trabalhos acadêmicos — apresentação. Rio de Janeiro, 2005. 9 p.
- ASSOCIAÇÃO BRASILEIRA DE NORMAS TÉCNICAS. **NBR 14724**: Informação e documentação — trabalhos acadêmicos — apresentação. Rio de Janeiro, 2011. 15 p. Substitui a Ref. ABNT (2005).
- BELCAK, P.; HEINRICH, G.; DIAO, S.; FU, Y.; DONG, X.; MURALIDHARAN, S.; LIN, Y. C.; MOLCHANOV, P. Small language models are the future of agentic AI. **arXiv preprint arXiv:2506.02153**, 2025. Disponível em: <<https://arxiv.org/abs/2506.02153>>.
- BELLAN, P.; AA, H. van der; DRAGONI, M.; GHIDINI, C.; PONZETTO, S. P. PET: An annotated dataset for process extraction from natural language text tasks. In: **Business Process Management Workshops: BPM 2022 International Workshops**. Cham: Springer, 2023. (Lecture Notes in Business Information Processing, v. 460), p. 315–321. Disponível em: <https://link.springer.com/chapter/10.1007/978-3-031-25383-6_23>.
- BRISSARD, A.; CUPPENS, F.; ZOUAQ, A. **PMo Dataset**. Zenodo, 2025. Version 1.0.0. Disponível em: <<https://zenodo.org/records/15857589>>. Acesso em: 17 maio 2026.
- BRISSARD, A.; CUPPENS, F.; ZOUAQ, A. What is the best process model representation? a comparative analysis for process modeling with large language models. In: **Proceedings of the AI4BPM Workshop at BPM 2025**. [S.l.: s.n.], 2025. Accepted for publication.
- BROWN, T. B.; MANN, B.; RYDER, N.; SUBBIAH, M. *et al.* Language models are few-shot learners. In: **Advances in Neural Information Processing Systems (NeurIPS)**. [s.n.], 2020. v. 33, p. 1877–1901. Disponível em: <<https://proceedings.neurips.cc/paper/2020/hash/1457c0d6bfcb4967418bfb8ac142f64a-Abstract.html>>.
- CHEN, M.; TWOREK, J.; JUN, H.; YUAN, Q.; PINTO, H. Ponde de O. *et al.* Evaluating large language models trained on code. **arXiv preprint arXiv:2107.03374**, 2021. Disponível em: <<https://arxiv.org/abs/2107.03374>>.
- DETTMERS, T.; PAGNONI, A.; HOLTZMAN, A.; ZETTLEMOYER, L. QLoRA: Efficient finetuning of quantized LLMs. In: **Advances in Neural Information Processing Systems (NeurIPS)**. [s.n.], 2023. v. 36. Disponível em: <https://proceedings.neurips.cc/paper_files/paper/2023/hash/1feb87871436031bdc0f2beaa62a049b-Abstract.html>.

DIJKMAN, R.; DUMAS, M.; DONGEN, B. van; KÄÄRIK, R.; MENDLING, J. Similarity of business process models: Metrics and evaluation. **Information Systems**, v. 36, n. 2, p. 498–516, 2011.

DUMAS, M.; ROSA, M. L.; MENDLING, J.; REIJERS, H. A. **Fundamentals of Business Process Management**. 2. ed. Berlin, Heidelberg: Springer, 2018. Disponível em: <<https://link.springer.com/book/10.1007/978-3-662-56509-4>>.

FOWLER, M. **Domain-Specific Languages**. 1. ed. Boston: Addison-Wesley Professional, 2010. ISBN 978-0-321-71294-3. Disponível em: <<https://www.informit.com/store/domain-specific-languages-9780321712943>>.

FRIEDRICH, F.; MENDLING, J.; PUHLMANN, F. Process model generation from natural language text. In: **Advanced Information Systems Engineering**. Berlin, Heidelberg: Springer, 2011. (Lecture Notes in Computer Science, v. 6741), p. 482–496. Disponível em: <https://link.springer.com/chapter/10.1007/978-3-642-21640-4_36>.

GAO, X.; XIAO, B.; TAO, D.; LI, X. A survey of graph edit distance. **Pattern Analysis and Applications**, v. 13, n. 1, p. 113–129, 2010. Disponível em: <<https://link.springer.com/article/10.1007/s10044-008-0141-y>>.

Headroom Labs. **Headroom: Compress Tool Outputs, Logs, Files, and RAG Chunks Before They Reach the LLM**. 2026. <<https://github.com/headroomlabs-ai/headroom>>. Versão 0.27.0. Software de código aberto, licença Apache-2.0. Disponível em: <<https://github.com/headroomlabs-ai/headroom>>. Acesso em: 8 ago. 2026.

HU, E. J.; SHEN, Y.; WALLIS, P.; ALLEN-ZHU, Z.; LI, Y.; WANG, S.; WANG, L.; CHEN, W. LoRA: Low-rank adaptation of large language models. In: **International Conference on Learning Representations (ICLR)**. [s.n.], 2022. Disponível em: <<https://openreview.net/forum?id=nZeVKeeFYf9>>.

HUI, B.; YANG, J.; CUI, Z.; YANG, J.; LIU, D.; ZHANG, L.; LIU, T.; ZHANG, J.; YU, B.; LU, K. *et al.* Qwen2.5-Coder technical report. **arXiv preprint arXiv:2409.12186**, 2024. Disponível em: <<https://arxiv.org/abs/2409.12186>>.

JIANG, H.; WU, Q.; LIN, C.-Y.; YANG, Y.; QIU, L. LLMingua: Compressing prompts for accelerated inference of large language models. In: **Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing (EMNLP)**. Singapore: [s.n.], 2023. p. 13358–13376. Disponível em: <<https://aclanthology.org/2023.emnlp-main.825/>>.

KÖPKE, J.; SAFAN, M. Efficient LLM-based conversational process modeling. In: **Business Process Management Workshops**. [S.l.]: Springer, 2024.

KOURANI, H.; BERTI, A.; SCHUSTER, D.; AALST, W. M. P. van der. ProMoAI: Process modeling with generative AI. In: **Proceedings of the Thirty-Third International Joint Conference on Artificial Intelligence (IJCAI-24), Demo Track**. International Joint Conferences on Artificial Intelligence Organization, 2024. p. 8708–8712. Disponível em: <<https://www.ijcai.org/proceedings/2024/1014>>.

MANGLER, J.; KLIEVTSOVA, N. **Textual Process Descriptions and Corresponding BPMN Models**. Zenodo, 2023. Version 1.0. Disponível em: <<https://zenodo.org/records/7783492>>. Acesso em: 17 maio 2026.

MERNIK, M.; HEERING, J.; SLOANE, A. M. When and how to develop domain-specific languages. **ACM Computing Surveys**, v. 37, n. 4, p. 316–344, 2005. Disponível em: <<https://dl.acm.org/doi/10.1145/1118890.1118892>>.

Object Management Group. **Business Process Model and Notation (BPMN), Version 2.0**. Needham, MA, USA, 2011. Documento OMG formal/2011-01-03. Disponível em: <<https://www.omg.org/spec/BPMN/2.0/>>.

OUYANG, L.; WU, J.; JIANG, X.; ALMEIDA, D.; WAINWRIGHT, C.; MISHKIN, P. *et al.* Training language models to follow instructions with human feedback. In: **Advances in Neural Information Processing Systems (NeurIPS)**. [s.n.], 2022. v. 35. Disponível em: <https://proceedings.neurips.cc/paper_files/paper/2022/hash/b1efde53be364a73914f58805a001731-Abstract.html>.

POESIA, G.; POLOZOV, A.; LE, V.; TIWARI, A.; SOARES, G.; MEEK, C.; GULWANI, S. Synchromesh: Reliable code generation from pre-trained language models. In: **International Conference on Learning Representations (ICLR)**. [s.n.], 2022. Disponível em: <<https://openreview.net/forum?id=KmtVD97J43e>>.

SANFELIU, A.; FU, K.-S. A distance measure between attributed relational graphs for pattern recognition. **IEEE Transactions on Systems, Man, and Cybernetics**, SMC-13, n. 3, p. 353–362, 1983.

SENNRICH, R.; HADDOW, B.; BIRCH, A. Neural machine translation of rare words with subword units. In: **Proceedings of the 54th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)**. Berlin, Germany: Association for Computational Linguistics, 2016. p. 1715–1725. Disponível em: <<https://aclanthology.org/P16-1162/>>.

SHAO, Z.; WANG, P.; ZHU, Q.; XU, R.; SONG, J.; BI, X.; ZHANG, H.; ZHANG, M.; LI, Y. K.; WU, Y.; GUO, D. DeepSeekMath: Pushing the limits of mathematical reasoning in open language models. **arXiv preprint arXiv:2402.03300**, 2024. Disponível em: <<https://arxiv.org/abs/2402.03300>>.

VASWANI, A.; SHAZEER, N.; PARMAR, N.; USZKOREIT, J.; JONES, L.; GOMEZ, A. N.; KAISER, Ł.; POLOSUKHIN, I. Attention is all you need. In: **Advances in Neural Information Processing Systems (NeurIPS)**. [s.n.], 2017. v. 30. Disponível em: <<https://papers.nips.cc/paper/7181-attention-is-all-you-need>>.

VÖLTER, M.; HAKE, P.; FETTKE, P. Generative AI for business process management: Suitability of modalities. In: **Business Process Management Workshops**. [S.l.]: Springer, 2024.

WEIDLICH, M.; MENDLING, J.; WESKE, M. Efficient consistency measurement based on behavioral profiles of process models. **IEEE Transactions on Software Engineering**, v. 37, n. 3, p. 410–429, 2011.

WESKE, M. **Business Process Management: Concepts, Languages, Architectures**. 3. ed. Berlin, Heidelberg: Springer, 2019. Disponível em: <<https://link.springer.com/book/10.1007/978-3-662-59432-2>>.

ZHA, H.; WANG, J.; WEN, L.; WANG, C.; SUN, J. A workflow net similarity measure based on transition adjacency relations. **Computers in Industry**, v. 61, n. 5, p. 463–471, 2010.

APÊNDICES

APÊNDICE A – Lorem Ipsum

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Ut purus elit, vestibulum ut, placerat ac, adipiscing vitae, felis. Curabitur dictum gravida mauris. Nam arcu libero, nonummy eget, consectetur id, vulputate a, magna. Donec vehicula augue eu neque. Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Mauris ut leo. Cras viverra metus rhoncus sem. Nulla et lectus vestibulum urna fringilla ultrices. Phasellus eu tellus sit amet tortor gravida placerat. Integer sapien est, iaculis in, pretium quis, viverra ac, nunc. Praesent eget sem vel leo ultrices bibendum. Aenean faucibus. Morbi dolor nulla, malesuada eu, pulvinar at, mollis ac, nulla. Curabitur auctor semper nulla. Donec varius orci eget risus. Duis nibh mi, congue eu, accumsan eleifend, sagittis quis, diam. Duis eget orci sit amet orci dignissim rutrum.

APÊNDICE B – Modelo de Capa

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Ut purus elit, vestibulum ut, placerat ac, adipiscing vitae, felis. Curabitur dictum gravida mauris. Nam arcu libero, nonummy eget, consectetur id, vulputate a, magna. Donec vehicula augue eu neque. Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Mauris ut leo. Cras viverra metus rhoncus sem. Nulla et lectus vestibulum urna fringilla ultrices. Phasellus eu tellus sit amet tortor gravida placerat. Integer sapien est, iaculis in, pretium quis, viverra ac, nunc. Praesent eget sem vel leo ultrices bibendum. Aenean faucibus. Morbi dolor nulla, malesuada eu, pulvinar at, mollis ac, nulla. Curabitur auctor semper nulla. Donec varius orci eget risus. Duis nibh mi, congue eu, accumsan eleifend, sagittis quis, diam. Duis eget orci sit amet orci dignissim rutrum.

APÊNDICE C – Termo de Fiel Depositário

Pesquisa: ANÁLISE DA MORTALIDADE INFANTIL COM MALFORMAÇÕES CONGÊNITAS.

Pelo presente instrumento que atende às exigências legais, a Sra. Maria Consuelo Martins Saraiva, “fiel depositário” com o cargo de Secretária Municipal de Saúde de Iracema, após ter tomado conhecimento do protocolo de pesquisa intitulado: ANÁLISE DA MORTALIDADE INFANTIL COM MALFORMAÇÕES CONGÊNITAS. Analisando a repercussão desse estudo no contexto da saúde pública e epidemiologia, autoriza Karla Maria da Silva Lima, enfermeira, aluna do Curso de Mestrado Acadêmico em Enfermagem da Universidade Estadual do Ceará (UECE), sob orientação do Prof. Dr. José Maria de Castro, da UECE, ter acesso aos bancos de dados do Sistema de Informação sobre Nascidos Vivos e do Sistema de Informação sobre Mortalidade da Secretaria Municipal de Saúde de Iracema, objeto deste estudo, e que se encontram sob sua total responsabilidade. Fica claro que o Fiel Depositário pode a qualquer momento retirar sua AUTORIZAÇÃO e ciente de que todas as informações prestadas tornar-se-ão confidenciais e guardadas por força de sigilo profissional, assegurando que os dados obtidos da pesquisa serão somente utilizados para estudo.

ANEXOS

ANEXO A – Exemplo de Anexo

Aliquam lectus. Vivamus leo. Quisque ornare tellus ullamcorper nulla. Mauris porttitor pharetra tortor. Sed fringilla justo sed mauris. Mauris tellus. Sed non leo. Nullam elementum, magna in cursus sodales, augue est scelerisque sapien, venenatis congue nulla arcu et pede. Ut suscipit enim vel sapien. Donec congue. Maecenas urna mi, suscipit in, placerat ut, vestibulum ut, massa. Fusce ultrices nulla et nisl.

ANEXO B – Dinâmica das classes sociais

Etiam ac leo a risus tristique nonummy. Donec dignissim tincidunt nulla. Vestibulum rhoncus molestie odio. Sed lobortis, justo et pretium lobortis, mauris turpis condimentum augue, nec ultricies nibh arcu pretium enim. Nunc purus neque, placerat id, imperdiet sed, pellentesque nec, nisl. Vestibulum imperdiet neque non sem accumsan laoreet. In hac habitasse platea dictumst. Etiam condimentum facilisis libero. Suspendisse in elit quis nisl aliquam dapibus. Pellentesque auctor sapien. Sed egestas sapien nec lectus. Pellentesque vel dui vel neque bibendum viverra. Aliquam porttitor nisl nec pede. Proin mattis libero vel turpis. Donec rutrum mauris et libero. Proin euismod porta felis. Nam lobortis, metus quis elementum commodo, nunc lectus elementum mauris, eget vulputate ligula tellus eu neque. Vivamus eu dolor.

ÍNDICE

AAA, 66