

FUNDAÇÃO EDSON QUEIROZ
UNIVERSIDADE DE FORTALEZA - UNIFOR
CENTRO DE CIÊNCIAS TECNOLÓGICAS
CURSO DE GRADUAÇÃO EM ENGENHARIA DA COMPUTAÇÃO

COMPRESSÃO SEMÂNTICA NA GERAÇÃO DE MODELOS BPMN 2.0 POR MODELOS DE LINGUAGEM: DSL E TRANSPILAÇÃO DETERMINÍSTICA

RAFAEL MARINS FLORENZANO

FORTALEZA – CEARÁ
2026

RAFAEL MARINS FLORENZANO

COMPRESSÃO SEMÂNTICA NA GERAÇÃO DE MODELOS BPMN 2.0 POR MODELOS DE LINGUAGEM: DSL E TRANSPILAÇÃO DETERMINÍSTICA

Trabalho de Conclusão de Curso apresentado ao Curso de Graduação em Engenharia da Computação do Centro de Ciências Tecnológicas da Universidade de Fortaleza, como requisito parcial à obtenção do grau de bacharel em Engenharia da Computação.

Orientador: Prof. Caio Marques

FORTALEZA – CEARÁ

2026

A ficha catalográfica deve ser gerada no site da biblioteca da Unifor através do link https://goo.gl/XYUWSC (link encurtado).

Preencha o formulário com as informações solicitadas e ao final será gerado um arquivo PDF da ficha catalográfica a ser anexada na versão final do TCC.

O arquivo PDF deve ser renomeado para "ficha-catalografica.pdf" (sem aspas) e colocado no diretório "elementos-pre-textuais" (sem aspas) do modelo de TCC da Unifor.

Ficha catalográfica da obra elaborada pelo autor através do programa de geração automática da Biblioteca Central da Universidade de Fortaleza

---

Batista, Bruno .
TEORIA DA RELATIVIDADE: SUBTÍTULO / Bruno Batista, Sandra Lima. - 2017
40 f.

Trabalho de Conclusão de Curso (Graduação) - Universidade de Fortaleza. Curso de Ciência da Computação, Fortaleza, 2017.
Orientação: Liadina Camargo.

1. FÍSICA. 2. RELATIVIDADE. 3. TEMPO. 4. ESPAÇO. I. Lima, Sandra. II. Camargo, Liadina. III. Título.

RAFAEL MARINS FLORENZANO

COMPRESSÃO SEMÂNTICA NA GERAÇÃO DE MODELOS BPMN 2.0 POR MODELOS DE LINGUAGEM: DSL E TRANSPILAÇÃO DETERMINÍSTICA

Trabalho de Conclusão de Curso apresentado ao Curso de Graduação em Engenharia da Computação do Centro de Ciências Tecnológicas da Universidade de Fortaleza, como requisito parcial à obtenção do grau de bacharel em Engenharia da Computação.

Aprovada em:

BANCA EXAMINADORA

Prof. Caio Marques (Orientador)
Centro de Ciências Tecnológicas - CCT
Universidade de Fortaleza - UNIFOR

Membro da Banca Dois
Centro de Ciências e Tecnologia - CCT
Universidade do Membro da Banca Dois - SIGLA

Membro da Banca Três
Centro de Ciências e Tecnologia - CCT
Universidade do Membro da Banca Três - SIGLA

Membro da Banca Quatro
Centro de Ciências e Tecnologia - CCT
Universidade do Membro da Banca Quatro - SIGLA

RESUMO

Este trabalho investiga se a geração de uma representação intermediária comprimida, seguida de expansão determinística, produz modelos BPMN 2.0 válidos de forma mais confiável e mais econômica em *tokens* do que a geração direta de XML por modelos de linguagem. Projetou-se uma linguagem de domínio específico com gramática EBNF formalmente especificada e um transpilador determinístico que a expande em XML validado contra o esquema oficial da OMG. Construiu-se um corpus de 1.021 processos a partir de fontes públicas de descrições textuais e especializou-se um modelo de sete bilhões de parâmetros por ajuste supervisionado com adaptação de baixo posto sobre pesos quantizados. A avaliação seguiu protocolo congelado antes de qualquer execução, com sete braços experimentais, 53 processos de referência modelados por especialistas e três repetições por item, totalizando 1.113 gerações. O componente determinístico produziu XML válido em 100% das amostras e preservou a equivalência topológica em 99,6%, e a representação proposta mostrou-se seis vezes mais compacta que o XML lógico equivalente. Contrariando a hipótese principal, fornecer a gramática no *prompt* reduziu a confiabilidade: modelos de fronteira assim instruídos produziram saída válida em 64,8% e 56,6% das gerações, contra 98,1% e 94,3% da geração direta de XML pelos mesmos modelos, com significância estatística e replicação em duas famílias distintas. A configuração que este trabalho propõe um modelo pequeno com a notação internalizada por ajuste fino, e não descrita no *prompt*, atingiu 86,8% de validade, vinte e dois pontos percentuais acima do modelo de fronteira instruído pela mesma gramática, ainda que abaixo dos 98,1% da geração direta de XML, emitindo 200 *tokens* medianos contra 631, a um custo de treinamento inferior a um dólar; patamar próximo, de 83,0%, replicou-se em verificação exploratória sobre duas famílias adicionais de modelos. Em fidelidade topológica, porém, o modelo especializado empata estatisticamente com o modelo de fronteira instruído por *prompt* e não alcança a geração direta de XML. Mediu-se ainda a concordância entre modelos de referência produzidos por especialistas distintos para um mesmo processo, obtendo-se F1 estrutural de 0,1449, patamar em que todos os métodos avaliados operam; disso decorre que métricas estruturais que identificam nós por rótulo saturam próximo ao ruído e não devem ser lidas como percentual de acerto. Conclui-se que o benefício de representações intermediárias compactas não se realiza por instrução em contexto, e sim por especialização do modelo, o que torna o ajuste fino condição de viabilidade da abordagem, e não etapa acessória.

Palavras-chave: BPMN; linguagem de domínio específico; modelos de linguagem; ajuste fino supervisionado; compressão de *tokens*.

ABSTRACT

This work investigates whether generating a compressed intermediate representation, followed by deterministic expansion, yields valid BPMN 2.0 models more reliably and more economically in tokens than direct XML generation by language models. A domain-specific language with a formally specified EBNF grammar was designed, together with a deterministic transpiler that expands it into XML validated against the official OMG schema. A corpus of 1,021 processes was built from public sources of textual process descriptions, and a seven-billion-parameter model was specialized through supervised fine-tuning with low-rank adaptation over quantized weights. The evaluation followed a protocol frozen prior to any execution, comprising seven experimental arms, 53 reference processes modeled by experts and three repetitions per item, totaling 1,113 generations. The deterministic component produced valid XML for 100% of the samples and preserved topological equivalence in 99.6%, and the proposed representation proved six times more compact than the equivalent logical XML. Contrary to the main hypothesis, describing the language through a prompt reduced reliability: frontier models instructed by the grammar produced valid output in 64.8% of generations, against 98.1% for direct XML generation by the same models, with statistical significance and replication across two distinct model families. The specialized small model, in turn, reached 86.8% validity, twenty-two percentage points above the frontier model instructed by the same grammar, emitting a median of 200 tokens against 631, at a training cost below one dollar; this validity level was replicated, as exploratory verification, across two additional model families. Agreement between reference models produced by different experts for the same process was also measured, yielding a structural F1 of 0.1449, the very range in which all evaluated methods operate; it follows that structural metrics identifying nodes by label saturate close to noise and should not be read as percentage of correctness. The conclusion is that the benefit of compact intermediate representations is not realized through in-context instruction, but through model specialization, which makes fine-tuning a condition for the viability of the approach rather than an accessory stage.

Keywords: BPMN; domain-specific language; language models; supervised fine-tuning; token compression.

LISTA DE ILUSTRAÇÕES

Figura 1 – Protocolo de compressão semântica: construção do corpus e inferência 36
Figura 2 – Validade sintática por braço experimental 59
Figura 3 – Perdas de treino e de validação no ajuste supervisionado 62
Figura 4 – Custo de saída contra validade sintática, por braço 64
Figura 5 – Saturação do DF-F1 conforme o casamento de rótulos é afrouxado . . . 69
Figura 6 – Divergência de nomenclatura sem divergência de estrutura (*pmo_52*) . 71
Figura 7 – Fidelidade topológica por braço, relativa à concordância entre especialistas 73

LISTA DE TABELAS

Tabela 1 – Fontes do conjunto de dados e partições 37
Tabela 2 – Braços experimentais 46
Tabela 3 – Hipóteses pré-registradas 47
Tabela 4 – Distribuição do corpus por partição 54
Tabela 5 – Fidelidade topológica por versão do conversor 56
Tabela 6 – Panorama dos braços executados 58
Tabela 7 – Contrastes pré-registrados 60
Tabela 8 – Contraste restrito aos itens com saída válida (exploratório) 61
Tabela 9 – Braço A3 antes e depois da emenda ao *prompt* 66
Tabela 10 – Compressão e custo de saída por braço 67
Tabela 11 – MF-F1 restrito aos dois itens com fluxo de mensagem na referência . . 72
Tabela 12 – Desempenho relativo ao teto humano (24 itens com referência múltipla) 73
Tabela 13 – Oráculo do pipeline de augmentation contra o *gold* 75
Tabela 14 – Curva de aprendizado sobre subconjuntos aninhados do treino 77
Tabela 15 – Replicação do ajuste fino em três famílias 78
Tabela 16 – Uso da construção de referência por família 78
Tabela 17 – Natureza das falhas de *parsing* por braço 80
Tabela 18 – Estado das hipóteses pré-registradas 82

LISTA DE CÓDIGOS-FONTE

Código-fonte 1 – Exemplo de processo na BPMN-DSL: decisão exclusiva com laço de repetição via referência. Rótulos em inglês conforme a Seção 4.4.5 39

LISTA DE ABREVIATURAS E SIGLAS

BPMN	*Business Process Model and Notation*
DF-F1	medida F1 sobre o multiconjunto *direct-follows*
DSL	*Domain-Specific Language* (linguagem de domínio específico)
EBNF	*Extended Backus-Naur Form*
GPU	*Graphics Processing Unit* (unidade de processamento gráfico)
GRPO	*Group Relative Policy Optimization*
JSON	*JavaScript Object Notation*
LLM	*Large Language Model* (modelo de linguagem de grande escala)
LoRA	*Low-Rank Adaptation* (adaptação de baixo posto)
MF-F1	medida F1 sobre os fluxos de mensagem
NF4	*Normal Float* de 4 *bits*
OMG	*Object Management Group*
QLoRA	*Quantized Low-Rank Adaptation*
SFT	*Supervised Fine-Tuning* (ajuste fino supervisionado)
TCR	*Token Compression Ratio* (razão de compressão de *tokens*)
XML	*eXtensible Markup Language*
XSD	*XML Schema Definition*
XSD-Val	taxa de validade contra o esquema XSD oficial

LISTA DE SÍMBOLOS

$\mathscr{R}$	Multiconjunto *direct-follows* do modelo de referência
$\mathscr{C}$	Multiconjunto *direct-follows* do modelo candidato
P	Precisão sobre o multiconjunto *direct-follows*
R	Revocação sobre o multiconjunto *direct-follows*
(a,b)	Par de atividades em que a é diretamente seguida por b
n	Número de itens do conjunto de avaliação
k	Número de repetições de geração por item
p	Valor-p do teste de Wilcoxon pareado
p_{Holm}	Valor-p após correção de Holm para múltiplas comparações
r_{rb}	Tamanho de efeito *rank-biserial*
r	Recompensa composta
r'	Recompensa restrita a componentes verificáveis sem referência
r_{sint}	Componente de validade sintática da recompensa
r_{sem}	Componente de adequação semântica da recompensa
r_{topo}	Componente de coerência topológica da recompensa
r_{comp}	Componente de economia de *tokens* da recompensa
α	Algoritmo α de descoberta de processos

SUMÁRIO

1 INTRODUÇÃO 15
1.1 MOTIVAÇÃO 18
1.2 OBJETIVOS 19
1.2.1 Objetivo Geral 19
1.2.2 Objetivos Específicos 19
1.3 ORGANIZAÇÃO DO TRABALHO 19
2 FUNDAMENTAÇÃO TEÓRICA 21
2.1 MODELAGEM DE PROCESSOS DE NEGÓCIO E A NOTAÇÃO BPMN 2.0 21
2.1.1 Gerenciamento de Processos de Negócio 21
2.1.2 A Notação BPMN 2.0 22
2.1.3 Representação XML e Verbosidade 22
2.2 MODELOS DE LINGUAGEM DE GRANDE ESCALA 23
2.2.1 Arquitetura Transformer 23
2.2.2 Tokenização e o Custo de Sequências Longas 23
2.2.3 Geração de Saídas Estruturadas 24
2.3 LINGUAGENS DE DOMÍNIO ESPECÍFICO E COMPRESSÃO SEMÂNTICA 24
2.3.1 Linguagens de Domínio Específico 24
2.3.2 Compressão Semântica como Estratégia de Geração 25
2.4 ADAPTAÇÃO DE MODELOS DE LINGUAGEM A TAREFAS ESPECÍFICAS 25
2.4.1 Supervised Fine-Tuning 25
2.4.2 Ajuste com Eficiência de Parâmetros: LoRA e QLoRA 26
2.4.3 Aprendizado por Reforço com GRPO 26
2.5 EXTRAÇÃO DE PROCESSOS A PARTIR DE TEXTO NATURAL 27
2.5.1 Caracterização do Problema 27
2.5.2 Recursos e Datasets Disponíveis 27
2.6 AVALIAÇÃO DE GERAÇÃO DE ARTEFATOS ESTRUTURADOS 28
2.6.1 Validação por Esquema 28
2.6.2 Métricas Sintáticas e Semânticas 28
2.6.3 Distância de Edição em Grafos 28
2.6.4 Eficiência: Razão de Compressão de Tokens 29
2.6.5 Função de Recompensa Composta 29

2.7 SÍNTESE DO CAPÍTULO 29
3 TRABALHOS RELACIONADOS 30
3.1 GERAÇÃO DE MODELOS DE PROCESSO COM LLMS 30
3.2 REPRESENTAÇÕES COMPACTAS DE PROCESSOS 30
3.3 COMPRESSÃO DE *TOKENS*: ENTRADA *VERSUS* SAÍDA 31
3.4 MODELOS PEQUENOS ESPECIALIZADOS 32
3.5 GARANTIA DE VALIDADE SINTÁTICA 32
4 METODOLOGIA 34
4.1 DELIMITAÇÃO DO PROBLEMA 34
4.2 PRÉ-REGISTRO DO PROTOCOLO EXPERIMENTAL 35
4.3 VISÃO GERAL DO PROTOCOLO 35
4.4 CONSTRUÇÃO DO CONJUNTO DE DADOS 36
4.4.1 Fontes e Curadoria 36
4.4.2 Pré-processamento com LLM 37
4.4.3 Seleção do Modelo Gerador 37
4.4.4 Geração do JSON BPMN Canônico 38
4.4.5 Idioma dos Artefatos 38
4.4.6 Partições e Prevenção de Contaminação 39
4.5 A BPMN-DSL 39
4.6 TRANSPILAÇÃO DETERMINÍSTICA 40
4.6.1 JSON para DSL 40
4.6.2 DSL para XML BPMN 2.0 41
4.6.3 Geração Determinística de Leiaute 41
4.7 PROTOCOLO DE AVALIAÇÃO 42
4.7.1 Eixo 1: Validade Sintática 42
4.7.2 Eixo 2: Equivalência Topológica 43
4.7.3 Eixo 3: Fluxos de Mensagem 44
4.7.4 Eixo 4: Compressão 45
4.7.5 Referências Múltiplas e Ambiguidade de Modelagem 45
4.7.6 Desenho dos Braços Experimentais 45
4.7.7 Hipóteses 47
4.7.8 Parâmetros Congelados e Análise Estatística 48
4.8 ESPECIALIZAÇÃO DO MODELO 49

4.8.1 Ajuste Supervisionado . . . 49
4.8.2 Etapa Opcional: Aprendizado por Reforço com Recompensa Verificável 51
4.9 INFRAESTRUTURA E REPRODUTIBILIDADE . . . 52
5 RESULTADOS . . . 54
5.1 COMPOSIÇÃO DO CORPUS . . . 54
5.2 EIXO 1: VALIDADE SINTÁTICA . . . 55
5.3 EIXO 2: FIDELIDADE TOPOLÓGICA . . . 55
5.3.1 Trajetória entre Versões . . . 55
5.3.2 Análise do Resíduo . . . 56
5.4 EIXO 4: COMPRESSÃO DE *TOKENS* . . . 56
5.5 CONJUNTO DE REFERÊNCIA . . . 57
5.6 AVALIAÇÃO COMPARATIVA DOS BRAÇOS . . . 57
5.6.1 Resultados Descritivos por Braço . . . 58
5.6.2 Testes das Hipóteses Pré-Registradas . . . 60
5.6.3 Análise do Mecanismo: Validade e Não Qualidade . . . 61
5.6.4 O Modelo Especializado . . . 62
5.6.5 Verificações de Validade do Resultado Adverso . . . 64
5.6.6 Emendas ao Protocolo Congelado . . . 65
5.6.7 Eixo Econômico . . . 67
5.6.8 Limitação Relevante da Métrica de Fidelidade . . . 68
5.6.9 Não Avaliabilidade do Eixo de Fluxos de Mensagem . . . 70
5.6.10 Teto Humano da Métrica . . . 72
5.6.11 Validação do Pipeline de Augmentation . . . 74
5.6.12 Braços Exploratórios . . . 76
5.6.13 Síntese . . . 82
6 CONCLUSÕES E TRABALHOS FUTUROS . . . 84
6.1 CONTRIBUIÇÕES DO TRABALHO . . . 84
6.2 LIMITAÇÕES . . . 85
6.3 TRABALHOS FUTUROS . . . 86
REFERÊNCIAS . . . 88

1 INTRODUÇÃO

Organizações dependem de processos documentados para operar de forma previsível, treinar pessoas e cumprir exigências regulatórias. A notação BPMN 2.0, padronizada pela Object Management Group (2011), tornou-se a linguagem de referência para essa documentação, com uso consolidado tanto na indústria quanto na literatura de gestão de processos (WESKE, 2019; DUMAS *et al.*, 2018). Na prática, porém, a maior parte do conhecimento sobre processos permanece registrada em linguagem natural: manuais internos, descrições de procedimentos e documentos de política. A conversão desse material em modelos formais continua sendo uma tarefa manual, lenta e dependente de especialistas (FRIEDRICH; MENDLING; PUHLMANN, 2011; AA *et al.*, 2018).

O avanço dos modelos de linguagem de grande porte (VASWANI *et al.*, 2017; BROWN *et al.*, 2020) tornou plausível automatizar essa conversão. A dificuldade está na forma de saída. A serialização XML da BPMN foi concebida para intercâmbio entre ferramentas, não para ser escrita diretamente por pessoas ou por modelos. Ao solicitar que um modelo produza XML BPMN completo, transfere-se a ele uma responsabilidade pouco adequada ao seu funcionamento: reproduzir com precisão um grande volume de marcação técnica, ainda que boa parte dessa marcação possa ser derivada de maneira determinística. O custo aparece em duas frentes. A primeira é econômica e não depende de verificação: cada *token* de marcação repetitiva consome contexto, tempo e dinheiro, e a quantidade emitida é diretamente mensurável. A segunda é de confiabilidade, e tem natureza distinta, é uma **expectativa a ser testada**, não um dado. O risco existe em princípio, pois uma única inconsistência estrutural invalida o documento inteiro; se ele de fato se materializa, e em que medida, é questão empírica. Adianta-se que a resposta obtida neste trabalho contraria a expectativa inicial, conforme discutido adiante.

O gargalo prático de sistemas construídos sobre modelos de linguagem não é propriamente o *token*, e sim o custo, que resulta do produto entre o preço unitário do modelo e o volume que se pede a ele que produza. Usarei como exemplo dois episódios de 2026 que definem bem esse problema. A Uber esgotou em quatro meses o orçamento anual destinado a ferramentas de codificação assistida e passou a exigir um teto de US$ 1.500 mensais por funcionário e por ferramenta, diante da dificuldade, reconhecida pela própria diretoria, de ligar o consumo de *tokens* a benefício mensurável (ROPEK, 2026). No mesmo período, a Microsoft cancelou a maior parte das licenças diretas de assistentes da Anthropic concedidas à sua engenharia e passou a rotear requisições de seus produtos para modelos próprios, declarando como objetivo explícito

a redução desse custo (COOTER, 2026). Em nenhum dos casos as ações foram geradas por insuficiência de qualidade: foi o preço de mante-la em escala. Cabe notar que a parcela sobre a qual este trabalho atua é a mais cara das duas. A geração é tarifada, na prática corrente dos provedores, a um múltiplo do preço da entrada, de modo que marcação redundante **emitida** pelo modelo custa várias vezes o que custaria a mesma marcação apenas lida por ele. Sendo o custo um produto de dois fatores, há duas frentes de ataque, e a abordagem investigada aqui atua sobre ambas: emitir menos e emitir com um modelo mais barato mantendo uma qualidade adequada ao problema.

A redução do número de *tokens* nesses sistemas tem sido atacada, contudo, principalmente do lado da entrada. Na pesquisa, o LLMLingua (JIANG *et al.*, 2023) comprime o contexto antes que ele alcance o modelo, com ganhos expressivos e pouca perda de desempenho. Na indústria, ferramentas como o Headroom (Headroom Labs, 2026) aplicam a mesma ideia a saídas de ferramentas, registros e trechos recuperados, relatando reduções entre 60% e 95% em conteúdo estruturado. Essas abordagens confirmam que a economia de *tokens* é uma preocupação concreta e que boa parte dela vem da remoção de repetição estrutural. Nenhuma delas, entretanto, atua sobre o lado da geração, justamente o lado mais caro: fazer com que o próprio modelo emita nativamente uma representação compacta, cuja expansão determinística produza um artefato válido segundo um esquema formal.

Duas linhas de trabalho se aproximam desse objetivo por caminhos distintos. A decodificação restrita, discutida por Poesia *et al.* (2022), garante conformidade sintática durante a geração, mas não reduz o volume que o modelo precisa emitir. Já o ProMoAI, de Kourani *et al.* (2024), gera modelos de processo por meio de uma representação intermediária expandida deterministicamente em BPMN, demonstrando que a estratégia é viável. O trabalho de Kourani *et al.* (2024) apoia-se, contudo, em um modelo de fronteira operado por *prompt* e não trata a representação intermediária como um problema de compressão com taxa medida. É exatamente nesse espaço que esta monografia se posiciona.

A escolha do modelo é um problema também. Belcak *et al.* (2025) argumentam que modelos pequenos e especializados, podem ser uma base adequada para tarefas agênticas repetitivas no lugar de fronteira genéricos, por razões de custo, latência e previsibilidade. Uma representação intermediária suficientemente compacta e regular torna essa especialização viável: reduz o que o modelo precisa aprender a emitir e permite que até mesmo um modelo de sete bilhões de parâmetros, como o Qwen2.5-Coder (HUI *et al.*, 2024), seja ajustado para a tarefa.

Este trabalho propõe, portanto, um protocolo de compressão semântica para geração

de BPMN. Um modelo de linguagem produz uma descrição concisa do processo em uma linguagem de domínio específico projetada para esse fim, e um transpilador baseado em gramática EBNF expande essa descrição em XML BPMN 2.0 validado contra o esquema oficial. A separação de responsabilidades gera um efeito útil para a depuração: quando ocorre uma falha, ela fica localizada na geração da DSL, no transpilador ou na validação, em vez de diluída em um documento XML extenso. Medido sobre 1.021 processos com o tokenizador do Qwen2.5-Coder, o artefato proposto é **seis vezes** mais compacto que o XML lógico correspondente, equivalente a uma redução de 83,4% no número de *tokens* que o modelo precisa emitir, sobre as saídas efetivamente geradas pelos braços experimentais, a razão sobe para cerca de sete.

Os resultados obtidos são previamente citados neste parágrafo, por contrariarem em parte as hipóteses registradas antes da execução. A economia e a tese principal do modelo pequeno treinado se confirmam.

O que o registro prévio desmentiu diz respeito a **como** a representação intermediária chega ao modelo. Havia-se previsto que descrever a gramática no *prompt* bastaria para elevar a confiabilidade de um modelo de fronteira; o observado é o oposto: assim instruídos, esses modelos produziram saída válida em 64,8% e 56,6% das gerações, contra 98,1% e 94,3% da geração direta de XML pelos mesmos modelos. Convém situar o que esse desfecho atinge e o que não atinge. Esses braços não constituem a configuração proposta, e sim o método executado com um modelo caro operado por instrução, papel de referência no desenho experimental. A proposta sempre foi outra, e o próprio *pipeline* de construção do corpus a reflete: a DSL de treino não é escrita por modelo algum, e sim derivada deterministicamente de uma estrutura intermediária, de modo que o componente probabilístico nunca responde pela sintaxe do artefato. Internalizada nos pesos por ajuste fino, a notação sustenta-se: um modelo de sete bilhões de parâmetros atingiu 86,8% de validade, vinte e dois pontos percentuais acima do modelo de fronteira instruído pela mesma gramática, embora ainda abaixo da geração direta. O efeito não se restringe a um modelo isolado: o mesmo ajuste fino, repetido sobre duas famílias adicionais de sete e oito bilhões de parâmetros, produziu 83,0% de validade em ambas, ainda que como verificação exploratória, fora do conjunto de braços pré-registrados. A explicação é que a serialização XML da BPMN, embora verbosa, é amplamente representada no pré-treinamento dos modelos, ao passo que a linguagem aqui proposta lhes é inteiramente nova, verbosidade não constitui dificuldade para quem já viu o formato, novidade sim. Segue-se que o ajuste fino não é etapa acessória da abordagem, e sim condição de sua viabilidade.

Registra-se também um achado de ordem metodológica, obtido durante a avaliação

e independente da linguagem proposta: foi medido a concordância entre modelos de referência produzidos por especialistas distintos para o mesmo processo, e ela é baixa. Métricas estruturais que identificam nós por rótulo saturam, por isso, muito abaixo do máximo teórico, e todos os métodos avaliados operam nessa vizinhança. Portanto, os valores absolutos dessas métricas não devem ser lidos como percentual de acerto.

1.1 MOTIVAÇÃO

A modelagem de processos ainda é caro justamente aonde é mais necessário. Empresas que documentam seus processos textualmente raramente dispõe de tempo e recurso especializado para convertê-los em modelos formais, o resultado disso é uma base documental não visual e que não pode ser analisada, simulada ou automatizada. Reduzir o custo e tornar possível a conversão amplia o acesso à modelagem e libera o especialista para focar em ações menos repetitivas e mais estratégicas.

Há ainda uma motivação técnica, e ela independe do desfecho particular observado na BPMN. O padrão de separar a geração de uma representação compacta da expansão determinística em um artefato validável é aplicável a qualquer domínio em que a saída precise obedecer a um esquema formal e a serialização oficial seja verbosa. O que este trabalho tem a oferecer a esses domínios não é apenas a confirmação de um ganho, mas a identificação da **condição** sob a qual ele se realiza, questão que só uma avaliação com protocolo previamente fixado poderia responder em qualquer direção. A BPMN oferece um caso de teste favorável para essa investigação porque possui esquema oficial, conjuntos de dados públicos com modelos de referência e métricas estruturais bem definidas, o que permite verificação objetiva em vez de avaliação subjetiva.

Por fim, a economia de *tokens* deixou de ser detalhe de implementação. Em fluxos que geram modelos em escala, o custo de emitir marcação redundante é recorrente, e a alternativa de depender continuamente de modelos de fronteira concentra esse custo em um fornecedor externo. Um modelo pequeno ajustado para emitir uma representação comprimida é, nesse cenário, uma resposta de engenharia e não apenas um exercício acadêmico.

1.2 OBJETIVOS

1.2.1 Objetivo Geral

Investigar se a geração de uma representação intermediária comprimida, seguida de expansão determinística, produz modelos BPMN 2.0 válidos de forma mais confiável e mais econômica em *tokens* do que a geração direta de XML por modelos de linguagem.

1.2.2 Objetivos Específicos

a) projetar uma linguagem de domínio específico para descrição de processos BPMN, com gramática EBNF formalmente especificada;
b) implementar um transpilador determinístico que expanda essa linguagem em XML BPMN 2.0 validado contra o esquema oficial;
c) construir um conjunto de dados de pares formados por descrição textual e representação na linguagem proposta, a partir de fontes públicas de descrições de processos;
d) realizar o ajuste fino supervisionado de um modelo de linguagem de pequeno porte para emitir a representação comprimida;
e) quantificar a compressão obtida e a fidelidade estrutural dos modelos gerados, comparando a abordagem proposta com a geração direta de XML sob protocolo de avaliação definido previamente à execução dos experimentos.

1.3 ORGANIZAÇÃO DO TRABALHO

O Capítulo 2 reúne os conceitos necessários à proposta: modelagem de processos e a notação BPMN 2.0, funcionamento e limitações dos modelos de linguagem na geração estruturada, linguagens de domínio específico como camada de mediação, e os métodos de adaptação de modelos empregados na etapa experimental.

O Capítulo 3 posiciona a proposta frente à literatura, distinguindo-a tanto das abordagens de compressão de contexto, que atuam sobre a entrada, quanto dos trabalhos que geram modelos de processo por representação intermediária sem tratá-la como problema de compressão com taxa medida.

O Capítulo 4 descreve a linguagem proposta e sua gramática, o transpilador determinístico e o gerador de leiaute, o *pipeline* de construção do conjunto de dados, e de forma

destacada, o protocolo de avaliação, congelado antes da execução de qualquer experimento e reproduzido ali na íntegra, incluindo hipóteses, métricas, braços experimentais e plano de análise estatística.

O Capítulo 5 reporta a verificação do componente determinístico sobre o corpus completo e, em seguida, a avaliação comparativa dos sete braços experimentais contra modelos de referência produzidos por especialistas. Reporta também as emendas ao protocolo, as verificações de validade aplicadas aos resultados adversos e as limitações identificadas na própria métrica de fidelidade.

O Capítulo 6 retoma o objetivo geral à luz das evidências, sistematiza as contribuições e as limitações, e enumera as extensões que a investigação deixou em aberto.

2 FUNDAMENTAÇÃO TEÓRICA

O ponto de partida deste trabalho é uma dificuldade prática: gerar XML BPMN 2.0 completo por meio de Modelos de Linguagem de Grande Escala (LLMs, do inglês *Large Language Models*) tende a ser custoso, verboso e sujeito a erros estruturais. Para discutir esse problema, este capítulo reúne os conceitos necessários à proposta de um protocolo de compressão semântica voltado à geração de *markup* XML. A fundamentação começa pela modelagem de processos de negócio e pela notação BPMN 2.0, passa pelos princípios de funcionamento dos LLMs e pelos desafios da geração estruturada, e então discute Linguagens de Domínio Específico (DSLs, do inglês *Domain-Specific Languages*) como mecanismo de mediação entre descrição semântica e representação XML. Em seguida, são apresentados os métodos de adaptação de modelos que sustentam a etapa experimental do projeto, especialmente SFT, LoRA, QLoRA e GRPO. Por fim, o capítulo aborda recursos disponíveis para extração de processos a partir de texto natural e métricas adequadas à avaliação de artefatos estruturados.

2.1 MODELAGEM DE PROCESSOS DE NEGÓCIO E A NOTAÇÃO BPMN 2.0

2.1.1 Gerenciamento de Processos de Negócio

O Gerenciamento de Processos de Negócio (BPM, do inglês *Business Process Management*) trata processos organizacionais como objetos que podem ser descritos, analisados, executados e aperfeiçoados de forma sistemática (DUMAS *et al.*, 2018). Essa área aproxima contribuições da administração, da engenharia de software e da pesquisa operacional, sobretudo quando o processo precisa deixar de ser apenas uma prática informal e passar a funcionar como um artefato verificável (WESKE, 2019).

Essa formalização é importante porque iniciativas de automação, auditoria e conformidade dependem de uma representação compartilhada do processo. Ao mesmo tempo, a notação adotada precisa equilibrar dois requisitos que nem sempre caminham juntos: ser compreensível para analistas e gestores, sem exigir domínio técnico profundo, e preservar precisão suficiente para permitir análise computacional ou execução automatizada. A BPMN se consolidou justamente nesse espaço, oferecendo uma linguagem visual relativamente acessível, mas apoiada por uma especificação formal.

2.1.2 A Notação BPMN 2.0

A *Business Process Model and Notation*, em sua versão 2.0, é mantida pelo *Object Management Group* e é uma das principais referências para a representação de processos de negócio (Object Management Group, 2011). Seu papel é duplo: por um lado, define símbolos gráficos usados por analistas de processo; por outro, estabelece uma serialização XML descrita por um *XML Schema Definition* (XSD). Essa combinação permite que um mesmo modelo seja lido visualmente por pessoas e processado por ferramentas.

Segundo a especificação da BPMN 2.0, os elementos da notação são agrupados em categorias principais Object Management Group (2011):

- **Objetos de fluxo** (*flow objects*): eventos (*events*), atividades (*activities*) e *gateways*, que representam os principais nós do processo;
- **Objetos de conexão** (*connecting objects*): fluxos de sequência, fluxos de mensagem e associações, responsáveis por explicitar relações entre elementos;
- **Raias** (*swimlanes*): *pools* e *lanes*, usadas para indicar participantes, setores ou responsabilidades;
- **Artefatos** (*artifacts*): grupos, anotações textuais e objetos de dados, empregados para acrescentar informação complementar ao modelo.

Com esses elementos, a BPMN permite representar padrões comuns de processos, como decisões exclusivas, execuções paralelas, eventos intermediários e interações entre participantes. A expressividade da notação, no entanto, cobra seu preço: quanto mais completa é a representação, maior tende a ser a complexidade para quem modela, valida ou gera o artefato. Dumas *et al.* (2018) observam que essa riqueza da BPMN exige aprendizado, tanto do analista humano quanto de qualquer sistema que tente manipulá-la automaticamente.

2.1.3 Representação XML e Verbosidade

Na prática, um modelo BPMN 2.0 interoperável costuma ser armazenado em XML conforme o esquema oficial. Essa escolha favorece o intercâmbio entre ferramentas e reduz ambiguidades de implementação, mas produz documentos consideravelmente maiores do que a descrição conceitual do processo. Em um exemplo simples, o XML precisa declarar *namespaces*, identificadores, elementos de diagrama, coordenadas, fluxos, referências cruzadas e atributos previstos pela especificação.

Essa verbosidade não é um problema grave quando o XML é gerado por uma

ferramenta de modelagem. A situação muda quando o alvo de geração passa a ser um LLM. Nesse caso, o modelo precisa emitir uma sequência longa, com muitos trechos repetitivos e com baixa tolerância a pequenos desvios. Uma *tag* ausente, um identificador trocado ou uma referência inconsistente pode invalidar o documento inteiro, mesmo que a estrutura geral do processo tenha sido compreendida corretamente. Esse descompasso entre conteúdo semântico e representação textual motiva a busca por uma camada intermediária mais curta e mais controlável.

2.2 MODELOS DE LINGUAGEM DE GRANDE ESCALA

2.2.1 Arquitetura Transformer

A arquitetura Transformer, proposta por Vaswani *et al.* (2017), marcou uma mudança importante na modelagem de sequências. Em vez de processar a entrada de forma recorrente, o Transformer usa mecanismos de *self-attention* para relacionar diretamente diferentes posições da sequência. Esse desenho favoreceu paralelização em larga escala e abriu caminho para os modelos de linguagem atuais.

Os LLMs mais utilizados seguem, em geral, uma formulação autorregressiva: a cada passo, o modelo estima o próximo *token* a partir dos anteriores. Quando treinados sobre grandes coleções de texto, esses modelos passam a apresentar capacidade de generalização para tarefas variadas, inclusive tarefas que não aparecem explicitamente como objetivos de treinamento (BROWN *et al.*, 2020). Essa flexibilidade explica seu interesse para geração de código, consultas, marcações e outros formatos estruturados.

2.2.2 Tokenização e o Custo de Sequências Longas

LLMs não operam diretamente sobre palavras completas. A entrada e a saída são decompostas em *tokens*, frequentemente obtidos por técnicas como *Byte-Pair Encoding* (SENNRICH; HADDOW; BIRCH, 2016). Essa estratégia funciona bem para texto natural, mas pode ser pouco econômica para formatos como XML. Identificadores longos, nomes de atributos, símbolos de marcação e padrões repetidos tendem a ser fragmentados em vários *tokens*.

O aumento no número de *tokens* tem consequências diretas. O mecanismo de atenção cresce em custo com o comprimento da sequência, o que afeta memória, tempo de treinamento e latência de inferência. Em um ambiente acadêmico com recursos limitados, gerar XML BPMN completo significa gastar parte relevante do orçamento computacional em trechos que

são necessários para a conformidade do arquivo, mas não necessariamente para a descrição semântica do processo.

2.2.3 Geração de Saídas Estruturadas

A geração de artefatos estruturados por LLMs, como código-fonte, consultas e linguagens de marcação, tornou-se uma linha de pesquisa relevante a partir de trabalhos como o de Chen *et al.* (2021). O desafio central é que a geração probabilística não garante, por si só, validade sintática nem conformidade a um esquema externo. Em linguagem natural, um pequeno desvio pode ser tolerável; em XML, uma inconsistência local pode tornar todo o documento inválido.

Poesia *et al.* (2022) discutem esse problema no contexto de geração de código e defendem a combinação entre modelos probabilísticos e mecanismos determinísticos de restrição. A ideia é simples, mas importante para este trabalho: quando a saída precisa obedecer a regras formais, a geração livre do modelo deve ser complementada por alguma forma de controle. Esse controle pode aparecer durante a decodificação, em uma etapa posterior de validação ou por meio de uma representação intermediária projetada para ser mais simples de gerar e de verificar.

2.3 LINGUAGENS DE DOMÍNIO ESPECÍFICO E COMPRESSÃO SEMÂNTICA

2.3.1 Linguagens de Domínio Específico

Para Fowler (2010), uma Linguagem de Domínio Específico é uma linguagem computacional criada para um domínio particular, com escopo e expressividade intencionalmente limitados. Essa limitação não é uma deficiência. Pelo contrário, ela permite que a linguagem se aproxime dos conceitos do problema e reduza detalhes que seriam necessários em uma linguagem de propósito geral. Mernik, Heering e Sloane (2005) apontam benefícios recorrentes das DSLs, entre eles a elevação do nível de abstração, a redução de código repetitivo e a maior facilidade para realizar análises estáticas.

No caso da BPMN, a serialização XML já é uma linguagem formal, mas não foi pensada para ser escrita diretamente por pessoas ou por modelos de linguagem. Ela foi concebida principalmente para intercâmbio entre ferramentas. Por isso, quando se pede a um LLM que produza XML BPMN completo, transfere-se ao modelo uma responsabilidade pouco adequada ao seu funcionamento: repetir com precisão uma grande quantidade de marcação técnica, ainda

que parte dessa marcação possa ser gerada de maneira determinística.

2.3.2 Compressão Semântica como Estratégia de Geração

Neste trabalho, compressão semântica designa a redução da representação textual de um artefato sem perda do conteúdo essencial, desde que a forma completa possa ser reconstruída por uma etapa determinística. A compressão, portanto, não é tratada como objetivo isolado. Seu papel é separar duas responsabilidades: o LLM deve produzir uma descrição concisa do processo, enquanto o transpilador deve expandir essa descrição para XML BPMN 2.0 válido.

A proposta segue três etapas. Primeiro, o LLM gera uma representação intermediária em uma DSL voltada à descrição de processos BPMN. Em seguida, um transpilador baseado em gramática EBNF e regras de enriquecimento converte essa representação em XML BPMN 2.0. Por fim, o XML gerado é validado contra o XSD oficial. Quando ocorre erro, a falha tende a ficar mais localizada: pode estar na geração da DSL, no transpilador ou na validação do XML. Esse desenho facilita a depuração quando comparado à geração direta de um documento XML longo.

A motivação para essa estratégia combina três aspectos. O primeiro é computacional, pois uma saída mais curta reduz o número de *tokens* e pode baratear treinamento e inferência. O segundo é de aprendizado, já que uma representação menos redundante pode concentrar melhor o sinal supervisionado no que realmente descreve o processo. O terceiro é metodológico: a separação entre modelo e transpilador permite avaliar de forma mais clara o que foi aprendido pelo LLM e o que foi garantido por regras determinísticas.

2.4 ADAPTAÇÃO DE MODELOS DE LINGUAGEM A TAREFAS ESPECÍFICAS

2.4.1 Supervised Fine-Tuning

O ajuste supervisionado, ou *Supervised Fine-Tuning* (SFT), é uma das formas mais diretas de adaptar um LLM a uma tarefa específica. O procedimento continua o treinamento do modelo sobre pares de entrada e saída esperada, deslocando a distribuição gerada na direção do comportamento desejado (OUYANG *et al.*, 2022). Neste projeto, cada exemplo associa uma descrição textual de processo a uma representação na DSL proposta.

A qualidade do SFT depende fortemente do corpus. Em tarefas muito específicas, como gerar uma DSL nova para processos BPMN, não há um conjunto público pronto que

resolva o problema de forma direta. Isso torna necessária a construção de dados por meio de conversões, curadoria e aumento de dados. Modelos mais capazes podem atuar como apoio nessa etapa, gerando pseudoexemplos que depois precisam ser filtrados e validados.

2.4.2 Ajuste com Eficiência de Parâmetros: LoRA e QLoRA

O ajuste completo de modelos com bilhões de parâmetros costuma ser inviável em computadores de uso acadêmico. Hu *et al.* (2022) propuseram o método *Low-Rank Adaptation* (LoRA) como uma alternativa mais econômica: em vez de atualizar todos os pesos do modelo, treinam-se matrizes de baixa dimensão acopladas a camadas específicas. Os pesos originais permanecem congelados, e apenas os parâmetros adicionais são ajustados.

O método reduz a quantidade de parâmetros treináveis e, consequentemente, o consumo de memória. O QLoRA, apresentado por Dettmers *et al.* (2023), amplia essa economia ao quantizar os pesos congelados do modelo base para 4 *bits*, mantendo as adaptações em maior precisão. Essa combinação é especialmente relevante para o presente estudo, pois o projeto considera treinamento em uma estação local com 12 GB de memória dedicada de GPU.

2.4.3 Aprendizado por Reforço com GRPO

Embora o SFT ensine o modelo a imitar exemplos, ele não otimiza diretamente métricas externas de qualidade. Para uma tarefa como esta, algumas propriedades importantes são verificáveis por código: validade sintática, conformidade ao XSD, fidelidade semântica, coerência topológica do grafo e economia de *tokens*. Essas propriedades podem ser usadas como sinais de recompensa em uma etapa posterior de treinamento.

Shao *et al.* (2024) introduziram o *Group Relative Policy Optimization* (GRPO) no contexto de modelos voltados a raciocínio matemático. O método deriva do PPO, mas evita manter um modelo crítico separado. Para cada *prompt*, gera-se um grupo de respostas, e a vantagem de cada resposta é estimada em relação à média do próprio grupo. Essa simplificação reduz custo de memória, característica importante em cenários com restrição de hardware.

Neste trabalho, o GRPO é previsto como uma segunda etapa após o SFT. A função de recompensa combina dimensões diferentes da qualidade esperada: sintaxe, semântica, topologia e eficiência da DSL gerada. A composição ponderada dessas dimensões permite transformar critérios de avaliação em um sinal de treinamento, sem reduzir a qualidade do processo a uma única métrica isolada.

2.5 EXTRAÇÃO DE PROCESSOS A PARTIR DE TEXTO NATURAL

2.5.1 Caracterização do Problema

A extração automática de modelos de processo a partir de texto natural é anterior ao uso recente de LLMs. Friedrich, Mendling e Puhlmann (2011), por exemplo, já investigavam a geração de modelos BPMN com apoio de técnicas tradicionais de Processamento de Linguagem Natural (PLN), como análise sintática, resolução de correferências e regras de mapeamento. Os resultados indicavam potencial, mas também deixavam claro que textos de processo podem conter ambiguidades e informações implícitas.

Aa *et al.* (2018) organizam esses desafios em dimensões como ambiguidade lexical e estrutural, variação de granularidade, lacunas de informação e possibilidade de múltiplos modelos válidos para uma mesma descrição. Essa última questão é particularmente importante: em muitos casos, não existe apenas uma modelagem correta. O que existe são representações mais ou menos adequadas a uma interpretação do texto, ao nível de detalhe escolhido e ao objetivo da modelagem.

2.5.2 Recursos e Datasets Disponíveis

O domínio ainda possui poucos *benchmarks* consolidados. Bellan *et al.* (2023) apresentaram o *Process Extraction from Text* (PET), composto por 45 descrições textuais anotadas com atividades, *gateways*, atores e relações de fluxo. O PET é relevante por oferecer anotações em granularidade fina, úteis tanto para treinamento quanto para avaliação de tarefas de extração.

Outro recurso importante é o *PMo Dataset*, disponibilizado por Brissard, Cuppens e Zouaq (2025a). O conjunto reúne 55 modelos de processo com descrições textuais correspondentes e diferentes representações de modelo, incluindo BPMN, Mermaid, Graphviz, POWL code e XML simplificado. A presença de uma representação BPMN padronizada como referência torna o conjunto especialmente útil para avaliação. Já o dataset de Mangler e Klievtsova (2023) oferece 24 descrições textuais acompanhadas de múltiplos modelos BPMN possíveis, com pontuações atribuídas por especialistas, o que ajuda a observar a ambiguidade natural da modelagem de processos.

Além desses conjuntos especializados, o projeto pode recorrer a textos procedurais não anotados, como trechos públicos de documentação organizacional, para etapas de aumento de dados. A distinção entre essas fontes é metodologicamente relevante: datasets anotados

servem como referência e avaliação, enquanto textos abertos podem alimentar a construção de pares sintéticos, desde que passem por validação.

2.6 AVALIAÇÃO DE GERAÇÃO DE ARTEFATOS ESTRUTURADOS

2.6.1 Validação por Esquema

A validação por esquema é o primeiro critério para avaliar XML BPMN. No caso da BPMN 2.0, o XSD oficial define se o documento respeita a estrutura esperada pela especificação. O resultado é binário: o XML é válido ou inválido. Esse critério é necessário, mas não suficiente. Um arquivo pode ser válido em termos de esquema e ainda assim representar um processo diferente daquele descrito no texto de entrada.

2.6.2 Métricas Sintáticas e Semânticas

Para avaliar a fidelidade ao processo de referência, métricas como precisão, revocação e F1 podem ser calculadas sobre elementos extraídos do modelo gerado. Atividades, atores, *gateways* e arestas podem ser comparados com os elementos presentes no modelo esperado. A medida F1 é útil nesse contexto porque resume precisão e revocação, evitando uma leitura baseada apenas em acertos brutos.

2.6.3 Distância de Edição em Grafos

Como modelos BPMN podem ser interpretados como grafos, a comparação estrutural também é necessária. A *Graph Edit Distance* (GED), associada ao trabalho de Sanfeliu e Fu (1983), mede a distância entre grafos a partir do custo mínimo de operações de edição, como inserção, remoção e substituição de vértices e arestas. Em formulações gerais, o cálculo exato é computacionalmente difícil, razão pela qual aproximações são frequentemente usadas em aplicações práticas (GAO *et al.*, 2010).

Para este estudo, a GED é interessante porque considera a organização topológica do processo, não apenas a presença ou ausência de elementos individuais. Ainda assim, sua utilidade depende do modelo de custo adotado. Esse modelo precisa refletir o que, no contexto da BPMN, deve ser tratado como diferença relevante entre dois processos.

2.6.4 Eficiência: Razão de Compressão de Tokens

A Razão de Compressão de Tokens (TCR, do inglês *Token Compression Ratio*) é usada para medir a eficiência da representação intermediária. A métrica compara a quantidade de *tokens* necessária para representar o processo em XML BPMN com a quantidade necessária para representá-lo na DSL proposta, usando o mesmo tokenizador. Valores superiores a um indicam que a DSL é mais compacta que o XML correspondente.

Essa métrica, sozinha, não mede qualidade. Uma representação pode ser muito curta e ainda assim perder informação relevante. Por isso, a TCR precisa ser analisada junto às métricas de validade, fidelidade semântica e estrutura topológica. O interesse do trabalho está exatamente nesse equilíbrio: reduzir a saída gerada pelo LLM sem comprometer a reconstrução determinística do BPMN.

2.6.5 Função de Recompensa Composta

No treinamento por GRPO, as métricas anteriores podem ser combinadas em uma função de recompensa composta. Essa função precisa equilibrar critérios diferentes: validade sintática, adequação semântica ao texto, plausibilidade topológica e eficiência em *tokens*. Uma formulação ponderada facilita a interpretação dos resultados, pois permite identificar que dimensão da qualidade está contribuindo mais ou menos para o comportamento do modelo.

2.7 SÍNTESE DO CAPÍTULO

A discussão apresentada neste capítulo delimita o problema e justifica a estratégia proposta. A BPMN 2.0 oferece uma representação rica para processos de negócio, mas sua serialização XML é longa e sensível a erros. LLMs são capazes de gerar texto estruturado, porém não garantem conformidade formal por si mesmos. DSLs oferecem uma alternativa intermediária: descrevem o conteúdo essencial em uma forma mais curta, enquanto um transpilador assume a expansão para XML válido. As técnicas de SFT, LoRA, QLoRA e GRPO fornecem o caminho para adaptar o modelo à tarefa, e as métricas discutidas permitem avaliar a solução sob diferentes aspectos.

Com essa base, o Capítulo de Metodologia pode especificar de maneira operacional a gramática da DSL, o funcionamento do transpilador, a construção dos dados, os parâmetros de treinamento e o protocolo de avaliação.

3 TRABALHOS RELACIONADOS

Este capítulo situa o trabalho em relação a quatro linhas de pesquisa que o tangenciam: geração de modelos de processo por modelos de linguagem, representações compactas de processos, compressão de *tokens* em sistemas com LLMs, e garantia de validade sintática na geração de linguagens formais. O critério de organização é a proximidade com a pergunta desta pesquisa — o custo de gerar marcação hierárquica verbosa —, e não a cronologia ou a autoria.

3.1 GERAÇÃO DE MODELOS DE PROCESSO COM LLMS

A referência mais próxima em objetivo é o ProMoAI (KOURANI *et al.*, 2024), que emprega um LLM de fronteira, guiado por *prompt*, para produzir código POWL executável, posteriormente traduzido para BPMN. A estratégia compartilha com este trabalho a premissa central de **não** pedir XML diretamente ao modelo, interpondo uma representação intermediária mais adequada às capacidades do gerador.

As diferenças são de natureza e de escopo. O ProMoAI depende de um modelo de fronteira em tempo de inferência, o que mantém o custo por geração no patamar que este trabalho procura reduzir; a representação intermediária é código Python, escolhida por familiaridade do modelo com tarefas de programação, e não projetada para minimizar *tokens* emitidos; e a compressão obtida não é medida nem tratada como objetivo. Aqui, ao contrário, a compressão é métrica de primeira classe, a representação é projetada para isso, e o gerador-alvo é um modelo pequeno especializado por ajuste supervisionado. A reexecução do ProMoAI está fora do escopo desta versão, de modo que ele é tratado como referência qualitativa; comparar com números publicados sob protocolo distinto seria metodologicamente indefensável.

3.2 REPRESENTAÇÕES COMPACTAS DE PROCESSOS

Diversas notações alternativas ao XML BPMN foram propostas com objetivos que se sobrepõem parcialmente ao deste trabalho. A representação *JSON branches* (KÖPKE; SAFAN, 2025) foi introduzida explicitamente para reduzir contagem de *tokens* e favorecer aderência a esquema na geração por LLMs. A representação *Process Model Elements* (VOELTER *et al.*, 2024) organiza o modelo em listas planas de elementos, facilitando contagem e comparação. Somam-se a elas notações de visualização como Mermaid e Graphviz, e simplificações do próprio XML.

O trabalho de Brissard, Cuppens e Zouaq (2025b) é o que mais se aproxima em objeto empírico: realiza análise comparativa de nove representações de modelos de processo para geração com LLMs, sobre o mesmo conjunto de dados aqui utilizado como *holdout*. É, por isso, o antecedente que exige posicionamento mais cuidadoso.

A distinção é de **pergunta de pesquisa**, e não de artefato. Aquele trabalho pergunta qual representação produz os melhores modelos de processo quando um LLM é instruído por *prompt* — uma pergunta sobre adequação de notação à tarefa de modelagem. Esta pesquisa pergunta se a estratégia de comprimir a saída e expandi-la deterministicamente torna economicamente viável a geração de marcação hierárquica verbosa por modelos pequenos, usando BPMN como caso de estudo instrumentado. Disso decorrem três diferenças operacionais:

a) **o gerador**: representações avaliadas por *prompt* em modelos de fronteira, contra um modelo pequeno especializado por ajuste supervisionado, cujo custo por inferência é ordens de grandeza menor;
b) **a garantia sintática**: notações comparadas quanto à qualidade do modelo produzido, contra uma cadeia em que a validade perante o esquema é assegurada por construção, deixando de ser variável aleatória;
c) **a métrica de custo**: compressão medida e reportada como resultado de primeira ordem, e não como propriedade qualitativa da notação.

Que representações compactas de BPMN já existam não é objeção a este trabalho — é evidência de que o problema é reconhecido. A contribuição pretendida não é a notação em si, mas a demonstração empírica de que a combinação entre compressão medida, expansão determinística verificável e especialização de modelo pequeno desloca a fronteira de custo da tarefa. Registre-se ainda que a DSL proposta cobre construções que algumas dessas notações não representam — múltiplos eventos de início e fim, fluxos de mensagem e raias —, embora essa maior expressividade seja consequência do desenho, e não sua justificativa.

3.3 COMPRESSÃO DE *TOKENS*: ENTRADA *VERSUS* SAÍDA

A redução do consumo de *tokens* em sistemas com LLMs é problema ativo, e a literatura predominante trata do lado da **entrada**. O LLMLingua (JIANG *et al.*, 2023) comprime *prompts* removendo conteúdo de baixa informação segundo um modelo de linguagem auxiliar, preservando o desempenho na tarefa a jusante. Trabalhos de gestão de contexto perseguem objetivo análogo por seleção e sumarização do que entra na janela.

Este trabalho ataca o lado oposto e complementar: o custo da **saída**. A assimetria é relevante e raramente explicitada. *Tokens* de entrada podem ser processados em paralelo e beneficiam-se de mecanismos de cache; *tokens* de saída são gerados sequencialmente, dominam a latência percebida e são tipicamente tarifados a preço superior. Em tarefas cuja saída é marcação verbosa, o gargalo econômico está na geração, não na leitura — e comprimir o *prompt* não o alivia. As duas famílias de técnica são, portanto, ortogonais e combináveis, e não concorrentes.

3.4 MODELOS PEQUENOS ESPECIALIZADOS

A viabilidade da proposta depende de que um modelo de pequeno porte, especializado, alcance desempenho competitivo em tarefa estreita. Essa premissa é sustentada por evidência recente sobre o papel de modelos pequenos em sistemas agênticos (BELCAK *et al.*, 2025), que argumenta serem eles suficientes — e economicamente preferíveis — para subtarefas repetitivas e bem delimitadas, reservando modelos de fronteira para as etapas que exigem generalidade.

A geração de marcação estruturada a partir de descrição textual é exatamente uma dessas subtarefas: formato fixo, vocabulário restrito, critério de sucesso verificável. Métodos de ajuste eficiente em parâmetros (HU *et al.*, 2022), especialmente em sua variante quantizada (DETTMERS *et al.*, 2023), tornam a especialização exequível com recursos computacionais modestos, o que é condição para que o argumento econômico se sustente.

3.5 GARANTIA DE VALIDADE SINTÁTICA

Há uma alternativa à estratégia adotada que precisa ser reconhecida: a **decodificação restrita**, que impõe a gramática do formato-alvo durante a amostragem, impedindo por construção a emissão de sequências inválidas (POESIA *et al.*, 2022). Aplicada ao XML BPMN, garantiria validade sintática sem representação intermediária alguma.

Duas considerações delimitam a comparação. A primeira é que a decodificação restrita resolve a validade, mas **não** o custo: o modelo continua emitindo cada *token* da marcação verbosa, de modo que a economia perseguida aqui permanece inalcançada — e, com efeito, as duas técnicas são combináveis, podendo a decodificação restrita ser aplicada sobre a própria DSL. A segunda é que restringir a decodificação a uma gramática garante boa formação sintática, mas não coerência estrutural: um documento pode respeitar o esquema e ainda referenciar identificadores inexistentes ou descrever um grafo desconexo, classe de erro que a expansão

determinística elimina por não permitir que ela seja expressa.

A avaliação empírica da decodificação restrita como braço experimental está fora do escopo desta versão, e é registrada como trabalho futuro derivado.

4 METODOLOGIA

Este capítulo descreve o protocolo de compressão semântica proposto e o desenho experimental usado para avaliá-lo. Trata-se de uma pesquisa aplicada, de natureza experimental e abordagem quantitativa: todos os critérios de qualidade adotados são computáveis por código, e todos os artefatos intermediários são persistidos e versionados para permitir a reprodução integral dos resultados.

4.1 DELIMITAÇÃO DO PROBLEMA

O objeto deste trabalho não é a modelagem de processos em si, mas um problema mais geral do qual ela é um caso concreto: o **custo de geração de linguagens de marcação hierarquicamente complexas e verbosas por modelos de linguagem**. Formatos como XML impõem ao modelo gerador um ônus que é, em grande parte, sintático e não semântico: abertura e fechamento de dezenas de elementos aninhados, declaração de *namespaces*, identificadores de serialização, atributos obrigatórios de referência cruzada. Cada um desses *tokens* é cobrado, aumenta a latência e oferece uma nova oportunidade de erro estrutural, sem acrescentar informação sobre o que o documento significa.

A hipótese de trabalho é que essa carga pode ser deslocada do componente probabilístico para um componente determinístico. Ao modelo cabe emitir apenas o conteúdo semântico, em uma representação intermediária compacta; a expansão para o formato verbossintático é feita por um transpilador que não erra sintaxe por construção. O ganho esperado é duplo e mensurável: **econômico**, pela redução do número de *tokens* gerados, e de **confiabilidade**, pela transferência da validade sintática do domínio estatístico para o domínio algorítmico.

A BPMN 2.0 é adotada como **caso de estudo** por reunir as propriedades que tornam o problema difícil e a avaliação possível: é um XML normativo com esquema oficial (permitindo verificação binária de validade), é hierárquico e verboso ao ponto de a marcação dominar o conteúdo, e possui uma semântica de grafo bem definida (permitindo comparação objetiva entre modelos). As conclusões que dependerem apenas dessas três propriedades, e não de particularidades da BPMN, são as candidatas naturais à generalização, e o texto sinaliza explicitamente quando é o caso.

Essa delimitação distingue o trabalho de investigações sobre *qual* representação de processo é a melhor para modelagem com LLMs, como a de Brissard, Cuppens e Zouaq (2025b), discutida no Capítulo 3. Aqui a pergunta não é qual notação produz o modelo de processo mais

fiel, e sim se a estratégia de comprimir a saída e expandi-la deterministicamente torna a geração de marcação verbosa economicamente viável em modelos pequenos. Sobreposição de artefatos com esses trabalhos é esperada e desejável, inclusive porque permite reaproveitar seus conjuntos de referência.

4.2 PRÉ-REGISTRO DO PROTOCOLO EXPERIMENTAL

Uma decisão metodológica antecede as demais e condiciona a leitura de todo o capítulo. Métricas de comparação entre modelos de processo admitem muitos graus de liberdade: o que conta como nó equivalente, como tratar *gateways*, qual referência usar quando há várias válidas. Escolher esses parâmetros *depois* de observar os resultados permitiria, ainda que involuntariamente, selecionar a configuração que favorece a hipótese defendida.

Para eliminar esse grau de liberdade, o protocolo de avaliação foi **integralmente especificado e congelado antes da primeira execução** dos braços experimentais, em documento versionado com *hash* de *commit* datado. O congelamento cobre: definição operacional de cada métrica, número de amostras por item, regra de agregação, testes estatísticos, contrastes planejados e critérios de aceitação do próprio *harness*. Hipóteses foram registradas com direção esperada, e ficou consignado que **resultado contrário às hipóteses é resultado publicável** e deve ser reportado como tal.

Qualquer alteração posterior é registrada como emenda datada, com o motivo e a indicação explícita de se ocorreu antes ou depois da observação dos resultados. Essa prática é incomum em trabalhos de conclusão de curso da área, e é adotada aqui por uma razão prática: as métricas propostas envolvem escolhas de projeto suficientes para que a ausência de pré-registro tornasse os resultados difíceis de defender.

4.3 VISÃO GERAL DO PROTOCOLO

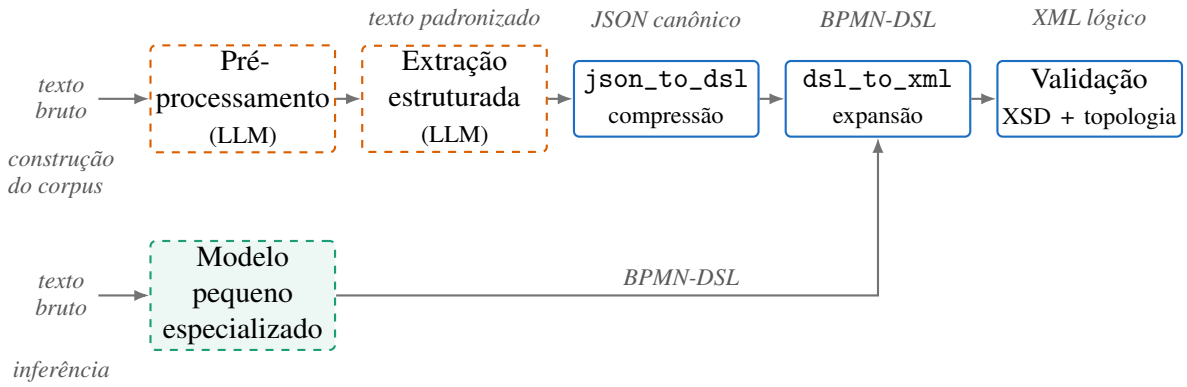
O protocolo separa a geração de um modelo BPMN 2.0 em uma etapa probabilística curta e uma etapa determinística verificável. Na fase de construção do conjunto de dados, o fluxo completo é:

1. **Pré-processamento**: a descrição textual bruta do processo é reestruturada por um LLM de fronteira em um formato padronizado em linguagem natural (atores, fluxo principal, decisões e paralelismos);
2. **Extração estruturada**: um segundo LLM de fronteira converte o texto padroni-

zado em um JSON canônico de BPMN, contendo elementos, fluxos de sequência e *gateways*, sem informação de leiaute;

3. **Compressão**: um conversor determinístico (*json_to_dsl*) lineariza o grafo do JSON na DSL proposta, com garantia formal de preservação topológica;
4. **Expansão**: um transpilador determinístico (*dsl_to_xml*) expande a DSL para XML BPMN 2.0 completo;
5. **Validação**: o XML é validado contra o XSD oficial da especificação BPMN 2.0 e comparado topologicamente com o JSON de origem.

Figura 1 – Protocolo de compressão semântica: construção do corpus e inferência



Fonte: Elaborado pelo autor

Nota: Borda tracejada indica etapa probabilística; borda sólida, etapa determinística. Na construção do corpus, dois modelos de fronteira produzem o JSON canônico do qual a DSL é derivada. Na inferência, o modelo especializado emite a DSL em uma única passagem, e a expansão e a validação são as mesmas nos dois fluxos: a sintaxe do documento final nunca depende do componente probabilístico.

Os pares (descrição textual, DSL) resultantes constituem o corpus de treino. Na fase de avaliação, um modelo de linguagem de pequeno porte especializado gera a DSL diretamente do texto, e as etapas 4 e 5 reconstituem e verificam o XML. O modelo probabilístico nunca é responsável pela sintaxe do documento final, apenas pelo conteúdo semântico da representação intermediária.

4.4 CONSTRUÇÃO DO CONJUNTO DE DADOS

4.4.1 Fontes e Curadoria

Não existe conjunto público em escala que associe descrições textuais de processos a modelos BPMN em formato de intercâmbio. A estratégia adotada foi coletar apenas o lado de entrada (descrições textuais) de fontes heterogêneas e sintetizar o lado de saída pelo pipeline da

Seção 4.3. As fontes utilizadas são apresentadas na Tabela 1.

Tabela 1 – Fontes do conjunto de dados e partições

Fonte	N	Partição	Papel
GitLab Handbook (seções curadas)	728	*sft*	treino supervisionado
GitLab Handbook (seções lineares)	172	*grpo*	etapa opcional de reforço
PET (BELLAN *et al.*, 2023)	44	*sft*	treino supervisionado
PMo (BRISSARD; CUPPENS; ZOUAQ, 2025a)	53	*holdout*	avaliação (nunca treino)
Zenodo (MANGLER; KLIEVTSOVA, 2023)	24	*holdout*	avaliação (nunca treino)

Fonte**:** Elaborado pelo autor

Nota**:** De 1.047 amostras coletadas, 26 foram excluídas por degradação identificada durante a validação topológica, resultando em 1.021 amostras ativas.

A principal fonte de volume é o *handbook* público da empresa GitLab, um manual operacional aberto com milhares de seções procedurais. As seções foram coletadas por *web scraping* e submetidas a uma curadoria automática que atribui um escore procedural (presença de passos, decisões e atores) e classifica cada seção em quatro categorias: *ideal* (passos, decisões e atores), *good* (passos e decisões ou atores), *linear* (apenas passos) e *marginal* (sem passos, descartada). Seções *ideal* e *good* compõem a partição de treino supervisionado; seções *linear*, por não exigirem estrutura de decisão, são reservadas como *prompts* para a etapa opcional de aprendizado por reforço.

4.4.2 Pré-processamento com LLM

Cada descrição bruta é reestruturada por um LLM de fronteira em um formato padronizado que explicita nome do processo, atores, fluxo principal numerado, decisões com os dois caminhos (sim/não) e ações paralelas. O *prompt* instrui o modelo a apenas reorganizar e limpar o texto, sem inventar informação, e a separar blocos independentes quando a descrição contém múltiplos processos. Essa etapa normaliza a variação estilística das fontes e aproxima o texto do vocabulário estrutural do BPMN sem ainda impor formato de máquina.

4.4.3 Seleção do Modelo Gerador

O modelo responsável pelos dois estágios de construção do corpus foi escolhido por experimento-piloto, e não por preferência. Três configurações candidatas foram executadas sobre uma amostra estratificada de 50 itens, e a seleção considerou taxa de conversão bem-sucedida até o XML válido, preservação topológica e custo. A configuração vencedora, o modelo *glm-5.2*

em ambos os estágios, está registrada em documento de decisão versionado.

Duas limitações desse procedimento merecem registro. Primeiro, o provedor utilizado não oferece *tags* datadas para os modelos empregados, apenas um apelido móvel; a data de acesso é registrada e o banco de dados do projeto é o registro autoritativo dos artefatos gerados, uma vez que a reexecução bit-idêntica não é garantida. Segundo, verificou-se empiricamente que temperatura zero **não** produz saídas determinísticas nesses modelos, pois execuções idênticas divergiram, o que motivou a adoção de múltiplas amostras por item na fase de avaliação (Seção 4.7.8).

4.4.4 Geração do JSON BPMN Canônico

O texto padronizado é convertido em um JSON canônico que descreve o processo como grafo: nós tipados (eventos de início e fim, tarefas por tipo, *gateways* exclusivos, paralelos e inclusivos), arestas de fluxo de sequência com condições, e raias de responsabilidade. O JSON não contém leiaute nem identificadores de serialização, apenas a estrutura lógica do processo. Esse artefato cumpre dois papéis: é a fonte da qual a DSL é derivada deterministicamente e é a referência contra a qual a equivalência topológica do XML final é verificada (Seção 4.7).

4.4.5 Idioma dos Artefatos

Todos os artefatos de máquina (rótulos do JSON canônico, da DSL e do XML gerado) são produzidos em **inglês**, enquanto esta monografia é redigida em português. A decisão foi tomada após se constatar que *prompts* redigidos em português, sem diretiva explícita de idioma, produziam corpus com rótulos em idioma inconsistente entre amostras. Como o modelo base escolhido é orientado a código e treinado predominantemente em inglês, e como a consistência de rótulos é pré-requisito para que a métrica de fidelidade topológica, que usa o rótulo como identidade de nó (Seção 4.7.2), não penalize diferenças meramente linguísticas, o corpus foi integralmente regenerado com diretiva de idioma explícita nos dois estágios.

Cabe registrar uma limitação assumida: o "gabarito"estrutural de cada amostra é a interpretação do processo feita por um LLM de fronteira, não uma anotação humana. Essa escolha é o que torna viável a escala do corpus, e seu risco é mitigado pela avaliação final contra o conjunto PMo, cujos modelos de referência são curados por especialistas.

4.4.6 Partições e Prevenção de Contaminação

As amostras são particionadas em *sft* (772), *grpo* (172) e *holdout* (77). Duas regras protegem a integridade da avaliação:

a) o conjunto PMo é exclusivamente de avaliação: nenhum artefato derivado dele participa de qualquer etapa de treino;
b) as 24 descrições da fonte Zenodo (MANGLER; KLIEVTSOVA, 2023) provêm da mesma origem dos itens 25–48 do PMo (com pré-processamento distinto). Para evitar contaminação indireta do *holdout*, isto é, treinar com versões alternativas dos mesmos processos usados na avaliação, essa fonte foi igualmente excluída do treino e alocada à partição *holdout*, onde suas múltiplas modelagens de referência com pontuação de especialistas apoiam a análise de ambiguidade.

4.5 A BPMN-DSL

A representação intermediária é uma DSL projetada neste trabalho, uma vez que não há linguagem consolidada para descrição textual compacta de BPMN. Seu desenho segue princípios explícitos: cada conceito BPMN tem exatamente uma forma sintática; o nome serve à legibilidade e o identificador, à referência, de modo que apenas elementos referenciados recebem o sufixo `#id` estável; raias são escopos que envolvem o fluxo (bloco `@lane`), eliminando a dupla declaração de atividades; ramos vazios de decisão são explícitos (`()`); e propriedades adicionais usam sintaxe única de pares chave-valor. A gramática é formalizada em EBNF e implementada com o *parser* Lark[1].

A DSL cobre os elementos essenciais da BPMN 2.0, a saber: eventos (com gatilhos de mensagem, temporizador, erro, sinal e escalonamento), oito tipos de tarefa, *gateways* exclusivos, paralelos, inclusivos e baseados em eventos, subprocessos, raias, *pools*, colaborações com fluxos de mensagem e anotações. A cada construção corresponde um elemento XML determinado. Conceitos avançados (eventos de borda, compensação, multi-instância) ficam explicitamente fora do escopo desta versão. O Código 1 ilustra um processo com decisão e repetição.

Código-fonte 1 – Exemplo de processo na BPMN-DSL: decisão exclusiva com laço de repetição via referência. Rótulos em inglês conforme a Seção 4.4.5

[1] <https://github.com/lark-parser/lark>

```
process "Order Processing with Retry" {
  start
  -> service "Fetch data" #fetch
  -> service "Validate"
  -> xor "Valid?" {
    ["yes"] -> service "Process" -> end
    ["no"]  -> xor "Retry?" {
                 ["yes"] -> #fetch
                 ["no"]  -> end:error "Invalid"
               }
  }
}
```

O exemplo evidencia a propriedade que motiva a DSL: o laço de repetição, que em XML BPMN exigiria a declaração de dois *gateways* com identificadores próprios e quatro elementos `sequenceFlow` referenciando-os cruzadamente, é expresso por uma única referência `#fetch`. A razão de compressão obtida empiricamente sobre o corpus é reportada no Capítulo 5.

4.6 TRANSPILAÇÃO DETERMINÍSTICA

4.6.1 JSON para DSL

O conversor *json_to_dsl* lineariza o grafo do JSON canônico em texto DSL. O componente central é o linearizador, que deve satisfazer um único invariante:

> Todo nó alcançável do grafo é emitido exatamente uma vez; qualquer reencontro posterior com um nó já emitido é serializado como referência (`#id`), nunca como nova emissão.

Esse invariante é o que garante que estruturas não estritamente aninhadas (caudas compartilhadas entre ramos, laços com arestas de retorno e convergências múltiplas) sejam representáveis sem duplicação de nós nem perda de lógica. A implementação final sustenta o invariante com três mecanismos: (i) um conjunto único de nós emitidos, compartilhado por referência em toda a travessia recursiva, de modo que cada ramo enxerga o que os demais já emitiram; (ii) detecção determinística de pontos de convergência por pós-dominador imediato, em substituição a heurísticas de busca de junção; e (iii) uma rede de segurança que, ao final da

travessia, compara o conjunto de nós alcançáveis a partir do início com o conjunto efetivamente emitido: qualquer diferença é emitida em um apêndice conectado por referências e sinalizada com um aviso rastreável, transformando qualquer perda silenciosa em falha visível.

O conversor foi desenvolvido iterativamente em dez versões, cada uma registrada em banco com estado, avisos e erros por amostra, o que permite auditar regressões entre versões. Da segunda versão em diante, toda execução cobriu o corpus inteiro. A versão final converte 100% das 1.021 amostras ativas com preservação topológica verificada.

O processo iterativo é, ele próprio, um resultado metodológico: duas classes de defeito só se tornaram visíveis porque a verificação topológica era executada em lote sobre todo o corpus, e não por inspeção amostral. A primeira foi a perda silenciosa de arestas de convergência em estruturas não estritamente aninhadas, que reduzia a equivalência exata sem produzir erro algum: o XML permanecia válido no esquema e apenas descrevia um processo diferente. A segunda foi a divisão implícita: nós não-*gateway* com mais de uma aresta de saída no JSON de origem, cuja semântica de bifurcação se perdia na linearização. A correção adotada normaliza esses casos inserindo um *gateway* sintético (exclusivo quando todas as arestas de saída portam condição, paralelo caso contrário), tornando explícito no grafo aquilo que estava implícito.

4.6.2 DSL para XML BPMN 2.0

O transpilador *dsl_to_xml* expande a DSL para o XML BPMN 2.0 explícito, sem reinterpretar o processo: cada conexão gera um `sequenceFlow`; blocos de *gateway* geram os nós de divisão e, quando há continuação, de convergência; escopos `@lane` materializam `laneSet`, `lane` e `flowNodeRef`; colaborações geram participantes e `messageFlow`. Um contexto global de alocação garante unicidade de identificadores em documentos com múltiplos processos. O XML resultante é validado com a biblioteca lxml contra o XSD oficial da OMG versionado no repositório; a validação por esquema é tratada como critério binário obrigatório de aceitação, e não como métrica.

4.6.3 Geração Determinística de Leiaute

O XML produzido pelo transpilador contém apenas a lógica do processo. Um documento BPMN sem a seção de *diagram interchange* é válido perante o esquema e íntegro do ponto de vista semântico, mas abre como tela em branco na maioria das ferramentas de modelagem: as coordenadas de cada forma são obrigatórias para a exibição, ainda que opcionais

para a validação. Um pós-processador independente supre essa lacuna.

O algoritmo segue a estrutura clássica de leiaute em camadas atribuída a Sugiyama, Tagawa e Toda (1981). Arestas de retorno são descartadas por busca em profundidade, tornando acíclico o grafo de fluxo; os nós recebem então uma camada pela regra do caminho mais longo a partir dos eventos iniciais, o que preserva a ordem de precedência no eixo horizontal; dentro de cada camada, os nós são distribuídos verticalmente respeitando a raia a que pertencem, com altura de raia calculada a partir do maior empilhamento simultâneo observado. As arestas são roteadas ortogonalmente entre as bordas das formas. O espaçamento é fixo e as dimensões seguem as convenções usuais da notação.

O gerador de leiaute é **determinístico**: a mesma entrada produz sempre as mesmas coordenadas. Duas propriedades decorrem disso e merecem registro.

A primeira é de **escopo de medição**. O leiaute é gerado por pós-processamento e nenhuma das abordagens comparadas exige que o modelo o produza; incluí-lo em qualquer métrica atribuiria à representação um custo que ela não impõe. Por isso o numerador da taxa de compressão é o XML lógico (Seção 4.7.4), a projeção de equivalência topológica ignora coordenadas, e a validação por esquema é indiferente a elas. **Nenhum resultado deste trabalho depende do leiaute**, e essa independência é garantida por construção, não por convenção: a rotina que remove a seção de diagrama antes de medir é a mesma em todos os eixos.

A segunda é de **comparabilidade visual**. Como referências e candidatos são posicionados pelo mesmo algoritmo, a partir do zero e sem intervenção manual, qualquer diferença observada entre dois diagramas é diferença de conteúdo, e não de estilo de desenho. É essa propriedade que sustenta a comparação qualitativa apresentada na Seção 5.6.8: ali, referência e candidato exibem estruturas visualmente próximas e rótulos distintos, e o leitor pode atribuir a divergência ao vocabulário porque o desenho não é variável livre.

4.7 PROTOCOLO DE AVALIAÇÃO

A avaliação é organizada em eixos independentes, para que se possa atribuir cada tipo de falha ao componente responsável.

4.7.1 Eixo 1: Validade Sintática

Todo XML produzido, seja na construção do corpus, seja na inferência do modelo, deve ser bem formado e válido contra o XSD BPMN 2.0. Para a saída do modelo especializado,

mede-se adicionalmente a taxa de DSL sintaticamente válida (aceita pela gramática Lark).

4.7.2 Eixo 2: Equivalência Topológica

A validade por esquema não garante que o XML represente o mesmo processo de origem: um documento pode ser impecável perante o XSD e descrever outro processo. O segundo eixo mede fidelidade estrutural pela métrica **DF-F1**, definida a seguir e usada tanto na verificação interna do corpus (contra o JSON de origem) quanto na avaliação final (contra os modelos de referência).

Definição

Cada processo é projetado no multiconjunto de pares ordenados (a,b) tais que a atividade a é **diretamente seguida** pela atividade b, percorrendo-se e descartando-se os *gateways* de roteamento. A identidade de um nó é o seu rótulo; eventos anônimos colapsam para uma categoria derivada do tipo (`<start>`, `<end>`), neutralizando os nomes padrão que o serializador atribui. Sendo $\mathscr{R}$ o multiconjunto da referência e $\mathscr{C}$ o do candidato, define-se

$$P = \frac{|\mathscr{R} \cap \mathscr{C}|}{|\mathscr{C}|}, \qquad R = \frac{|\mathscr{R} \cap \mathscr{C}|}{|\mathscr{R}|}, \qquad \text{DF-F1} = \frac{2\,P \cdot R}{P + R}, \tag{4.1}$$

com interseção sobre multiconjuntos, de modo que arestas repetidas contam com sua multiplicidade. Candidato vazio contra referência não vazia recebe precisão zero, e não um; documento que não é sequer bem formado recebe falha total em todas as métricas, jamais linha ausente.

Justificativa

Comparar dois XML BPMN por igualdade textual é inviável: identificadores, ordem de elementos, espaçamento e coordenadas diferem sempre, mesmo entre documentos semanticamente idênticos. A relação *directly-follows* é a abstração canônica de mineração de processos: é sobre ela que se constrói o algoritmo α (AALST; WEIJTERS; MARUSTER, 2004) e o grafo que alimenta os mineradores subsequentes (AALST, 2016). Descartar os *gateways* é deliberado: um *gateway* é roteamento, não trabalho, e dois modelos que codifiquem a mesma decisão com estilos diferentes de bifurcação não devem ser penalizados por isso. O que a métrica mede é a **ordem do trabalho**, não a escolha de codificação.

Proveniência e delimitação

A métrica não é original deste trabalho, e é importante não apresentá-la como tal. Medir similaridade entre modelos de processo por pares de tarefas adjacentes tem precedente direto na similaridade por *transition adjacency relations* (ZHA *et al.*, 2010), e abordagens correlatas incluem perfis comportamentais (WEIDLICH; MENDLING; WESKE, 2011) e distância de edição de grafos (DIJKMAN *et al.*, 2011). A contribuição aqui é de **operacionalização**: projeção estrutural sobre BPMN com descarte de *gateways*, agregação por F1 sobre multiconjuntos e regra de máximo sobre múltiplas referências.

Dessa operacionalização decorre uma limitação que precisa ser declarada. A projeção adotada é **estrutural**, ao passo que Zha *et al.* (2010) e Weidlich, Mendling e Weske (2011) derivam suas relações do **comportamento** do modelo. A diferença é observável em blocos paralelos: em $A \rightarrow \{B,C\} \rightarrow D$ com bifurcação paralela, as execuções admitem B e C em qualquer ordem, e uma métrica comportamental registraria os pares (B,C) e (C,B); a projeção estrutural aqui empregada não os registra. A escolha é intencional: dispensa conversão para rede de Petri sã, é determinística e de custo linear, e mede se o candidato reproduziu a estrutura que a referência especifica, sem premiar intercalações equivalentes. Implica, contudo, que os valores reportados não são diretamente comparáveis a números publicados sob formulação comportamental.

4.7.3 Eixo 3: Fluxos de Mensagem

Fluxos de mensagem entre participantes (`messageFlow`) são comunicação, não ordem de execução. Fundi-los à relação *directly-follows* produziria casamento espúrio, com uma mensagem no candidato satisfazendo uma sequência na referência. São, por isso, medidos por uma métrica separada, **MF-F1**, de formulação idêntica à do Eixo 2 aplicada ao multiconjunto de pares (origem, destino) dos fluxos de mensagem, e **reportada ao lado, nunca somada** ao DF-F1.

A separação também torna visível uma assimetria real entre as abordagens comparadas: embora a DSL e o transpilador suportem fluxos de mensagem, nenhuma das 1.021 amostras do corpus os contém, de modo que contá-los no DF-F1 conferiria vantagem estrutural às configurações que emitem XML diretamente. Nos modelos de referência a construção aparece em 2 dos 53 itens de avaliação. Um candidato que omita todas as mensagens preserva DF-F1 igual a 1 e obtém MF-F1 igual a 0, perda que, sem a separação, seria invisível.

4.7.4 Eixo 4: Compressão

A razão de compressão de *tokens* (TCR) é definida como

$$\mathrm{TCR} = \frac{\mathrm{tokens}(\text{XML BPMN lógico})}{\mathrm{tokens}(\mathrm{DSL})}, \tag{4.2}$$

medida com o tokenizador do modelo pequeno especializado, fixado no protocolo. O numerador é o XML **lógico**, sem a seção de diagrama (BPMNDI), por definição normativa, e não por conveniência: a informação de leiaute é gerada deterministicamente por pós-processamento e nenhuma das abordagens comparadas exige que o modelo a produza. Incluí-la no numerador inflaria artificialmente o ganho atribuído à DSL, e por isso o XML com leiaute nunca é materializado na mesma coluna do XML lógico no banco de dados, eliminando a possibilidade de medição contra o artefato errado.

4.7.5 Referências Múltiplas e Ambiguidade de Modelagem

Uma mesma descrição textual admite múltiplas modelagens corretas (AA *et al.*, 2018), e tratar uma delas como única verdade penalizaria candidatos legítimos. A porção do *holdout* derivada de Mangler e Klievtsova (2023) oferece, para 24 dos 53 itens de avaliação, vários modelos por descrição, cada um com nota de especialista de 0 a 5.

A regra congelada é: pontuar o candidato contra **todas** as referências admitidas e reter o **máximo**. São admitidas a referência primária do PMo, que é o gabarito do próprio conjunto de avaliação, e as alternativas do Zenodo com nota maior ou igual a 4. A regra mede a alegação correta, a de que o candidato equivale a ao menos uma modelagem que um especialista aprovou, e descarta as variantes reprovadas. Entre as alternativas, aquelas sem nota atribuída ficam fora por ausência de evidência de aprovação, assim como as que não produzam nenhuma aresta, por serem degeneradas. O número de referências admitidas por item é reportado junto aos resultados: a ambiguidade de modelagem é achado, não ruído.

4.7.6 Desenho dos Braços Experimentais

O desenho é fatorial, cruzando **modelo** e **formato de saída** sobre os mesmos 53 itens de avaliação, com comparação pareada por item, e acrescenta a esse cruzamento um braço de controle (Tabela 2).

Tabela 2 – Braços experimentais

ID	Modelo	Saída	*Prompt*	Papel
A1	LLM de fronteira independente	XML	notação XML	*baseline* externo
A2	LLM de fronteira independente	DSL	gramática	isola o efeito da DSL
A1g	LLM gerador do corpus	XML	notação XML	leitura de destilação
A2g	LLM gerador do corpus	DSL	gramática	teto do método
A3	Modelo pequeno base	DSL	gramática	piso do modelo pequeno
A3m	Modelo pequeno base	DSL	mínimo	controle do A4
A4	Modelo pequeno especializado	DSL	mínimo	**a proposta**

Fonte**:** Elaborado pelo autor

Nota**:** A coluna *Prompt* indica o que o contexto informa sobre a notação pedida: um exemplo em XML, a gramática completa da DSL, ou instrução mínima sem gramática. A3m e A4 recebem o mesmo *prompt* e diferem apenas pela presença do adaptador treinado.

A coluna *Prompt* registra uma dimensão que não entra no cruzamento fatorial: o quanto o contexto informa sobre a notação a ser emitida. São três *prompts* congelados: um para o formato XML, um para a DSL com a gramática completa e um **mínimo**, sem gramática nem exemplo de notação, que é deliberadamente o mesmo *prompt* usado no treinamento do modelo especializado, para que a inferência do braço A4 ocorra na distribuição em que ele foi treinado. Medido com o tokenizador do modelo base, o *prompt* mínimo ocupa 753 *tokens*, contra 1.351 do que carrega a gramática.

A equidade entre os formatos é condição para que o contraste A2 contra A1 meça a representação, e não a redação da instrução. Ela é garantida por construção e travada por teste automatizado: os blocos de papel, idioma, regras de modelagem e contrato de saída são **idênticos byte a byte** nos três *prompts*, de modo que a única diferença admitida é o formato pedido. Os exemplos de notação que acompanham o *prompt* de XML e o da DSL foram, ainda, verificados como descrições do **mesmo processo**: transpilado o exemplo da DSL, a comparação topológica com o exemplo em XML resulta em DF-F1 igual a 1. Nenhum braço recebe, assim, um padrão de modelagem que o outro não recebeu.

O braço A3m existe por causa dessa assimetria de instrução, e foi acrescentado antes do congelamento do protocolo. Sem ele, o contraste entre o modelo especializado e o modelo pequeno sem especialização variaria duas coisas ao mesmo tempo: os pesos e a instrução recebida. A3m mantém o modelo e o *prompt* do A4 e retira apenas o adaptador, de sorte que A4 contra A3m isola o efeito do ajuste supervisionado, ao passo que A4 contra A3 mede a intervenção inteira, isto é, os pesos somados à dispensa da gramática. Ambos os contrastes são exploratórios e nenhum deles integra o conjunto submetido a correção de múltiplas comparações (Seção 4.7.7).

Cabe explicitar um ponto de leitura: os braços A2 e A2g **não são abordagens concorrentes**, e sim o método proposto executado com um modelo de alto custo, o teto que A4 procura alcançar por muito menos. O único *baseline* externo é A1/A1g, que representa a prática corrente de gerar o XML diretamente. Os contrastes planejados decorrem dessa estrutura: A2 contra A1 mantém o modelo fixo e varia apenas o formato, separando o efeito da representação do efeito da capacidade do modelo; A2g contra A1g replica o contraste com outro modelo, de modo que um efeito que apareça em um e não no outro seja atribuível ao modelo e não à DSL; e A4 contra A2 responde se a especialização de um modelo pequeno alcança o modelo de fronteira. Sem o par A2/A1, um bom resultado de A4 seria ambíguo entre o mérito da DSL e o do ajuste supervisionado.

O emprego de dois modelos de fronteira é deliberado. Como um deles gerou o corpus de treino, utilizá-lo como *baseline* único tornaria A4 uma destilação sua, leitura legítima, porém que confunde "a DSL ajuda"com "o aluno imita o professor". O segundo modelo é independente do corpus e fornece o *baseline* limpo, enquanto o primeiro permanece para que a leitura de destilação seja reportável.

4.7.7 Hipóteses

As hipóteses foram registradas com direção esperada antes da primeira execução de qualquer braço, e são reproduzidas na Tabela 3 na forma em que foram congeladas. Todas são enunciadas como contraste entre dois braços da Tabela 2, de modo que cada desfecho seja decidido por comparação pareada sobre os mesmos 53 itens, e não por apreciação do conjunto dos resultados.

Tabela 3 – Hipóteses pré-registradas

Hipótese	Enunciado	Papel no desenho
H1	A2 $\geq$ A1 em DF-F1	primária
H1g	A2g $\geq$ A1g em DF-F1	replicação interna
H2	A2 $>$ A1 em XSD-Val	validade por construção
H3	A4 $\geq$ A2 em DF-F1	viabilidade do modelo pequeno
H4	TCR ≥ 2 nos braços de DSL	descritiva

Fonte**:** Elaborado pelo autor

Nota**:** Apenas H1, H1g e H3 correspondem aos três contrastes submetidos a teste estatístico e a correção de múltiplas comparações (Seção 4.7.8). H2 compara taxas de validade e H4 verifica magnitude de compressão; ambas são reportadas descritivamente.

H1 é a hipótese primária: mantido o modelo fixo, emitir a DSL não perde fidelidade

estrutural frente a emitir XML diretamente. **H1g** repete o contraste com o outro modelo de fronteira e cumpre a função de replicação interna descrita na Seção 4.7.6: um efeito que apareça em apenas um dos dois pares é atribuível ao modelo, e não ao formato.

H2 atribui ao componente determinístico o ganho de confiabilidade: a transpilação garante validade perante o esquema que a geração direta não garante. Registre-se que o enunciado toma como cumprida a etapa que o antecede, a aceitação da DSL pela gramática, de modo que a taxa observada incide sobre a conjunção das duas.

H3 é a pergunta que motiva o trabalho: se o modelo pequeno especializado alcança o modelo de fronteira operado por *prompt*, a custo muito menor. A forma $\geq$ a constitui como alegação de **não inferioridade**, e disso decorre uma regra de leitura fixada aqui, antes dos dados: um empate estatístico não a refuta, mas tampouco a demonstra, porque quem responde não inferioridade é o intervalo de confiança, e não a ausência de significância.

H4 é descritiva, e seu limiar foi fixado como piso, não como expectativa: a medição sobre o corpus de construção já indicava razão próxima de seis (Seção 5.4), de sorte que a hipótese verifica se a compressão se sustenta sobre as saídas efetivamente geradas pelos braços. Nos braços de XML direto não há representação intermediária e a razão não é definida, e reportá-la como 1,0 apresentaria uma tautologia como resultado.

Os desfechos são reportados na Seção 5.6.2. Nenhum dos enunciados acima foi alterado após a primeira execução.

4.7.8 Parâmetros Congelados e Análise Estatística

A temperatura é fixada em zero para reduzir variância, sem que se alegue determinismo, pois o oposto foi verificado empiricamente (Seção 4.4.3). Em consequência, cada item é gerado $k = 3$ vezes e a **unidade de análise é a mediana por item**; adota-se a mediana, e não a média, porque saídas ocasionalmente degeneradas deslocariam a média de forma desproporcional. A dispersão entre as três execuções é reportada, por constituir a evidência empírica do não determinismo.

Os limites de *tokens* são deliberadamente distintos por braço, calibrados por medição prévia sobre o *holdout*: os braços que emitem XML recebem teto substancialmente maior que os que emitem DSL, porque um teto único estrangularia o *baseline* que o trabalho pretende superar. O orçamento equalizado entre braços é o **modelo**, não o teto de saída. Truncamento é registrado por amostra e reportado separadamente de erro de modelo. Não há reexecução em caso de falha

de análise sintática no número principal: a taxa de falha é resultado, não obstáculo a contornar.

Os três braços executados com o modelo pequeno (A3, A3m e A4) usam configuração de inferência **idêntica**: pesos quantizados em 4 *bits* no formato NF4 com dupla quantização, tipo de computação em ponto flutuante de 16 *bits* e implementação de atenção *scaled dot-product*. A escolha do tipo de computação e da implementação de atenção é imposta pelo hardware: a arquitetura Turing da GPU utilizada precede o suporte nativo a *bfloat16*, e as versões correntes de FlashAttention-2 não a contemplam. A identidade de configuração entre os três é o que preserva a interpretação dos contrastes entre eles: quantizações distintas fariam a comparação medir precisão numérica somada ao efeito da especialização.

Registre-se que a quantização de **treino** e a de **inferência** são parâmetros independentes, e que a restrição de memória que motiva a primeira não se aplica à segunda no cenário adotado, uma vez que o ajuste supervisionado é executado em infraestrutura de nuvem e apenas a inferência ocorre na estação local.

A comparação estatística usa teste de Wilcoxon pareado por postos com sinal, ao nível de 5%, sobre a métrica primária, restrito aos três contrastes planejados (A2 contra A1, A2g contra A1g e A4 contra A2, correspondentes a H1, H1g e H3, conforme a Seção 4.7.7) e com correção de Holm sobre eles; qualquer outro par é exploratório e reportado como tal. O teste é **bilateral**, ainda que as hipóteses sejam direcionais: a alegação a responder é de não inferioridade, e quem a responde é o intervalo de confiança, não a lateralidade do teste; bilateral é a escolha conservadora e afasta a suspeita de que a direção tenha sido decidida depois de vistos os dados. Diferenças exatamente nulas são descartadas do teste, e o número de empates é reportado junto de cada contraste. Intervalos de confiança de 95% são obtidos por *bootstrap* pareado com 10.000 reamostragens. Como o conjunto de avaliação tem 53 itens, reportam-se tamanho de efeito e intervalo de confiança, e não apenas o valor-p.

4.8 ESPECIALIZAÇÃO DO MODELO

4.8.1 Ajuste Supervisionado

O modelo base é o Qwen2.5-Coder-7B-Instruct (HUI *et al.*, 2024), um modelo aberto de 7 bilhões de parâmetros orientado a código, sob licença Apache 2.0, perfil adequado a uma tarefa de emissão de linguagem formal. Adota-se a variante ajustada para instrução, e não a base pura, por uma razão de honestidade experimental: o braço A3 mede o desempenho do modelo pequeno *sem* a especialização proposta, e um modelo base, que não segue instruções de

forma confiável, produziria um piso artificialmente baixo, inflando o ganho atribuído ao ajuste supervisionado. Pelo mesmo motivo, A3 e A4 partem exatamente do mesmo ponto, de modo que a diferença entre eles seja o adaptador treinado, e não o modelo de origem.

A especialização usa ajuste supervisionado com adaptação de baixo posto (LoRA) (HU *et al.*, 2022) sobre pesos quantizados em 4 *bits* (QLoRA) (DETTMERS *et al.*, 2023), viabilizando a inferência local na fase exploratória, com o treinamento final executado em infraestrutura de nuvem. Os exemplos de treino são os pares (descrição textual bruta, DSL) da partição *sft* com equivalência topológica exata verificada pelo Eixo 2. O texto de entrada é a descrição original, e não o texto pré-processado, de modo que o modelo especializado absorva também a etapa de estruturação e o sistema final dependa de uma única inferência.

O comprimento de sequência foi fixado por medição, e não por convenção. Tokenizando os 768 pares com o tokenizador do modelo base, o exemplo mediano ocupa **1.615 *tokens***, dos quais 753 vêm do *prompt* fixo e o restante se reparte entre a descrição textual e a DSL de destino, com percentil 90 em 2.753 e máximo em 13.112. O valor de 1.024 *tokens*, usual em ajuste de modelos desse porte e inicialmente previsto, truncaria **757 dos 768 exemplos**. Como o truncamento incide sobre o final da sequência, ele removeria precisamente o alvo a ser aprendido, e o efeito esperado seria degradação da validade sintática, isto é, exatamente o sintoma que o ajuste se propõe a corrigir, atribuído por engano ao método. Adota-se **4.096 *tokens***, que preserva 98% dos exemplos íntegros; os 18 que excedem esse limite são **descartados**, e não truncados. A distinção é consequência do próprio argumento anterior: truncá-los cortaria o alvo pelo fim e ensinaria ao modelo DSL sintaticamente incompleta, que é precisamente o defeito que a escolha do comprimento pretende evitar.

Dos 768 pares, **78 são reservados para validação** e 690 para treino, dos quais restam **672** após o descarte acima. A reserva é feita **por documento de origem**, e não por exemplo: como um único *handbook* corporativo responde por quase todo o corpus (Seção 5.1), um corte aleatório deixaria seções do mesmo documento nos dois lados, e a validação passaria a medir memorização. Esse conjunto é o critério de parada, uma vez que, em corpus pequeno, a perda de treino não indica o ponto em que o sobreajuste começa.

Os demais hiperparâmetros são: adaptador de posto 16 com fator de escala 32, aplicado a todas as camadas lineares, com *dropout* de 0,05; taxa de aprendizado de 1×10^{-4} com decaimento por cosseno e aquecimento de 3% dos passos; otimizador AdamW de 8 *bits* paginado; três épocas; lote efetivo de oito sequências por passo; *checkpointing* de gradiente; e semente fixada em 42. O orçamento resultante é de **1,17 milhão de *tokens* por época**.

4.8.2 Etapa Opcional: Aprendizado por Reforço com Recompensa Verificável

Como extensão opcional ao escopo deste trabalho, prevê-se uma etapa de *Group Relative Policy Optimization* (SHAO *et al.*, 2024) sobre o modelo ajustado, usando como *prompts* as seções da partição *grpo* e as amostras sem equivalência exata (que não exigem DSL de referência). A recompensa composta é definida como

$$r \;=\; 0{,}35\, r_{\text{sint}} \;+\; 0{,}30\, r_{\text{sem}} \;+\; 0{,}25\, r_{\text{topo}} \;+\; 0{,}10\, r_{\text{comp}}, \tag{4.3}$$

em que r_{sint} (validade da DSL e do XML), r_{topo} (coerência topológica) e r_{comp} (economia de tokens) são integralmente verificáveis por código, enquanto r_{sem} (adequação semântica ao texto) requer sinal aproximado e é o componente metodologicamente mais frágil.

Revisão do desenho da recompensa

A medição do teto humano da métrica de fidelidade (Seção 5.6.10) impõe uma revisão a esta formulação, registrada aqui por afetar o desenho e não apenas a execução. O componente r_{topo} recompensa a concordância com um modelo de referência; uma vez estabelecido que os artefatos produzidos pelo trabalho já **superam** a concordância que duas referências de especialista exibem entre si, otimizar esse termo deixa de significar "aproximar-se do modelo correto" e passa a significar "aproximar-se das escolhas idiossincráticas de um modelador específico". Como todas as referências disponíveis pertencem à partição *holdout*, tal otimização constituiria ainda contaminação do conjunto de avaliação.

Prevê-se, portanto, que a etapa, caso venha a ser executada, use recompensa restrita aos componentes **verificáveis sem referência**:

$$r' \;=\; 0{,}80\, r_{\text{sint}} \;+\; 0{,}20\, r_{\text{comp}}. \tag{4.4}$$

A restrição tem três justificativas convergentes. A primeira é de **validade**: r_{sint} e r_{comp} são calculáveis por chamada ao *parser* e ao tokenizador, sem qualquer modelo de referência, e portanto não podem contaminar a avaliação. A segunda é de **alvo**: a validade sintática é o eixo em que os resultados da Seção 5.6 identificam folga substancial (64,8% no braço A2 contra 98,1% no A1), ao passo que a fidelidade topológica encontra-se saturada. A

terceira é de **custo**: uma recompensa que dispensa referência dispensa também dado anotado, tornando a etapa viável sem ampliação do corpus.

Degenerescência da recompensa restrita

A formulação r' acima, contudo, é **explorável**, e registra-se a objeção por ser decisiva quanto à viabilidade da etapa. Sob r', a política ótima consiste em emitir a menor DSL sintaticamente válida possível, um processo contendo apenas evento inicial e final, o que maximiza simultaneamente r_{sint} e r_{comp} enquanto descreve processo algum. Ao remover r_{topo} para evitar contaminação do conjunto de avaliação, elimina-se o único termo que penalizava conteúdo incorreto, e o desenho passa a premiar a degenerescência que pretende evitar.

O reparo exige um termo de ancoragem **calculável sem referência**. A Seção 5.6.11 fornece um candidato: a proporção de palavras do rótulo presentes no texto de origem, medida entre 69,6% e 76,1% em todas as origens avaliadas, inclusive nas referências de especialista. Um termo dessa natureza penaliza saída degenerada, que não cobre o texto, sem consultar modelo de referência algum. Sua calibração, entretanto, constitui contribuição autônoma e não trivial, e não uma configuração a ser ajustada em poucas horas.

Posição no cronograma

Conjugadas, as duas observações desta seção reposicionam a etapa. O resultado do braço A4 (Seção 5.6.4) reduziu a folga para a validade plena, garantida pela cadeia determinística, de 41,5 pontos percentuais no braço A3 para 13,2 no A4, de modo que o retorno esperado do aprendizado por reforço é hoje substancialmente menor do que se antecipava; e a recompensa aplicável requer redesenho com validação própria. Mantém-se, portanto, a classificação original de **trabalho futuro**, agora por razão substantiva e não apenas por cronograma.

4.9 INFRAESTRUTURA E REPRODUTIBILIDADE

Todo o pipeline é implementado em Python 3.12, com dependências gerenciadas por *uv*, testes automatizados com *pytest* e análise estática com *ruff*. Os artefatos de todas as etapas (texto bruto, texto pré-processado, JSON canônico, DSL, XML e métricas de avaliação) são persistidos em um banco SQLite único, com cada execução de conversor registrada com número de versão, estado e diagnósticos, o que permite auditar e reproduzir qualquer resultado intermediário. A fase exploratória utiliza uma estação com GPU NVIDIA RTX 2080 Ti (11 GB),

e o treinamento final, aceleradores de nuvem. Ao término do trabalho, o conjunto de dados e o modelo especializado serão disponibilizados publicamente na plataforma Hugging Face, juntamente com o código-fonte do protocolo.

Registra-se um detalhe de reprodução que não é evidente e cuja omissão inviabiliza a etapa de treinamento: a resolução automática de dependências instala a compilação de *PyTorch* correspondente à versão mais recente de CUDA, que não opera com *drivers* anteriores e torna o acelerador invisível ao *framework*. É necessário fixar explicitamente a compilação compatível com o *driver* da máquina utilizada. O sintoma é silencioso: nenhuma etapa falha e o treinamento simplesmente não encontra a GPU, enquanto a máquina alugada é cobrada por hora.

5 RESULTADOS

Este capítulo reporta os resultados em duas partes de natureza distinta. A primeira é a **verificação do protocolo determinístico** sobre o corpus completo (Seções 5.1 a 5.5): trata-se de comportamento de *software*, e os valores próximos de 100% ali apresentados são esperados por construção, servindo para confirmar que o transpilador cumpre a garantia que lhe é atribuída. A segunda é a **avaliação comparativa dos braços experimentais** (Seção 5.6), na qual as hipóteses do trabalho são efetivamente testadas contra modelos de referência produzidos por especialistas.

A distinção é essencial para a leitura: os dois conjuntos de números **não são comparáveis entre si**. Um DF-F1 de 0,9999 na primeira parte mede a fidelidade de uma conversão determinística entre representações do mesmo processo; um DF-F1 de 0,19 na segunda mede o quanto um modelo de linguagem, partindo apenas de texto em prosa, reconstrói um processo modelado independentemente por um especialista. São tarefas de dificuldade incomparável, e confundi-las levaria a conclusão inteiramente equivocada.

Todos os valores são recuperáveis do banco de dados do projeto, no qual cada execução é registrada com versão, estado e diagnósticos por amostra.

5.1 COMPOSIÇÃO DO CORPUS

Foram coletadas 1.047 amostras, das quais 26 foram excluídas por degradação identificada durante a validação, resultando em **1.021 amostras ativas**. A distribuição por partição é apresentada na Tabela 4.

Tabela 4 – Distribuição do corpus por partição

Partição	N	Uso
sft	772	treino supervisionado
grpo	172	etapa opcional de reforço
holdout	77	avaliação exclusivamente
Total	1.021	

Fonte**:** Elaborado pelo autor

Nota**:** A partição *holdout* agrega os 53 itens do PMo e as 24 descrições da fonte Zenodo, esta última excluída do treino por compartilhar origem com parte do PMo.

Registra-se uma ameaça à validade externa: 900 das 944 amostras de treino (95,3%) provêm de uma única fonte, o *handbook* da GitLab. O modelo especializado é, portanto, treinado

predominantemente sobre o estilo redacional de uma única organização e avaliado contra o PMo, de domínio distinto. Essa assimetria é reconhecida como limitação, e a consequência prática é que aumento de volume só reduz o risco se vier de **fontes novas**, não de mais seções do mesmo *handbook*.

5.2 EIXO 1: VALIDADE SINTÁTICA

As 1.021 amostras ativas produzem DSL aceita pela gramática e XML válido contra o XSD oficial da BPMN 2.0: **1.021/1.021 (100%)** em ambos os critérios. O resultado é esperado por construção — a validade sintática do XML final é responsabilidade do transpilador determinístico, não do modelo probabilístico — e sua função aqui é confirmar que o transpilador cumpre a garantia que o protocolo lhe atribui.

O valor desse número está no contraste que ele permite: nos braços que geram XML diretamente, a validade passa a ser uma variável aleatória dependente do modelo, e a diferença entre 100% garantido e a taxa observada é precisamente o que a hipótese H2 afirma.

5.3 EIXO 2: FIDELIDADE TOPOLÓGICA

Sobre a base ativa, a comparação entre o JSON canônico de origem e o XML reconstituído pela cadeia DSL apresenta **1.017 de 1.021 amostras (99,6%) com equivalência exata de arestas** e DF-F1 médio de **0,9999** (mínimo observado 0,9545). A contagem de nós por categoria coincide em **1.021/1.021 (100%)** das amostras.

Por partição: *sft* 768/772, *grpo* 172/172 e *holdout* 77/77 com equivalência exata. O subconjunto de 768 pares da partição *sft* com equivalência exata constitui o conjunto de treino supervisionado de alta confiança.

5.3.1 Trajetória entre Versões

O desenvolvimento iterativo do linearizador foi verificado executando-se a comparação topológica sobre o corpus **inteiro** a cada versão, e não por inspeção amostral. A Tabela 5 apresenta a trajetória.

Dois achados metodológicos emergem da tabela. O primeiro é o salto de v7 para v8, que corrigiu a perda silenciosa de arestas de convergência em estruturas não estritamente aninhadas: 891 para 1.015 amostras exatas, com as 127 amostras que perdiam arestas indo a

Tabela 5 – Fidelidade topológica por versão do conversor

Versão (DSL / XML)	Idioma	Exatas	DF-F1	Com arestas perdidas
v7 / v3	pt	891	0,9939	127
v8 / v3	pt	1.015	0,9999	0
v8 / v3	en	998	0,9970	20
v9 / v3	en	1.015	0,9998	1
v10 / v4	en	1.016	0,9998	1
v10 / v5	**en**	**1.017**	**0,9999**	**0**

Fonte**:** Elaborado pelo autor

Nota**:** N = 1.021 em todas as versões. "Com arestas perdidas"conta amostras em que ao menos uma aresta da referência não aparece no candidato.

zero. Essa classe de defeito é particularmente perigosa porque não produz erro observável — o XML permanece válido no esquema e apenas descreve um processo diferente.

O segundo é a **regressão introduzida pela regeneração em inglês**: a versão v8 aplicada ao corpus regenerado voltou a apresentar 20 amostras com arestas perdidas, apesar de a mesma versão do conversor ter atingido zero na base anterior. O conteúdo novo expôs defeitos latentes que o corpus antigo não exercitava — notadamente a divisão implícita descrita na Seção 4.6.1. As versões v9 e v10 eliminaram a regressão. O episódio sustenta uma escolha metodológica do trabalho: verificação sobre o corpus completo a cada versão, com resultado persistido, é o que torna regressões detectáveis; amostragem manual não as teria revelado.

5.3.2 Análise do Resíduo

As quatro amostras sem equivalência exata na base ativa compartilham uma propriedade relevante: em todas, o conjunto de arestas ausentes é **vazio**. O resíduo consiste exclusivamente em arestas *excedentes* — uma ou duas por amostra — e não em lógica perdida. Em termos práticos, a cadeia determinística nunca descarta uma relação de precedência presente no processo de origem; nos quatro casos remanescentes, ela introduz uma relação adicional decorrente da serialização de convergências. Sendo a preservação da lógica do processo o objetivo do componente determinístico, essa assimetria do erro é favorável: o modo de falha residual é conservador.

5.4 EIXO 4: COMPRESSÃO DE *TOKENS*

Medida com o tokenizador do modelo base sobre as 1.021 amostras, a razão de compressão é de **6,01** (IC95% [5,96; 6,06], mediana 5,99), correspondente a uma **redução de**

83,4% no número de *tokens* que o modelo precisa emitir em relação ao XML BPMN lógico equivalente.

Cabe explicitar o que o número **não** é. O denominador é o XML lógico, sem a seção de diagrama. Medindo-se contra o XML com informação de leiaute, a razão triplicaria — e seria um artefato de medição, já que o leiaute é gerado deterministicamente por pós-processamento e nenhuma das abordagens comparadas exige que o modelo o produza. Essa distinção é registrada aqui porque uma medição preliminar contra o artefato errado chegou a indicar cerca de 91% de redução, valor que foi descartado ao se identificar a inconsistência; a definição normativa da métrica foi então fixada no protocolo, e o XML com leiaute deixou de ser materializado na mesma coluna do XML lógico no banco, tornando o erro irreproduzível.

Registra-se ainda que a meta de projeto inicialmente estipulada era de 85% de redução, e o valor medido (83,4%) ficou abaixo dela. Como a meta havia sido fixada antes de qualquer medição e sem base empírica, e como o protocolo de avaliação foi congelado com a definição normativa da métrica, opta-se por reportar o valor obtido e registrar a divergência, em vez de reajustar a meta *a posteriori*.

5.5 CONJUNTO DE REFERÊNCIA

O conjunto de avaliação reúne **53 modelos de referência primários** do PMo, um por item, e **172 referências alternativas** da fonte Zenodo distribuídas sobre 24 desses itens (de 4 a 11 por item), admitidas segundo a regra de nota mínima da Seção 4.7.5.

A curadoria descartou referências por dois motivos declarados: um modelo sem nota de especialista atribuída, por ausência de evidência de aprovação, e três modelos que, apesar de nota suficiente, não produzem nenhuma aresta na projeção adotada — referência degenerada não serve de referência. O mapeamento entre as duas fontes é verificado como bijeção no momento da carga, falhando explicitamente caso a propriedade não se sustente, em vez de gravar correspondência parcial.

5.6 AVALIAÇÃO COMPARATIVA DOS BRAÇOS

Esta seção reporta a execução completa dos braços experimentais definidos na Seção 4.7.6: **1.113 gerações** (7 braços $\times$ 53 itens $\times$ 3 repetições), sem qualquer erro de geração.

Antecipa-se o desfecho, para que a leitura das subseções seguintes seja feita com ele em mente. **As hipóteses H1, H1g e H2 foram refutadas** com significância estatística nas duas

famílias de modelos: gerar XML diretamente superou gerar a DSL por *prompting*. **A hipótese H3 não foi refutada nem demonstrada** — o modelo especializado empata estatisticamente com o modelo de fronteira que recebe a gramática no *prompt*. **A hipótese H4 foi confirmada com folga.**

O achado de maior magnitude, contudo, não corresponde a nenhuma hipótese pré-registrada e emerge do eixo de validade sintática: o modelo de 7 bilhões de parâmetros com ajuste fino produz DSL válida em **86,8%** das gerações, contra **64,8%** do modelo de fronteira instruído pela gramática. Esse resultado é examinado na Seção 5.6.4.

O pré-registro (Seção 4.2) existe precisamente para que o parágrafo acima pudesse ser escrito na ordem em que foi escrito.

5.6.1 Resultados Descritivos por Braço

A Tabela 6 apresenta o panorama. Duas convenções de leitura são necessárias. Primeiro, a validade XSD é reportada **por geração** (sobre 159), enquanto a coluna de itens conta quantos dos 53 obtiveram ao menos uma geração válida — a distinção importa porque um item pode alternar entre válido e inválido nas três repetições. Segundo, o DF-F1 reportado é a **média das medianas por item**, conforme a unidade de análise fixada na Seção 4.7.8.

Tabela 6 – Panorama dos braços executados

Braço	Saída	XSD	Itens	DF-F1	Máx.	*Tokens*
A1 (DeepSeek)	XML	**98,1%**	53/53	**0,1942**	0,571	631
A1g (GLM)	XML	94,3%	53/53	0,1551	0,593	699
A4 (Qwen 7B + SFT)	DSL	**86,8%**	**46/53**	0,1114	0,395	200
A2 (DeepSeek)	DSL	64,8%	40/53	0,1375	0,714	**138**
A3 (Qwen 7B)	DSL	58,5%	31/53	0,0666	0,333	159
A2g (GLM)	DSL	56,6%	41/53	0,0783	0,387	149
A3m (Qwen 7B)	DSL	0,0%	0/53	0,0000	0,000	2.041

Fonte**:** Elaborado pelo autor

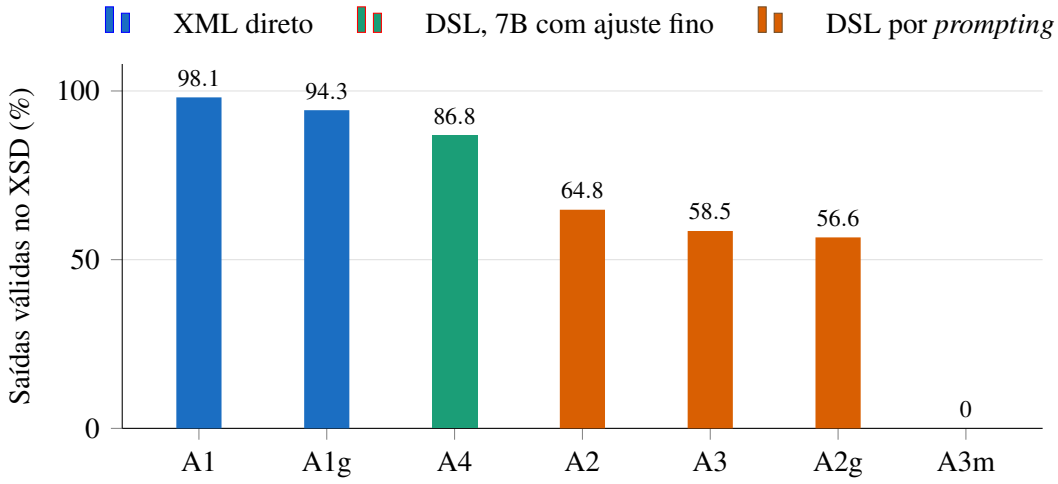
Nota**:** XSD por geração (N = 159 por braço). "Itens"conta itens com ao menos uma geração válida. DF-F1 é a média das medianas por item. "Máx."é o melhor item do braço. *Tokens* é a mediana de *tokens* emitidos. Nenhum braço registrou erro de geração.

Quatro leituras imediatas. A primeira é que **os braços de XML dominam a coluna de DF-F1**. A segunda é que **os braços de DSL dominam a coluna de *tokens*** por margem de quatro a cinco vezes. A terceira é que o melhor item isolado pertence ao A2 (0,714), acima do melhor item do A1 (0,571) — indício, explorado adiante, de que a DSL não é inferior *quando*

funciona.

A quarta é a que reorganiza a tabela: **o braço A4 ocupa a terceira posição em validade**, à frente de todos os demais braços de DSL, inclusive dos dois conduzidos por modelos de fronteira. A Figura 2 apresenta esse eixo isoladamente.

Figura 2 – Validade sintática por braço experimental



Fonte**:** Elaborado pelo autor

Nota**:** Percentual sobre as 159 gerações de cada braço. Nos braços de DSL a validade XSD coincide com a taxa de *parsing*, pois a transpilação é determinística e sempre produz XML válido a partir de DSL aceita.

A progressão que a figura torna visível — **0%** sem gramática no contexto, **58,5%** com a gramática no *prompt*, **86,8%** com a notação nos pesos — percorre os três braços que compartilham o mesmo modelo base de 7 bilhões de parâmetros. Como A3m e A4 usam ainda o **mesmo *prompt***, diferindo apenas pela presença do adaptador, o salto entre eles isola o efeito do ajuste supervisionado sem confundi-lo com mudança de instrução.

O braço A3m merece registro à parte por não ser uma falha de medição. Submetido ao *prompt* mínimo — o mesmo que será usado no treinamento do A4, e que deliberadamente não contém gramática nem exemplo de notação — o modelo base produziu **BPMN XML em 53 dos 53 itens**, jamais tentando a DSL. Um modelo sem a notação nos pesos e sem a especificação no contexto recorre ao formato que conhece do pré-treinamento. Os 81 truncamentos do braço têm a mesma origem: gerar um documento XML completo sob um teto de 2.048 *tokens* dimensionado para DSL. O zero do A3m não mede incapacidade de modelagem; mede que **o *prompt* mínimo não carrega informação suficiente sem o ajuste fino** — que é exatamente a função de piso que lhe foi atribuída no desenho.

5.6.2 Testes das Hipóteses Pré-Registradas

Os três contrastes planejados (Seção 4.7.7) foram submetidos ao teste de Wilcoxon pareado bilateral com correção de Holm, conforme o plano de análise congelado. A Tabela 7 apresenta os resultados.

Tabela 7 – Contrastes pré-registrados

Contraste	Dif. mediana	IC95%	r_{rb}	p_{Holm}	Desfecho
A2 vs A1	−0,0067	[−0,0769; 0,0]	−0,366	0,0387	H1 refutada
A2g vs A1g	−0,0287	[−0,0845; 0,0]	−0,429	0,0062	H1g refutada
A4 vs A2	0,0	[−0,0329; 0,0]	−0,231	0,2496	H3 não refutada

Fonte**:** Elaborado pelo autor

Nota**:** N = 53 pares em todos os contrastes; 12, 11 e 14 empates, respectivamente. r_{rb} é o tamanho de efeito rank-biserial. IC95% por *bootstrap* pareado com 10.000 reamostragens e semente fixa. Sinal negativo indica vantagem do braço de XML.

O sinal negativo em ambos os contrastes indica que o braço de XML superou o de DSL. A magnitude do efeito é moderada ($|r_{rb}|$ entre 0,37 e 0,43), e o valor-p permanece significativo após a correção de Holm nos dois casos.

A **replicação interna** cumpriu sua função de desenho. A Seção 4.7.6 havia registrado que, se H1 falhasse e H1g se sustentasse, o efeito seria atribuível ao modelo e não ao formato. Como ambas falharam na mesma direção, com dois modelos de famílias distintas, a conclusão é atribuível ao **formato**: não é idiossincrasia do DeepSeek.

O contraste A4 vs. A2 exige leitura cuidadosa e é reportado sem atenuação. O teste **não é significativo** ($p_{Holm} = 0{,}25$) e o intervalo de confiança contém o zero. Como H3 foi enunciada na forma $\geq$, um empate estatístico não a refuta — mas tampouco a demonstra. **O braço A4 não supera o A2 em fidelidade topológica; iguala-o.** O tamanho de efeito ($-0{,}231$) e o intervalo $[-0{,}0329;\ 0{,}0]$ apontam ligeira desvantagem do modelo especializado, sem que o teste a distinga de zero com $n = 53$. Interpretar resultado nulo como confirmação seria abuso do enunciado da hipótese, e registra-se aqui a recusa em fazê-lo.

A hipótese H2 foi a refutada de forma mais acentuada, e por isso mesmo a mais instrutiva. Ela afirmava que a transpilação determinística garantiria validade que a geração direta não garante. O raciocínio estava correto quanto ao transpilador — este produz XML válido em 100% dos casos, conforme a Seção 5.2 — mas **condicionado a que a DSL seja aceita pela gramática**. O protocolo tratava o *parsing* como etapa dada, e é ele o gargalo: apenas 64,8% das gerações do A2 produziram DSL sintaticamente aceita. Enquanto isso, o DeepSeek redigiu

BPMN XML válido contra o esquema oficial em 98,1% das gerações, sem qualquer garantia estrutural — apenas por competência adquirida no pré-treinamento.

Esse resultado contradiz uma premissa implícita e raramente examinada do trabalho: a de que uma notação compacta seria *mais fácil* de emitir do que XML verboso. Para um modelo que processou milhões de documentos XML durante o pré-treinamento, a verbosidade não constitui dificuldade. A **novidade** da notação, sim.

5.6.3 Análise do Mecanismo: Validade e Não Qualidade

A refutação de H1 admite duas explicações concorrentes, com implicações opostas para a continuidade do trabalho. Ou a DSL degrada a qualidade da modelagem, ou ela apenas falha em ser produzida corretamente, sendo competitiva quando produzida. A distinção é decisiva: a primeira invalidaria a abordagem, a segunda a redirecionaria para o ajuste fino.

Para separá-las, repetiu-se o contraste **restrito aos itens em que o braço de DSL produziu saída válida**. Trata-se de análise exploratória, não pré-registrada, e o condicionamento em uma variável posterior à intervenção introduz viés de seleção — o subconjunto pode conter os itens mais fáceis. O resultado é indicativo, não confirmatório.

Tabela 8 – Contraste restrito aos itens com saída válida (exploratório)

Subconjunto	N	DSL	XML	Diferença
Todos os itens (A2 vs A1)	53	0,1375	0,1942	−0,0567
Só onde A2 valida	40	0,1821	0,2040	−0,0219
Todos os itens (A2g vs A1g)	53	0,0783	0,1551	−0,0768
Só onde A2g valida	41	0,1012	0,1420	−0,0408

Fonte**:** Elaborado pelo autor

Nota**:** Análise exploratória, não pré-registrada. O condicionamento em variável pós-intervenção introduz viés de seleção; os valores são indicativos.

A distância cai a menos da metade quando se descartam as falhas de validade: de $-0{,}0567$ para $-0{,}0219$ no DeepSeek, e de $-0{,}0768$ para $-0{,}0408$ no GLM. **A maior parte da desvantagem da DSL é perda de validade, não perda de qualidade de modelagem** — porém a diferença não se anula, e portanto a explicação não é exclusivamente de validade. Some-se a isso que o melhor item do A2 (0,714) supera o melhor do A1 (0,571).

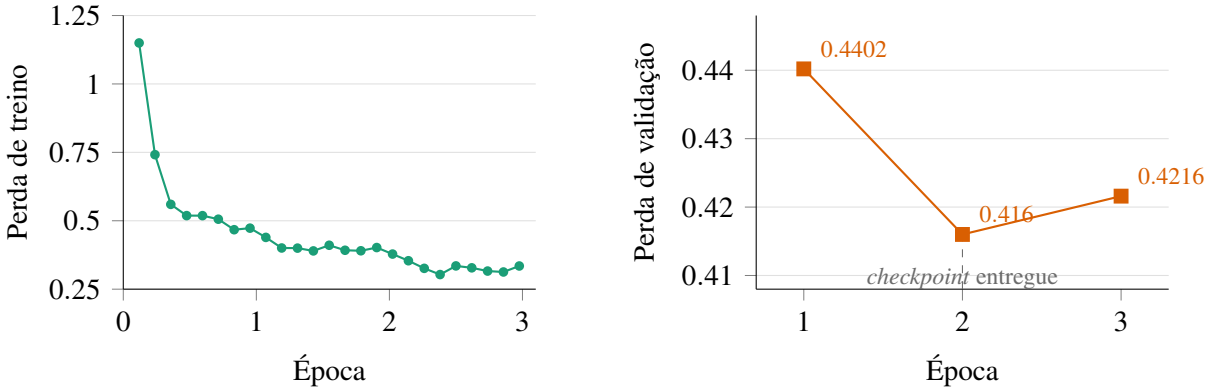
A consequência para o trabalho é direta e delimita o que resta a investigar: se a desvantagem se concentra na taxa de aceitação sintática, então a intervenção adequada é

internalizar a notação nos pesos, que é precisamente o que o ajuste fino do braço A4 se propõe a fazer. A cadeia de evidências A3m (0/53, sem gramática no contexto) → A3 (31/53, com gramática no contexto) → A2 (40/53, com gramática e modelo grande) mostra a aceitação sintática crescendo com a informação disponível sobre a notação, o que torna a hipótese plausível — sem, evidentemente, demonstrá-la.

5.6.4 O Modelo Especializado

O ajuste supervisionado consumiu **672 pares** de treino — os 690 exportados menos 18 que excediam o comprimento de sequência — e 78 de validação, agrupados por documento de origem. Executou-se em uma GPU NVIDIA A40 alugada, em **1 hora e 1 minuto**, ao custo de **US$ 0,47**. O adaptador resultante ocupa 161 MB e opera sobre o modelo base quantizado em 4 *bits*, na mesma configuração de inferência do braço A3.

Figura 3 – Perdas de treino e de validação no ajuste supervisionado



Fonte**:** Elaborado pelo autor

Nota**:** Treino sobre 672 exemplos; validação sobre 78, agrupada por documento de origem. A perda de treino cai de forma monótona (1,1498 a 0,3347) e a otimização não apresenta instabilidade — não é ela, portanto, que limita o resultado. A de validação atinge o mínimo na época 2 e sobe na terceira, indicando início de sobreajuste; o critério de parada descartou automaticamente a última época, e verificou-se por soma de verificação criptográfica que o adaptador entregue é idêntico ao *checkpoint* da época 2.

A Figura 3 registra o comportamento da validação. A perda cai da primeira para a segunda época e **sobe na terceira**, indicando início de sobreajuste sobre um conjunto de 672 exemplos. O critério de parada selecionou automaticamente o *checkpoint* da época 2, e verificou-se por soma de verificação criptográfica que o adaptador entregue é idêntico a ele. Registra-se a consequência prática: o agrupamento da validação por documento de origem, adotado por causa da predominância do *handbook* corporativo (Seção 5.1), não foi formalidade

— **ele mudou o modelo entregue**.

Efeito sobre a validade sintática

O resultado de maior magnitude do trabalho está neste eixo. Os três braços que compartilham o modelo base de 7 bilhões de parâmetros ordenam-se de forma inequívoca:

- **A3m** — *prompt* mínimo, sem adaptador: **0/53**. O modelo produziu BPMN XML em todos os itens, jamais tentando a DSL.
- **A3** — gramática completa no *prompt*: **58,5%**.
- **A4** — *prompt* mínimo, com adaptador: **86,8%**.

A comparação A4 vs. A3m é a que isola melhor o efeito, por manter constante o *prompt* e variar apenas os pesos. A comparação A4 vs. A3 é mais informativa em termos práticos: o modelo especializado supera em 28 pontos percentuais o mesmo modelo instruído pela gramática, e o faz consumindo **753 *tokens* de entrada em vez de 1.351** — a especialização reduz simultaneamente o custo de entrada e a taxa de falha.

Mais relevante para a tese: **o A4 supera em 22 pontos percentuais o braço A2**, conduzido por um modelo de fronteira com a gramática completa no contexto. Um modelo de 7 bilhões de parâmetros executando em placa de consumidor produz notação válida com mais confiabilidade do que um modelo de fronteira instruído por *prompt*.

Contrastes exploratórios

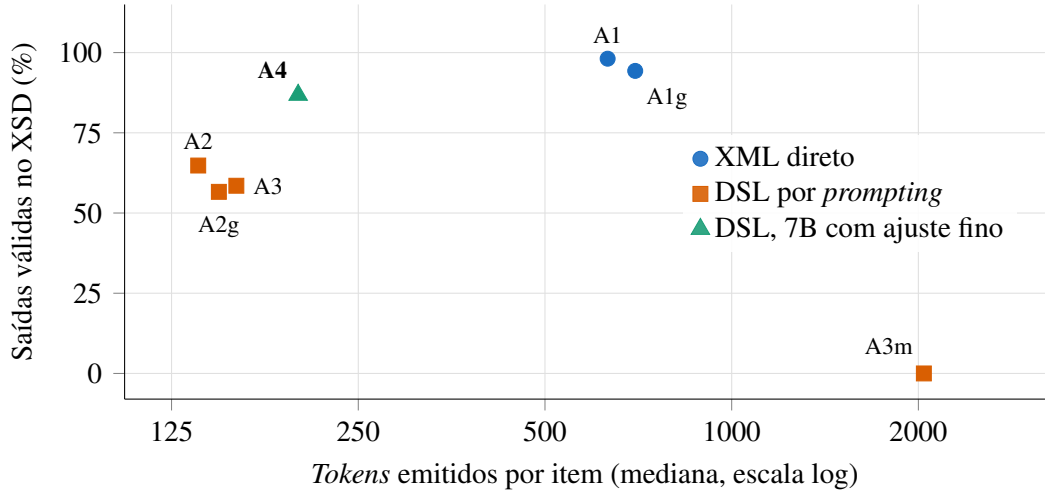
Os contrastes envolvendo A4 que não constam do plano confirmatório são reportados sem correção de múltiplas comparações e sem valor confirmatório. A4 supera A3 com efeito $r_{rb} = 0{,}405$ e $p = 0{,}013$; A4 supera A3m com efeito máximo ($r_{rb} = 1{,}0$), o que é trivial dado que A3m pontua zero em todos os itens.

O eixo econômico

A Figura 4 posiciona os sete braços no plano custo–validade, que é a forma mais direta de expor o argumento central do trabalho. O braço A4 emite **200 *tokens* medianos contra 631 do A1**, mantendo 86,8% de validade, e dispensa modelo de fronteira: executa localmente sobre *hardware* de consumidor, com custo marginal por inferência essencialmente nulo após um treinamento de menos de um dólar.

O A1 permanece à frente em validade (98,1%) e em fidelidade (0,1942). A afirmação

Figura 4 – Custo de saída contra validade sintática, por braço



Fonte**:** Elaborado pelo autor

Nota**:** Canto superior esquerdo é o desejável: alta validade a baixo custo. O braço A4 emite 200 *tokens* medianos contra 631 do A1, mantendo 86,8% de validade, e executa em placa de consumidor. O A3m aparece isolado à direita por gerar XML sob teto dimensionado para DSL, truncando em metade das execuções.

que os dados sustentam não é de superioridade absoluta, e sim de **posição favorável na fronteira entre custo e qualidade** — que é precisamente o enunciado delimitado na Seção 4.1.

5.6.5 Verificações de Validade do Resultado Adverso

Um resultado contrário às hipóteses do autor exige o mesmo escrutínio que um resultado favorável, e preferencialmente antes de ser aceito. Quatro verificações foram executadas.

Simetria do casamento de rótulos. O DF-F1 identifica nós por rótulo, com alinhamento por Jaccard (Seção 4.7.2). Se um formato induzisse rótulos sistematicamente mais longos ou mais curtos, o limiar penalizaria os formatos de modo desigual e contaminaria o contraste. Mediu-se o comprimento dos rótulos efetivamente emitidos: mediana de **3,0 palavras em todos os quatro braços**, com médias entre 3,02 e 3,46, contra 3,61 na referência. A penalidade é simétrica; o contraste não está contaminado por esse caminho.

Revalidação independente do XSD. A taxa de 98,1% do braço A1 foi reverificada submetendo-se as 53 saídas novamente ao esquema oficial, a partir do texto bruto armazenado. A concordância com o valor registrado foi total, sem saídas vazias. A validade do baseline é real, não artefato de contabilização.

Truncamento. Os braços de DSL não registraram truncamento algum; os de XML registraram 3 e 2 gerações truncadas em 159. O teto de *tokens* não é fator explicativo do resultado. Medição prévia sobre o conjunto de referência já havia estabelecido que o pior caso do XML

lógico consome 4.232 dos 8.192 *tokens* disponíveis, e o pior caso da DSL, 520 dos 2.048.

Correção de defeito no tratamento de cercas. Durante a análise do braço A3m identificou-se que a função de remoção de cercas *markdown* exigia delimitador de fechamento, ausente por construção em saídas truncadas, deixando a abertura no texto e reprovando o candidato por defeito do instrumento. O viés não seria neutro: emitir cerca é hábito mais treinado em XML, e os braços de XML são os que mais se aproximam do teto. O defeito foi corrigido antes da execução dos braços A1 e A1g, com teste de regressão, e verificou-se que o braço A3m permanece inalterado — suas 53 saídas são XML e seguem sem aceitação pela gramática. Registra-se por integridade: a correção **favoreceu o baseline** contra o qual a hipótese do trabalho compete.

5.6.6 Emendas ao Protocolo Congelado

O pré-registro admite emendas mediante declaração explícita de data, motivo e de sua anterioridade ou posterioridade à observação dos resultados. Duas emendas foram registradas, e sua divulgação integral é aqui cumprida. Elas diferem no ponto que mais importa: a primeira só podia prejudicar as hipóteses do autor, a segunda só podia favorecê-las.

E-1: glosa das palavras-chave no *prompt* de DSL

Após a execução do braço A3, constatou-se que o bloco de gramática do *prompt* listava as palavras-chave dos *gateways* sem vinculá-las aos nomes de conceito empregados no bloco de regras de modelagem — este último deliberadamente neutro quanto à notação, por ser compartilhado com o braço de XML. Adicionalmente, o *prompt* exibia duas formas distintas de sintaxe de ramificação sem advertir que uma não generaliza para a outra. O *prompt* de XML não requer glosa equivalente, pois a terminologia BPMN já integra o pré-treinamento dos modelos; a omissão penalizava, portanto, **apenas os braços de DSL**.

Ambos os defeitos são verificáveis pela leitura dos artefatos e pela submissão de construções ao *parser*, sem qualquer referência a pontuação obtida — critério adotado para distinguir emenda legítima de racionalização posterior. A emenda foi realizada **depois** de observados os resultados do A3, e é defensável apenas porque seu efeito possível era unicamente contrário às hipóteses do autor: elevar o A3 reduz o ganho aparente que o A4 poderá reivindicar.

O efeito da correção foi **pequeno**, e as palavras-chave inventadas não desapareceram. Conclui-se que o gargalo do braço A3 é a capacidade do modelo de 7 bilhões de parâmetros, não

Tabela 9 – Braço A3 antes e depois da emenda ao *prompt*

Métrica	Antes	Depois
Parsing aceito	27/53	31/53
XSD válido	26/53	31/53
DF-F1	0,0525	0,0666
Palavras-chave inventadas	9	7

Fonte**:** Elaborado pelo autor

Nota**:** As 159 gerações descartadas foram preservadas em arquivo e permanecem auditáveis. Contagem de palavras-chave inventadas sobre a primeira repetição.

a redação do *prompt*. Esse desfecho é favorável à integridade do trabalho: caso a emenda tivesse elevado substancialmente o A3, boa parte do ganho que o ajuste fino viesse a demonstrar seria atribuível a um defeito introduzido pelo próprio autor, e não ao método.

E-2: correção do transpilador quanto à unicidade de identificadores

Em 25 de agosto de 2026, já observados todos os resultados, identificou-se defeito no transpilador: quando uma referência `#id` era redeclarada como declaração completa, emitia-se um **segundo** elemento com o mesmo identificador. O XSD da BPMN tipa identificadores como `xs:ID`, cuja unicidade é requisito do documento; a saída era, portanto, inválida por construção.

O defeito é verificável sem qualquer referência a pontuação obtida — basta submeter ao esquema oficial uma DSL que redeclare uma referência. Dois testes de regressão foram acrescentados e **verificou-se que ambos falham sem a correção**, o que fixa a asserção em código e não em prosa.

A direção do efeito, contudo, inverte-se em relação à E-1, e isso exige rigor maior, não menor. Corrigir o transpilador só pode **elevar** a validade dos braços de DSL, que são os braços cuja superioridade o autor postulou. Uma correção favorável à própria hipótese, aplicada depois de vistos os resultados, é exatamente a categoria de decisão que o pré-registro existe para constranger. Três salvaguardas foram adotadas: a correção foi aplicada a **todos** os braços simultaneamente, por reprocessamento determinístico da saída bruta armazenada, sem nova chamada a modelo algum; nenhum braço foi reprocessado isoladamente; e o efeito é aqui reportado por inteiro.

O efeito foi **seis linhas em mil quinhentas e noventa**. Três no braço A2g (validade de 54,7% para 56,6%) e três no braço exploratório de curva de aprendizado com 25% dos dados (86,8% para 88,7%). Os demais braços não registraram alteração alguma — em particular, **o**

braço A4 não mudou, de modo que o resultado central do trabalho não foi tocado pela correção que o favoreceria.

Nenhuma ordenação de tabela se alterou e nenhum desfecho de hipótese mudou. A hipótese H1g permanece refutada, com p_{Holm} passando de 0,005 para 0,006 e tamanho de efeito de $-0{,}463$ para $-0{,}429$: a correção moveu o resultado marginalmente na direção da hipótese do autor, e ainda assim a hipótese continua refutada. As 1.021 saídas do corpus de *augmentation* foram reprocessadas e permaneceram **idênticas byte a byte**, o que confirma que o defeito só se manifestava em DSL gerada por modelo, e não na produzida pelo pipeline determinístico.

Registre-se, por fim, que o defeito estava visível na própria tabela de resultados antes de ser procurado: o braço A2g exibia 56,6% de *parsing* contra 54,7% de validade XSD, ao passo que a nota da Figura 2 afirma — corretamente, como especificação do transpilador — que as duas taxas coincidem nos braços de DSL, pois a transpilação é determinística. A discrepância entre a nota e a tabela era a assinatura do defeito. Após a correção, a igualdade vale em todos os braços de DSL.

5.6.7 Eixo Econômico

A hipótese H4 estipulava TCR ≥ 2 nos braços com representação intermediária. A Tabela 10 apresenta o resultado.

Tabela 10 – Compressão e custo de saída por braço

Braço	Saída	*Tokens* (mediana)	TCR	Redução
A1	XML	631	—	—
A1g	XML	699	—	—
A2	DSL	138	**7,03**	85,8%
A2g	DSL	149	6,70	85,1%
A3	DSL	159	6,70	85,1%
A4	DSL	**200**	**6,50**	**84,6%**

Fonte**:** Elaborado pelo autor

Nota**:** IC95% da TCR: A2 [6,88; 7,17], A2g [6,57; 6,83], A3 [6,44; 6,94], A4 [6,38; 6,62]. Nos braços de XML direto não há representação intermediária e a razão não é definida; reportá-la como 1,0 apresentaria uma tautologia como resultado. O A4 emite mais *tokens* que os demais braços de DSL por produzir saída válida com mais frequência — as falhas de *parsing* dos outros braços são frequentemente truncadas ou degeneradas, e portanto curtas.

H4 é confirmada com folga: a razão observada situa-se em torno de 7, contra o

limiar de 2. O braço A2 emite **138 *tokens* medianos contra 631 do A1** — uma redução de 4,6 vezes no custo de saída para a mesma tarefa. Registra-se que a TCR medida sobre as saídas dos braços (7,03) supera a medida sobre o corpus de treino (6,01, Seção 5.4), o que é coerente com a medição prévia sobre o conjunto de referência, que indicava razão de 8,84 para os itens do PMo especificamente.

Este é o eixo em que a abordagem permanece integralmente sustentada, e é ele que confere sentido à continuidade: o trabalho não se propôs a demonstrar superioridade absoluta de qualidade, mas **viabilidade econômica na geração de linguagens de marcação hierárquicas**. A pergunta que resta, formalizada em H3 e ainda não respondida, é se um modelo pequeno com a notação internalizada nos pesos recupera a qualidade perdida operando a um quinto do custo de saída.

5.6.8 Limitação Relevante da Métrica de Fidelidade

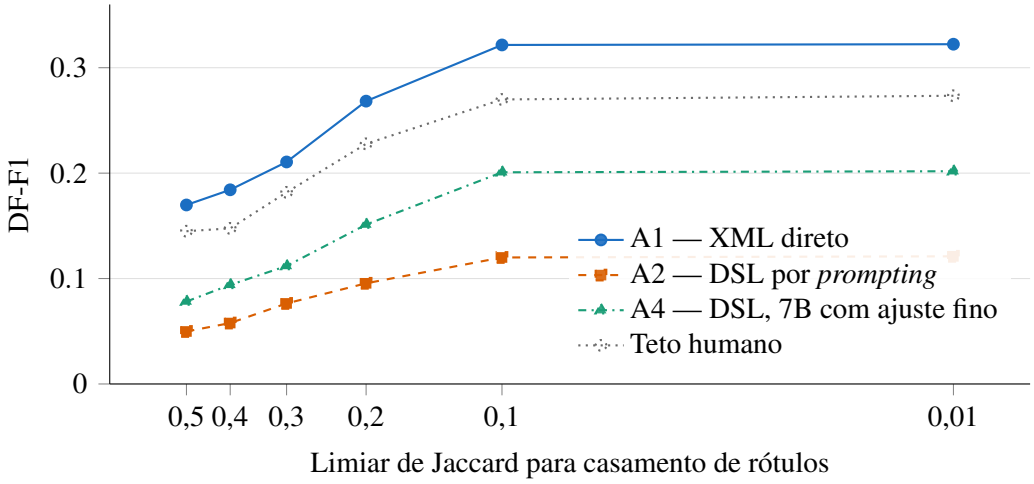
Os valores absolutos de DF-F1 são baixos em todos os braços, incluindo os de modelos de fronteira, e a interpretação desse fato exige cautela. Investigação sobre o braço A2 revelou que **apenas 40,5% dos rótulos da referência encontram par no candidato** sob o limiar de Jaccard adotado, com mediana de 12 rótulos na referência contra 9,5 no candidato — isto é, os modelos produzem processos da escala correta, porém **nomeiam as atividades de modo distinto**.

Como cada aresta do multiconjunto *direct-follows* depende do alinhamento de **dois** rótulos, uma taxa de alinhamento de 40,5% deprime o F1 muito abaixo desse patamar. Um item ilustrativo obteve DF-F1 nulo apesar de XSD válido: onde a referência registra *Clarify shipment method*, o candidato escreveu *Clarify shipping responsibility* — paráfrase cuja sobreposição de *tokens* normalizados fica abaixo do limiar.

Decorrem daí duas consequências. A primeira é que **o DF-F1 absoluto não deve ser lido como percentual de acerto**; ele constitui um limite inferior severo, que penaliza paráfrase junto com erro estrutural sem distinguir as duas causas. A segunda é que **as comparações entre braços permanecem válidas**, pois todos são submetidos ao mesmo critério, com a simetria de comprimento de rótulo verificada na Seção 5.6.5.

A Figura 5 quantifica a afirmação. Afrouxando-se o limiar de 0,5 até 0,01 — ponto em que qualquer sobreposição de *tokens* basta para casar dois rótulos —, nenhuma série ultrapassa 0,33, e as curvas achatam-se antes mesmo do extremo. O que resta depois de neutralizada a

Figura 5 – Saturação do DF-F1 conforme o casamento de rótulos é afrouxado



Fonte**:** Elaborado pelo autor

Nota**:** Séries calculadas sobre os **24 itens com referência múltipla**, o recorte em que o teto humano é medido. O valor congelado no protocolo é 0,5; os demais pontos são análise de sensibilidade e não substituem a métrica primária. Mesmo com o casamento praticamente livre (0,01), nenhuma série passa de 0,33 — o resíduo é divergência estrutural, não lexical. O teto humano não contém saídas inválidas, por construção; os braços contam-nas como zero.

divergência lexical é **divergência estrutural**: os modelos, humanos inclusive, discordam sobre quais arestas o processo possui. E o teto humano acompanha as curvas dos braços em toda a faixa — permanece abaixo do A1 e acima dos braços de DSL em todos os limiares —, o que significa que a saturação não é limitação dos métodos avaliados, e sim da tarefa sob esta métrica.

Itens estruturalmente inatingíveis

A heterogeneidade de nomenclatura do conjunto de referência produz um efeito mais severo do que a degradação gradual descrita acima. Em **8 dos 53 itens**, **todos os sete braços** obtêm DF-F1 exatamente zero — inclusive os conduzidos por modelos de fronteira. As referências desses itens não são degeneradas: possuem de 4 a 73 arestas.

A causa é convenção de nomenclatura incompatível com a instrução dada aos modelos. As referências desses itens nomeiam atividades como **orações em terceira pessoa com o ator por sujeito**, ao passo que o bloco de regras de modelagem instrui explicitamente a forma imperativa sem ator. Três exemplos, extraídos da referência e do braço A4 no mesmo item:

IP checks the request of the INQ vs. `Check Request`

MPOO confirmes the dismissal vs. `Confirm Dismissal`

MPON sents the dismissal to the MPOO vs. `Send Dismissal`

Os rótulos desses oito itens têm **5,22 palavras** em média, contra 3,47 nos demais — e a diferença de comprimento, somada à ausência de radicalização morfológica no casamento (*checks* não casa com *check*), coloca a similaridade de Jaccard estruturalmente abaixo do limiar. Nenhum modelo que siga a instrução recebida pode pontuar nesses itens.

O efeito sobre os resultados é uniforme e não altera ordenação alguma: excluindo-os, A1 passa de 0,1942 para 0,2287, A2 de 0,1375 para 0,1619 e A4 de 0,1114 para 0,1312 — elevação de cerca de 18% em todos. Os valores reportados neste capítulo **incluem** os oito itens, conforme o protocolo congelado; a exclusão é apresentada apenas como quantificação do efeito.

A Figura 6 torna o fenômeno concreto. O braço A4 produziu, para o item *pmo_52*, um modelo de processo que qualquer leitor reconhece como descrição correta do mesmo fluxo da referência — mesma sequência, mesma decisão, mesmos dois desfechos — e obteve **DF-F1 igual a zero**. É a demonstração mais direta disponível de que o valor absoluto da métrica não deve ser lido como percentual de acerto.

O limiar não foi alterado. Diferentemente da emenda descrita na Seção 5.6.6, cujo efeito possível era exclusivamente contrário às hipóteses do autor, afrouxar o casamento de rótulos após observar que a métrica produz valores baixos elevaria indistintamente todos os braços — movimento que o pré-registro existe para impedir. Recomenda-se, como trabalho futuro, análise de sensibilidade sobre múltiplos limiares, reportada como verificação de robustez, mantendo-se o valor congelado como número primário.

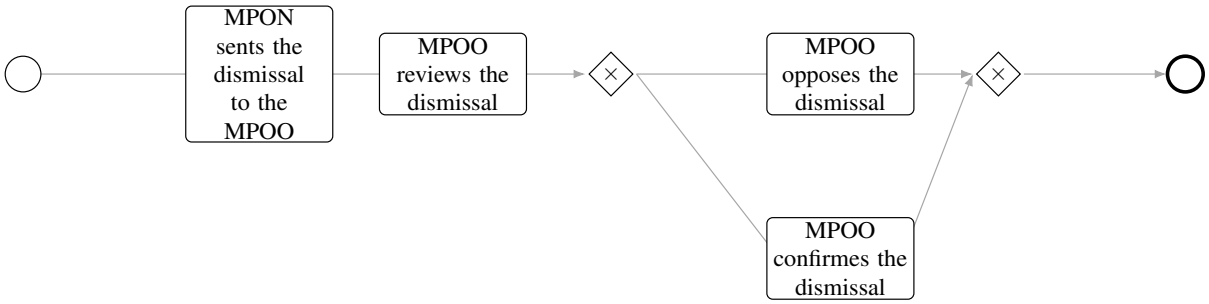
5.6.9 Não Avaliabilidade do Eixo de Fluxos de Mensagem

O Eixo 3 (Seção 4.7.3) previa a medição de MF-F1 sobre os fluxos de mensagem entre participantes. Constatou-se que **apenas 2 dos 53 itens do conjunto de avaliação** — *pmo_23* e *pmo_38* — possuem `messageFlow` no modelo de referência. O eixo é, portanto, **não avaliável** neste conjunto, e os valores são reportados como descritivos, jamais como base de comparação entre braços.

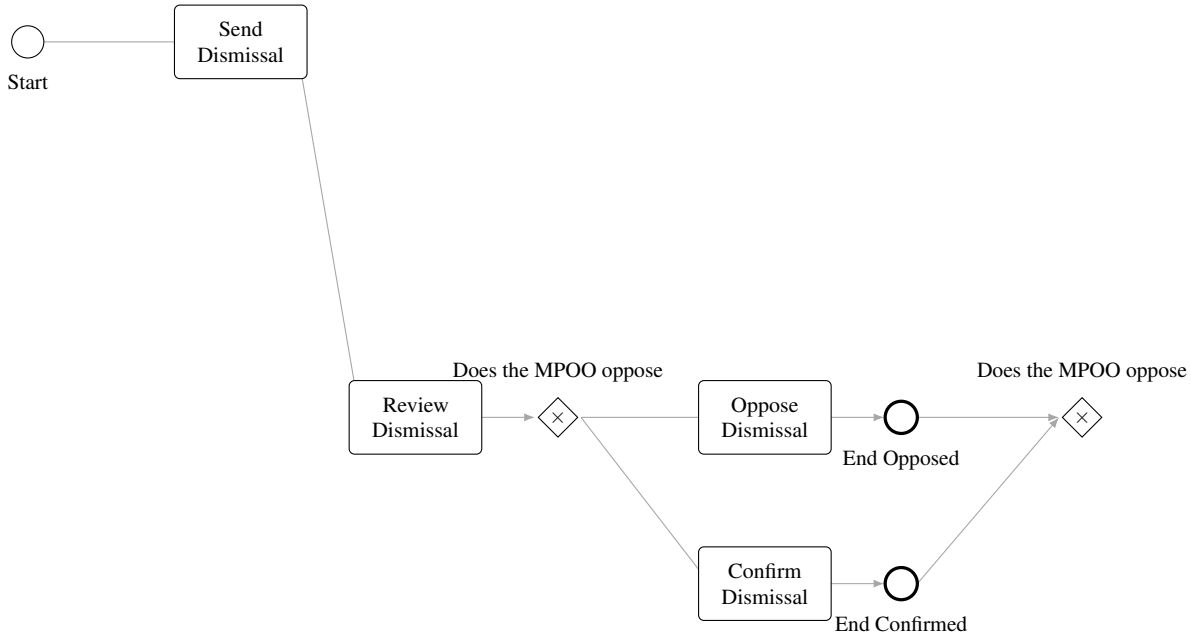
A limitação é dupla. A primeira é de **potência**: seis linhas por braço (2 itens $\times$ 3 repetições) não sustentam inferência estatística de espécie alguma, e nenhum teste foi conduzido sobre elas. A segunda é de **construção da métrica**, e produz o efeito ilustrado na Tabela 11: quando referência e candidato não têm fluxo de mensagem, o F1 é definido como 1,0 por vacuidade. Em 125 das 159 gerações do braço A1 esse é o caso, de modo que a média sobre todas as linhas (0,786) mede predominantemente a ausência de mensagens, e não o acerto sobre

Figura 6 – Divergência de nomenclatura sem divergência de estrutura (*pmo_52*)

(a) Referência de especialista



(b) Braço A4 — modelo de 7B com ajuste fino **DF-F1** $= 0{,}000$



Fonte**:** Elaborado pelo autor

Nota**:** Item selecionado pela regra, declarada antes da inspeção, de **menor número de nós na referência entre os itens em que o braço A4 produziu saída válida** — critério de legibilidade, independente de pontuação. Os diagramas usam a topologia e o leiaute automáticos do próprio *pipeline*; apenas o espaçamento vertical foi ampliado, porque os rótulos da referência ocupam quatro a cinco linhas e estouram a altura reservada ao nó pelo leiaute. A referência escreve *MPOO confirmes the dismissal*; o candidato, *Confirm Dismissal*. A sobreposição de *tokens* normalizados fica abaixo do limiar de casamento, e a aresta correspondente é contabilizada como erro estrutural.

elas.

A tabela evidencia o problema de forma direta: o braço A1g emitiu `messageFlow` em todas as seis gerações e obteve MF-F1 nulo, enquanto o A3 não emitiu em nenhuma e obteve 0,500. Um número que ordena assim os braços não está medindo competência em modelar comunicação entre participantes — está medindo, sobretudo, coincidência de ausências.

Registra-se que essa fragilidade havia sido antecipada no protocolo, que já determinava reportar o MF-F1 apenas sobre os itens cuja referência contém mensagens e jamais somá-lo

Tabela 11 – MF-F1 restrito aos dois itens com fluxo de mensagem na referência

Braço	MF-F1	Gerações que emitiram `messageFlow`
A1	0,500	3/6
A1g	0,000	6/6
A2	0,167	0/6
A2g	0,333	0/6
A3	0,500	0/6

Fonte**:** Elaborado pelo autor

Nota**:** N = 6 linhas por braço (2 itens × 3 repetições). Valores descritivos; nenhum teste de hipótese foi conduzido sobre eles.

ao DF-F1. A execução confirmou a previsão e acrescentou a magnitude: com 2 itens, a restrição prescrita pelo protocolo esvazia o eixo em vez de corrigi-lo.

A consequência prática é que **avaliar geração de colaborações BPMN exige um conjunto de avaliação construído para esse fim**. O PMo, concebido para processos únicos, não o oferece, e nenhuma correção de métrica supre ausência de dados. Fica registrado como trabalho futuro, e como critério para a seleção de conjuntos de avaliação em extensões deste trabalho.

5.6.10 Teto Humano da Métrica

A seção anterior estabelece que o DF-F1 penaliza divergência de nomenclatura como se fosse erro estrutural. Resta quantificar a magnitude dessa penalidade, e o conjunto de referências múltiplas permite fazê-lo diretamente: as 172 referências alternativas cobrem 24 itens com 4 a 11 modelos distintos do **mesmo** processo, todos aprovados por especialista. Comparar essas referências **entre si** mede o quanto dois modeladores humanos competentes concordam — isto é, o valor máximo que qualquer método pode razoavelmente aspirar.

A medição aplica aos especialistas exatamente o tratamento dado aos braços: cada referência é pontuada contra as demais sob a regra do máximo. Pares exatamente idênticos são descartados, pois em 17 dos 24 itens a referência primária coincide com uma das alternativas — ambas derivam da mesma fonte — e mantê-los mediria autocomparação.

O teto humano situa-se em **0,1449**, e a Figura 7 o apresenta como linha de referência sobre os sete braços. A consequência é de primeira ordem para a leitura de todo este capítulo: **os valores de DF-F1 não devem ser comparados a 1,0**, que é inalcançável, mas a essa faixa. O braço A1 não obtém 19% de um máximo teórico — obtém **117% da concordância que dois especialistas humanos exibem entre si** sobre os mesmos processos.

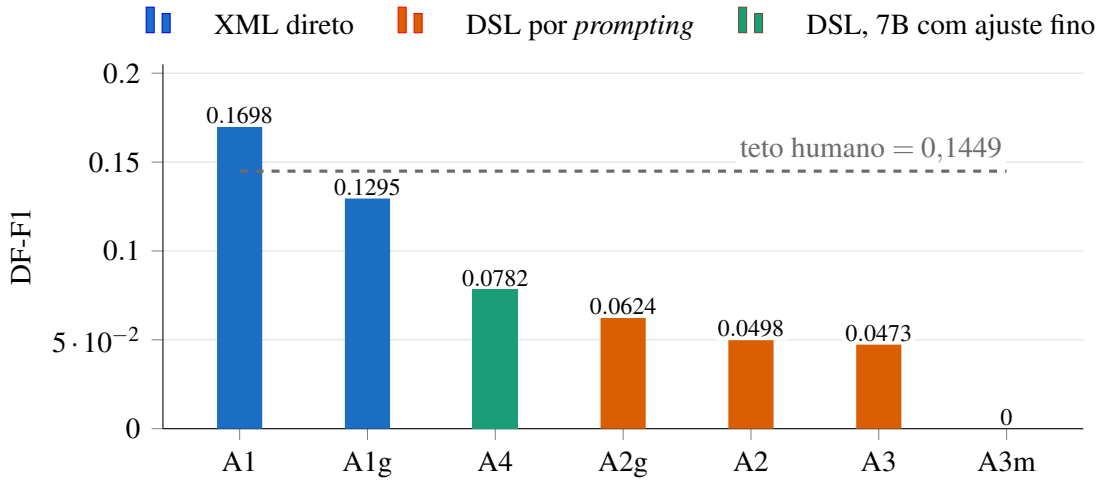
Tabela 12 – Desempenho relativo ao teto humano (24 itens com referência múltipla)

Origem do modelo	DF-F1	% do teto
A1 (DeepSeek → XML)	0,1698	**117%**
Teto humano (especialista vs. especialista)	**0,1449**	—
A1g (GLM → XML)	0,1295	89%
Pipeline de augmentation	0,1103	76%
A4 (Qwen 7B + SFT)	**0,0782**	**54%**
A2g (GLM → DSL)	0,0624	43%
A2 (DeepSeek → DSL)	0,0498	34%
A3 (Qwen 7B → DSL)	0,0473	33%
A3m (Qwen 7B, *prompt* mínimo)	0,0000	0%

Fonte**:** Elaborado pelo autor

Nota**:** Restrito aos 24 itens com referência múltipla, para que todas as linhas sejam comparáveis — inclusive a do teto, medida sobre esses mesmos itens. Os valores diferem da Tabela 6, calculada sobre os 53 itens, e a ordenação entre braços não é a mesma nos dois recortes. O teto aparece em posição ordenada, e não como cabeçalho, porque um dos braços o supera.

Figura 7 – Fidelidade topológica por braço, relativa à concordância entre especialistas



Fonte**:** Elaborado pelo autor

Nota**:** Média das medianas por item sobre os **24 itens com referência múltipla** — o mesmo recorte em que o teto é medido, para que barras e linha comparem a mesma coisa; os valores sobre os 53 itens estão na Tabela 6. O teto humano é a concordância média entre referências de especialista do mesmo processo, sob a mesma regra do máximo aplicada aos braços (Seção 5.6.10). Apenas o braço A1 o ultrapassa.

O mecanismo é aritmético e coerente com a Seção 5.6.8. Mediu-se em 30,5% a taxa média com que dois especialistas concordam quanto aos rótulos. Como cada aresta do multiconjunto *direct-follows* exige o alinhamento de **dois** rótulos, a concordância esperada ao nível de aresta cai para a ordem de $0{,}305^2 \approx 0{,}09$, antes ainda de exigir que a aresta exista em ambos os modelos. Uma métrica de identidade lexical aplicada a uma tarefa com liberdade de denominação satura, portanto, muito abaixo da unidade.

Três consequências são registradas. A primeira é que **a refutação de H1 permanece**

válida: o contraste A2 vs. A1 é pareado, aplicado às mesmas referências e ao mesmo critério, e a ordenação entre braços não depende da escala absoluta. A segunda é que **a magnitude do efeito deve ser lida contra o teto**, e não contra a unidade, sob pena de superestimar a distância que separa os métodos avaliados do desempenho humano. A terceira é que **o pipeline de augmentation opera a 76% do teto humano**, superando todos os braços que emitem DSL, o que reposiciona o oráculo discutido na seção seguinte.

Registra-se a limitação da própria estimativa: o teto é obtido sobre 24 itens, e não sobre os 53, por serem os únicos com referência múltipla. Trata-se, ainda assim, da melhor estimativa disponível, e sua ausência levaria a interpretação sistematicamente pessimista de todos os resultados reportados. O recorte tem, além do tamanho, um efeito de ordenação que merece registro: nele o braço A4 (0,0782) fica **acima** dos dois braços de DSL conduzidos por modelos de fronteira, invertendo a ordem observada sobre os 53 itens da Tabela 6. Com 24 itens e diferenças dessa magnitude, a inversão é evidência de fragilidade da ordenação — não de superioridade do braço especializado.

5.6.11 Validação do Pipeline de Augmentation

A verificação do Eixo 2 (Seção 5.3), com 99,6% de equivalência exata, atesta a fidelidade da cadeia **determinística** JSON $\rightarrow$ DSL $\rightarrow$ XML. Ela nada afirma, contudo, sobre o passo **anterior** — a conversão de texto em prosa para o JSON canônico, executada por modelos de linguagem — que até a obtenção do conjunto de referência jamais fora confrontado com modelagem humana. O conjunto *gold* do PMo fecha esse ponto cego, e a medição correspondente é reportada aqui.

Construiu-se para isso um **oráculo**: a DSL produzida pelo próprio pipeline de augmentation para os 53 itens do PMo, transpilada e pontuada contra as referências de especialista pela mesma métrica aplicada aos braços. Esse valor estima o **teto** que o ajuste fino poderia alcançar, pois representa o desempenho de um modelo que reproduzisse os dados de treinamento com fidelidade perfeita.

O oráculo situa-se em **0,1533** sobre os 53 itens, e em 0,1103 no subconjunto de referência múltipla — **76% do teto humano** estabelecido na Seção 5.6.10, acima de todos os braços que emitem DSL e abaixo apenas dos braços de XML direto.

A leitura correta desse valor exige a moldura da seção anterior. Confrontado com a unidade, o oráculo sugeriria dado de treinamento gravemente defeituoso; confrontado com o

Tabela 13 – Oráculo do pipeline de augmentation contra o *gold*

Origem do modelo	DF-F1	Rótulos alinhados	Arestas	*n*
Gold (referência)	—	—	18	53
A1 (DeepSeek → XML)	0,1942	40,1%	12	53
Pipeline de augmentation	0,1533	41,3%	14	53
A2 (DeepSeek → DSL)	0,1375	40,5%	13,5	40
A4 (Qwen 7B + SFT)	0,1114	38,2%	13	46

Fonte**:** Elaborado pelo autor

Nota**:** Arestas: mediana do multiconjunto *direct-follows*. Rótulos alinhados: proporção dos rótulos da referência com par no candidato sob o limiar de Jaccard adotado, excluídas as categorias de evento anônimo, que são tipo e não denominação. O DF-F1 segue a regra congelada, na qual geração inválida conta zero; as duas colunas de diagnóstico são calculadas apenas sobre as gerações válidas de cada origem (*n*), pois documento inválido não tem rótulo nem aresta a comparar — zerá-las faria a coluna medir validade, que é o que a primeira já mede.

teto, indica que **o pipeline de augmentation produz modelos cuja divergência em relação à referência é da ordem da divergência entre dois especialistas humanos**. O limite que ele impõe a H3 é, portanto, real mas moderado, e não o obstáculo intransponível que a comparação ingênua sugeriria.

A investigação das causas descartou três explicações que a inspeção superficial sugeria. A primeira é perda de paralelismo na conversão: o JSON canônico registra *gateways* paralelos em 68% dos itens do PMo e a DSL preserva 66%, com perda residual compatível com a da Seção 5.3.2. A segunda é afastamento do vocabulário de origem por efeito dos dois estágios de processamento por modelo de linguagem: mediu-se a proporção de palavras do rótulo presentes no texto-fonte e obteve-se 69,6% para o pipeline, contra 69,9% da própria referência de especialista — o pipeline é, portanto, **tão ancorado no texto original quanto o humano**, com diferença de três décimos de ponto. O braço A1 fica acima dos dois, em 76,1%: o modelo de fronteira reaproveita mais palavras da descrição do que o especialista, o que não recupera a hipótese descartada. A terceira é subdimensionamento estrutural: a contagem de arestas do pipeline (14) é a **mais próxima** da referência (18) entre todas as origens avaliadas.

O que resta como explicação é a **escolha lexical**: pipeline e especialista extraem denominações distintas do mesmo texto, ambas legítimas e ambas ancoradas na fonte, e o DF-F1 pontua tal divergência como erro estrutural. E aqui a Seção 5.6.10 fornece o parâmetro decisivo: a taxa de alinhamento de rótulos do pipeline com a referência é de **41,3%**, ao passo que dois especialistas humanos alinham entre si a **30,5%** — esta última medida sobre os 24 itens com referência múltipla, como o teto de DF-F1, e portanto comparável apenas em ordem de grandeza.

O pipeline opera **acima da faixa de variação humana** quanto à denominação de atividades, e o mesmo vale para todas as demais origens da Tabela 13, que se distribuem entre 38% e 41%.

A consequência prática é que **não há defeito de nomenclatura a corrigir**. Tentar elevar o alinhamento acima desse patamar significaria ajustar o pipeline às escolhas lexicais idiossincráticas de um modelador específico — e, como todas as referências disponíveis pertencem à partição *holdout*, tal ajuste constituiria contaminação do conjunto de avaliação, não melhoria de método. Registra-se a decisão de não o fazer.

Registra-se ainda uma divergência de composição entre treino e avaliação, de efeito distinto: o pipeline atribui raias a **100%** das amostras, enquanto apenas **3 dos 53** modelos de referência as empregam. Como raias particionam elementos sem alterar relações de precedência, a divergência não afeta o DF-F1; ela é registrada por constituir viés de estilo herdável pelo ajuste fino, e por decorrer da predominância do *handbook* corporativo documentada na Seção 5.1.

A conclusão metodológica generaliza para além deste trabalho: **validar a porção determinística de um pipeline de geração de dados não valida o pipeline**. A etapa probabilística que a antecede requer confronto com referência independente, e a ausência desse confronto permaneceu invisível enquanto o único critério disponível foi a consistência interna entre representações.

5.6.12 Braços Exploratórios

Os braços descritos nesta seção **não integram o conjunto pré-registrado**. Foram definidos após a observação dos resultados confirmatórios, vivem em espaço de nomes próprio (prefixo `X-`) e nenhum deles entra nos contrastes submetidos à correção de Holm. A separação é sustentada por teste automatizado. Seus resultados são indicativos e orientam trabalho futuro; não sustentam afirmação confirmatória alguma.

Curva de aprendizado: mais dados ajudariam?

A pergunta é de decisão prática — vale investir em coletar mais dados? — e admite resposta empírica sem coleta nova, treinando com **menos**. Treinaram-se dois modelos adicionais sobre subconjuntos do mesmo corpus, lendo-se a inclinação da curva na sua borda direita.

Duas decisões de amostragem tornam a curva interpretável. Primeira, a amostra é **por documento de origem, não por exemplo**: como 95,3% do treino provém de um único *handbook*, sortear exemplos soltos mediria o efeito de rotular mais seções do mesmo documento,

que é outra pergunta. Segunda, as frações são **aninhadas** — a ordem dos documentos vem do *hash* do nome e cada fração é um prefixo dessa ordem, de modo que 25% $\subset$ 50% $\subset$ 100% (verificado por asserção). Sem o aninhamento, a curva confundiria efeito de volume com efeito de composição do corpus. O conjunto de validação é **o mesmo nos três pontos**, sem sobreposição de documentos com o treino.

Tabela 14 – Curva de aprendizado sobre subconjuntos aninhados do treino

Braço	Documentos	Exemplos	*Loss* de val.	XSD-Val	DF-F1
X-lc25	51	167	0,4945	88,7%	0,1000
X-lc50	96	339	0,4488	86,8%	0,1141
A4	207	672	**0,4160**	86,8%	0,1114

Fonte**:** Elaborado pelo autor

Nota**:** O ponto de 100% é o próprio adaptador do braço A4, não um treino novo: regerá-lo produziria outro adaptador e invalidaria números já reportados sob protocolo congelado. *Loss* de validação é o melhor valor entre as três épocas, sobre os mesmos 78 exemplos de validação nos três pontos.

O resultado é uma **dissociação**. A *loss* de validação melhora de forma monótona com o volume — 0,4945, 0,4488, 0,4160 —, exatamente como se espera. As métricas da tarefa, porém, **não acompanham**: a validade sintática vai de 88,7% a 86,8%, e o DF-F1 oscila entre 0,1000 e 0,1141 sem tendência. A diferença de validade entre o menor e o maior ponto corresponde a três gerações em 159, o que a coloca abaixo de qualquer limiar de relevância.

A leitura é que, **neste corpus**, o dado adicional compra verossimilhança e não capacidade: o modelo torna-se melhor em prever o próximo *token* da notação sem tornar-se melhor em produzir modelos válidos e fiéis. A explicação mais provável é a que já se registrou como ameaça à validade externa — quase todo o treino provém de uma única fonte, de modo que "mais dados"significou, aqui, mais do mesmo documento. A implicação prática é específica e não deve ser generalizada além dela: **coletar mais seções do mesmo *handbook* não é investimento produtivo**; coletar de fontes distintas permanece não testado, e é a pergunta que a curva não responde.

Registre-se ainda um sinal de convergência coerente com o volume: os dois pontos reduzidos ainda melhoravam na terceira época, ao passo que o ponto completo atingiu seu melhor valor na segunda e piorou na terceira. Menos dados, convergência mais tardia — o que indica que os pontos reduzidos não foram prejudicados por treino insuficiente.

Replicação em outras famílias de modelos

O braço A4 estabelece que o ajuste fino viabiliza a notação em **um** modelo. Se o resultado dependesse de particularidade do Qwen, a contribuição seria sobre esse modelo e não sobre o método. Treinaram-se, portanto, réplicas em outras famílias, sob protocolo idêntico — mesmo corpus, mesmos hiperparâmetros, mesma divisão, mesmo *prompt* — variando apenas o modelo base. **Registrou-se antes da execução o compromisso de reportar toda réplica treinada, replicasse ela ou não.**

Tabela 15 – Replicação do ajuste fino em três famílias

Braço	Modelo base	*Tokenizador*	XSD-Val	Itens	DF-F1
A4	Qwen2.5-Coder-7B	151.665	**86,8%**	46/53	0,1114
X-gr	Granite 4.1-8B	100.352	83,0%	44/53	0,0992
X-mi	MiMo-7B-RL	151.665	83,0%	44/53	0,1009
X-ds	DeepSeek-Coder-6.7B	—	**invalidado** — ver adiante		

Fonte**:** Elaborado pelo autor

Nota**:** Braços exploratórios, fora do conjunto pré-registrado. O X-mi emprega o **mesmo** tokenizador do A4 (`Qwen2Tokenizer`, 151.665 entradas); o X-gr emprega `GPT2Tokenizer` com 100.352. A comparação de *loss* entre vocabulários distintos não é lícita e não é feita.

O método replica. Duas famílias adicionais alcançam 83,0% de validade — rigorosamente o mesmo número, 132 gerações válidas em 159 e 44 itens em 53 — contra 86,8% do Qwen. A diferença de 3,8 pontos corresponde a seis gerações. Nenhuma das réplicas supera o braço original, e nenhuma fracassa: o ajuste fino sobre esta notação não é propriedade de um modelo.

Um controle não planejado tornou-se disponível. O MiMo compartilha com o Qwen **o tokenizador exato**, ao passo que o Granite usa outro, com dois terços do vocabulário. Se a tokenização governasse o comportamento, o MiMo deveria assemelhar-se ao Qwen. Não é o que se observa:

Tabela 16 – Uso da construção de referência por família

Braço	Itens em que emprega `#ref`	Falhas referenciais	Taxa condicional
A4 (Qwen)	45	5	**11,1%**
X-gr (Granite)	23	8	34,8%
X-mi (MiMo)	24	8	33,3%

Fonte**:** Elaborado pelo autor

Nota**:** O X-mi usa o mesmo tokenizador do A4 e comporta-se como o X-gr, que usa outro.

O MiMo comporta-se como o Granite, não como o Qwen. Segue-se que a divergência **não é artefato de tokenização**: é propriedade do pré-treinamento. E as duas estratégias são distintas diante da mesma dificuldade — o Qwen emprega a construção com liberdade e erra pouco; os outros dois a evitam, restringindo-a a cerca de metade dos itens, e erram três vezes mais quando a arriscam. Essa observação só se tornou possível porque ambas as réplicas foram executadas, e ilustra por que o compromisso de reportar réplicas independentemente do desfecho tem valor informativo, e não apenas ético.

Um braço invalidado, e por quê

O braço X-ds, sobre DeepSeek-Coder-6.7B, foi treinado e avaliado antes de constatar-se que seu tokenizador, sob a versão de biblioteca empregada, **não preserva espaços na ida e volta**: `decode(encode(t))` difere de `t`, fragmentando a notação. Treino e avaliação estavam corrompidos pela mesma causa, e por isso o braço é descartado em vez de reportado — seus 75,5% não medem o método. A verificação prévia que ele havia passado testava a coincidência dos identificadores de *token* entre *prompt* e alvo, invariante que se mantém quando ambos são corrompidos do mesmo modo; a verificação foi substituída pelo teste de ida e volta, que é o que de fato importa. O episódio é registrado por três razões: o braço consumiu recursos, sua ausência da tabela precisa de explicação, e a distinção entre "não replicou"e "não foi medido"é justamente o tipo de informação que a omissão destruiria.

Registre-se, por fim, que um quarto braço (X-ms, Mistral-7B) **não foi executado**, conforme regra fixada antes da execução: ele estava previsto apenas como substituto caso o MiMo falhasse em um teste de compatibilidade arquitetural. O MiMo passou, e o substituto não roda.

O resíduo de falhas é predominantemente referencial

Os braços com a notação nos pesos falham pouco e falham de modo **concentrado**. A Tabela 17 decompõe o resíduo.

Duas leituras. A primeira é que o ajuste fino **elimina a falha léxica**: o braço A3, mesmo modelo base com a gramática no *prompt*, falha 66 vezes em 66 por caractere inesperado e nenhuma por referência; os braços ajustados não registram esse erro de modo dominante em nenhum caso. Aprender a notação é, sobretudo, deixar de errar sua superfície.

A segunda é que o resíduo se concentra num único mecanismo: das 38 falhas de

Tabela 17 – Natureza das falhas de *parsing* por braço

Braço	Notação	Itens que falham	Taxa condicional	Erro dominante
A3	no *prompt*	22	—	léxico (66/66)
A4	nos pesos	7/45	15,6%	referência (5/7)
X-gr	nos pesos	9/23	39,1%	referência (8/9)
X-mi	nos pesos	9/24	37,5%	referência (8/9)
X-lc25	nos pesos	6/38	15,8%	referência (3/6)
X-lc50	nos pesos	7/49	14,3%	referência (7/7)

Fonte**:** Elaborado pelo autor

Nota**:** "Itens que falham"é contado sobre os itens em que o braço emitiu ao menos uma referência; a taxa condicional é o quociente. Nos braços ajustados, as falhas são determinísticas por item: as três repetições falham ou acertam em conjunto. O erro dominante "referência"corresponde a `Unresolved DSL ref`.

item somadas nos cinco braços ajustados, **31 são referências não resolvidas** — 82% do total. O modelo emite `#t07` sem jamais ter declarado `#t07`.

A taxa condicional separa-se com nitidez em dois regimes. Entre os braços construídos sobre o Qwen, ela é **estável em 14,3% a 15,8%** apesar de volumes de treino que variam por fator de quatro — o que exclui o volume como explicação. Entre as réplicas em outras famílias, ela sobe para 37,5% e 39,1%, mas sobre uma base muito menor de itens: Granite e MiMo empregam a construção em cerca de metade dos itens em que o Qwen a emprega. O que **não** varia é a natureza do resíduo — referencial em todos os cinco braços.

Diagnóstico do mecanismo: a notação exige antecipação

A causa da falha foi isolada, e não é capacidade do modelo. Na notação avaliada, um nó só pode ser referenciado se houver sido **marcado no momento de sua emissão** com um identificador explícito. Nos dados de treino essa disciplina é perfeita — os 690 exemplos declaram todas as referências que usam, sem uma única exceção — porque foram produzidos por transpilação determinística, que conhece o grafo inteiro antes de escrevê-lo. Um gerador autorregressivo não dispõe dessa informação: das 200 referências do treino, **151 apontam para trás**, a uma distância mediana de 334 caracteres. Para acertá-las, o modelo teria de saber, ao emitir um nó, que um ramo ainda não escrito voltaria a ele.

O mecanismo faz uma predição verificável: se a falha decorre de arestas de retorno, ela deve concentrar-se nos itens cujo modelo de referência contém **ciclo**. A predição confirma-se na direção esperada — todas as falhas referenciais dos três braços ajustados ocorrem em itens com ciclo (5/5 no A4, 8/8 no X-gr, 8/8 no X-mi), e nenhum dos 13 itens acíclicos falhou em

braço algum. O teste, contudo, é **subdimensionado**: 40 dos 53 itens contêm ciclo, de modo que a concentração observada não atinge significância isoladamente ($p = 0{,}23$ no A4 e $p = 0{,}09$ no X-gr e no X-mi, teste exato de Fisher unilateral), e agregar os braços não é lícito, pois compartilham os mesmos itens. A observação vale como corroboração do mecanismo, não como estabelecimento estatístico da associação.

O que o modelo faz, diante disso, é notavelmente sistemático. Ele adota a convenção majoritária do treino — identificadores da forma `#tNN`, que aparecem 753 vezes — e a emprega **posicionalmente**: `#t03` designa a terceira tarefa emitida. Interpretando as referências não resolvidas sob essa regra, e substituindo-as pelo *slug* do rótulo correspondente, obtêm-se documentos válidos em 12 das 15 falhas do A4 e em **24 das 24** tanto do X-gr quanto do X-mi. O modelo não alucina identificadores: ele mantém um esquema coerente que a notação não sabe ler.

Três observações delimitam o alcance dessa análise. Primeira, **a totalidade das falhas referenciais é reparável alterando apenas a forma da referência** — o corpo do documento está correto, e é só o endereçamento que falha. Segunda, o reparo eleva a validade a um teto de 96,2% no A4 e 98,1% no X-gr e no X-mi, mas esse número é um **limite superior** obtido com conhecimento do alvo, e não uma medição de desempenho. Terceira, e mais importante para a honestidade do argumento, o DF-F1 **não tem poder** para confirmar que a referência reparada aponta para o nó semanticamente pretendido: uma aresta de retorno é uma entre dezenas do multiconjunto, e sua realocação quase não move a métrica. De fato, no X-gr o reparo posicional (0,1251) e um reparo arbitrário (0,1247) são indistinguíveis. A evidência sustenta que o esquema do modelo é *sistemático*; não sustenta que seja *correto*.

A consequência de projeto é direta e o custo foi medido. O transpilador já resolve referências **por rótulo**: a resolução tenta o identificador declarado, depois o *slug* do rótulo, depois a declaração adiante. Referenciar os nós pelo rótulo que o próprio modelo acabou de emitir elimina inteiramente a exigência de antecipação, pois o rótulo é conteúdo que já está no contexto do gerador e não precisa ter sido planejado. Reescrevendo o corpus de treino nessa forma, o custo é de **2,31% em *tokens*** — 7,7 *tokens* por exemplo, o que levaria a TCR de aproximadamente 7,0 para 6,8. Contra os 85% de economia que a notação entrega, a troca é praticamente gratuita, e a tensão com o eixo econômico que se poderia supor não se materializa. A hipótese permanece **não testada** — exigiria retreinar sobre o corpus reescrito — e é o trabalho futuro mais bem fundamentado que esta avaliação produziu.

5.6.13 Síntese

A Tabela 18 consolida o estado das hipóteses.

Tabela 18 – Estado das hipóteses pré-registradas

Hipótese	Enunciado	Desfecho
H1	A2 $\geq$ A1 em DF-F1	**Refutada** ($p_{Holm} = 0{,}039$)
H1g	A2g $\geq$ A1g em DF-F1	**Refutada** ($p_{Holm} = 0{,}006$)
H2	A2 $>$ A1 em XSD-Val	**Refutada** (64,8% vs 98,1%)
H3	A4 $\geq$ A2 em DF-F1	Não refutada, não demonstrada ($p_{Holm} = 0{,}25$)
H4	TCR ≥ 2 nos braços DSL	**Confirmada** (TCR ≈ 7)

Fonte**:** Elaborado pelo autor

O conjunto de evidências sustenta uma cadeia argumentativa distinta daquela originalmente antecipada, e mais informativa que ela:

1. Fornecer a notação **no contexto** é inferior a permitir que o modelo emita o formato que já domina — H1, H1g e H2 refutadas, com replicação em duas famílias de modelos.
2. A notação precisa estar **nos pesos**. A progressão 0% $\rightarrow$ 58,5% $\rightarrow$ 86,8%, sobre o mesmo modelo base, mede o quanto se ganha ao mover a especificação do *prompt* para os parâmetros.
3. A desvantagem da DSL concentra-se em **validade sintática**, não em qualidade de modelagem — e é exatamente essa a barreira que o ajuste fino remove, elevando o modelo de 7 bilhões acima do modelo de fronteira instruído por *prompt*.
4. Em **fidelidade topológica** o modelo especializado empata com o modelo de fronteira prompted e não alcança a geração direta de XML. A hipótese H3 não é refutada, mas tampouco demonstrada.
5. A métrica de fidelidade **satura próximo ao ruído**: dois especialistas humanos concordam a 0,1449, e todos os braços operam nessa vizinhança. Comparações de fidelidade acima desse patamar não discriminam qualidade.
6. O ganho econômico é **substancial e não contestado**: 200 *tokens* contra 631, TCR de 6,5, e execução local dispensando modelo de fronteira.

A afirmação que o conjunto sustenta é, portanto, delimitada e verificável: **um modelo de 7 bilhões de parâmetros, especializado ao custo de menos de um dólar e executado em *hardware* de consumidor, produz notação válida com mais confiabilidade do que um modelo de fronteira instruído por *prompt*, com fidelidade estatisticamente indistinguível deste e a um terço do custo de saída da geração direta de XML.** Não se afirma superioridade sobre a

geração direta de XML por modelo de fronteira — os dados não a sustentam, e a Seção 5.6.10 indica que a métrica disponível dificilmente sustentaria tal afirmação para método algum.

Reitera-se o compromisso registrado no pré-registro e agora exercido em ambas as direções: das cinco hipóteses, três foram refutadas, uma ficou indeterminada e uma foi confirmada. Todas são reportadas como tais.

Fora do conjunto pré-registrado, e portanto sem força confirmatória, dois achados exploratórios orientam o que vem depois. A curva de aprendizado (Seção 5.6.12) indica que **mais dados da mesma fonte não elevam as métricas da tarefa**, ainda que reduzam a *loss* de validação — o que desloca o esforço de coleta para fontes distintas, e não para mais volume. E o resíduo de falhas do modelo especializado é **predominantemente referencial**, concentrando-se num traço de projeto da notação que o transpilador já sabe dispensar. Nenhum dos dois é resultado deste trabalho no sentido confirmatório; ambos são hipóteses agora fundamentadas em medição.

6 CONCLUSÕES E TRABALHOS FUTUROS

O objetivo geral deste trabalho (Seção 1.2.1) foi investigar se a geração de uma representação intermediária comprimida, seguida de expansão determinística, produz modelos BPMN 2.0 válidos de forma mais confiável e mais econômica em *tokens* do que a geração direta de XML. A resposta obtida é **parcialmente afirmativa, e sua parte negativa é tão informativa quanto a positiva**.

Quanto à economia, a resposta é inequívoca: a representação proposta reduz em cerca de 85% o volume de *tokens* que o modelo precisa emitir, com razão de compressão em torno de 7 medida sobre as saídas efetivamente geradas. Quanto à confiabilidade, a resposta depende de como a representação chega ao modelo. Fornecida por *prompt*, ela **piora** o resultado: os braços que descrevem a gramática no contexto obtiveram 64,8% e 56,6% de validade, contra 98,1% e 94,3% da geração direta de XML pelos mesmos modelos. Internalizada nos pesos por ajuste fino supervisionado, ela **melhora substancialmente**: um modelo de sete bilhões de parâmetros atingiu 86,8% de validade, superando em vinte e dois pontos percentuais o modelo de fronteira instruído pela mesma gramática, ainda que sem alcançar a geração direta de XML.

A explicação para essa assimetria organiza os achados do trabalho. A serialização XML da BPMN é verbosa, mas está amplamente representada no pré-treinamento dos modelos de linguagem; a linguagem proposta é compacta, porém inteiramente nova para eles. Verbosidade não constitui dificuldade para quem já viu o formato milhões de vezes — novidade, sim. Segue-se que o benefício de uma representação intermediária compacta não se realiza por instrução em contexto, e sim por especialização do modelo, o que reposiciona o ajuste fino de etapa acessória a condição necessária da abordagem.

6.1 CONTRIBUIÇÕES DO TRABALHO

Artefato técnico. Uma linguagem de domínio específico para descrição de processos, com gramática EBNF formalmente especificada, e um transpilador determinístico que a expande em XML BPMN 2.0. Sobre as 1.021 amostras ativas, a cadeia produz 100% de documentos válidos contra o esquema oficial da OMG e preserva a equivalência topológica em 99,6% dos casos, com resíduo composto exclusivamente por arestas excedentes — isto é, o modo de falha remanescente nunca descarta lógica do processo de origem.

Evidência empírica sobre representações intermediárias. Três hipóteses foram refutadas com significância estatística e replicação em duas famílias de modelos: descrever uma

notação nova em *prompt* é inferior a deixar o modelo emitir o formato que já domina, tanto em fidelidade quanto em validade. Resultados negativos dessa natureza raramente são publicados, e sua ausência na literatura leva projetos a repetirem a mesma tentativa. O pré-registro do protocolo (Seção 4.2), prática incomum em trabalhos de conclusão de curso, é o que tornou esse relato possível sem suspeita de racionalização posterior.

Viabilidade econômica da especialização. O modelo ajustado emite 200 *tokens* medianos contra 631 da geração direta, executa em placa gráfica de consumidor e custou menos de um dólar para ser treinado; o patamar de validade que alcança foi replicado, em verificação exploratória, em duas famílias adicionais de modelos (Seção 5.6.12). Sua fidelidade topológica é estatisticamente indistinguível da obtida por um modelo de fronteira operado por *prompt*. A afirmação sustentada pelos dados não é de superioridade absoluta, e sim de posição favorável na fronteira entre custo e qualidade.

Contribuição metodológica. Mediu-se o **teto humano** da métrica de fidelidade adotada (Seção 5.6.10): duas referências de especialista para o mesmo processo concordam entre si em DF-F1 de apenas 0,1449, e em apenas 30,5% dos rótulos. Todos os métodos avaliados operam nessa vizinhança, e apenas um deles — a geração direta de XML pelo modelo de fronteira independente — a ultrapassa. Decorre daí que **métricas estruturais com identidade de nó por rótulo saturam próximo ao ruído** quando aplicadas a uma tarefa sem resposta única, e que reportá-las contra um máximo teórico de 1,0 conduz a interpretação sistematicamente pessimista. Essa observação não depende da BPMN nem da linguagem aqui proposta, e é possivelmente a contribuição de maior alcance do trabalho.

6.2 LIMITAÇÕES

Validade externa do conjunto de treino. 95,3% das amostras de treinamento provêm de uma única fonte, o *handbook* corporativo da GitLab (Seção 5.1). O modelo especializado é, portanto, treinado predominantemente sobre o estilo redacional de uma organização e avaliado contra um conjunto de domínio distinto. Ampliar o volume só reduz esse risco se as amostras vierem de fontes novas.

Replicação do ajuste fino apenas exploratória. O patamar de validade do modelo especializado foi replicado em duas famílias adicionais de modelos — Granite e MiMo, com 83,0% de validade em ambas contra 86,8% do braço principal (Seção 5.6.12) —, de modo que a alegação não repousa sobre família única. As réplicas foram, contudo, executadas como braços

exploratórios, fora do protocolo pré-registrado, e não carregam força confirmatória. O espaço de modelos tampouco se esgota nelas: o braço sobre uma quarta família foi invalidado por defeito de tokenização antes de qualquer medição, e o comportamento referencial divergiu entre as famílias — a taxa condicional de falha, estável entre 14% e 16% na família do modelo principal, sobe a 37–39% nas outras duas —, indício de que parte do resultado é propriedade do pré-treinamento, e não do método.

Teto imposto pelos dados de treinamento. A saída do próprio *pipeline* de geração de dados, pontuada contra as referências, alcança DF-F1 de 0,1533 (Seção 5.6.11). Um modelo que aprendesse o conjunto de treinamento com fidelidade perfeita não superaria esse valor, o que limita superiormente qualquer ganho atribuível ao ajuste fino sob os dados atuais.

Limitações da métrica primária. Além da saturação já discutida, oito dos cinquenta e três itens de avaliação produzem DF-F1 nulo em **todos** os braços, incluindo os de geração direta de XML. A causa é convenção de nomenclatura: essas referências nomeiam atividades como orações em terceira pessoa com o ator por sujeito, ao passo que o protocolo instrui a forma imperativa. Como o casamento de rótulos não aplica radicalização morfológica, a similaridade fica estruturalmente abaixo do limiar. O efeito é uniforme entre braços e não altera ordenação alguma, mas deprime todos os valores absolutos em cerca de 18%.

Eixo de fluxos de mensagem não avaliável. Apenas dois dos cinquenta e três itens possuem `messageFlow` na referência (Seção 5.6.9), o que impede qualquer inferência sobre a capacidade de modelar comunicação entre participantes.

Dimensão do conjunto de avaliação. Com $n = 53$ itens e variância elevada, os contrastes têm potência estatística modesta. A ordenação entre braços chegou a inverter-se entre o conjunto completo e o subconjunto com referência múltipla, o que recomenda cautela na leitura de diferenças pequenas.

6.3 TRABALHOS FUTUROS

Refinamento do casamento de rótulos. Radicalização morfológica e remoção de ator no início do rótulo endereçam diretamente a limitação mais severa identificada, e podem ser avaliadas como verificação de robustez sobre múltiplos limiares, preservando-se o valor congelado como número primário. Alterar o limiar após observar que a métrica produz valores baixos elevaria indistintamente todos os braços, motivo pelo qual não foi feito neste trabalho.

Convenção de referência por rótulo na notação. A classe dominante de falha dos

modelos ajustados foi localizada num traço de projeto da notação: um nó só pode ser referenciado se houver sido marcado com identificador no momento de sua emissão, e 151 das 200 referências do conjunto de treino apontam para trás — o que exige de um gerador autorregressivo antecipar ramos ainda não escritos (Seção 5.6.12). Referenciar os nós pelo rótulo, forma que o transpilador já aceita e cujo custo medido é de 2,31% em *tokens*, eliminaria essa exigência; avaliá-la, porém, exige retreinar sobre o corpus reescrito, e é a extensão mais bem fundamentada que esta avaliação produziu.

Ampliação do corpus por fontes distintas. A curva de aprendizado executada sobre frações aninhadas do conjunto (25%, 50% e 100%) mostrou que a perda de validação melhora monotonicamente com o volume, mas as métricas da tarefa não a acompanham — mais dados da mesma fonte compram verossimilhança, não capacidade (Seção 5.6.12). A questão que permanece em aberto é o efeito de **fontes novas**, que combinam volume com diversidade estilística, sobre um treino hoje concentrado em 95,3% num único *handbook* (Seção 5.1).

Aprendizado por reforço com recompensa verificável. A etapa prevista na Seção 4.8.2 permanece como extensão, com a ressalva ali registrada: a recompensa restrita a componentes verificáveis sem referência é explorável, pois premia a emissão da menor saída sintaticamente válida. Seu reparo exige um termo de ancoragem no texto de origem, cuja calibração constitui contribuição autônoma.

Decodificação restrita como linha de base concorrente. Garantir conformidade sintática durante a geração é alternativa direta ao que o ajuste fino alcançou aqui por outro caminho, e o contraste entre as duas estratégias — uma que restringe o espaço de saída, outra que o internaliza — não foi avaliado.

Generalização para além da BPMN. A hipótese que motivou o trabalho é independente do domínio: aplica-se a qualquer esquema formal cuja serialização oficial seja verbosa. Avaliar o mesmo protocolo sobre outra linguagem de marcação testaria se o padrão observado — benefício condicionado à internalização da notação nos pesos — é propriedade geral da abordagem ou particularidade da BPMN.

REFERÊNCIAS

AA, H. van der *et al.* Challenges and opportunities of applying natural language processing in business process management. In: *Proceedings of the 27th International Conference on Computational Linguistics*. Santa Fe, New Mexico, USA: Association for Computational Linguistics, 2018. p. 2791–2801. Disponível em: <https://aclanthology.org/C18-1236/>.

AALST, W. M. P. van der. **Process Mining: Data Science in Action**. 2. ed. Berlin, Heidelberg: Springer, 2016.

AALST, W. M. P. van der; WEIJTERS, T.; MARUSTER, L. Workflow mining: Discovering process models from event logs. **IEEE Transactions on Knowledge and Data Engineering**, v. 16, n. 9, p. 1128–1142, 2004.

BELCAK, P.; HEINRICH, G.; DIAO, S.; FU, Y.; DONG, X.; MURALIDHARAN, S.; LIN, Y. C.; MOLCHANOV, P. Small language models are the future of agentic AI. **arXiv preprint arXiv:2506.02153**, 2025. Disponível em: <https://arxiv.org/abs/2506.02153>.

BELLAN, P.; AA, H. van der; DRAGONI, M.; GHIDINI, C.; PONZETTO, S. P. PET: An annotated dataset for process extraction from natural language text tasks. In: **Business Process Management Workshops: BPM 2022 International Workshops**. Cham: Springer, 2023. (Lecture Notes in Business Information Processing, v. 460), p. 315–321. Disponível em: <https://link.springer.com/chapter/10.1007/978-3-031-25383-6_23>.

BRISSARD, A.; CUPPENS, F.; ZOUAQ, A. **PMo Dataset**. Zenodo, 2025. Version 1.0.0. Disponível em: <https://zenodo.org/records/15857589>. Acesso em: 17 maio 2026.

BRISSARD, A.; CUPPENS, F.; ZOUAQ, A. What is the best process model representation? a comparative analysis for process modeling with large language models. In: **Proceedings of the AI4BPM Workshop at BPM 2025**. [S.l.: s.n.], 2025. Aceito para publicação; pré-print em arXiv:2507.11356.

BROWN, T. B.; MANN, B.; RYDER, N.; SUBBIAH, M. *et al.* Language models are few-shot learners. In: **Advances in Neural Information Processing Systems (NeurIPS)**. [s.n.], 2020. v. 33, p. 1877–1901. Disponível em: <https://proceedings.neurips.cc/paper/2020/hash/1457c0d6bfcb4967418bfb8ac142f64a-Abstract.html>.

CHEN, M.; TWOREK, J.; JUN, H.; YUAN, Q.; PINTO, H. Ponde de O. *et al.* Evaluating large language models trained on code. **arXiv preprint arXiv:2107.03374**, 2021. Disponível em: <https://arxiv.org/abs/2107.03374>.

COOTER, M. **Anthropic's AI services are too expensive, says Microsoft AI head**. 2026. CIO. Disponível em: <https://www.cio.com/article/4181777/anthropics-ai-services-are-too-expensive-says-microsoft-ai-head.html>. Acesso em: 6 set. 2026.

DETTMERS, T.; PAGNONI, A.; HOLTZMAN, A.; ZETTLEMOYER, L. QLoRA: Efficient finetuning of quantized LLMs. In: **Advances in Neural Information Processing Systems (NeurIPS)**. [s.n.], 2023. v. 36. Disponível em: <https://proceedings.neurips.cc/paper_files/paper/2023/hash/1feb87871436031bdc0f2beaa62a049b-Abstract.html>.

DIJKMAN, R.; DUMAS, M.; DONGEN, B. van; KÄÄRIK, R.; MENDLING, J. Similarity of business process models: Metrics and evaluation. **Information Systems**, v. 36, n. 2, p. 498–516, 2011.

DUMAS, M.; ROSA, M. L.; MENDLING, J.; REIJERS, H. A. **Fundamentals of Business Process Management**. 2. ed. Berlin, Heidelberg: Springer, 2018. Disponível em: <https://link.springer.com/book/10.1007/978-3-662-56509-4>.

FOWLER, M. **Domain-Specific Languages**. 1. ed. Boston: Addison-Wesley Professional, 2010. ISBN 978-0-321-71294-3. Disponível em: <https://www.informit.com/store/domain-specific-languages-9780321712943>.

FRIEDRICH, F.; MENDLING, J.; PUHLMANN, F. Process model generation from natural language text. In: **Advanced Information Systems Engineering**. Berlin, Heidelberg: Springer, 2011. (Lecture Notes in Computer Science, v. 6741), p. 482–496. Disponível em: <https://link.springer.com/chapter/10.1007/978-3-642-21640-4_36>.

GAO, X.; XIAO, B.; TAO, D.; LI, X. A survey of graph edit distance. **Pattern Analysis and Applications**, v. 13, n. 1, p. 113–129, 2010. Disponível em: <https://link.springer.com/article/10.1007/s10044-008-0141-y>.

Headroom Labs. **Headroom: Compress Tool Outputs, Logs, Files, and RAG Chunks Before They Reach the LLM**. 2026. <https://github.com/headroomlabs-ai/headroom>. Versão 0.27.0. Software de código aberto, licença Apache-2.0. Disponível em: <https://github.com/headroomlabs-ai/headroom>. Acesso em: 8 ago. 2026.

HU, E. J.; SHEN, Y.; WALLIS, P.; ALLEN-ZHU, Z.; LI, Y.; WANG, S.; WANG, L.; CHEN, W. LoRA: Low-rank adaptation of large language models. In: **International Conference on Learning Representations (ICLR)**. [s.n.], 2022. Disponível em: <https://openreview.net/forum?id=nZeVKeeFYf9>.

HUI, B.; YANG, J.; CUI, Z.; YANG, J.; LIU, D.; ZHANG, L.; LIU, T.; ZHANG, J.; YU, B.; LU, K. *et al.* Qwen2.5-Coder technical report. **arXiv preprint arXiv:2409.12186**, 2024. Disponível em: <https://arxiv.org/abs/2409.12186>.

JIANG, H.; WU, Q.; LIN, C.-Y.; YANG, Y.; QIU, L. LLMLingua: Compressing prompts for accelerated inference of large language models. In: **Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing (EMNLP)**. Singapore: [s.n.], 2023. p. 13358–13376. Disponível em: <https://aclanthology.org/2023.emnlp-main.825/>.

KÖPKE, J.; SAFAN, A. Efficient LLM-based conversational process modeling. In: **Business Process Management Workshops (BPM 2024)**. Cham: Springer, 2025. (Lecture Notes in Business Information Processing, v. 534).

KOURANI, H.; BERTI, A.; SCHUSTER, D.; AALST, W. M. P. van der. ProMoAI: Process modeling with generative AI. In: **Proceedings of the Thirty-Third International Joint Conference on Artificial Intelligence (IJCAI-24), Demo Track**. International Joint Conferences on Artificial Intelligence Organization, 2024. p. 8708–8712. Disponível em: <https://www.ijcai.org/proceedings/2024/1014>.

MANGLER, J.; KLIEVTSOVA, N. **Textual Process Descriptions and Corresponding BPMN Models**. Zenodo, 2023. Version 1.0. Disponível em: <https://zenodo.org/records/7783492>. Acesso em: 17 maio 2026.

MERNIK, M.; HEERING, J.; SLOANE, A. M. When and how to develop domain-specific languages. **ACM Computing Surveys**, v. 37, n. 4, p. 316–344, 2005. Disponível em: <https://dl.acm.org/doi/10.1145/1118890.1118892>.

Object Management Group. **Business Process Model and Notation (BPMN), Version 2.0**. Needham, MA, USA, 2011. Documento OMG formal/2011-01-03. Disponível em: <https://www.omg.org/spec/BPMN/2.0/>.

OUYANG, L.; WU, J.; JIANG, X.; ALMEIDA, D.; WAINWRIGHT, C.; MISHKIN, P. *et al.* Training language models to follow instructions with human feedback. In: **Advances in Neural Information Processing Systems (NeurIPS)**. [s.n.], 2022. v. 35. Disponível em: <https://proceedings.neurips.cc/paper_files/paper/2022/hash/b1efde53be364a73914f58805a001731-Abstract.html>.

POESIA, G.; POLOZOV, A.; LE, V.; TIWARI, A.; SOARES, G.; MEEK, C.; GULWANI, S. Synchromesh: Reliable code generation from pre-trained language models. In: **International Conference on Learning Representations (ICLR)**. [s.n.], 2022. Disponível em: <https://openreview.net/forum?id=KmtVD97J43e>.

ROPEK, L. **Uber caps employee AI spending after blowing through budget in four months**. 2026. TechCrunch. Disponível em: <https://techcrunch.com/2026/06/02/uber-caps-employee-ai-spending-after-blowing-through-budget-in-four-months/>. Acesso em: 6 set. 2026.

SANFELIU, A.; FU, K.-S. A distance measure between attributed relational graphs for pattern recognition. **IEEE Transactions on Systems, Man, and Cybernetics**, SMC-13, n. 3, p. 353–362, 1983.

SENNRICH, R.; HADDOW, B.; BIRCH, A. Neural machine translation of rare words with subword units. In: **Proceedings of the 54th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)**. Berlin, Germany: Association for Computational Linguistics, 2016. p. 1715–1725. Disponível em: <https://aclanthology.org/P16-1162/>.

SHAO, Z.; WANG, P.; ZHU, Q.; XU, R.; SONG, J.; BI, X.; ZHANG, H.; ZHANG, M.; LI, Y. K.; WU, Y.; GUO, D. DeepSeekMath: Pushing the limits of mathematical reasoning in open language models. **arXiv preprint arXiv:2402.03300**, 2024. Disponível em: <https://arxiv.org/abs/2402.03300>.

SUGIYAMA, K.; TAGAWA, S.; TODA, M. Methods for visual understanding of hierarchical system structures. **IEEE Transactions on Systems, Man, and Cybernetics**, v. 11, n. 2, p. 109–125, 1981.

VASWANI, A.; SHAZEER, N.; PARMAR, N.; USZKOREIT, J.; JONES, L.; GOMEZ, A. N.; KAISER, Ł.; POLOSUKHIN, I. Attention is all you need. In: **Advances in Neural Information Processing Systems (NeurIPS)**. [s.n.], 2017. v. 30. Disponível em: <https://papers.nips.cc/paper/7181-attention-is-all-you-need>.

VOELTER, M.; HADIAN, R.; KAMPIK, T.; BREITMAYER, M.; REICHERT, M. **Leveraging Generative AI for Extracting Process Models from Multimodal Documents**. 2024.

WEIDLICH, M.; MENDLING, J.; WESKE, M. Efficient consistency measurement based on behavioral profiles of process models. **IEEE Transactions on Software Engineering**, v. 37, n. 3, p. 410–429, 2011.

WESKE, M. **Business Process Management: Concepts, Languages, Architectures**. 3. ed. Berlin, Heidelberg: Springer, 2019. Disponível em: <https://link.springer.com/book/10.1007/978-3-662-59432-2>.

ZHA, H.; WANG, J.; WEN, L.; WANG, C.; SUN, J. A workflow net similarity measure based on transition adjacency relations. **Computers in Industry**, v. 61, n. 5, p. 463–471, 2010.