

FUNDAÇÃO EDSON QUEIROZ
UNIVERSIDADE DE FORTALEZA - UNIFOR
CENTRO DE CIÊNCIAS TECNOLÓGICAS
CURSO DE GRADUAÇÃO EM ENGENHARIA DA COMPUTAÇÃO

COMPRESSÃO SEMÂNTICA NA GERAÇÃO DE MODELOS BPMN 2.0 POR MODELOS DE LINGUAGEM: DSL E TRANSPILAÇÃO DETERMINÍSTICA

RAFAEL MARINS FLORENZANO

FORTALEZA – CEARÁ
2026

RAFAEL MARINS FLORENZANO

COMPRESSÃO SEMÂNTICA NA GERAÇÃO DE MODELOS BPMN 2.0 POR MODELOS DE LINGUAGEM: DSL E TRANSPILAÇÃO DETERMINÍSTICA

Trabalho de Conclusão de Curso apresentado ao Curso de Graduação em Engenharia da Computação do Centro de Ciências Tecnológicas da Universidade de Fortaleza, como requisito parcial à obtenção do grau de bacharel em Engenharia da Computação.

Orientador: Prof. Caio Marques

FORTALEZA – CEARÁ

2026

A ficha catalográfica deve ser gerada no site da biblioteca da Unifor através do link https://goo.gl/XYUWSC (link encurtado).

Preencha o formulário com as informações solicitadas e ao final será gerado um arquivo PDF da ficha catalográfica a ser anexada na versão final do TCC.

O arquivo PDF deve ser renomeado para "ficha-catalografica.pdf" (sem aspas) e colocado no diretório "elementos-pre-textuais" (sem aspas) do modelo de TCC da Unifor.

Ficha catalográfica da obra elaborada pelo autor através do programa de geração automática da Biblioteca Central da Universidade de Fortaleza

---

Batista, Bruno .
TEORIA DA RELATIVIDADE: SUBTÍTULO / Bruno Batista, Sandra Lima. - 2017
40 f.

Trabalho de Conclusão de Curso (Graduação) - Universidade de Fortaleza. Curso de Ciência da Computação, Fortaleza, 2017.
Orientação: Liadina Camargo.

1. FÍSICA. 2. RELATIVIDADE. 3. TEMPO. 4. ESPAÇO. I. Lima, Sandra. II. Camargo, Liadina. III. Título.

RAFAEL MARINS FLORENZANO

COMPRESSÃO SEMÂNTICA NA GERAÇÃO DE MODELOS BPMN 2.0 POR MODELOS DE LINGUAGEM: DSL E TRANSPILAÇÃO DETERMINÍSTICA

Trabalho de Conclusão de Curso apresentado ao Curso de Graduação em Engenharia da Computação do Centro de Ciências Tecnológicas da Universidade de Fortaleza, como requisito parcial à obtenção do grau de bacharel em Engenharia da Computação.

Aprovada em:

BANCA EXAMINADORA

Prof. Caio Marques (Orientador)
Centro de Ciências Tecnológicas - CCT
Universidade de Fortaleza - UNIFOR

Membro da Banca Dois
Centro de Ciências e Tecnologia - CCT
Universidade do Membro da Banca Dois - SIGLA

Membro da Banca Três
Centro de Ciências e Tecnologia - CCT
Universidade do Membro da Banca Três - SIGLA

Membro da Banca Quatro
Centro de Ciências e Tecnologia - CCT
Universidade do Membro da Banca Quatro - SIGLA

RESUMO

Este trabalho investiga se a geração de uma representação intermediária comprimida, seguida de expansão determinística, produz modelos BPMN 2.0 válidos de forma mais confiável e mais econômica do que a geração direta de XML por modelos de linguagem. Projetou-se uma linguagem de domínio específico com gramática EBNF formalmente especificada e um transpilador determinístico que a expande em XML validado contra o esquema oficial da OMG. Construiu-se um corpus de 1.021 processos a partir de fontes públicas de descrições textuais e especializou-se um modelo de sete bilhões de parâmetros por ajuste supervisionado com adaptação de baixo posto sobre pesos quantizados. A avaliação seguiu protocolo definido antes da execução, com 53 processos de referência modelados por especialistas e três repetições por item. O componente determinístico produziu XML válido em 100% das amostras e preservou a equivalência topológica em 99,6%, e a representação proposta mostrou-se seis vezes mais compacta que o XML lógico equivalente. Na primeira versão da notação, descrita no *prompt*, modelos de fronteira (DeepSeek e GLM) produziram saída válida em 64,8% e 56,6% das gerações, respectivamente, contra 98,1% e 94,3% da geração direta de XML pelos mesmos modelos, contrariando a hipótese principal. A análise das falhas atribuiu a maior parte delas não à novidade da linguagem, mas a um traço de seu desenho: referenciar um elemento exigia marcá-lo no momento em que era escrito, antecipando ramos ainda não gerados. Acrescentada a referência pelo rótulo de elementos já escritos, em emenda posterior à observação dos resultados e de valor exploratório, o mesmo modelo atingiu 86,8% de validade, com fidelidade topológica estatisticamente indistinguível da geração direta de XML e custo por requisição 47% menor. O modelo pequeno especializado, sem a gramática no contexto, alcançou os mesmos 86,8%, patamar replicado em 83,0% sobre duas famílias adicionais de modelos, com fidelidade inferior à do modelo de fronteira e custo por requisição de duas a quatro vezes menor sob preço de mercado, após treinamento de menos de um dólar. Mediu-se ainda a concordância entre especialistas distintos para um mesmo processo, com F1 estrutural de 0,1449, patamar em que operam todos os métodos avaliados: métricas estruturais que identificam nós por rótulo saturam próximo ao ruído e não devem ser lidas como percentual de acerto. Conclui-se que notações destinadas a modelos autorregressivos devem permitir referência ao que já foi escrito e que, satisfeita essa condição, o ajuste fino de um modelo pequeno é uma troca de custo por fidelidade, e não condição de viabilidade da abordagem.

Palavras-chave: BPMN; linguagem de domínio específico; modelos de linguagem; ajuste fino supervisionado; compressão de *tokens*.

ABSTRACT

This work investigates whether generating a compressed intermediate representation, followed by deterministic expansion, yields valid BPMN 2.0 models more reliably and more economically than direct XML generation by language models. A domain-specific language with a formally specified EBNF grammar was designed, together with a deterministic transpiler that expands it into XML validated against the official OMG schema. A corpus of 1,021 processes was built from public sources of textual process descriptions, and a seven-billion-parameter model was specialized through supervised fine-tuning with low-rank adaptation over quantized weights. The evaluation followed a protocol defined before execution, with 53 reference processes modeled by experts and three repetitions per item. The deterministic component produced valid XML for 100% of the samples and preserved topological equivalence in 99.6%, and the proposed representation proved six times more compact than the equivalent logical XML. In the first version of the notation, described in the prompt, frontier models (DeepSeek and GLM) produced valid output in 64.8% and 56.6% of generations, respectively, against 98.1% and 94.3% for direct XML generation by the same models, contrary to the main hypothesis. Failure analysis traced most of these failures not to the novelty of the language but to a feature of its design: referencing an element required marking it at the moment it was written, anticipating branches not yet generated. Once references by the label of already-written elements were added, in an amendment made after the results were observed and of exploratory value, the same model reached 86.8% validity, with topological fidelity statistically indistinguishable from direct XML generation and a 47% lower cost per request. The specialized small model, without the grammar in context, reached the same 86.8%, a level replicated at 83.0% across two additional model families, with lower fidelity than the frontier model and a cost per request two to four times lower at market prices, after training that cost less than one dollar. Agreement between different experts modeling the same process was also measured, yielding a structural F1 of 0.1449, the range in which all evaluated methods operate: structural metrics that identify nodes by label saturate close to noise and should not be read as percentage of correctness. The conclusion is that notations meant for autoregressive models should allow references to what has already been written and that, once this condition holds, fine-tuning a small model is a trade of cost for fidelity rather than a condition for the viability of the approach.

Keywords: BPMN; domain-specific language; language models; supervised fine-tuning; token compression.

LISTA DE ILUSTRAÇÕES

Figura 1 – Visão geral: construção do corpus e avaliação 37
Figura 2 – Validade sintática por braço experimental 66
Figura 3 – Perdas de treino e de validação no ajuste supervisionado 70
Figura 4 – Custo por requisição contra validade sintática, por braço 72
Figura 5 – Saturação do DF-F1 conforme o casamento de rótulos é afrouxado . . . 80
Figura 6 – Divergência de nomenclatura sem divergência de estrutura (*pmo_52*) . 81
Figura 7 – Fidelidade topológica por braço, relativa à concordância entre especialistas 84

LISTA DE TABELAS

Tabela 1 – Fontes de dados e uso no trabalho 37
Tabela 2 – Configuração do ajuste supervisionado 44
Tabela 3 – Braços experimentais 45
Tabela 4 – Preços usados no cálculo do custo (US$ por milhão de *tokens*) 48
Tabela 5 – Validação por perturbação controlada 51
Tabela 6 – Desvios do protocolo inicial 55
Tabela 7 – Distribuição do corpus por partição 61
Tabela 8 – Fidelidade topológica por versão do conversor 63
Tabela 9 – Panorama dos braços executados 65
Tabela 10 – Contrastes pré-registrados 67
Tabela 11 – Contrastes com o braço A2r (exploratório) 68
Tabela 12 – Contraste restrito aos itens com saída válida (exploratório) 69
Tabela 13 – Braço A3 antes e depois da emenda ao *prompt* 74
Tabela 14 – Braço A2 contra A2r 76
Tabela 15 – Compressão e custo de saída por braço 77
Tabela 16 – Custo por requisição 78
Tabela 17 – MF-F1 restrito aos dois itens com fluxo de mensagem na referência . . 82
Tabela 18 – Desempenho relativo ao teto humano (24 itens com referência múltipla) 83
Tabela 19 – Oráculo do pipeline de augmentation contra o *gold* 85
Tabela 20 – Curva de aprendizado sobre subconjuntos aninhados do treino 88
Tabela 21 – Replicação do ajuste fino em três famílias 89
Tabela 22 – Uso da construção de referência por família 89
Tabela 23 – Natureza das falhas de *parsing* por braço 90
Tabela 24 – Estado das hipóteses registradas 93

LISTA DE CÓDIGOS-FONTE

Código-fonte 1 – Processo com decisão e repetição na BPMN-DSL 41
Código-fonte 2 – XML gerado pelo transpilador a partir do Código 1 41

LISTA DE SÍMBOLOS

$\mathscr{R}$	Multiconjunto *direct-follows* do modelo de referência
$\mathscr{C}$	Multiconjunto *direct-follows* do modelo candidato
P	Precisão sobre o multiconjunto *direct-follows*
R	Revocação sobre o multiconjunto *direct-follows*
(a,b)	Par de atividades em que a é diretamente seguida por b
n	Número de itens do conjunto de avaliação
k	Número de repetições de geração por item
p	Valor-p do teste de Wilcoxon pareado
p_{Holm}	Valor-p após correção de Holm para múltiplas comparações
r_{rb}	Tamanho de efeito *rank-biserial*
r	Recompensa composta
r'	Recompensa restrita a componentes verificáveis sem referência
r_{sint}	Componente de validade sintática da recompensa
r_{sem}	Componente de adequação semântica da recompensa
r_{topo}	Componente de coerência topológica da recompensa
r_{comp}	Componente de economia de *tokens* da recompensa
α	Algoritmo α de descoberta de processos

SUMÁRIO

1 INTRODUÇÃO 16
1.1 MOTIVAÇÃO 19
1.2 OBJETIVOS 20
1.2.1 Objetivo Geral 20
1.2.2 Objetivos Específicos 20
1.3 ORGANIZAÇÃO DO TRABALHO 20
2 FUNDAMENTAÇÃO TEÓRICA 22
2.1 MODELAGEM DE PROCESSOS DE NEGÓCIO E A NOTAÇÃO BPMN 2.0 22
2.1.1 Gerenciamento de Processos de Negócio 22
2.1.2 A Notação BPMN 2.0 23
2.1.3 Representação XML e Verbosidade 23
2.2 MODELOS DE LINGUAGEM DE GRANDE ESCALA 24
2.2.1 Arquitetura Transformer 24
2.2.2 Tokenização e o Custo de Sequências Longas 24
2.2.3 Geração de Saídas Estruturadas 25
2.3 LINGUAGENS DE DOMÍNIO ESPECÍFICO E COMPRESSÃO SEMÂNTICA 25
2.3.1 Linguagens de Domínio Específico 25
2.3.2 Compressão Semântica como Estratégia de Geração 26
2.4 ADAPTAÇÃO DE MODELOS DE LINGUAGEM A TAREFAS ESPECÍFICAS 27
2.4.1 Supervised Fine-Tuning 27
2.4.2 Ajuste com Eficiência de Parâmetros: LoRA e QLoRA 27
2.4.3 Aprendizado por Reforço com GRPO 27
2.5 EXTRAÇÃO DE PROCESSOS A PARTIR DE TEXTO NATURAL 28
2.5.1 Caracterização do Problema 28
2.5.2 Recursos e Datasets Disponíveis 28
2.6 AVALIAÇÃO DE GERAÇÃO DE ARTEFATOS ESTRUTURADOS 29
2.6.1 Validação por Esquema 29
2.6.2 Métricas Sintáticas e Semânticas 29
2.6.3 Distância de Edição em Grafos 30
2.6.4 Eficiência: Razão de Compressão de Tokens 30
2.6.5 Função de Recompensa Composta 30

2.7 SÍNTESE DO CAPÍTULO 31
3 TRABALHOS RELACIONADOS 32
3.1 GERAÇÃO DE MODELOS DE PROCESSO COM LLMS 32
3.2 REPRESENTAÇÕES COMPACTAS DE PROCESSOS 32
3.3 COMPRESSÃO DE *TOKENS*: ENTRADA *VERSUS* SAÍDA 34
3.4 MODELOS PEQUENOS ESPECIALIZADOS 34
3.5 GARANTIA DE VALIDADE SINTÁTICA 35
4 METODOLOGIA 36
4.1 VISÃO GERAL 36
4.2 DADOS 37
4.2.1 Fontes 37
4.2.2 Geração dos pares de treino 38
4.2.3 Partições e prevenção de contaminação 39
4.3 A BPMN-DSL 40
4.4 TRANSPILAÇÃO 42
4.5 ESPECIALIZAÇÃO DO MODELO 43
4.6 BRAÇOS EXPERIMENTAIS 44
4.7 MEDIDAS 46
4.7.1 Validade 47
4.7.2 Custo por requisição 47
4.7.3 Razão de compressão 48
4.7.4 Fidelidade 49
4.7.4.1 O juiz 49
4.7.4.2 Validação contra notas de especialista 50
4.7.4.3 Validação por perturbação controlada 51
4.7.4.4 Uso da medida 52
4.7.5 A medida originalmente prevista: DF-F1 52
4.8 PROTOCOLO E ANÁLISE ESTATÍSTICA 53
4.8.1 Execução 53
4.8.2 Unidade de análise e comparações 53
4.8.3 Equivalência 54
4.8.4 Custo e compressão 54
4.8.5 Estatuto dos resultados 54

4.9 DESVIOS DO PROTOCOLO INICIAL 55
4.9.1 Mudanças nos artefatos 55
4.9.2 Mudanças nos dados 56
4.9.3 Mudanças nas medidas e na análise 57
4.10 AMEAÇAS À VALIDADE 57
4.10.1 Validade interna 58
4.10.2 Validade de construto 58
4.10.3 Validade externa 59
4.10.4 Validade da conclusão 59
5 RESULTADOS 61
5.1 COMPOSIÇÃO DO CORPUS 61
5.2 EIXO 1: VALIDADE SINTÁTICA 62
5.3 EIXO 2: FIDELIDADE TOPOLÓGICA 62
5.3.1 Trajetória entre Versões 62
5.3.2 Análise do Resíduo 63
5.4 EIXO 4: COMPRESSÃO DE *TOKENS* 63
5.5 CONJUNTO DE REFERÊNCIA 64
5.6 AVALIAÇÃO COMPARATIVA DOS BRAÇOS 64
5.6.1 Resultados Descritivos por Braço 65
5.6.2 Testes das Hipóteses Pré-Registradas 67
5.6.3 Análise do Mecanismo: Validade e Não Qualidade 69
5.6.4 O Modelo Especializado 70
5.6.5 Verificações de Validade do Resultado Adverso 73
5.6.6 Emendas ao Protocolo Congelado 73
5.6.7 Eixo Econômico 77
5.6.8 Limitação Relevante da Métrica de Fidelidade 79
5.6.9 Não Avaliabilidade do Eixo de Fluxos de Mensagem 82
5.6.10 Teto Humano da Métrica 83
5.6.11 Validação do Pipeline de Augmentation 85
5.6.12 Braços Exploratórios 87
5.6.13 Síntese 92
6 CONCLUSÕES E TRABALHOS FUTUROS 95
6.1 CONTRIBUIÇÕES DO TRABALHO 95

6.2 LIMITAÇÕES 97
6.3 TRABALHOS FUTUROS 98
REFERÊNCIAS 100

APÊNDICES **103**
APÊNDICE A – Prompts dos braços experimentais 104
APÊNDICE B – Prompts do juiz de fidelidade e da paráfrase 105
APÊNDICE C – Piloto de escolha do modelo gerador 106
APÊNDICE D – Resultados das hipóteses originais 107

1 INTRODUÇÃO

Organizações dependem de processos documentados para operar de forma previsível, treinar pessoas e cumprir exigências regulatórias. A notação BPMN 2.0, padronizada pela Object Management Group (2011), tornou-se a linguagem de referência para essa documentação, com uso consolidado tanto na indústria quanto na literatura de gestão de processos (WESKE, 2019; DUMAS *et al.*, 2018). Na prática, porém, a maior parte do conhecimento sobre processos permanece registrada em linguagem natural: manuais internos, descrições de procedimentos e documentos de política. A conversão desse material em modelos formais continua sendo uma tarefa manual, lenta e dependente de especialistas (FRIEDRICH; MENDLING; PUHLMANN, 2011; AA *et al.*, 2018).

O avanço dos modelos de linguagem de grande porte (VASWANI *et al.*, 2017; BROWN *et al.*, 2020) tornou plausível automatizar essa conversão. A dificuldade está na forma de saída. A serialização XML da BPMN foi concebida para intercâmbio entre ferramentas, não para ser escrita diretamente por pessoas ou por modelos. Ao solicitar que um modelo produza XML BPMN completo, transfere-se a ele uma responsabilidade pouco adequada ao seu funcionamento: reproduzir com precisão um grande volume de marcação técnica, ainda que boa parte dessa marcação possa ser derivada de maneira determinística. O custo aparece em duas frentes. A primeira é econômica e não depende de verificação: cada *token* de marcação repetitiva consome contexto, tempo e dinheiro, e a quantidade emitida é diretamente mensurável. A segunda é de confiabilidade, e tem natureza distinta, é uma **expectativa a ser testada**, não um dado. O risco existe em princípio, pois uma única inconsistência estrutural invalida o documento inteiro; se ele de fato se materializa, e em que medida, é questão empírica. Adianta-se que a resposta obtida neste trabalho contrariou, em parte, a expectativa inicial, e mostrou que o risco depende menos do formato do que de um traço específico do desenho da notação, conforme discutido adiante.

O gargalo prático de sistemas construídos sobre modelos de linguagem não é propriamente o *token*, e sim o custo, que resulta do produto entre o preço unitário do modelo e o volume que se pede a ele que produza. Usarei como exemplo dois episódios de 2026 que definem bem esse problema. A Uber esgotou em quatro meses o orçamento anual destinado a ferramentas de codificação assistida e passou a exigir um teto de US$ 1.500 mensais por funcionário e por ferramenta, diante da dificuldade, reconhecida pela própria diretoria, de ligar o consumo de *tokens* a benefício mensurável (ROPEK, 2026). No mesmo período, a Microsoft cancelou a

maior parte das licenças diretas de assistentes da Anthropic concedidas à sua engenharia e passou a rotear requisições de seus produtos para modelos próprios, declarando como objetivo explícito a redução desse custo (COOTER, 2026). Em nenhum dos casos as ações foram geradas por insuficiência de qualidade: foi o preço de mante-la em escala. Cabe notar que a parcela sobre a qual este trabalho atua é a mais cara das duas. A geração é tarifada, na prática corrente dos provedores, a um múltiplo do preço da entrada, de modo que marcação redundante **emitida** pelo modelo custa várias vezes o que custaria a mesma marcação apenas lida por ele. Sendo o custo um produto de dois fatores, há duas frentes de ataque, e a abordagem investigada aqui atua sobre ambas: emitir menos e emitir com um modelo mais barato mantendo uma qualidade adequada ao problema.

A redução do número de *tokens* nesses sistemas tem sido atacada, contudo, principalmente do lado da entrada. Na pesquisa, o LLMLingua (JIANG *et al.*, 2023) comprime o contexto antes que ele alcance o modelo, com ganhos expressivos e pouca perda de desempenho. Na indústria, ferramentas como o Headroom (Headroom Labs, 2026) aplicam a mesma ideia a saídas de ferramentas, registros e trechos recuperados, relatando reduções entre 60% e 95% em conteúdo estruturado. Essas abordagens confirmam que a economia de *tokens* é uma preocupação concreta e que boa parte dela vem da remoção de repetição estrutural. Nenhuma delas, entretanto, atua sobre o lado da geração, justamente o lado mais caro: fazer com que o próprio modelo emita nativamente uma representação compacta, cuja expansão determinística produza um artefato válido segundo um esquema formal.

Duas linhas de trabalho se aproximam desse objetivo por caminhos distintos. A decodificação restrita, discutida por Poesia *et al.* (2022), garante conformidade sintática durante a geração, mas não reduz o volume que o modelo precisa emitir. Já o ProMoAI, de Kourani *et al.* (2024), gera modelos de processo por meio de uma representação intermediária expandida deterministicamente em BPMN, demonstrando que a estratégia é viável. O trabalho de Kourani *et al.* (2024) apoia-se, contudo, em um modelo de fronteira operado por *prompt* e não trata a representação intermediária como um problema de compressão com taxa medida. É exatamente nesse espaço que esta monografia se posiciona.

A escolha do modelo é um problema também. Belcak *et al.* (2025) argumentam que modelos pequenos e especializados, podem ser uma base adequada para tarefas agênticas repetitivas no lugar de fronteira genéricos, por razões de custo, latência e previsibilidade. Uma representação intermediária suficientemente compacta e regular torna essa especialização viável: reduz o que o modelo precisa aprender a emitir e permite que até mesmo um modelo de sete

bilhões de parâmetros, como o Qwen2.5-Coder (HUI *et al.*, 2024), seja ajustado para a tarefa.

Este trabalho propõe, portanto, um protocolo de compressão semântica para geração de BPMN. Um modelo de linguagem produz uma descrição concisa do processo em uma linguagem de domínio específico projetada para esse fim, e um transpilador baseado em gramática EBNF expande essa descrição em XML BPMN 2.0 validado contra o esquema oficial. A separação de responsabilidades gera um efeito útil para a depuração: quando ocorre uma falha, ela fica localizada na geração da DSL, no transpilador ou na validação, em vez de diluída em um documento XML extenso. Medido sobre 1.021 processos com o tokenizador do Qwen2.5-Coder, o artefato proposto é **seis vezes** mais compacto que o XML lógico correspondente, equivalente a uma redução de 83,4% no número de *tokens* que o modelo precisa emitir, sobre as saídas efetivamente geradas pelos braços experimentais, a razão sobe para cerca de sete.

Os resultados contrariaram em parte as hipóteses registradas antes da execução, e por isso são antecipados aqui.

A primeira versão da notação, descrita no *prompt* de dois modelos de fronteira (DeepSeek e GLM), produziu saída válida em 64,8% e 56,6% das gerações, respectivamente, contra 98,1% e 94,3% da geração direta de XML pelos mesmos modelos. A análise dessas falhas mostrou que a maior parte delas não decorria da novidade da linguagem, e sim de um traço de seu desenho: para referenciar um elemento, a notação exigia marcá-lo com identificador no momento em que era escrito, antes de o modelo saber que um ramo posterior voltaria a ele. Um modelo autorregressivo, que gera da esquerda para a direita sem revisar o que já escreveu, não dispõe dessa informação. Acrescentada à notação a referência pelo rótulo do elemento já escrito, o mesmo modelo de fronteira passou a 86,8% de validade, com fidelidade estatisticamente indistinguível da geração direta de XML. Essa correção foi introduzida depois de observados os resultados e é reportada como emenda ao protocolo, com valor exploratório.

O modelo pequeno chega ao mesmo ponto por outro caminho. Com a notação internalizada nos pesos por ajuste fino, um modelo de sete bilhões de parâmetros atingiu os mesmos 86,8% de validade, sem precisar da gramática no contexto; o mesmo ajuste fino, repetido sobre duas famílias adicionais de modelos, produziu 83,0% em ambas, em verificação exploratória. Em fidelidade estrutural ele é inferior ao modelo de fronteira com a notação corrigida, e a troca que oferece é de custo: sob preço de mercado, cada requisição sai de duas a quatro vezes mais barata. Nenhuma das configurações alcança a validade da geração direta de XML, que permanece em 98,1%.

Registra-se também um achado de ordem metodológica, obtido durante a avaliação

e independente da linguagem proposta: foi medido a concordância entre modelos de referência produzidos por especialistas distintos para o mesmo processo, e ela é baixa. Métricas estruturais que identificam nós por rótulo saturam, por isso, muito abaixo do máximo teórico, e todos os métodos avaliados operam nessa vizinhança. Portanto, os valores absolutos dessas métricas não devem ser lidos como percentual de acerto.

1.1 MOTIVAÇÃO

A modelagem de processos ainda é caro justamente aonde é mais necessário. Empresas que documentam seus processos textualmente raramente dispõe de tempo e recurso especializado para convertê-los em modelos formais, o resultado disso é uma base documental não visual e que não pode ser analisada, simulada ou automatizada. Reduzir o custo e tornar possível a conversão amplia o acesso à modelagem e libera o especialista para focar em ações menos repetitivas e mais estratégicas.

Há ainda uma motivação técnica, e ela independe do desfecho particular observado na BPMN. O padrão de separar a geração de uma representação compacta da expansão determinística em um artefato validável é aplicável a qualquer domínio em que a saída precise obedecer a um esquema formal e a serialização oficial seja verbosa. O que este trabalho tem a oferecer a esses domínios não é apenas a confirmação de um ganho, mas a identificação da **condição** sob a qual ele se realiza: que a notação não exija do gerador antecipar o que ainda não escreveu. A BPMN oferece um caso de teste favorável para essa investigação porque possui esquema oficial, conjuntos de dados públicos com modelos de referência e métricas estruturais bem definidas, o que permite verificação objetiva em vez de avaliação subjetiva.

Por fim, a economia de *tokens* deixou de ser detalhe de implementação. Em fluxos que geram modelos em escala, o custo de emitir marcação redundante é recorrente, e a alternativa de depender continuamente de modelos de fronteira concentra esse custo em um fornecedor externo. Um modelo pequeno ajustado para emitir uma representação comprimida é, nesse cenário, uma resposta de engenharia e não apenas um exercício acadêmico.

1.2 OBJETIVOS

1.2.1 Objetivo Geral

Investigar se a geração de uma representação intermediária comprimida, seguida de expansão determinística, produz modelos BPMN 2.0 válidos de forma mais confiável e mais econômica em *tokens* do que a geração direta de XML por modelos de linguagem.

1.2.2 Objetivos Específicos

a) projetar uma linguagem de domínio específico para descrição de processos BPMN, com gramática EBNF formalmente especificada;
b) implementar um transpilador determinístico que expanda essa linguagem em XML BPMN 2.0 validado contra o esquema oficial;
c) construir um conjunto de dados de pares formados por descrição textual e representação na linguagem proposta, a partir de fontes públicas de descrições de processos;
d) realizar o ajuste fino supervisionado de um modelo de linguagem de pequeno porte para emitir a representação comprimida;
e) quantificar a compressão obtida, o custo por requisição e a fidelidade estrutural dos modelos gerados, comparando a abordagem proposta com a geração direta de XML sob protocolo de avaliação definido previamente à execução dos experimentos.

1.3 ORGANIZAÇÃO DO TRABALHO

O Capítulo 2 reúne os conceitos necessários à proposta: modelagem de processos e a notação BPMN 2.0, funcionamento e limitações dos modelos de linguagem na geração estruturada, linguagens de domínio específico como camada de mediação, e os métodos de adaptação de modelos empregados na etapa experimental.

O Capítulo 3 posiciona a proposta frente à literatura, distinguindo-a tanto das abordagens de compressão de contexto, que atuam sobre a entrada, quanto dos trabalhos que geram modelos de processo por representação intermediária sem tratá-la como problema de compressão com taxa medida.

O Capítulo **??** descreve a linguagem proposta e sua gramática, o transpilador deter-

minístico e o gerador de leiaute, o *pipeline* de construção do conjunto de dados, e o protocolo de avaliação, definido antes da execução dos experimentos, incluindo hipóteses, métricas, braços experimentais e plano de análise estatística.

O Capítulo 5 reporta a verificação do componente determinístico sobre o corpus completo e, em seguida, a avaliação comparativa dos braços experimentais contra modelos de referência produzidos por especialistas, e o custo por requisição de cada abordagem. Reporta também as emendas ao protocolo, as verificações de validade aplicadas aos resultados adversos e as limitações identificadas na própria métrica de fidelidade.

O Capítulo 6 retoma o objetivo geral à luz das evidências, sistematiza as contribuições e as limitações, e enumera as extensões que a investigação deixou em aberto.

2 FUNDAMENTAÇÃO TEÓRICA

O ponto de partida deste trabalho é uma dificuldade prática: gerar XML BPMN 2.0 completo por meio de Modelos de Linguagem de Grande Escala (LLMs, do inglês *Large Language Models*) tende a ser custoso, verboso e sujeito a erros estruturais. Para discutir esse problema, este capítulo reúne os conceitos necessários à proposta de um protocolo de compressão semântica voltado à geração de *markup* XML. A fundamentação começa pela modelagem de processos de negócio e pela notação BPMN 2.0, passa pelos princípios de funcionamento dos LLMs e pelos desafios da geração estruturada, e então discute Linguagens de Domínio Específico (DSLs, do inglês *Domain-Specific Languages*) como mecanismo de mediação entre descrição semântica e representação XML. Em seguida, são apresentados os métodos de adaptação de modelos que sustentam a etapa experimental do projeto, especialmente SFT, LoRA, QLoRA e GRPO. Por fim, o capítulo aborda recursos disponíveis para extração de processos a partir de texto natural e métricas adequadas à avaliação de artefatos estruturados.

2.1 MODELAGEM DE PROCESSOS DE NEGÓCIO E A NOTAÇÃO BPMN 2.0

2.1.1 Gerenciamento de Processos de Negócio

O Gerenciamento de Processos de Negócio (BPM, do inglês *Business Process Management*) trata processos organizacionais como objetos que podem ser descritos, analisados, executados e aperfeiçoados de forma sistemática (DUMAS *et al.*, 2018). Essa área aproxima contribuições da administração, da engenharia de software e da pesquisa operacional, sobretudo quando o processo precisa deixar de ser apenas uma prática informal e passar a funcionar como um artefato verificável (WESKE, 2019).

Essa formalização é importante porque iniciativas de automação, auditoria e conformidade dependem de uma representação compartilhada do processo. Ao mesmo tempo, a notação adotada precisa equilibrar dois requisitos que nem sempre caminham juntos: ser compreensível para analistas e gestores, sem exigir domínio técnico profundo, e preservar precisão suficiente para permitir análise computacional ou execução automatizada. A BPMN se consolidou justamente nesse espaço, oferecendo uma linguagem visual relativamente acessível, mas apoiada por uma especificação formal.

2.1.2 A Notação BPMN 2.0

A *Business Process Model and Notation*, em sua versão 2.0, é mantida pelo *Object Management Group* e é uma das principais referências para a representação de processos de negócio (Object Management Group, 2011). Seu papel é duplo: por um lado, define símbolos gráficos usados por analistas de processo; por outro, estabelece uma serialização XML descrita por um *XML Schema Definition* (XSD). Essa combinação permite que um mesmo modelo seja lido visualmente por pessoas e processado por ferramentas.

Segundo a especificação da BPMN 2.0, os elementos da notação são agrupados em categorias principais Object Management Group (2011):

- **Objetos de fluxo** (*flow objects*): eventos (*events*), atividades (*activities*) e *gateways*, que representam os principais nós do processo;
- **Objetos de conexão** (*connecting objects*): fluxos de sequência, fluxos de mensagem e associações, responsáveis por explicitar relações entre elementos;
- **Raias** (*swimlanes*): *pools* e *lanes*, usadas para indicar participantes, setores ou responsabilidades;
- **Artefatos** (*artifacts*): grupos, anotações textuais e objetos de dados, empregados para acrescentar informação complementar ao modelo.

Com esses elementos, a BPMN permite representar padrões comuns de processos, como decisões exclusivas, execuções paralelas, eventos intermediários e interações entre participantes. A expressividade da notação, no entanto, cobra seu preço: quanto mais completa é a representação, maior tende a ser a complexidade para quem modela, valida ou gera o artefato. Dumas *et al.* (2018) observam que essa riqueza da BPMN exige aprendizado, tanto do analista humano quanto de qualquer sistema que tente manipulá-la automaticamente.

2.1.3 Representação XML e Verbosidade

Na prática, um modelo BPMN 2.0 interoperável costuma ser armazenado em XML conforme o esquema oficial. Essa escolha favorece o intercâmbio entre ferramentas e reduz ambiguidades de implementação, mas produz documentos consideravelmente maiores do que a descrição conceitual do processo. Em um exemplo simples, o XML precisa declarar *namespaces*, identificadores, elementos de diagrama, coordenadas, fluxos, referências cruzadas e atributos previstos pela especificação.

Essa verbosidade não é um problema grave quando o XML é gerado por uma

ferramenta de modelagem. A situação muda quando o alvo de geração passa a ser um LLM. Nesse caso, o modelo precisa emitir uma sequência longa, com muitos trechos repetitivos e com baixa tolerância a pequenos desvios. Uma *tag* ausente, um identificador trocado ou uma referência inconsistente pode invalidar o documento inteiro, mesmo que a estrutura geral do processo tenha sido compreendida corretamente. Esse descompasso entre conteúdo semântico e representação textual motiva a busca por uma camada intermediária mais curta e mais controlável.

2.2 MODELOS DE LINGUAGEM DE GRANDE ESCALA

2.2.1 Arquitetura Transformer

A arquitetura Transformer, proposta por Vaswani *et al.* (2017), marcou uma mudança importante na modelagem de sequências. Em vez de processar a entrada de forma recorrente, o Transformer usa mecanismos de *self-attention* para relacionar diretamente diferentes posições da sequência. Esse desenho favoreceu paralelização em larga escala e abriu caminho para os modelos de linguagem atuais.

Os LLMs mais utilizados seguem, em geral, uma formulação autorregressiva: a cada passo, o modelo estima o próximo *token* a partir dos anteriores. Quando treinados sobre grandes coleções de texto, esses modelos passam a apresentar capacidade de generalização para tarefas variadas, inclusive tarefas que não aparecem explicitamente como objetivos de treinamento (BROWN *et al.*, 2020). Essa flexibilidade explica seu interesse para geração de código, consultas, marcações e outros formatos estruturados. Uma consequência dessa formulação é relevante para formatos estruturados: o modelo gera da esquerda para a direita e não revisa o que já emitiu. Cada *token* é decidido apenas com base no que o precede, de modo que um formato que exija declarar, num ponto do texto, informação que só se determina adiante impõe ao gerador uma antecipação que a decodificação não oferece.

2.2.2 Tokenização e o Custo de Sequências Longas

LLMs não operam diretamente sobre palavras completas. A entrada e a saída são decompostas em *tokens*, frequentemente obtidos por técnicas como *Byte-Pair Encoding* (SENNRICH; HADDOW; BIRCH, 2016). Essa estratégia funciona bem para texto natural, mas pode ser pouco econômica para formatos como XML. Identificadores longos, nomes de atributos, símbolos de marcação e padrões repetidos tendem a ser fragmentados em vários *tokens*.

O aumento no número de *tokens* tem consequências diretas. O mecanismo de atenção cresce em custo com o comprimento da sequência, o que afeta memória, tempo de treinamento e latência de inferência. Quando o modelo é acessado por meio de uma API comercial, o efeito é também financeiro: os provedores cobram por *token* de entrada e de saída, em geral com preço maior para a saída. Em um ambiente acadêmico com recursos limitados, gerar XML BPMN completo significa gastar parte relevante do orçamento computacional em trechos que são necessários para a conformidade do arquivo, mas não necessariamente para a descrição semântica do processo.

2.2.3 Geração de Saídas Estruturadas

A geração de artefatos estruturados por LLMs, como código-fonte, consultas e linguagens de marcação, tornou-se uma linha de pesquisa relevante a partir de trabalhos como o de Chen *et al.* (2021). O desafio central é que a geração probabilística não garante, por si só, validade sintática nem conformidade a um esquema externo. Em linguagem natural, um pequeno desvio pode ser tolerável; em XML, uma inconsistência local pode tornar todo o documento inválido.

Poesia *et al.* (2022) discutem esse problema no contexto de geração de código e defendem a combinação entre modelos probabilísticos e mecanismos determinísticos de restrição. A ideia é simples, mas importante para este trabalho: quando a saída precisa obedecer a regras formais, a geração livre do modelo deve ser complementada por alguma forma de controle. Esse controle pode aparecer durante a decodificação, em uma etapa posterior de validação ou por meio de uma representação intermediária projetada para ser mais simples de gerar e de verificar.

2.3 LINGUAGENS DE DOMÍNIO ESPECÍFICO E COMPRESSÃO SEMÂNTICA

2.3.1 Linguagens de Domínio Específico

Para Fowler (2010), uma Linguagem de Domínio Específico é uma linguagem computacional criada para um domínio particular, com escopo e expressividade intencionalmente limitados. Essa limitação não é uma deficiência. Pelo contrário, ela permite que a linguagem se aproxime dos conceitos do problema e reduza detalhes que seriam necessários em uma linguagem de propósito geral. Mernik, Heering e Sloane (2005) apontam benefícios recorrentes das DSLs, entre eles a elevação do nível de abstração, a redução de código repetitivo e a maior facilidade

para realizar análises estáticas.

No caso da BPMN, a serialização XML já é uma linguagem formal, mas não foi pensada para ser escrita diretamente por pessoas ou por modelos de linguagem. Ela foi concebida principalmente para intercâmbio entre ferramentas. Por isso, quando se pede a um LLM que produza XML BPMN completo, transfere-se ao modelo uma responsabilidade pouco adequada ao seu funcionamento: repetir com precisão uma grande quantidade de marcação técnica, ainda que parte dessa marcação possa ser gerada de maneira determinística.

2.3.2 Compressão Semântica como Estratégia de Geração

Neste trabalho, compressão semântica designa a redução da representação textual de um artefato sem perda do conteúdo essencial, desde que a forma completa possa ser reconstruída por uma etapa determinística. A compressão, portanto, não é tratada como objetivo isolado. Seu papel é separar duas responsabilidades: o LLM deve produzir uma descrição concisa do processo, enquanto o transpilador deve expandir essa descrição para XML BPMN 2.0 válido.

A proposta segue três etapas. Primeiro, o LLM gera uma representação intermediária em uma DSL voltada à descrição de processos BPMN. Em seguida, um transpilador baseado em gramática EBNF e regras de enriquecimento converte essa representação em XML BPMN 2.0. Por fim, o XML gerado é validado contra o XSD oficial. Quando ocorre erro, a falha tende a ficar mais localizada: pode estar na geração da DSL, no transpilador ou na validação do XML. Esse desenho facilita a depuração quando comparado à geração direta de um documento XML longo.

A motivação para essa estratégia combina três aspectos. O primeiro é computacional, pois uma saída mais curta reduz o número de *tokens* e pode baratear treinamento e inferência. O segundo é de aprendizado, já que uma representação menos redundante pode concentrar melhor o sinal supervisionado no que realmente descreve o processo. O terceiro é metodológico: a separação entre modelo e transpilador permite avaliar de forma mais clara o que foi aprendido pelo LLM e o que foi garantido por regras determinísticas.

2.4 ADAPTAÇÃO DE MODELOS DE LINGUAGEM A TAREFAS ESPECÍFICAS

2.4.1 Supervised Fine-Tuning

O ajuste supervisionado, ou *Supervised Fine-Tuning* (SFT), é uma das formas mais diretas de adaptar um LLM a uma tarefa específica. O procedimento continua o treinamento do modelo sobre pares de entrada e saída esperada, deslocando a distribuição gerada na direção do comportamento desejado (OUYANG *et al.*, 2022). Neste projeto, cada exemplo associa uma descrição textual de processo a uma representação na DSL proposta.

A qualidade do SFT depende fortemente do corpus. Em tarefas muito específicas, como gerar uma DSL nova para processos BPMN, não há um conjunto público pronto que resolva o problema de forma direta. Isso torna necessária a construção de dados por meio de conversões, curadoria e aumento de dados. Modelos mais capazes podem atuar como apoio nessa etapa, gerando pseudoexemplos que depois precisam ser filtrados e validados.

2.4.2 Ajuste com Eficiência de Parâmetros: LoRA e QLoRA

O ajuste completo de modelos com bilhões de parâmetros costuma ser inviável em computadores de uso acadêmico. Hu *et al.* (2022) propuseram o método *Low-Rank Adaptation* (LoRA) como uma alternativa mais econômica: em vez de atualizar todos os pesos do modelo, treinam-se matrizes de baixa dimensão acopladas a camadas específicas. Os pesos originais permanecem congelados, e apenas os parâmetros adicionais são ajustados.

O método reduz a quantidade de parâmetros treináveis e, consequentemente, o consumo de memória. O QLoRA, apresentado por Dettmers *et al.* (2023), amplia essa economia ao quantizar os pesos congelados do modelo base para 4 *bits*, mantendo as adaptações em maior precisão. Essa combinação é especialmente relevante para o presente estudo, pois viabiliza a inferência do modelo especializado em uma estação local com 11 GB de memória de GPU, enquanto o treinamento é executado em infraestrutura de nuvem.

2.4.3 Aprendizado por Reforço com GRPO

Embora o SFT ensine o modelo a imitar exemplos, ele não otimiza diretamente métricas externas de qualidade. Para uma tarefa como esta, algumas propriedades importantes são verificáveis por código: validade sintática, conformidade ao XSD, fidelidade semântica, coerência topológica do grafo e economia de *tokens*. Essas propriedades podem ser usadas como

sinais de recompensa em uma etapa posterior de treinamento.

Shao *et al.* (2024) introduziram o *Group Relative Policy Optimization* (GRPO) no contexto de modelos voltados a raciocínio matemático. O método deriva do PPO, mas evita manter um modelo crítico separado. Para cada *prompt*, gera-se um grupo de respostas, e a vantagem de cada resposta é estimada em relação à média do próprio grupo. Essa simplificação reduz custo de memória, característica importante em cenários com restrição de hardware.

Neste trabalho, o GRPO foi considerado como possível segunda etapa após o SFT e permanece como trabalho futuro (Seção **??**). A função de recompensa combina dimensões diferentes da qualidade esperada: sintaxe, semântica, topologia e eficiência da DSL gerada. A composição ponderada dessas dimensões permite transformar critérios de avaliação em um sinal de treinamento, sem reduzir a qualidade do processo a uma única métrica isolada.

2.5 EXTRAÇÃO DE PROCESSOS A PARTIR DE TEXTO NATURAL

2.5.1 Caracterização do Problema

A extração automática de modelos de processo a partir de texto natural é anterior ao uso recente de LLMs. Friedrich, Mendling e Puhlmann (2011), por exemplo, já investigavam a geração de modelos BPMN com apoio de técnicas tradicionais de Processamento de Linguagem Natural (PLN), como análise sintática, resolução de correferências e regras de mapeamento. Os resultados indicavam potencial, mas também deixavam claro que textos de processo podem conter ambiguidades e informações implícitas.

Aa *et al.* (2018) organizam esses desafios em dimensões como ambiguidade lexical e estrutural, variação de granularidade, lacunas de informação e possibilidade de múltiplos modelos válidos para uma mesma descrição. Essa última questão é particularmente importante: em muitos casos, não existe apenas uma modelagem correta. O que existe são representações mais ou menos adequadas a uma interpretação do texto, ao nível de detalhe escolhido e ao objetivo da modelagem.

2.5.2 Recursos e Datasets Disponíveis

O domínio ainda possui poucos *benchmarks* consolidados. Bellan *et al.* (2023) apresentaram o *Process Extraction from Text* (PET), composto por 45 descrições textuais anotadas com atividades, *gateways*, atores e relações de fluxo. O PET é relevante por oferecer anotações

em granularidade fina, úteis tanto para treinamento quanto para avaliação de tarefas de extração.

Outro recurso importante é o *PMo Dataset*, disponibilizado por Brissard, Cuppens e Zouaq (2025a). O conjunto reúne 55 modelos de processo com descrições textuais correspondentes e diferentes representações de modelo, incluindo BPMN, Mermaid, Graphviz, POWL code e XML simplificado. A presença de uma representação BPMN padronizada como referência torna o conjunto especialmente útil para avaliação. Já o dataset de Mangler e Klievtsova (2023) oferece 24 descrições textuais acompanhadas de múltiplos modelos BPMN possíveis, com pontuações atribuídas por especialistas, o que ajuda a observar a ambiguidade natural da modelagem de processos.

Além desses conjuntos especializados, o projeto pode recorrer a textos procedurais não anotados, como trechos públicos de documentação organizacional, para etapas de aumento de dados. A distinção entre essas fontes é metodologicamente relevante: datasets anotados servem como referência e avaliação, enquanto textos abertos podem alimentar a construção de pares sintéticos, desde que passem por validação.

2.6 AVALIAÇÃO DE GERAÇÃO DE ARTEFATOS ESTRUTURADOS

2.6.1 Validação por Esquema

A validação por esquema é o primeiro critério para avaliar XML BPMN. No caso da BPMN 2.0, o XSD oficial define se o documento respeita a estrutura esperada pela especificação. O resultado é binário: o XML é válido ou inválido. Esse critério é necessário, mas não suficiente. Um arquivo pode ser válido em termos de esquema e ainda assim representar um processo diferente daquele descrito no texto de entrada.

2.6.2 Métricas Sintáticas e Semânticas

Para avaliar a fidelidade ao processo de referência, métricas como precisão, revocação e F1 podem ser calculadas sobre elementos extraídos do modelo gerado. Atividades, atores, *gateways* e arestas podem ser comparados com os elementos presentes no modelo esperado. A medida F1 é útil nesse contexto porque resume precisão e revocação, evitando uma leitura baseada apenas em acertos brutos.

2.6.3 Distância de Edição em Grafos

Como modelos BPMN podem ser interpretados como grafos, a comparação estrutural também é necessária. A *Graph Edit Distance* (GED), associada ao trabalho de Sanfeliu e Fu (1983), mede a distância entre grafos a partir do custo mínimo de operações de edição, como inserção, remoção e substituição de vértices e arestas. Em formulações gerais, o cálculo exato é computacionalmente difícil, razão pela qual aproximações são frequentemente usadas em aplicações práticas (GAO *et al.*, 2010).

Para este estudo, a GED é interessante porque considera a organização topológica do processo, não apenas a presença ou ausência de elementos individuais. Ainda assim, sua utilidade depende do modelo de custo adotado. Esse modelo precisa refletir o que, no contexto da BPMN, deve ser tratado como diferença relevante entre dois processos.

2.6.4 Eficiência: Razão de Compressão de Tokens

A Razão de Compressão de Tokens (TCR, do inglês *Token Compression Ratio*) é usada para medir a eficiência da representação intermediária. A métrica compara a quantidade de *tokens* necessária para representar o processo em XML BPMN com a quantidade necessária para representá-lo na DSL proposta, usando o mesmo tokenizador. Valores superiores a um indicam que a DSL é mais compacta que o XML correspondente.

Essa métrica, sozinha, não mede qualidade. Uma representação pode ser muito curta e ainda assim perder informação relevante. Por isso, a TCR precisa ser analisada junto às métricas de validade, fidelidade semântica e estrutura topológica. O interesse do trabalho está exatamente nesse equilíbrio: reduzir a saída gerada pelo LLM sem comprometer a reconstrução determinística do BPMN.

2.6.5 Função de Recompensa Composta

No treinamento por GRPO, as métricas anteriores podem ser combinadas em uma função de recompensa composta. Essa função precisa equilibrar critérios diferentes: validade sintática, adequação semântica ao texto, plausibilidade topológica e eficiência em *tokens*. Uma formulação ponderada facilita a interpretação dos resultados, pois permite identificar que dimensão da qualidade está contribuindo mais ou menos para o comportamento do modelo.

2.7 SÍNTESE DO CAPÍTULO

A discussão apresentada neste capítulo delimita o problema e justifica a estratégia proposta. A BPMN 2.0 oferece uma representação rica para processos de negócio, mas sua serialização XML é longa e sensível a erros. LLMs são capazes de gerar texto estruturado, porém não garantem conformidade formal por si mesmos. DSLs oferecem uma alternativa intermediária: descrevem o conteúdo essencial em uma forma mais curta, enquanto um transpilador assume a expansão para XML válido. As técnicas de SFT, LoRA, QLoRA e GRPO fornecem o caminho para adaptar o modelo à tarefa, e as métricas discutidas permitem avaliar a solução sob diferentes aspectos.

Com essa base, o Capítulo de Metodologia pode especificar de maneira operacional a gramática da DSL, o funcionamento do transpilador, a construção dos dados, os parâmetros de treinamento e o protocolo de avaliação.

3 TRABALHOS RELACIONADOS

Este capítulo situa o trabalho em relação a quatro linhas de pesquisa que o tangenciam: geração de modelos de processo por modelos de linguagem, representações compactas de processos, compressão de *tokens* em sistemas com LLMs, e garantia de validade sintática na geração de linguagens formais. O critério de organização é a proximidade com a pergunta desta pesquisa — o custo de gerar marcação hierárquica verbosa —, e não a cronologia ou a autoria.

3.1 GERAÇÃO DE MODELOS DE PROCESSO COM LLMS

A referência mais próxima em objetivo é o ProMoAI (KOURANI *et al.*, 2024), que emprega um LLM de fronteira, guiado por *prompt*, para produzir código POWL executável, posteriormente traduzido para BPMN. A estratégia compartilha com este trabalho a premissa central de **não** pedir XML diretamente ao modelo, interpondo uma representação intermediária mais adequada às capacidades do gerador.

As diferenças são de natureza e de escopo. O ProMoAI depende de um modelo de fronteira em tempo de inferência, o que mantém o custo por geração no patamar que este trabalho procura reduzir; a representação intermediária é código Python, escolhida por familiaridade do modelo com tarefas de programação, e não projetada para minimizar *tokens* emitidos; e a compressão obtida não é medida nem tratada como objetivo. Aqui, ao contrário, a compressão é métrica de primeira classe, a representação é projetada para isso, e o gerador-alvo é um modelo pequeno especializado por ajuste supervisionado. A reexecução do ProMoAI está fora do escopo desta versão, de modo que ele é tratado como referência qualitativa; comparar com números publicados sob protocolo distinto seria metodologicamente indefensável.

3.2 REPRESENTAÇÕES COMPACTAS DE PROCESSOS

Diversas notações alternativas ao XML BPMN foram propostas com objetivos que se sobrepõem parcialmente ao deste trabalho. A representação *JSON branches* (KÖPKE; SAFAN, 2025) foi introduzida explicitamente para reduzir contagem de *tokens* e favorecer aderência a esquema na geração por LLMs. A representação *Process Model Elements* (VOELTER *et al.*, 2024) organiza o modelo em listas planas de elementos, facilitando contagem e comparação. Somam-se a elas notações de visualização como Mermaid e Graphviz, e simplificações do próprio XML.

O trabalho de Brissard, Cuppens e Zouaq (2025b) é o que mais se aproxima em objeto empírico: realiza análise comparativa de nove representações de modelos de processo para geração com LLMs, sobre o mesmo conjunto de dados aqui utilizado como *holdout*. É, por isso, o antecedente que exige posicionamento mais cuidadoso.

A distinção é de **pergunta de pesquisa**, e não de artefato. Aquele trabalho pergunta qual representação produz os melhores modelos de processo quando um LLM é instruído por *prompt* — uma pergunta sobre adequação de notação à tarefa de modelagem. Esta pesquisa pergunta se a estratégia de comprimir a saída e expandi-la deterministicamente torna economicamente viável a geração de marcação hierárquica verbosa por modelos pequenos, usando BPMN como caso de estudo instrumentado. Disso decorrem três diferenças operacionais:

a) **o gerador**: representações avaliadas por *prompt* em modelos de fronteira, contra um modelo pequeno especializado por ajuste supervisionado, cujo custo por requisição é de duas a quatro vezes menor sob preço de mercado (Seção 5.6.7);
b) **a garantia sintática**: notações comparadas quanto à qualidade do modelo produzido, contra uma cadeia em que a validade perante o esquema é assegurada por construção sempre que a DSL é aceita pela gramática, o que desloca a variável aleatória do documento inteiro para a aceitação de uma representação curta;
c) **a métrica de custo**: compressão medida e reportada como resultado de primeira ordem, e não como propriedade qualitativa da notação.

Que representações compactas de BPMN já existam não é objeção a este trabalho — é evidência de que o problema é reconhecido. A contribuição pretendida não é a notação em si, mas a demonstração empírica de que a combinação entre compressão medida, expansão determinística verificável e especialização de modelo pequeno desloca a fronteira de custo da tarefa. Registre-se ainda que a DSL proposta cobre construções que algumas dessas notações não representam — múltiplos eventos de início e fim, fluxos de mensagem e raias —, embora essa maior expressividade seja consequência do desenho, e não sua justificativa. Os resultados acrescentam a essa comparação uma condição de desenho que as notações citadas não explicitam: a forma de referência entre elementos deve permitir apontar para o que já foi escrito, sem exigir do gerador antecipar o que ainda não escreveu (Seção 5.6.6).

3.3 COMPRESSÃO DE *TOKENS*: ENTRADA *VERSUS* SAÍDA

A redução do consumo de *tokens* em sistemas com LLMs é problema ativo, e a literatura predominante trata do lado da **entrada**. O LLMLingua (JIANG *et al.*, 2023) comprime *prompts* removendo conteúdo de baixa informação segundo um modelo de linguagem auxiliar, preservando o desempenho na tarefa a jusante. Trabalhos de gestão de contexto perseguem objetivo análogo por seleção e sumarização do que entra na janela.

Este trabalho ataca o lado oposto e complementar: o custo da **saída**. A assimetria é relevante e raramente explicitada. *Tokens* de entrada podem ser processados em paralelo e beneficiam-se de mecanismos de cache; *tokens* de saída são gerados sequencialmente, dominam a latência percebida e são tipicamente tarifados a preço superior. Em tarefas cuja saída é marcação verbosa, o gargalo econômico está na geração, não na leitura — e comprimir o *prompt* não o alivia. As duas famílias de técnica são, portanto, ortogonais e combináveis, e não concorrentes. Os resultados mostram, porém, que a fronteira entre os dois lados não é estanque: quando a notação compacta é ensinada por *prompt*, a gramática passa a dominar o custo da entrada, e o ajuste fino, ao dispensá-la, atua também sobre esse lado (Seção 5.6.7).

3.4 MODELOS PEQUENOS ESPECIALIZADOS

A viabilidade da proposta depende de que um modelo de pequeno porte, especializado, alcance desempenho competitivo em tarefa estreita. Essa premissa é sustentada por evidência recente sobre o papel de modelos pequenos em sistemas agênticos (BELCAK *et al.*, 2025), que argumenta serem eles suficientes — e economicamente preferíveis — para subtarefas repetitivas e bem delimitadas, reservando modelos de fronteira para as etapas que exigem generalidade. Os resultados deste trabalho confirmam a premissa em validade sintática, em que o modelo pequeno especializado iguala o de fronteira, mas não em fidelidade estrutural, em que permanece inferior (Seção 5.6.2).

A geração de marcação estruturada a partir de descrição textual é exatamente uma dessas subtarefas: formato fixo, vocabulário restrito, critério de sucesso verificável. Métodos de ajuste eficiente em parâmetros (HU *et al.*, 2022), especialmente em sua variante quantizada (DETTMERS *et al.*, 2023), tornam a especialização exequível com recursos computacionais modestos, o que é condição para que o argumento econômico se sustente.

3.5 GARANTIA DE VALIDADE SINTÁTICA

Há uma alternativa à estratégia adotada que precisa ser reconhecida: a **decodificação restrita**, que impõe a gramática do formato-alvo durante a amostragem, impedindo por construção a emissão de sequências inválidas (POESIA *et al.*, 2022). Aplicada ao XML BPMN, garantiria validade sintática sem representação intermediária alguma.

Duas considerações delimitam a comparação. A primeira é que a decodificação restrita resolve a validade, mas **não** o custo: o modelo continua emitindo cada *token* da marcação verbosa, de modo que a economia perseguida aqui permanece inalcançada — e, com efeito, as duas técnicas são combináveis, podendo a decodificação restrita ser aplicada sobre a própria DSL. A segunda é que restringir a decodificação a uma gramática garante boa formação sintática, mas não coerência estrutural: um documento pode respeitar o esquema e ainda referenciar identificadores inexistentes ou descrever um grafo desconexo. A expansão determinística não impede que o gerador escreva esse erro, mas o detecta e o rejeita: uma referência a elemento inexistente no fluxo é falha de transpilação, e não documento válido e incoerente. Essa foi, aliás, a classe de falha mais frequente nos braços de DSL (Seção 5.6.6).

A avaliação empírica da decodificação restrita como braço experimental está fora do escopo desta versão, e é registrada como trabalho futuro derivado.

4 METODOLOGIA

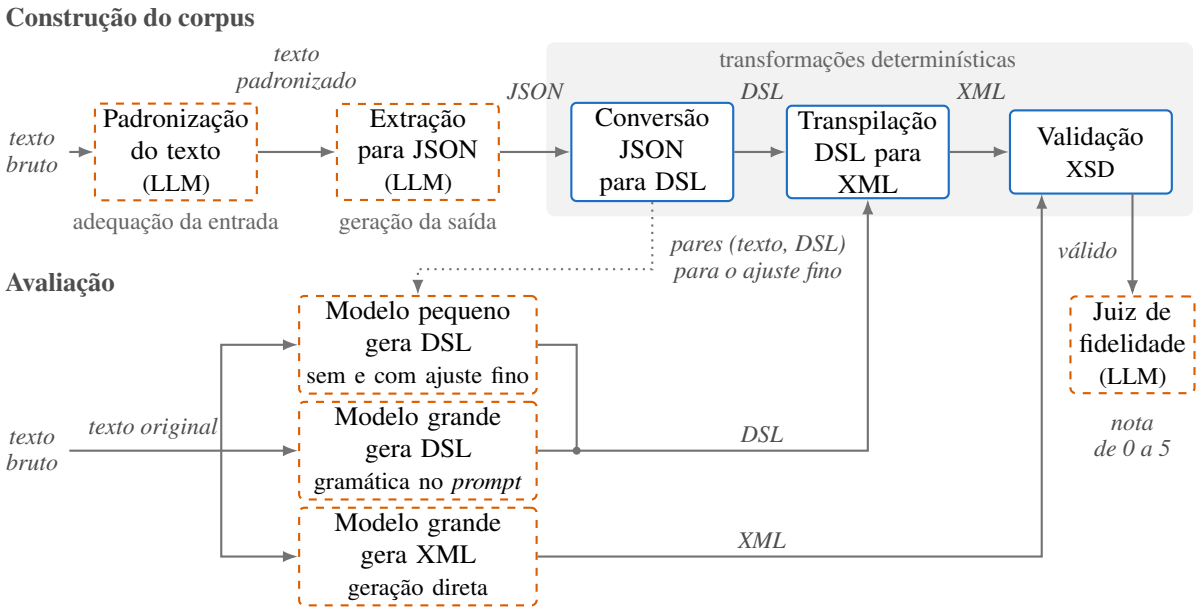
4.1 VISÃO GERAL

Neste trabalho, o modelo de linguagem não escreve o XML do BPMN 2.0 diretamente. Ele gera uma representação compacta do processo, a BPMN-DSL, e um programa determinístico, o transpilador, expande essa representação para o XML completo. O experimento compara essa estratégia com a geração direta de XML e verifica se um modelo de pequeno porte, especializado na DSL, alcança os resultados de modelos de grande porte com uma fração do uso de tokens e do custo.

O trabalho tem duas fases, resumidas na Figura 1. Na construção do corpus, descrições textuais de processos, a maior parte extraída do *handbook* público da GitLab, são padronizadas e depois convertidas em um JSON que descreve o processo, em duas chamadas a um modelo de grande porte. Um conversor determinístico transforma esse JSON na DSL, e o transpilador gera o XML correspondente (Seção 4.2). Os pares formados pelo texto original e pela DSL treinam o modelo pequeno. Trata-se de uma destilação: o modelo pequeno aprende a partir dos dados que os modelos grandes produziram (Seção 4.5). Na avaliação, cada braço experimental recebe o texto de um processo do conjunto de teste e gera XML ou DSL. A DSL passa pelo transpilador, e todas as saídas são medidas da mesma forma (Seções 4.6 e 4.7).

A divisão de responsabilidades entre as partes define o que precisa ser medido. O transpilador garante que toda DSL sintaticamente correta produza um XML válido segundo o esquema oficial do BPMN 2.0, o que foi verificado nas 1.021 amostras do corpus (Seção 4.4). O modelo continua responsável pela sintaxe da DSL e pelo conteúdo do processo, e pode errar em qualquer um dos dois. Por isso a validade e a fidelidade são medidas separadamente. A validade é verificada por programa, contra o esquema XSD. A fidelidade, isto é, se o modelo representa o processo descrito no texto, exige julgamento e foi medida por um modelo de linguagem usado como juiz. Como a validação desse juiz foi apenas parcial (Seção 4.7), as conclusões principais se apoiam na validade e no custo, e a fidelidade é reportada como exploratória.

Figura 1 – Visão geral: construção do corpus e avaliação



Fonte**:** Elaborado pelo autor

Nota**:** Borda tracejada indica etapa probabilística; borda sólida, etapa determinística. Na construção do corpus, a padronização só adequa o texto de entrada, e a extração gera a saída como JSON; daí em diante há apenas transformações determinísticas entre representações. Os pares formados pelo texto original e pela DSL treinam o modelo pequeno (seta pontilhada). Na avaliação, os braços recebem o texto original e ocupam o lugar da extração: os que geram DSL passam pela mesma transpilação, e os que geram XML seguem direto para a validação. As saídas válidas seguem para o juiz de fidelidade, um modelo de linguagem que compara o processo gerado com o texto original; por isso ele também tem borda tracejada.

4.2 DADOS

4.2.1 Fontes

Não existe um conjunto público, em escala e confiável, que associe descrições textuais de processos a modelos BPMN. Dado esse fato, somente o lado da entrada foi coletado e o lado da saída foi gerado pelo processo descrito na Seção 4.1. A Tabela 1 resume as fontes e o uso de cada uma.

Tabela 1 – Fontes de dados e uso no trabalho

Fonte	Itens	Uso
Handbook da GitLab, seções com decisões ou atores	728	treino
Handbook da GitLab, seções lineares	172	só verificação do transpilador
PET (BELLAN *et al.*, 2023)	44	treino
PMo (BRISSARD; CUPPENS; ZOUAQ, 2025a)	53	avaliação ($n = 46$, ver Seção 4.2.3)
Zenodo (MANGLER; KLIEVTSOVA, 2023)	24	validação da medida de fidelidade

Fonte**:** Elaborado pelo autor

A principal fonte de volume foi o *handbook* público da GitLab que é um manual operacional aberto com milhares de páginas. As páginas foram coletadas e divididas em seções, e cada seção recebeu uma pontuação procedural baseada na presença de passos numerados, decisões e atores. Foram mantidas as seções com passos e com decisões ou atores, que descrevem processos com alguma estrutura além de uma lista. As seções lineares, só com passos, foram separadas e não entram nos experimentos. O PET (BELLAN *et al.*, 2023) também entra no treino com 44 descrições de processos de outros domínios.

O conjunto de teste é o PMo (BRISSARD; CUPPENS; ZOUAQ, 2025a), que reúne 53 descrições de processos de fontes distintas, cada uma acompanhada de um modelo BPMN de referência. O Zenodo (MANGLER; KLIEVTSOVA, 2023) traz 24 descrições, as mesmas de 24 itens do PMo, cada uma com 8 a 11 modelos feitos por modeladores iniciantes e avaliados por um especialista com uma nota de 0 a 5. Essas notas são usadas na validação da medida de fidelidade (Seção 4.7). A sobreposição entre as duas fontes tem uma consequência para as referências do PMo: em pelo menos 10 desses 24 itens, a referência coincide, após normalização dos rótulos e fluxos, com um dos modelos feitos por iniciantes no Zenodo, e não é, portanto, um modelo de especialista. Por isso, a fidelidade das saídas é julgada contra o texto, e não contra a referência (Seção 4.7).

4.2.2 Geração dos pares de treino

Cada descrição de treino passa por duas chamadas a um modelo de grande porte, o GLM 5.2. A primeira padroniza o texto: reorganiza a descrição em atores, passos, decisões e atividades paralelas, sem acrescentar informação. A segunda converte o texto padronizado em um JSON com os elementos, os fluxos e as raias do processo. Nos casos em que o GLM 5.2 falhou na geração do JSON, foi usado o Kimi K2.6 como alternativa, o que ocorreu em 32 das 1.021 amostras.

A escolha do GLM 5.2 veio de um teste piloto com 50 amostras de treino, que comparou três configurações: o GLM 5.2 nas duas etapas, a combinação de Kimi K2.6 e DeepSeek V4 Pro, e o DeepSeek V4 Flash. O GLM 5.2 teve a maior taxa de JSON aproveitável e o menor número de falhas, além da maior proporção de XML válido ao fim do processo (96%, contra 92% da segunda melhor configuração). Essa vantagem, porém, corresponde a apenas 2 amostras em 50, e o próprio piloto mostrou que repetir a geração de uma mesma amostra pode mudar o resultado. Por isso, a escolha se apoia no fato de o GLM 5.2 ter ficado à frente nas três

medidas ao mesmo tempo, e não em uma diferença estatisticamente comprovável.

O JSON é convertido em DSL por um programa determinístico, e a DSL é transpilada para XML. Para o treino, só foram mantidos os pares em que o XML reconstrói exatamente a topologia do JSON de origem, critério atendido por 768 das 772 amostras de treino. Os pares de treino são formados pelo texto original e pela DSL. O texto padronizado serve apenas para gerar os dados e não é visto pelo modelo pequeno. Todos os rótulos dos artefatos gerados são em inglês, a mesma língua dos textos de origem e do conjunto de teste.

4.2.3 Partições e prevenção de contaminação

Os 768 pares foram divididos em treino (690) e validação (78). A divisão é feita por documento de origem, de modo que seções da mesma página do *handbook* ficam sempre do mesmo lado. Como as seções de uma página compartilham redação e vocabulário, uma divisão aleatória colocaria seções quase iguais dos dois lados, e a perda de validação mediria memorização, e não generalização.

Os conjuntos de avaliação, PMo e Zenodo, por também terem modelos BPMN de referência já em suas fontes, foram escolhidos para o conjunto de testes, e nunca entram no treino. Porém, uma verificação posterior mostrou que 7 dos 53 itens do PMo têm como texto descrições que também fazem parte do PET: seis vêm do subconjunto PET-7 incorporado ao PMo, e um sétimo coincide com um documento do PET. Como o PET está no treino, esses 7 itens foram excluídos da avaliação, que passa a ter 46 itens.

Para verificar se havia outras sobreposições, cada texto de avaliação foi comparado com os 944 textos da partição de treino, contando com as seções lineares do *handbook*, por sequências de oito palavras consecutivas, após normalização de caixa e pontuação. Os 7 itens excluídos compartilham entre 87% e 100% dessas sequências com um documento do PET. Nenhum dos outros 70 textos de avaliação (46 do PMo e 24 do Zenodo) compartilha sequência alguma. Com sequências de cinco palavras, a maior sobreposição entre eles é de cerca de 2%, formada por expressões comuns da língua, como “if you do not have” e “at the end of the”.

Uma limitação desta composição é que 94,4% dos pares de treino vêm do *handbook* da GitLab, de uma única empresa e com estilo próprio, enquanto o teste é feito sobre processos de outros domínios. Isso é discutido na Seção 4.10.

4.3 A BPMN-DSL

A BPMN-DSL é a representação intermediária, criada de forma autoral, para este trabalho. Existem outras representações textuais de processos, comparadas por Brissard, Cuppens e Zouaq (2025b), mas o foco aqui é específico: uma notação que um modelo de linguagem consiga gerar da esquerda para a direita, com poucos *tokens*, e que tenha uma tradução determinística e completa para BPMN 2.0 XML.

O Código 1 mostra um processo com uma decisão e uma repetição usando o BPMN-DSL, e o Código 2 mostra o XML que o transpilador gera a partir dele. A DSL tem 286 caracteres e o XML, 1.833.

A diferença de tamanho se dá principalmente pela forma de ligar os elementos. No XML, cada ligação é um elemento `sequenceFlow` próprio, que repete os identificadores da origem e do destino, e esses identificadores precisam ser consistentes em todo o documento. Na DSL, a ligação é dada pela posição: o operador `->` liga um elemento ao seguinte, e os ramos de uma decisão ficam dentro do bloco dela. A junção dos ramos também é implícita, e o transpilador cria o *gateway* de convergência quando ele é necessário. A razão de compressão medida no corpus e nas saídas dos braços é apresentada na Seção 4.7.

O desenho da notação segue quatro princípios:

1. cada conceito do BPMN tem uma única forma de escrita, o que reduz as escolhas que o modelo precisa fazer; a exceção é a referência, que tem duas formas, descritas a seguir;
2. o nome de um elemento serve à leitura, e o identificador, à referência, de modo que só recebem identificador os elementos referenciados em outro ponto;
3. raias são escopos que envolvem parte do fluxo (bloco `@lane`), em vez de listas de elementos declaradas à parte, o que evita declarar cada atividade duas vezes;
4. ramos vazios de uma decisão são escritos explicitamente, com `()`.

Um elemento que já apareceu no fluxo é referenciado com `#`, o que permite escrever repetições e convergências. Existem duas formas de referência, equivalentes para o transpilador. Na primeira, o elemento recebe um identificador quando aparece (`service "Fetch data" #fetch`) e é referenciado por ele (`#fetch`), como no Código 1. Na segunda, a referência repete o rótulo do elemento (`#"Fetch data"`), sem declaração prévia. A comparação de rótulos ignora diferenças de caixa, espaçamento e pontuação, e só alcança elementos que já apareceram. As duas formas produzem o mesmo XML. A diferença entre elas é para quem gera: a primeira exige decidir, ao

Código-fonte 1 – Processo com decisão e repetição na BPMN-DSL

```
process "Order Processing with Retry" {
  start
  -> service "Fetch data" #fetch
  -> service "Validate"
  -> xor "Valid?" {
    [yes] -> service "Process" -> end
    [no]  -> xor "Retry?" {
               [yes] -> #fetch
               [no]  -> end:error "Invalid"
             }
  }
}
```

Código-fonte 2 – XML gerado pelo transpilador a partir do Código 1

```
<definitions xmlns="http://www.omg.org/spec/BPMN/20100524/MODEL" ...>
  <process id="Process_Order_Processing_with_Retry" name="Order Processing
      with Retry">
    <startEvent id="StartEvent_1" name="start"/>
    <serviceTask id="ServiceTask_1" name="Fetch data"/>
    <sequenceFlow id="SequenceFlow_1" sourceRef="StartEvent_1" targetRef="
        ServiceTask_1"/>
    <serviceTask id="ServiceTask_2" name="Validate"/>
    <sequenceFlow id="SequenceFlow_2" sourceRef="ServiceTask_1" targetRef="
        ServiceTask_2"/>
    <exclusiveGateway id="ExclusiveGateway_1" name="Valid?"/>
    <serviceTask id="ServiceTask_3" name="Process"/>
    <sequenceFlow id="SequenceFlow_3" sourceRef="ExclusiveGateway_1"
        targetRef="ServiceTask_3">
      <conditionExpression>yes</conditionExpression>
    </sequenceFlow>
    <endEvent id="EndEvent_1" name="end"/>
    <sequenceFlow id="SequenceFlow_4" sourceRef="ServiceTask_3" targetRef="
        EndEvent_1"/>
    <exclusiveGateway id="ExclusiveGateway_2" name="Retry?"/>
    <sequenceFlow id="SequenceFlow_5" sourceRef="ExclusiveGateway_2"
        targetRef="ServiceTask_1">
      <conditionExpression>yes</conditionExpression>
    </sequenceFlow>
    <endEvent id="EndEvent_2" name="Invalid">
      <errorEventDefinition/>
    </endEvent>
    <sequenceFlow id="SequenceFlow_6" sourceRef="ExclusiveGateway_2"
        targetRef="EndEvent_2">
      <conditionExpression>no</conditionExpression>
    </sequenceFlow>
    <sequenceFlow id="SequenceFlow_7" sourceRef="ExclusiveGateway_1"
        targetRef="ExclusiveGateway_2">
      <conditionExpression>no</conditionExpression>
    </sequenceFlow>
    <sequenceFlow id="SequenceFlow_8" sourceRef="ServiceTask_2" targetRef="
        ExclusiveGateway_1"/>
  </process>
</definitions>
```

escrever o elemento, que ele será referenciado mais adiante; a segunda não.

A DSL cobre eventos iniciais, intermediários e finais, com gatilhos de mensagem, temporizador, erro, sinal e escalonamento; oito tipos de tarefa; *gateways* exclusivos, paralelos, inclusivos e baseados em eventos; subprocessos; chamadas a outros processos; raias; *pools* com fluxos de mensagem entre eles; e anotações. Ficam fora desta versão os eventos de borda, a compensação e as atividades de múltiplas instâncias.

4.4 TRANSPILAÇÃO

Existem dois programas determinísticos que fazem as conversões entre representações. O primeiro converte o JSON do processo para DSL e é usado só na construção do corpus. O segundo é o transpilador, ele transforma a DSL em BPMN 2.0 XML e é usado tanto no corpus quanto na avaliação.

A conversão de JSON para DSL percorre o grafo do processo e segue uma regra: todo elemento alcançável é escrito uma única vez, e qualquer novo encontro com um elemento já escrito vira uma referência. Essa regra é o que permite representar laços, ramos que voltam a um ponto anterior e convergências de vários ramos sem duplicar elementos nem perder ligações. O conversor sempre usa a referência por identificador, de modo que o corpus de treino contém só essa forma.

O transpilador lê a DSL com um analisador gerado a partir da gramática formal da notação e traduz cada construção em um elemento XML fixo. Cada ligação vira um `sequenceFlow`; um bloco de decisão vira o *gateway* de divisão e, quando algum ramo continua depois dele, o *gateway* de convergência; um bloco `@lane` vira a raia com a lista dos seus elementos; um *pool* vira um participante, com seus fluxos de mensagem. Um ramo que termina em um evento de fim ou em uma referência não é ligado à convergência, porque ali o fluxo já se encerrou ou seguiu para outro ponto. Os identificadores do XML são gerados pelo transpilador e são únicos no documento.

O componente foi verificado de duas formas sobre as 1.021 amostras do corpus. Na primeira, o XML de todas as amostras foi validado contra o esquema XSD oficial do BPMN 2.0, e as 1.021 passaram. Na segunda, a estrutura do XML foi comparada com a do JSON originalmente gerado, pelos pares de atividades e eventos que se sucedem no fluxo. As estruturas ficaram idênticas em 1.020 amostras. Na amostra restante, o próprio JSON tem fluxos saindo de eventos de fim, que o transpilador não reproduz porque um evento de fim encerra o fluxo.

Nas saídas dos braços experimentais, as 951 DSL que seguiram a gramática produziram XML válido. A falha de validade de uma saída em DSL vem, portanto, sempre da geração, e não da transpilação.

O XML gerado contém só a lógica do processo. Para que seja possível abrir o modelo em uma ferramenta de modelagem, é necessário possuir um pós-processador que acrescenta as coordenadas de cada elemento, com um leiaute em camadas no estilo de Sugiyama, Tagawa e Toda (1981): os laços são desconsiderados para ordenar os elementos, cada elemento é posicionado pela distância até o início, e as raias são respeitadas. O leiaute é determinístico e serve apenas à visualização. Nenhuma medida deste trabalho depende dele: a validade e a razão de compressão são medidas sobre o XML sem coordenadas.

4.5 ESPECIALIZAÇÃO DO MODELO

O modelo pequeno é o Qwen2.5-Coder-7B-Instruct (HUI *et al.*, 2024), tem 7 bilhões de parâmetros e licença Apache 2.0 e foi ajustado de forma supervisionada sobre os pares de texto original como entrada e DSL descritos na Seção 4.2 como saída. O texto original foi mantido apesar de existir uma versão do texto padronizado (Seção 4.2.2) porque os textos do conjunto de teste também são descrições sem padronização textual. As saídas em DSL foram geradas por modelos de grande porte, por isso o ajuste é uma destilação: o modelo pequeno aprende a reproduzir, na DSL, o que os modelos grandes extraíram dos textos. Ele não vê o texto padronizado, o JSON intermediário nem o BPMN 2.0 XML final.

O ajuste usa QLoRA (DETTMERS *et al.*, 2023). Os pesos do modelo base ficam congelados e quantizados em 4 bits, e só são treinadas matrizes de baixo posto acrescentadas às camadas lineares (HU *et al.*, 2022). A perda é calculada apenas sobre os *tokens* da DSL, e não sobre os do *prompt*. O *prompt* de treino é o mesmo usado na avaliação do modelo ajustado: curto e sem a gramática da DSL, de modo que o modelo aprende a notação pelos exemplos (o *prompt* completo está no Apêndice A). Os hiperparâmetros estão na Tabela 2.

Dos 690 pares de treino, 18 passam de 4.096 *tokens* e foram descartados, restando 672. O treino foi feito em uma GPU A40 alugada, com 48 GB de VRAM, em 1 hora e 1 minuto, ao custo de US$ 0,47. A perda na validação foi medida ao fim de cada época: 0,440, 0,416 e 0,422. O adaptador mantido é o da segunda época, a de menor perda. Como a validação é separada por documento de origem (Seção 4.2.3), essa escolha favorece a generalização para documentos não vistos, e não a memorização.

Tabela 2 – Configuração do ajuste supervisionado

Parâmetro	Valor
Modelo base	Qwen2.5-Coder-7B-Instruct
Quantização do modelo base	4 bits (NF4, dupla quantização)
Posto e α do LoRA	16 e 32
Dropout do LoRA	0,05
Camadas adaptadas	todas as projeções lineares
Comprimento máximo da sequência	4.096 *tokens*
Épocas	3
Taxa de aprendizado	10^{-4}, cosseno, 3% de aquecimento
Lote efetivo	8 (1 exemplo, 8 passos de acumulação)
Otimizador	AdamW paginado de 8 bits
Semente	42

Fonte**:** Elaborado pelo autor

Na avaliação, o modelo roda localmente em uma RTX 2080 Ti de 11 GB de VRAM, com o modelo base em 4 bits, cálculos em 16 bits de ponto flutuante e decodificação gulosa, com até 2.048 *tokens* gerados. O braço de controle com o mesmo modelo sem o adaptador (Seção 4.6) usa exatamente a mesma configuração, para que a diferença entre os dois meça o efeito do ajuste, e não da forma de execução. O treino usou o formato *bfloat16*, disponível na A40, e a inferência usa *float16*, porque a arquitetura da 2080 Ti não oferece o primeiro.

4.6 BRAÇOS EXPERIMENTAIS

Cada braço experimental é uma forma de gerar o modelo BPMN a partir da descrição: um modelo de linguagem, um *prompt* e um formato de saída. Todos os braços recebem as mesmas descrições do conjunto de teste, no texto original. Os braços que emitem DSL passam pelo mesmo transpilador (Seção 4.4), e os que emitem XML são avaliados diretamente. A Tabela 3 resume os braços.

Os sete primeiros braços foram definidos e congelados antes da primeira execução. O A1 e o A1g representam a prática corrente, em que o modelo de grande porte escreve o BPMN 2.0 XML diretamente, e contempla comparação externa ao método. O A2 usa o mesmo modelo, mas pede a DSL, de modo que a diferença entre A2 e A1 vem só do formato de saída. O DeepSeek V4 Pro foi escolhido por não ter participado da geração do corpus. O par A1g e A2g repete a mesma comparação com o GLM 5.2, que gerou o corpus. Se o efeito do formato aparecer com um modelo e não com o outro, indica que o efeito está atrelado ao mesmo, e não da DSL. A2 e A2g não são concorrentes do método: são o próprio método executado com um modelo de grande porte, a referência que o modelo pequeno tenta alcançar.

Tabela 3 – Braços experimentais

Braço	Modelo	Saída	*Prompt*	O que o braço mede
A1	DeepSeek V4 Pro	XML	XML	a prática corrente: XML gerado direto
A2	DeepSeek V4 Pro	DSL	gramática	o efeito do formato, com o modelo fixo
A1g	GLM 5.2	XML	XML	A1 com o modelo que gerou o corpus
A2g	GLM 5.2	DSL	gramática	A2 com o modelo que gerou o corpus
A3	Qwen 7B	DSL	gramática	o modelo pequeno sem ajuste
A3m	Qwen 7B	DSL	mínimo	o controle do A4: só falta o adaptador
A4	Qwen 7B†	DSL	mínimo	o modelo pequeno especializado
A2r	DeepSeek V4 Pro	DSL	gramática com rótulo	se as falhas do A2 vêm das referências
X-lc25/50	Qwen 7B†	DSL	mínimo	o A4 treinado com 25% e 50% dos dados
X-gr	Granite 4.1 8B†	DSL	mínimo	o A4 em outra família de modelo
X-mi	MiMo-7B-RL†	DSL	mínimo	o A4 em outra família de modelo

Fonte**:** Elaborado pelo autor

Nota**:** Qwen 7B é o Qwen2.5-Coder-7B-Instruct; † com o adaptador treinado (Seção 4.5). Os braços acima do traço foram definidos antes de qualquer execução; os de baixo são exploratórios (ver texto).

Os três braços do modelo pequeno separam o efeito do ajuste do efeito da instrução. O A3 recebe o *prompt* com a gramática completa, o mesmo do A2, e mede o que o modelo pequeno consegue sem ajuste. O A4 recebe o *prompt* mínimo, sem gramática nem exemplo da notação, que é o mesmo usado no treino (Seção 4.5). Como A3 e A4 diferem nos pesos e no *prompt* ao mesmo tempo, foi acrescentado o A3m, que usa o modelo e o *prompt* do A4 sem o adaptador. A diferença entre A4 e A3m mede só o ajuste. A diferença entre A4 e A3 mede a intervenção inteira: os pesos ajustados somados à dispensa da gramática.

O *prompt* indica o que o contexto informa sobre a notação. Há quatro *prompts*: um para XML, com um exemplo da notação; um para a DSL, com a gramática completa e um exemplo; a versão deste com a referência por rótulo (Seção 4.3); e o mínimo. Medidos com o tokenizador do Qwen, sem a descrição do processo, eles têm 1.147, 1.351, 1.452 e 753 *tokens*, respectivamente. As partes que descrevem o papel do modelo, o idioma, as regras de modelagem e o formato da resposta são idênticas em todos os *prompts*, e um teste automatizado garante

isso. Os exemplos do *prompt* de XML e do de DSL descrevem o mesmo processo. Assim, a comparação entre formatos não depende da redação da instrução.

Os demais braços são exploratórios, dado que foram definidos depois do congelamento e seus resultados são reportados à parte. O A2r foi definido depois de observados os resultados do A2, em que a maior parte das falhas sintáticas estava nas referências por identificador. Para voltar a um elemento já escrito, num laço ou numa convergência, o modelo precisava tê-lo marcado com um identificador quando o escreveu pela primeira vez, isto é, antecipar que ia precisar dele. O A2r repete o A2 com o mesmo modelo e o mesmo *prompt*, exceto no trecho sobre referências, onde passa a documentar a referência por rótulo, que aponta para trás sem declaração prévia (Seção 4.3). Na mesma ocasião, foram corrigidas duas imprecisões do *prompt* do A2 em relação à gramática, sobre onde cabem propriedades e como se escrevem identificadores. Como nenhuma saída do A2 usou as formas afetadas, essas correções não explicam a diferença entre os dois braços. Um teste automatizado garante que os dois *prompts* não diferem em mais nada. Como a gramática apenas ganhou uma forma alternativa, o modelo ajustado não precisou ser retreinado.

Os outros quatro braços exploratórios foram definidos antes de serem executados e respondem a duas perguntas sobre o A4. X-lc25 e X-lc50 repetem o treino do A4 com 25% e 50% dos pares de treino, selecionados por documento de origem e aninhados (os documentos de 25% estão contidos nos de 50%), para verificar se a qualidade ainda cresce com mais dados ou se já estabilizou; o ponto de 100% é o próprio A4. X-gr e X-mi repetem o treino com os mesmos dados e hiperparâmetros em modelos de outras famílias, o Granite 4.1 8B, da IBM, e o MiMo-7B-RL, da Xiaomi, para verificar se o resultado do A4 é do método ou do Qwen. Antes da execução, ficou registrado que todo braço treinado entraria no texto, qualquer que fosse o resultado. Um quinto braço, com o DeepSeek-Coder-6.7B, foi descartado sem que seus resultados fossem usados: o tokenizador desse modelo apaga os espaços do texto, de modo que o braço media o tokenizador, e não o método.

4.7 MEDIDAS

São quatro medidas: a validade, o custo por requisição, a razão de compressão e a fidelidade. As três primeiras são calculadas por programa, sem julgamento. A fidelidade exige julgamento e foi medida por um modelo de linguagem usado como juiz, cuja validação foi parcial (Seção 4.7.4). Por isso as conclusões principais do trabalho se apoiam na validade e no

custo, e a fidelidade é reportada como exploratória.

4.7.1 Validade

Uma saída é válida quando produz um BPMN 2.0 XML aceito pelo esquema XSD oficial. Nos braços que emitem XML, a saída é validada diretamente. Nos que emitem DSL, a saída precisa ser aceita pela gramática e ter todas as referências resolvidas, isto é, cada fluxo deve apontar para um elemento definido; só então é transpilada. Como o esquema XSD oficial aceitou todos os XMLs produzidos pelo transpilador, tanto no corpus quanto nas saídas dos braços (Seção 4.4), a validade desses braços equivale, na prática, à taxa de saídas que o transpilador consegue ler e converter. Saídas truncadas pelo limite de *tokens*, respostas com erro, saídas fora da gramática e saídas com referências a elementos inexistentes contam como inválidas. A validade de um braço é a proporção de saídas válidas entre todas as gerações: 46 itens com 3 repetições cada, ou 138 gerações (Seção 4.8).

A validade perante o esquema é uma condição necessária, e não suficiente: um XML válido pode descrever o processo errado. É por isso que a fidelidade é medida à parte.

4.7.2 Custo por requisição

O custo de uma requisição é

$$C = t_{\text{in}} \cdot p_{\text{in}} + t_{\text{out}} \cdot p_{\text{out}}, \tag{4.1}$$

em que t_{in} e t_{out} são as médias de *tokens* de entrada (*prompt* e descrição) e de saída das gerações de cada braço, e p_{in} e p_{out} são os preços por *token* do provedor (Tabela 4). Os *tokens* de todos os braços são contados com o mesmo tokenizador, o do Qwen2.5-Coder, o que é uma aproximação para os modelos de grande porte. Também é reportado o custo por saída válida, C dividido pela validade do braço, que incorpora o gasto com as gerações que não servem.

Todos os preços vêm de um único provedor, o Together AI, que oferece os três modelos, consultado em uma única data. Isso evita misturar tabelas de provedores diferentes e descontos por horário ou temporários. Dois cenários são calculados. No primeiro, toda a entrada é cobrada a preço cheio. No segundo, a parte do *prompt* anterior à descrição, que é igual em todas as requisições de um braço, é cobrada a preço de *cache*. Como o provedor não oferece *cache* para o modelo pequeno, o custo do A3 e do A4 é o mesmo nos dois cenários, o que desfavorece o A4 no segundo.

Tabela 4 – Preços usados no cálculo do custo (US$ por milhão de *tokens*)

Modelo	Entrada	Saída	Entrada em *cache*
DeepSeek V4 Pro	1,32	3,96	0,13
GLM 5.2	1,40	4,40	0,26
Qwen2.5 7B	0,30	0,30	—
Qwen2.5 7B com adaptador (hipótese)	0,45	0,45	—

Fonte**:** Elaborado pelo autor, com preços públicos do Together AI consultados em 24/10/2026 (Together AI, 2026b)

Nota**:** O preço do Qwen2.5 7B é o do Qwen2.5-7B-Instruct, que tem a mesma arquitetura e o mesmo porte do Qwen2.5-Coder-7B; nenhum provedor consultado oferecia a variante Coder por *token*. O acréscimo de 50% no cenário com adaptador é uma margem arbitrada, e não um preço observado. O provedor não oferece preço de *cache* para o Qwen2.5 7B, e toda a sua entrada é cobrada a preço cheio.

O preço do modelo base tem fonte: o Qwen2.5-7B-Instruct é oferecido a US$ 0,30 por milhão de *tokens*, e o único outro provedor encontrado cobrava menos (US$ 0,10 na entrada e US$ 0,20 na saída, no OpenRouter), de modo que o valor adotado é o menos favorável ao A4. O preço do adaptador, por outro lado, não existe no catálogo disponível dos provedores observados, por isso, foi estimado. Em outubro de 2026, os provedores consultados tinham encerrado a hospedagem de adaptadores LoRA cobrada por *token* e só os ofereciam em implantações dedicadas, cobradas por hora de uso (Together AI, 2026a; Fireworks AI, 2026). Por isso, o preço do A4 é uma hipótese, e não um valor observado. O cenário com acréscimo de 50% foi utilizado nas comparações, por ser o menos favorável ao A4. Para que a conclusão não dependa desse valor, também é calculado o preço de equilíbrio: o preço por *token* a partir do qual o A4 deixaria de ser mais barato que cada braço de grande porte, mantidos os *tokens* medidos e a validade de cada braço. O tempo de inferência não é medido, pois os modelos de grande porte rodaram na infraestrutura dos provedores e o modelo pequeno em uma estação local, de modo que a comparação mediria o equipamento, e não o método.

4.7.3 Razão de compressão

A razão de compressão de *tokens* (TCR) mede quanto a DSL é menor que o XML que ela produz:

$$\mathrm{TCR} = \frac{\mathrm{tokens}(\mathrm{XML})}{\mathrm{tokens}(\mathrm{DSL})}, \tag{4.2}$$

com o tokenizador do Qwen2.5-Coder. O XML do numerador é o produzido pelo transpilador, sem as coordenadas do leiaute, que inflariam a razão sem acrescentar conteúdo ao processo

(Seção 4.4). A TCR é calculada sobre o corpus e sobre as saídas dos braços que emitem DSL, considerando apenas as saídas que passam pela transpilação. Nos braços que emitem XML não há representação intermediária, e a razão não é definida.

4.7.4 Fidelidade

A fidelidade é o quanto o modelo gerado representa o processo descrito no texto. Neste trabalho, ser fiel é representar o que o texto diz sem inventar conteúdo: um modelo que acrescenta atividades ou decisões que o texto não sustenta é penalizado, mesmo que o acréscimo seja plausível. Essa definição foi escolhida porque, nas saídas de um modelo de linguagem, inventar conteúdo é justamente o erro que importa detectar.

4.7.4.1 O juiz

A fidelidade é medida por um modelo de linguagem usado como juiz, o `muse-spark-1.3-contributor`, da Meta. Dois critérios orientaram a escolha. O primeiro é a família: o juiz é de família diferente da de todos os modelos que geraram o corpus ou participam dos braços, o que reduz o risco de ele favorecer saídas parecidas com as que ele mesmo produziria. O segundo é a capacidade: no índice de inteligência do Artificial Analysis, que agrega avaliações independentes de modelos de linguagem (Artificial Analysis, 2026), o juiz obtém entre 45 e 48 pontos, conforme a configuração de raciocínio, contra no máximo 36 dos modelos de grande porte que geraram o corpus ou participam dos braços, cada um na sua configuração mais alta. Capacidade geral, porém, não garante que o juiz avalie fidelidade como um especialista, e por isso ele foi validado de duas formas antes de ser usado nos braços, como descrito a seguir.

O juiz recebe o texto original do processo e o modelo gerado, e devolve uma nota inteira de 0 a 5.

O juiz não vê o XML. O modelo é apresentado como uma lista neutra de elementos e fluxos, com tipo e rótulo de cada elemento e identificadores sem significado (N1, N2, . . .). Isso remove as diferenças de forma entre um XML escrito diretamente por um modelo e um XML produzido pelo transpilador, de modo que o juiz não sabe de que braço veio a saída.

A rubrica do juiz tem cinco critérios: as atividades do texto estão presentes e nenhuma foi inventada; as decisões aparecem com as saídas que o texto dá; o paralelismo corresponde ao texto; a ordem, as repetições e os finais correspondem ao texto; e o modelo é bem formado, com início, fim e todos os elementos alcançáveis. Cada nota de 0 a 5 tem uma descrição na rubrica.

Antes de dar a nota, o juiz lista os problemas encontrados em cada critério, em uma resposta com formato fixo, o que permite auditar cada nota. Quem executa cada atividade não é avaliado.

Cada saída é julgada três vezes, com temperatura zero e sementes diferentes, e a nota da saída é a mediana das três. O texto completo das instruções do juiz é fixado por um *hash*, gravado com cada julgamento, de modo que uma mudança na rubrica gera um novo conjunto de notas, e não uma mistura de versões. As instruções estão no Apêndice B.

4.7.4.2 Validação contra notas de especialista

A primeira validação comparou as notas do juiz com as do especialista no Zenodo: 222 modelos de 24 processos, cada um com uma nota de 0 a 5 (MANGLER; KLIEVTSOVA, 2023). O critério, fixado antes da execução, era uma correlação de Spearman de pelo menos 0,5 entre as duas notas, com intervalo de confiança obtido por *bootstrap* sobre os processos.

O juiz não passou. Na primeira tentativa, a escala tinha passos de meio ponto, e o juiz respondeu quase só com valores terminados em 0,5, o que reduziu a escala a cinco níveis deslocados; a correlação foi de 0,133, com intervalo de [0,005; 0,263]. Na segunda tentativa, com a escala de inteiros e a rubrica inalterada, o juiz passou a usar todos os níveis, e a correlação foi de 0,108 [−0,028; 0,258].

A leitura dos 10 casos de maior divergência, feita pelo autor, indicou que o juiz e o especialista não medem a mesma coisa. Em todos os 10, os problemas que o juiz apontou existiam de fato no modelo; o desacordo estava no peso dado a eles. A principal causa é a definição de fidelidade: os textos do Zenodo são enunciados de projeto vagos, como “crie um processo que dê suporte a...”, em que quem modela precisa inventar detalhes, e o especialista premia uma boa invenção, enquanto a rubrica do juiz a penaliza. Somam-se a isso três fatores: as notas vêm de um único avaliador, 48% delas são a nota máxima, e 8 dos 222 modelos têm fluxos que, no XML, não estão ligados aos elementos, embora pareçam ligados no desenho que o especialista avaliou. Como o juiz está entre os modelos mais bem posicionados no índice citado acima, a falta de concordância dificilmente se explica por falta de capacidade: ela aponta, antes, para a diferença entre o que a rubrica e o especialista consideram fiel.

A rubrica não foi ajustada para se aproximar do especialista. Uma terceira tentativa, feita depois de ver dois resultados, seria um ajuste aos dados, e uma rubrica que não penaliza acréscimos poderia premiar exatamente as invenções que se quer detectar nos braços.

4.7.4.3 Validação por perturbação controlada

A segunda validação usa casos em que a resposta certa é conhecida por construção. Partindo do modelo de referência de cada um dos 46 itens do PMo, foram gerados mutantes com defeitos conhecidos: a remoção de uma atividade, a inserção de uma atividade inventada, a troca dos rótulos de duas atividades, a troca de um paralelismo por uma escolha exclusiva e a troca dos destinos de dois ramos de uma decisão. Cada item recebeu ainda um mutante com três defeitos sorteados e uma paráfrase, em que todos os rótulos foram reescritos com o mesmo sentido por outro modelo de linguagem, o GLM 5.3. A reescrita foi leve, em geral trocando só o verbo: a semelhança média entre o rótulo original e a paráfrase foi de 0,41 pelo índice de Jaccard, o que limita o quanto a invariância (C3) demonstra. Ao todo, foram 343 casos.

Os critérios foram fixados antes de qualquer julgamento e comparam cada caso com o modelo intacto do mesmo item. A sensibilidade (C1) é a proporção de pares em que o intacto recebe nota maior que o mutante com um defeito, com empates contando meio ponto, e deve ser de pelo menos 0,80. A gradação (C2) é a correlação de Spearman entre o número de defeitos (0, 1 ou 3) e a variação da nota em relação ao intacto, e deve ser de no máximo $-0{,}5$. A invariância (C3) é a proporção de itens em que a paráfrase muda a nota em no máximo 20% da escala, e deve ser de pelo menos 0,80. A medida originalmente prevista para a fidelidade, o DF-F1 (Seção 4.7.5), recebeu o mesmo cálculo, como comparação. A Tabela 5 mostra os resultados.

Tabela 5 – Validação por perturbação controlada

Critério	Limiar	Juiz	DF-F1
C1 sensibilidade	$\geq 0{,}80$	0,702	0,837
C2 gradação	$\leq -0{,}5$	$-0{,}385$	$-0{,}588$
C3 invariância	$\geq 0{,}80$	1,000	0,000

Fonte**:** Elaborado pelo autor

Nenhuma das duas medidas passou. O DF-F1 falhou na invariância: a paráfrase derrubou sua nota, em média, em 0,80 numa escala de 0 a 1, embora o processo fosse o mesmo. Ele também não percebe a troca de paralelismo por escolha nem a troca de ramos, com concordância de 0,5 nos dois casos, porque a nota não muda. O juiz foi perfeito na invariância, mas ficou abaixo do limiar na sensibilidade e na gradação.

A análise dos erros do juiz, feita depois do resultado, mostrou que ele quase nunca inverte a ordem: em 205 pares de intacto e mutante com um defeito, o mutante recebeu nota maior em apenas 10. O que derruba a sensibilidade são os empates, que vêm de um efeito de

piso: em 28 dos 46 itens, o próprio modelo de referência recebeu nota 3 ou menor, e um defeito a mais em um modelo que já tem problemas nem sempre muda a nota. A concordância cresce com a nota do intacto, de 0,47 quando ela é 2 a 0,97 quando é 5. Esse piso tem uma causa identificada: em pelo menos 10 dos itens compartilhados com o Zenodo, a referência do PMo é um modelo feito por iniciante (Seção 4.2), e as críticas do juiz a essas referências procedem nos casos lidos. Nos 22 itens que não vêm do Zenodo, o juiz teria passado em C1 (0,826) e C2 ($-0{,}536$). Esse recorte, porém, foi feito depois de ver os dados e não substitui o critério fixado antes.

4.7.4.4 Uso da medida

Nenhuma medida de fidelidade passou nas validações fixadas antes da execução. O juiz tem evidências parciais a seu favor: é insensível à paráfrase, quase não inverte a ordem entre o modelo correto e o defeituoso, e passaria nos critérios nos itens cuja referência não vem do Zenodo, embora esse recorte seja posterior ao resultado. Por isso ele é usado, mas a fidelidade é reportada como medida exploratória, e nenhuma conclusão principal depende dela.

O juiz foi aplicado às saídas válidas dos braços A1, A1g, A2, A2g, A2r e A4. Uma saída inválida não tem modelo a julgar. A nota de um braço em um item é a média das notas das suas saídas válidas, e cada braço é reportado com a sua cobertura, isto é, o número de itens em que teve ao menos uma saída válida. Como os 24 itens de origem do Zenodo têm textos vagos e se comportaram de forma diferente na validação, a fidelidade também é reportada separadamente para eles e para os 22 demais.

4.7.5 A medida originalmente prevista: DF-F1

O protocolo inicial previa como medida de fidelidade o DF-F1, que compara a saída com o modelo de referência pelos pares de atividades e eventos que se sucedem no fluxo, após alinhar os rótulos, e resume a concordância por um F1. A medida tem duas falhas que só foram verificadas depois do congelamento do protocolo. Ela não concorda com o especialista do Zenodo (correlação de Spearman de 0,04) e falhou na validação por perturbação, como mostra a Tabela 5. Além disso, depende do modelo de referência, que em parte dos itens não é confiável. Por isso foi substituída pelo juiz, o que é declarado como desvio do protocolo (Seção 4.9). Os resultados das hipóteses originais, decididas pelo DF-F1, são apresentados no Apêndice D, apenas para registro.

4.8 PROTOCOLO E ANÁLISE ESTATÍSTICA

4.8.1 Execução

Cada braço gerou uma saída para cada um dos 46 itens do conjunto de teste, três vezes, num total de 138 gerações por braço. Os braços de grande porte foram chamados com temperatura zero, reduzindo assim a variação entre as repetições, mas não a eliminando, pois o mesmo pedido pode produzir saídas diferentes no provedor. Os braços do modelo pequeno rodaram localmente com decodificação gulosa, em que a repetição tende a ser idêntica. As três repetições foram mantidas em todos os braços, para que a variação entre elas seja medida, e não suposta.

O limite de *tokens* de saída foi de 8.192 nos braços que emitem XML e de 2.048 nos que emitem DSL. A diferença acompanha o tamanho de cada formato, já que o XML é várias vezes mais longo que a DSL equivalente (Seção 4.7.3). Uma saída que atinge o limite é registrada como truncada e conta como inválida (Seção 4.7.1). Com esses limites, foram truncadas 3 gerações do A1, 2 do A1g e 81 do A3m, e nenhuma dos demais braços. Nenhuma geração foi repetida em caso de falha, já que uma falha é parte do resultado do braço. Cada geração foi gravada com o modelo, o *hash* do *prompt* e a versão do código que a produziu.

4.8.2 Unidade de análise e comparações

A unidade de análise é o item. Como todos os braços recebem os mesmos 46 itens, as comparações entre dois braços são pareadas: calcula-se a diferença item a item, e o resultado é a média dessas diferenças, com intervalo de confiança de 95% obtido por *bootstrap* sobre os itens, com 10.000 reamostragens e semente fixa. O *bootstrap* foi escolhido por não exigir que as diferenças sigam uma distribuição conhecida, o que não vale para proporções de três repetições nem para notas inteiras.

Na validade, o valor de um braço em um item é a fração das três repetições que são válidas, isto é, 0, 1/3, 2/3 ou 1. Na fidelidade, também é reportado o teste de Wilcoxon pareado, que indica se as diferenças entre os braços pendem para um dos lados mais do que o acaso explicaria. O teste foi escolhido por não supor que as diferenças sigam uma distribuição normal, o que não vale para notas inteiras de 0 a 5, e é bilateral, isto é, considera tanto a possibilidade de um braço ser melhor quanto a de ser pior.

4.8.3 Equivalência

A ausência de diferença significativa não demonstra que dois braços são equivalentes: com 46 itens, um intervalo largo pode conter tanto o zero quanto diferenças grandes. Por isso, toda afirmação de empate exige uma margem de equivalência fixada de antemão. A regra é a mesma para as duas medidas. Se o intervalo de 95% da diferença cai inteiro dentro da margem, os braços são declarados equivalentes. Se cai inteiro fora, são declarados diferentes além da margem. Nos demais casos, o resultado é inconclusivo.

Na validade, a margem é de ± 10 pontos percentuais, fixada antes do cálculo dos intervalos, quando apenas as proporções de cada braço tinham sido vistas. Uma diferença menor que essa não altera a ordem de custo por saída válida entre os braços. Os contrastes são A4 $-$ A2r, que compara o modelo pequeno com o método executado pelo modelo de grande porte, e A2r $-$ A1, que compara o método com a geração direta de XML.

Na fidelidade, a margem é de $\pm 0{,}5$ ponto na escala de 0 a 5, e foi fixada depois de vistas as notas dos braços, o que torna esses vereditos exploratórios. A margem se justifica sem recorrer a essas notas: é metade do passo da escala inteira e é menor que a queda média de nota causada por um único defeito na validação por perturbação, de 0,63 ponto. Os contrastes são A2r $-$ A1, A2 $-$ A1, A4 $-$ A2r e A4 $-$ A1.

4.8.4 Custo e compressão

O custo e a razão de compressão são descritivos: reportam-se os valores de cada braço, sem teste. A conclusão sobre o custo é verificada pelo preço de equilíbrio do A4 (Seção 4.7.2), que diz quanto o preço do modelo pequeno poderia subir antes de a ordem entre os braços se inverter.

4.8.5 Estatuto dos resultados

O protocolo inicial, congelado antes da primeira execução, previa quatro hipóteses, três delas decididas pelo DF-F1, com teste de Wilcoxon pareado bilateral sobre a mediana das três repetições por item, correção de Holm sobre os três contrastes planejados (A2 $-$ A1, A2g $-$ A1g e A4 $-$ A2) e intervalos por *bootstrap*. Como o DF-F1 foi substituído (Seção 4.7.5), essa análise é reportada integralmente, mas apenas no Apêndice D.

As análises do corpo do trabalho foram definidas depois do congelamento, e o texto

as distingue pelo momento em que cada decisão foi tomada. A margem da validade foi fixada antes do cálculo dos intervalos. A margem da fidelidade, depois de vistas as notas. A fidelidade inteira é exploratória, pela validação parcial do juiz, e não recebe correção para comparações múltiplas. O braço A2r foi definido depois de vistos os resultados do A2. Os desvios em relação ao protocolo inicial estão reunidos na Seção 4.9.

4.9 DESVIOS DO PROTOCOLO INICIAL

O protocolo inicial fixou, antes da primeira execução, os braços, os *prompts*, as medidas, as hipóteses e a análise estatística. Ele admitia mudanças, desde que declaradas com a data, o motivo e a indicação de terem sido feitas antes ou depois de vistos os resultados. Uma mudança feita depois dos resultados é mais fraca, porque pode ter sido escolhida por favorecer as hipóteses do autor. Por isso, para cada desvio, é indicado também em que direção ele poderia mover os resultados. A Tabela 6 resume os desvios, descritos a seguir.

Tabela 6 – Desvios do protocolo inicial

Desvio	Data	Resultados	Efeito possível
Glosa no *prompt* de DSL	16/08/2026	depois (A3)	eleva o A3, contra a hipótese
Correção de identificadores duplicados	25/08/2026	depois	eleva a DSL, a favor
Braço A2r	12/10/2026	depois	a favor; braço exploratório
Medida de custo	12/10/2026	depois	medida nova
Exclusão de 7 itens vazados	14/10/2026	depois	nenhum previsível
Correções P9 e P10 do transpilador	18/10/2026	depois	reduz a TCR, contra
Substituição do DF-F1 pelo juiz	18–20/10/2026	depois	medida nova
Erro no desenho da perturbação	20/10/2026	depois	recorte posterior
Margens de equivalência	20/10/2026	ver texto	análise nova

Fonte**:** Elaborado pelo autor

Nota**:** A coluna “Resultados” indica se o desvio foi decidido antes ou depois de vistos os resultados que ele afeta.

4.9.1 Mudanças nos artefatos

Glosa no *prompt* de DSL. Depois da execução do A3, verificou-se que o *prompt* de DSL listava as palavras-chave dos *gateways* sem ligá-las aos conceitos de BPMN usados nas regras de modelagem, e mostrava duas sintaxes de ramificação sem avisar que uma não se generaliza para a outra. O *prompt* de XML não precisa dessa ligação, porque a terminologia

BPMN já está no pré-treinamento dos modelos, e a omissão prejudicava apenas os braços de DSL. Os dois defeitos são verificáveis lendo o *prompt* e testando construções no *parser*, sem recorrer a nenhum resultado. O *prompt* foi corrigido e o A3 foi executado de novo; o A2 e o A2g já foram executados com a versão corrigida. A mudança é posterior aos resultados do A3, mas só podia elevar o A3, o que reduz a vantagem que o A4 poderia mostrar sobre ele. O efeito foi pequeno, e as gerações anteriores foram preservadas.

Correção de identificadores duplicados. Quando uma DSL redeclarava um elemento já marcado com identificador, o transpilador emitia dois elementos com o mesmo identificador, e o XML era rejeitado pelo esquema. A correção é posterior aos resultados e só podia elevar a validade dos braços de DSL, isto é, favorecer o método. Por isso, foi aplicada a todos os braços ao mesmo tempo, retranspilando as saídas já gravadas, sem nova chamada a modelo. Mudaram 6 de 1.590 gerações, nenhuma do A4, e nenhum desfecho de hipótese mudou.

Correções P9 e P10 do transpilador. Antes da execução do juiz, foram corrigidos dois defeitos. O primeiro (P9) ligava ao *gateway* de convergência um ramo que terminava em evento de fim, gerando um fluxo saindo do fim. O segundo (P10) ignorava a raia indicada no próprio elemento e repetia a mesma raia, com todos os membros, quando o bloco aparecia mais de uma vez. Nenhuma das correções alterou a validade de nenhum braço. Todas as saídas e o corpus foram retranspilados, e o corpus continuou inteiramente válido. A P10 afetou a razão de compressão: as raias repetidas inflavam o XML, e a TCR do corpus caiu de 6,01 para 5,37 (Seção 4.7.3). O efeito é contrário à hipótese do trabalho, e os valores reportados são os corrigidos.

Braço A2r. O A2r foi definido depois de vistos os resultados do A2, a partir da análise das falhas de sintaxe (Seção 4.6). É, portanto, exploratório, e seus resultados são reportados como tais, mesmo sendo o braço do método com maior validade.

4.9.2 Mudanças nos dados

Exclusão de 7 itens. Uma auditoria posterior aos resultados encontrou 7 itens do PMo cujos textos também estão no PET, usado no treino (Seção 4.2.3). Os 7 itens foram excluídos de todas as análises, que passaram de 53 para 46 itens, sem apagar nenhuma geração. A exclusão segue um critério definido sem olhar o desempenho dos braços, a sobreposição de texto com o treino, e foi aplicada a todos os braços. As validades mudaram no máximo 3,7 pontos percentuais, e a ordem entre os braços se manteve.

4.9.3 Mudanças nas medidas e na análise

Medida de custo. O custo por requisição não estava no protocolo inicial. Ele não é uma medição nova, e sim a conversão em dinheiro de quantidades já medidas, os *tokens* de entrada e de saída de cada geração. Os preços e as hipóteses do cálculo estão na Seção 4.7.2.

Substituição do DF-F1 pelo juiz. A medida de fidelidade prevista, o DF-F1, falhou nas duas validações feitas depois do congelamento, e foi substituída pelo juiz (Seções 4.7.4 e 4.7.5). O juiz também não passou nos critérios fixados, e por isso a fidelidade é exploratória. As hipóteses originais, decididas pelo DF-F1, são reportadas no Apêndice D. Na validação contra o Zenodo, o juiz foi executado duas vezes: a segunda corrigiu a escala de meio ponto, que o juiz não usava por inteiro, e manteve a rubrica. As duas tentativas são reportadas.

Erro no desenho da perturbação. A validação por perturbação supunha que o modelo de referência de cada item estivesse correto. Depois do resultado, verificou-se que ao menos 10 referências são modelos de iniciantes do Zenodo (Seção 4.2), o que já se sabia antes do teste e deveria ter excluído esses itens da base. O teste mediu, em parte, a qualidade da referência, e não só a do juiz. O resultado nos 22 itens fora do Zenodo é reportado, mas como recorte posterior ao resultado, sem valor de validação.

Margens de equivalência e unidade da validade. O protocolo inicial não previa margens de equivalência, e um empate só podia ser descrito como ausência de diferença significativa. As margens foram acrescentadas depois do congelamento (Seção 4.8). A da validade foi fixada antes do cálculo dos intervalos, e a da fidelidade, depois de vistas as notas. Na mesma ocasião, a validade de um item passou a ser a fração das três repetições válidas, e não a mediana prevista no protocolo inicial. Com três repetições que valem 0 ou 1, a mediana vira um voto de maioria e descarta a informação de que, por exemplo, uma de três saídas falhou.

4.10 AMEAÇAS À VALIDADE

As ameaças estão agrupadas pelo tipo de conclusão que afetam, se os efeitos observados se devem aos braços (validade interna), se as medidas medem o que se pretende (validade de construto), se os resultados se estendem além deste estudo (validade externa) e se a análise sustenta as conclusões tiradas (validade da conclusão).

4.10.1 Validade interna

Decisões tomadas depois dos resultados. Parte das decisões foi tomada depois de vistos os resultados, o braço A2r, a medida de custo, a substituição do DF-F1 e a margem de equivalência da fidelidade (Seção 4.9). Cada uma pode ter sido influenciada, ainda que sem intenção, pelo que favorecia o trabalho. A mitigação adotada foi declarar o momento de cada decisão, reportar a análise original no apêndice e aplicar toda correção a todos os braços ao mesmo tempo.

Redação dos *prompts*. Cada formato foi testado com um único *prompt*, e testar com outras variantes poderiam mudar os resultados. As partes comuns são idênticas entre os *prompts*, o que torna a comparação entre formatos justa, mas não garante que cada *prompt* seja o melhor possível para o seu formato. A emenda da glosa (Seção 4.9) mostrou que uma correção de redação teve efeito pequeno, mas uma única emenda não basta para descartar essa sensibilidade.

Variação entre execuções e versões dos modelos. A temperatura zero não garante saídas idênticas nos provedores, e os modelos de grande porte foram acessados por API, cujas versões podem mudar sem aviso. As três repetições medem a variação dentro do período de execução, mas uma nova execução no futuro pode não reproduzir exatamente os números. Os resultados do modelo pequeno, executado localmente com pesos fixos, não têm essa limitação.

4.10.2 Validade de construto

Fidelidade. O juiz não passou nos critérios de validação fixados (Seção 4.7.4), e por isso a fidelidade é exploratória. Mesmo como medida exploratória, a escala do juiz não é calibrada, pois uma diferença de um ponto não corresponde a um número conhecido de defeitos, e as notas de braços diferentes só podem ser comparadas entre si, e não interpretadas em termos absolutos.

Referências e textos de avaliação. Ao menos 10 das referências do PMo são modelos feitos por iniciantes, e os 24 itens vindos do Zenodo têm enunciados de projeto vagos, em que quem modela precisa inventar parte do processo (Seção 4.2). Isso afeta qualquer medida que dependa da referência ou que penalize acréscimos. A fidelidade é julgada contra o texto, e não contra a referência, e é reportada separadamente para os dois grupos de itens, mas a vagueza desses textos continua afetando o julgamento.

Validade. A validade mede apenas a conformidade com o esquema XSD. Um XML válido pode ter elementos inalcançáveis, decisões sem saída ou um processo diferente do descrito,

e esses problemas só são capturados, em parte, pela fidelidade, que é exploratória.

Custo. O preço do modelo com adaptador é uma hipótese, porque nenhum provedor consultado oferecia esse serviço cobrando por *token*, e todos os preços são de um único provedor em uma única data. Além disso, os *tokens* de todos os braços foram contados com o tokenizador do Qwen, o que é uma aproximação para os modelos de grande porte. O preço de equilíbrio (Seção 4.7.2) reduz a dependência da conclusão em relação ao preço exato, mas não a elimina.

4.10.3 Validade externa

Domínio dos dados de treino. 94,4% dos pares de treino vêm do *handbook* da GitLab, de uma única empresa, enquanto o teste é feito sobre processos de outros domínios. Isso pode subestimar o modelo pequeno, que foi avaliado fora do domínio em que foi treinado, mas também significa que não se sabe como ele se comportaria com dados de treino mais variados. O desenho não separa o efeito dessa mudança de domínio do efeito do tamanho do modelo.

Dados de treino gerados por modelo. Os pares de treino foram gerados pelo GLM 5.2 e filtrados apenas pela consistência entre o JSON e o XML, sem verificação humana de que o JSON representa o texto. Erros do gerador podem ter sido aprendidos pelo modelo pequeno. O GLM 5.2 também é usado nos braços A1g e A2g, o que pode favorecê-lo nesses braços, já que o corpus segue o seu estilo de modelagem; por isso a comparação entre formatos foi replicada com o DeepSeek V4 Pro, que não participou da geração.

Contaminação dos modelos de grande porte. O PMo, o Zenodo e o PET são conjuntos públicos, e é possível que seus textos e modelos de referência estejam nos dados de pré-treinamento dos modelos de grande porte. Se estiverem, os braços A1, A1g, A2, A2g e A2r são favorecidos, e a comparação com o modelo pequeno fica desfavorável a ele. Não há como verificar essa contaminação em modelos de pesos fechados ou de dados de treino não publicados.

Alcance do estudo. O estudo usa uma linguagem de saída (BPMN 2.0), uma língua (inglês), uma família de modelo pequeno no braço principal e 46 itens de teste. Os braços com o Granite e o MiMo verificam parte da dependência em relação ao modelo pequeno, mas a generalização para outras linguagens XML, que é a motivação do método, não foi testada.

4.10.4 Validade da conclusão

Tamanho da amostra. Com 46 itens, os intervalos de confiança das diferenças de validade têm cerca de ± 13 pontos percentuais, mais largos que a margem de equivalência de 10

pontos. Por isso, a igualdade de validade entre o A4 e o A2r não pode ser declarada equivalência, e o estudo não tem itens suficientes para isso (Seção 4.8).

Comparações múltiplas. As análises de fidelidade e os braços exploratórios não recebem correção para comparações múltiplas. Com vários contrastes, a chance de algum resultado aparentemente significativo ser fruto do acaso aumenta, e esses resultados devem ser lidos como indicações, e não como confirmações.

5 RESULTADOS

Este capítulo reporta os resultados em duas partes de natureza distinta. A primeira é a **verificação do protocolo determinístico** sobre o corpus completo (Seções 5.1 a 5.5): trata-se de comportamento de *software*, e os valores próximos de 100% ali apresentados são esperados por construção, servindo para confirmar que o transpilador cumpre a garantia que lhe é atribuída. A segunda é a **avaliação comparativa dos braços experimentais** (Seção 5.6), na qual as hipóteses do trabalho são efetivamente testadas contra modelos de referência produzidos por especialistas.

A distinção é essencial para a leitura: os dois conjuntos de números **não são comparáveis entre si**. Um DF-F1 de 0,9999 na primeira parte mede a fidelidade de uma conversão determinística entre representações do mesmo processo; um DF-F1 de 0,19 na segunda mede o quanto um modelo de linguagem, partindo apenas de texto em prosa, reconstrói um processo modelado independentemente por um especialista. São tarefas de dificuldade incomparável, e confundi-las levaria a conclusão inteiramente equivocada.

Todos os valores são recuperáveis do banco de dados do projeto, no qual cada execução é registrada com versão, estado e diagnósticos por amostra.

5.1 COMPOSIÇÃO DO CORPUS

Foram coletadas 1.047 amostras, das quais 26 foram excluídas por degradação identificada durante a validação, resultando em **1.021 amostras ativas**. A distribuição por partição é apresentada na Tabela 7.

Tabela 7 – Distribuição do corpus por partição

Partição	N	Uso
sft	772	treino supervisionado
grpo	172	etapa opcional de reforço
holdout	77	avaliação exclusivamente
Total	1.021	

Fonte**:** Elaborado pelo autor

Nota**:** A partição *holdout* agrega os 53 itens do PMo e as 24 descrições da fonte Zenodo, esta última excluída do treino por compartilhar origem com parte do PMo.

Registra-se uma ameaça à validade externa: 900 das 944 amostras de treino (95,3%) provêm de uma única fonte, o *handbook* da GitLab. O modelo especializado é, portanto, treinado

predominantemente sobre o estilo redacional de uma única organização e avaliado contra o PMo, de domínio distinto. Essa assimetria é reconhecida como limitação, e a consequência prática é que aumento de volume só reduz o risco se vier de **fontes novas**, não de mais seções do mesmo *handbook*.

5.2 EIXO 1: VALIDADE SINTÁTICA

As 1.021 amostras ativas produzem DSL aceita pela gramática e XML válido contra o XSD oficial da BPMN 2.0: **1.021/1.021 (100%)** em ambos os critérios. O resultado é esperado por construção — a validade sintática do XML final é responsabilidade do transpilador determinístico, não do modelo probabilístico — e sua função aqui é confirmar que o transpilador cumpre a garantia que o protocolo lhe atribui.

O valor desse número está no contraste que ele permite: nos braços que geram XML diretamente, a validade passa a ser uma variável aleatória dependente do modelo, e a diferença entre 100% garantido e a taxa observada é precisamente o que a hipótese H2 afirma.

5.3 EIXO 2: FIDELIDADE TOPOLÓGICA

Sobre a base ativa, a comparação entre o JSON canônico de origem e o XML reconstituído pela cadeia DSL apresenta **1.017 de 1.021 amostras (99,6%) com equivalência exata de arestas** e DF-F1 médio de **0,9999** (mínimo observado 0,9545). A contagem de nós por categoria coincide em **1.021/1.021 (100%)** das amostras.

Por partição: *sft* 768/772, *grpo* 172/172 e *holdout* 77/77 com equivalência exata. O subconjunto de 768 pares da partição *sft* com equivalência exata constitui o conjunto de treino supervisionado de alta confiança.

5.3.1 Trajetória entre Versões

O desenvolvimento iterativo do linearizador foi verificado executando-se a comparação topológica sobre o corpus **inteiro** a cada versão, e não por inspeção amostral. A Tabela 8 apresenta a trajetória.

Dois achados metodológicos emergem da tabela. O primeiro é o salto de v7 para v8, que corrigiu a perda silenciosa de arestas de convergência em estruturas não estritamente aninhadas: 891 para 1.015 amostras exatas, com as 127 amostras que perdiam arestas indo a

Tabela 8 – Fidelidade topológica por versão do conversor

Versão (DSL / XML)	Idioma	Exatas	DF-F1	Com arestas perdidas
v7 / v3	pt	891	0,9939	127
v8 / v3	pt	1.015	0,9999	0
v8 / v3	en	998	0,9970	20
v9 / v3	en	1.015	0,9998	1
v10 / v4	en	1.016	0,9998	1
v10 / v5	**en**	**1.017**	**0,9999**	**0**

Fonte**:** Elaborado pelo autor

Nota**:** N = 1.021 em todas as versões. "Com arestas perdidas"conta amostras em que ao menos uma aresta da referência não aparece no candidato.

zero. Essa classe de defeito é particularmente perigosa porque não produz erro observável — o XML permanece válido no esquema e apenas descreve um processo diferente.

O segundo é a **regressão introduzida pela regeneração em inglês**: a versão v8 aplicada ao corpus regenerado voltou a apresentar 20 amostras com arestas perdidas, apesar de a mesma versão do conversor ter atingido zero na base anterior. O conteúdo novo expôs defeitos latentes que o corpus antigo não exercitava — notadamente a divisão implícita descrita na Seção **??**. As versões v9 e v10 eliminaram a regressão. O episódio sustenta uma escolha metodológica do trabalho: verificação sobre o corpus completo a cada versão, com resultado persistido, é o que torna regressões detectáveis; amostragem manual não as teria revelado.

5.3.2 Análise do Resíduo

As quatro amostras sem equivalência exata na base ativa compartilham uma propriedade relevante: em todas, o conjunto de arestas ausentes é **vazio**. O resíduo consiste exclusivamente em arestas *excedentes* — uma ou duas por amostra — e não em lógica perdida. Em termos práticos, a cadeia determinística nunca descarta uma relação de precedência presente no processo de origem; nos quatro casos remanescentes, ela introduz uma relação adicional decorrente da serialização de convergências. Sendo a preservação da lógica do processo o objetivo do componente determinístico, essa assimetria do erro é favorável: o modo de falha residual é conservador.

5.4 EIXO 4: COMPRESSÃO DE *TOKENS*

Medida com o tokenizador do modelo base sobre as 1.021 amostras, a razão de compressão é de **6,01** (IC95% [5,96; 6,06], mediana 5,99), correspondente a uma **redução de**

83,4% no número de *tokens* que o modelo precisa emitir em relação ao XML BPMN lógico equivalente.

Cabe explicitar o que o número **não** é. O denominador é o XML lógico, sem a seção de diagrama. Medindo-se contra o XML com informação de leiaute, a razão triplicaria — e seria um artefato de medição, já que o leiaute é gerado deterministicamente por pós-processamento e nenhuma das abordagens comparadas exige que o modelo o produza. Essa distinção é registrada aqui porque uma medição preliminar contra o artefato errado chegou a indicar cerca de 91% de redução, valor que foi descartado ao se identificar a inconsistência; a definição normativa da métrica foi então fixada no protocolo, e o XML com leiaute deixou de ser materializado na mesma coluna do XML lógico no banco, tornando o erro irreproduzível.

Registra-se ainda que a meta de projeto inicialmente estipulada era de 85% de redução, e o valor medido (83,4%) ficou abaixo dela. Como a meta havia sido fixada antes de qualquer medição e sem base empírica, e como o protocolo de avaliação foi congelado com a definição normativa da métrica, opta-se por reportar o valor obtido e registrar a divergência, em vez de reajustar a meta *a posteriori*.

5.5 CONJUNTO DE REFERÊNCIA

O conjunto de avaliação reúne **53 modelos de referência primários** do PMo, um por item, e **172 referências alternativas** da fonte Zenodo distribuídas sobre 24 desses itens (de 4 a 11 por item), admitidas segundo a regra de nota mínima da Seção **??**.

A curadoria descartou referências por dois motivos declarados: um modelo sem nota de especialista atribuída, por ausência de evidência de aprovação, e três modelos que, apesar de nota suficiente, não produzem nenhuma aresta na projeção adotada — referência degenerada não serve de referência. O mapeamento entre as duas fontes é verificado como bijeção no momento da carga, falhando explicitamente caso a propriedade não se sustente, em vez de gravar correspondência parcial.

5.6 AVALIAÇÃO COMPARATIVA DOS BRAÇOS

Esta seção reporta a execução completa dos braços experimentais definidos na Seção **??**: **1.113 gerações** (7 braços $\times$ 53 itens $\times$ 3 repetições), sem qualquer erro de geração, e as 159 gerações do braço A2r, acrescentado pela emenda E-3 (Seção 5.6.6).

Antecipa-se o desfecho, para que a leitura das subseções seguintes seja feita com ele

em mente. **As hipóteses H1, H1g e H2 foram refutadas** com significância estatística nas duas famílias de modelos: gerar XML diretamente superou gerar a DSL por *prompting*. **A hipótese H3 não foi refutada nem demonstrada** — o modelo especializado empata estatisticamente com o modelo de fronteira que recebe a gramática no *prompt*. **A hipótese H4 foi confirmada com folga.**

O achado de maior magnitude não corresponde a hipótese registrada alguma e emerge do eixo de validade sintática: a maior parte das falhas do modelo de fronteira instruído pela gramática decorria da forma de referência da notação, e não de sua novidade. Acrescentada a referência por rótulo (emenda E-3, Seção 5.6.6), o mesmo modelo passa de 64,8% a **86,8%** de validade, sem perda de qualidade nas saídas válidas e com fidelidade estatisticamente indistinguível da geração direta de XML. O modelo de 7 bilhões de parâmetros com ajuste fino atinge a mesma validade, 86,8%, a uma fração do custo (Seção 5.6.7).

5.6.1 Resultados Descritivos por Braço

A Tabela 9 apresenta o panorama. Duas convenções de leitura são necessárias. Primeiro, a validade XSD é reportada **por geração** (sobre 159), enquanto a coluna de itens conta quantos dos 53 obtiveram ao menos uma geração válida — a distinção importa porque um item pode alternar entre válido e inválido nas três repetições. Segundo, o DF-F1 reportado é a **média das medianas por item**, conforme a unidade de análise fixada na Seção **??**.

Tabela 9 – Panorama dos braços executados

Braço	Saída	XSD	Itens	DF-F1	Máx.	*Tokens*
A1 (DeepSeek)	XML	**98,1%**	53/53	**0,1942**	0,571	631
A1g (GLM)	XML	94,3%	53/53	0,1551	0,593	699
A2r (DeepSeek)	DSL	**86,8%**	**50/53**	0,1804	0,667	141
A4 (Qwen 7B + SFT)	DSL	**86,8%**	**46/53**	0,1114	0,395	200
A2 (DeepSeek)	DSL	64,8%	40/53	0,1375	0,714	**138**
A3 (Qwen 7B)	DSL	58,5%	31/53	0,0666	0,333	159
A2g (GLM)	DSL	56,6%	41/53	0,0783	0,387	149
A3m (Qwen 7B)	DSL	0,0%	0/53	0,0000	0,000	2.041

Fonte**:** Elaborado pelo autor

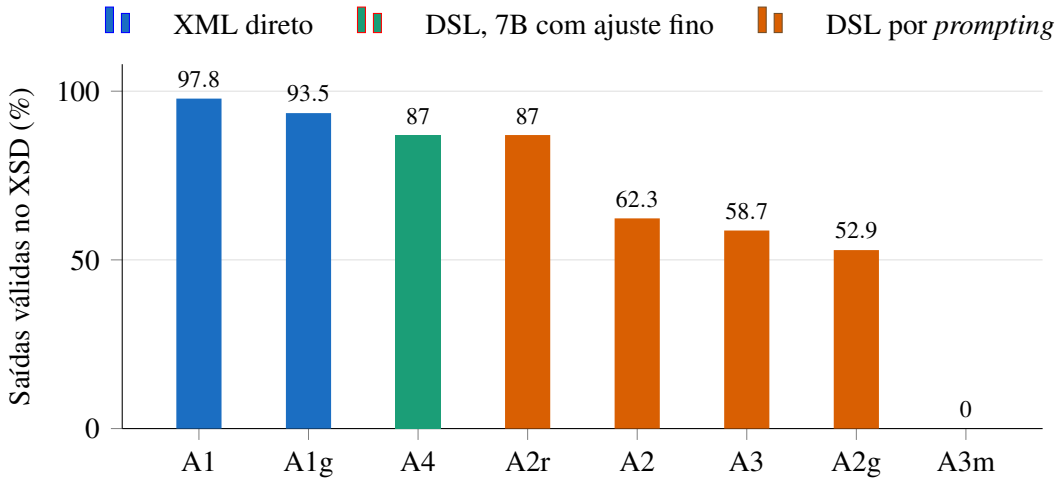
Nota**:** XSD por geração (N = 159 por braço). "Itens"conta itens com ao menos uma geração válida. DF-F1 é a média das medianas por item. "Máx."é o melhor item do braço. *Tokens* é a mediana de *tokens* emitidos. Nenhum braço registrou erro de geração. A2r: braço da emenda E-3, exploratório.

Quatro leituras imediatas. A primeira é que **os braços de XML dominam a coluna de DF-F1**. A segunda é que **os braços de DSL dominam a coluna de *tokens*** por margem de

quatro a cinco vezes. A terceira é que o melhor item isolado pertence ao A2 (0,714), acima do melhor item do A1 (0,571) — indício, explorado adiante, de que a DSL não é inferior *quando funciona*.

A quarta é a que reorganiza a tabela: **o braço A4 ocupa, empatado com o A2r, a terceira posição em validade**, à frente de todos os braços de DSL conduzidos por *prompt* com a primeira versão da notação, inclusive os de modelos de fronteira. O A2r, que repete o A2 com a referência por rótulo (emenda E-3), alcança a mesma taxa por outro caminho, sem ajuste fino. A Figura 2 apresenta esse eixo isoladamente.

Figura 2 – Validade sintática por braço experimental



Fonte**:** Elaborado pelo autor

Nota**:** Percentual sobre as 159 gerações de cada braço. Nos braços de DSL a validade XSD coincide com a taxa de *parsing*, pois a transpilação é determinística e sempre produz XML válido a partir de DSL aceita.

A progressão que a figura torna visível — **0%** sem gramática no contexto, **58,5%** com a gramática no *prompt*, **86,8%** com a notação nos pesos — percorre os três braços que compartilham o mesmo modelo base de 7 bilhões de parâmetros. Como A3m e A4 usam ainda o **mesmo *prompt***, diferindo apenas pela presença do adaptador, o salto entre eles isola o efeito do ajuste supervisionado sem confundi-lo com mudança de instrução.

O braço A3m merece registro à parte por não ser uma falha de medição. Submetido ao *prompt* mínimo — o mesmo que será usado no treinamento do A4, e que deliberadamente não contém gramática nem exemplo de notação — o modelo base produziu **BPMN XML em 53 dos 53 itens**, jamais tentando a DSL. Um modelo sem a notação nos pesos e sem a especificação no contexto recorre ao formato que conhece do pré-treinamento. Os 81 truncamentos do braço têm a mesma origem: gerar um documento XML completo sob um teto de 2.048 *tokens* dimensionado para DSL. O zero do A3m não mede incapacidade de modelagem; mede que **o *prompt* mínimo**

não carrega informação suficiente sem o ajuste fino — que é exatamente a função de piso que lhe foi atribuída no desenho.

5.6.2 Testes das Hipóteses Pré-Registradas

Os três contrastes planejados (Seção **??**) foram submetidos ao teste de Wilcoxon pareado bilateral com correção de Holm, conforme o plano de análise congelado. A Tabela 10 apresenta os resultados.

Tabela 10 – Contrastes pré-registrados

Contraste	Dif. mediana	IC95%	r_{rb}	p_{Holm}	Desfecho
A2 vs A1	−0,0067	[−0,0769; 0,0]	−0,366	0,0387	H1 refutada
A2g vs A1g	−0,0287	[−0,0845; 0,0]	−0,429	0,0062	H1g refutada
A4 vs A2	0,0	[−0,0329; 0,0]	−0,231	0,2496	H3 não refutada

Fonte**:** Elaborado pelo autor

Nota**:** N = 53 pares em todos os contrastes; 12, 11 e 14 empates, respectivamente. r_{rb} é o tamanho de efeito rank-biserial. IC95% por *bootstrap* pareado com 10.000 reamostragens e semente fixa. Sinal negativo indica vantagem do braço de XML.

O sinal negativo em ambos os contrastes indica que o braço de XML superou o de DSL. A magnitude do efeito é moderada ($|r_{rb}|$ entre 0,37 e 0,43), e o valor-p permanece significativo após a correção de Holm nos dois casos.

A **replicação interna** cumpriu sua função de desenho. A Seção **??** havia registrado que, se H1 falhasse e H1g se sustentasse, o efeito seria atribuível ao modelo e não ao formato. Como ambas falharam na mesma direção, com dois modelos de famílias distintas, a conclusão é atribuível ao **formato**: não é idiossincrasia do DeepSeek.

O contraste A4 vs. A2 exige leitura cuidadosa e é reportado sem atenuação. O teste **não é significativo** ($p_{Holm} = 0{,}25$) e o intervalo de confiança contém o zero. Como H3 foi enunciada na forma $\geq$, um empate estatístico não a refuta — mas tampouco a demonstra. **O braço A4 não supera o A2 em fidelidade topológica; iguala-o.** O tamanho de efeito ($-0{,}231$) e o intervalo $[-0{,}0329;\ 0{,}0]$ apontam ligeira desvantagem do modelo especializado, sem que o teste a distinga de zero com $n = 53$. Interpretar resultado nulo como confirmação seria abuso do enunciado da hipótese, e registra-se aqui a recusa em fazê-lo.

A hipótese H2 foi a refutada de forma mais acentuada, e por isso mesmo a mais instrutiva. Ela afirmava que a transpilação determinística garantiria validade que a geração direta não garante. O raciocínio estava correto quanto ao transpilador — este produz XML válido em

100% dos casos, conforme a Seção 5.2 — mas **condicionado a que a DSL seja aceita pela gramática**. O protocolo tratava o *parsing* como etapa dada, e é ele o gargalo: apenas 64,8% das gerações do A2 produziram DSL sintaticamente aceita. Enquanto isso, o DeepSeek redigiu BPMN XML válido contra o esquema oficial em 98,1% das gerações, sem qualquer garantia estrutural — apenas por competência adquirida no pré-treinamento.

Esse resultado pareceu, de início, contradizer uma premissa implícita do trabalho: a de que uma notação compacta seria *mais fácil* de emitir do que XML verboso. A análise das falhas (emenda E-3) localiza a causa com mais precisão: não na novidade da notação em si, e sim num traço específico de seu desenho, a exigência de declarar identificadores antes de saber que serão usados. Removida essa exigência, o mesmo modelo, com a mesma gramática no contexto, produz DSL válida em 86,8% das gerações. A validade do XML (98,1%) permanece superior, e H2 permanece refutada; mas a distância deixa de ser explicável pela familiaridade do modelo com o formato.

Os mesmos contrastes com o braço A2r (exploratório)

Os contrastes acima são decididos sobre o A2, como registrado. Repetidos com o A2r no lugar do A2 (emenda E-3), sem correção de múltiplas comparações e sem valor confirmatório, eles mudam de sentido nos dois casos (Tabela 11).

Tabela 11 – Contrastes com o braço A2r (exploratório)

Contraste	Dif. mediana	IC95%	r_{rb}	p	Leitura
A2r vs A1	0,0	[−0,0184; 0,0]	−0,122	0,40	sem diferença detectável
A4 vs A2r	−0,0219	[−0,1176; 0,0]	−0,349	0,001	A4 inferior

Fonte**:** Elaborado pelo autor

Nota**:** N = 53 pares; 12 e 10 empates, respectivamente. Valor-p sem correção de Holm: os pares não integram os contrastes planejados. Demais convenções como na Tabela 10.

Com a referência por rótulo, a DSL deixa de perder fidelidade para o XML gerado pelo mesmo modelo: as medianas por item são praticamente iguais (0,160 e 0,162), e o teste não distingue os braços. A refutação de H1 decorria, em sua maior parte, das saídas inválidas do A2, que pontuam zero. Em sentido oposto, e reportado sem atenuação: a não refutação de H3 também dependia da fragilidade do A2. Contra o A2r, o modelo especializado é **inferior em fidelidade**, com efeito moderado. O modelo pequeno alcança o de fronteira em validade sintática (Seção 5.6.4), mas não em fidelidade topológica.

5.6.3 Análise do Mecanismo: Validade e Não Qualidade

A refutação de H1 admite duas explicações concorrentes, com implicações opostas para a continuidade do trabalho. Ou a DSL degrada a qualidade da modelagem, ou ela apenas falha em ser produzida corretamente, sendo competitiva quando produzida. A distinção é decisiva: a primeira invalidaria a abordagem, a segunda a redirecionaria para o ajuste fino.

Para separá-las, repetiu-se o contraste **restrito aos itens em que o braço de DSL produziu saída válida**. Trata-se de análise exploratória, não pré-registrada, e o condicionamento em uma variável posterior à intervenção introduz viés de seleção — o subconjunto pode conter os itens mais fáceis. O resultado é indicativo, não confirmatório.

Tabela 12 – Contraste restrito aos itens com saída válida (exploratório)

Subconjunto	N	DSL	XML	Diferença
Todos os itens (A2 vs A1)	53	0,1375	0,1942	−0,0567
Só onde A2 valida	40	0,1821	0,2040	−0,0219
Todos os itens (A2g vs A1g)	53	0,0783	0,1551	−0,0768
Só onde A2g valida	41	0,1012	0,1420	−0,0408
Todos os itens (A2r vs A1)	53	0,1804	0,1942	−0,0138
Só onde A2r valida	50	0,1912	0,1884	+0,0028

Fonte**:** Elaborado pelo autor

Nota**:** Análise exploratória, não pré-registrada. O condicionamento em variável pós-intervenção introduz viés de seleção; os valores são indicativos.

A distância cai a menos da metade quando se descartam as falhas de validade: de $-0{,}0567$ para $-0{,}0219$ no DeepSeek, e de $-0{,}0768$ para $-0{,}0408$ no GLM. **A maior parte da desvantagem da DSL é perda de validade, não perda de qualidade de modelagem** — porém a diferença não se anula, e portanto a explicação não é exclusivamente de validade. Some-se a isso que o melhor item do A2 (0,714) supera o melhor do A1 (0,571). Com a referência por rótulo, a leitura se completa: nos 50 itens em que o A2r produz saída válida, a DSL iguala o XML gerado pelo mesmo modelo (0,1912 contra 0,1884). O resíduo que a primeira versão da notação deixava era, portanto, também de forma.

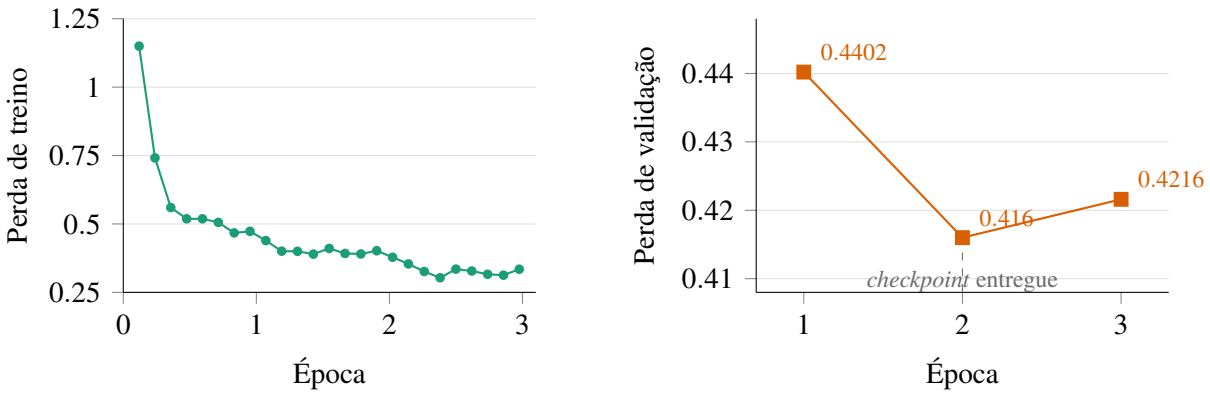
A consequência para o trabalho é direta e delimita o que resta a investigar: se a desvantagem se concentra na taxa de aceitação sintática, então há duas intervenções possíveis: **corrigir a notação**, removendo a exigência que causa as falhas, o que a emenda E-3 fez; ou **internalizar a notação nos pesos**, que é o que o ajuste fino do braço A4 se propõe a fazer. A primeira mantém o modelo de fronteira; a segunda troca-o por um modelo pequeno, e se justifica

pelo custo (Seção 5.6.7). A cadeia de evidências A3m (0/53, sem gramática no contexto) → A3 (31/53, com gramática no contexto) → A2 (40/53, com gramática e modelo grande) mostra a aceitação sintática crescendo com a informação disponível sobre a notação, o que torna a hipótese plausível — sem, evidentemente, demonstrá-la.

5.6.4 O Modelo Especializado

O ajuste supervisionado consumiu **672 pares** de treino — os 690 exportados menos 18 que excediam o comprimento de sequência — e 78 de validação, agrupados por documento de origem. Executou-se em uma GPU NVIDIA A40 alugada, em **1 hora e 1 minuto**, ao custo de **US$ 0,47**. O adaptador resultante ocupa 161 MB e opera sobre o modelo base quantizado em 4 *bits*, na mesma configuração de inferência do braço A3.

Figura 3 – Perdas de treino e de validação no ajuste supervisionado



Fonte: Elaborado pelo autor

Nota: Treino sobre 672 exemplos; validação sobre 78, agrupada por documento de origem. A perda de treino cai de forma monótona (1,1498 a 0,3347) e a otimização não apresenta instabilidade — não é ela, portanto, que limita o resultado. A de validação atinge o mínimo na época 2 e sobe na terceira, indicando início de sobreajuste; o critério de parada descartou automaticamente a última época, e verificou-se por soma de verificação criptográfica que o adaptador entregue é idêntico ao *checkpoint* da época 2.

A Figura 3 registra o comportamento da validação. A perda cai da primeira para a segunda época e **sobe na terceira**, indicando início de sobreajuste sobre um conjunto de 672 exemplos. O critério de parada selecionou automaticamente o *checkpoint* da época 2, e verificou-se por soma de verificação criptográfica que o adaptador entregue é idêntico a ele. Registra-se a consequência prática: o agrupamento da validação por documento de origem, adotado por causa da predominância do *handbook* corporativo (Seção 5.1), não foi formalidade — **ele mudou o modelo entregue**.

Efeito sobre a validade sintática

O resultado de maior magnitude do trabalho está neste eixo. Os três braços que compartilham o modelo base de 7 bilhões de parâmetros ordenam-se de forma inequívoca:

- **A3m** — *prompt* mínimo, sem adaptador: **0/53**. O modelo produziu BPMN XML em todos os itens, jamais tentando a DSL.
- **A3** — gramática completa no *prompt*: **58,5%**.
- **A4** — *prompt* mínimo, com adaptador: **86,8%**.

A comparação A4 vs. A3m é a que isola melhor o efeito, por manter constante o *prompt* e variar apenas os pesos. A comparação A4 vs. A3 é mais informativa em termos práticos: o modelo especializado supera em 28 pontos percentuais o mesmo modelo instruído pela gramática, e o faz consumindo **753 *tokens* de entrada em vez de 1.351** — a especialização reduz simultaneamente o custo de entrada e a taxa de falha.

O A4 supera em 22 pontos percentuais o braço A2, conduzido por um modelo de fronteira com a primeira versão da gramática no contexto. Contra o A2r, que documenta a referência por rótulo, o A4 **iguala** a validade: 86,8% nos dois. O modelo de 7 bilhões de parâmetros alcança, portanto, a confiabilidade sintática de um modelo de fronteira instruído por *prompt* sem precisar da gramática no contexto: consome 753 *tokens* de entrada, contra 1.452 do A2r.

A igualdade em 86,8% é coincidência

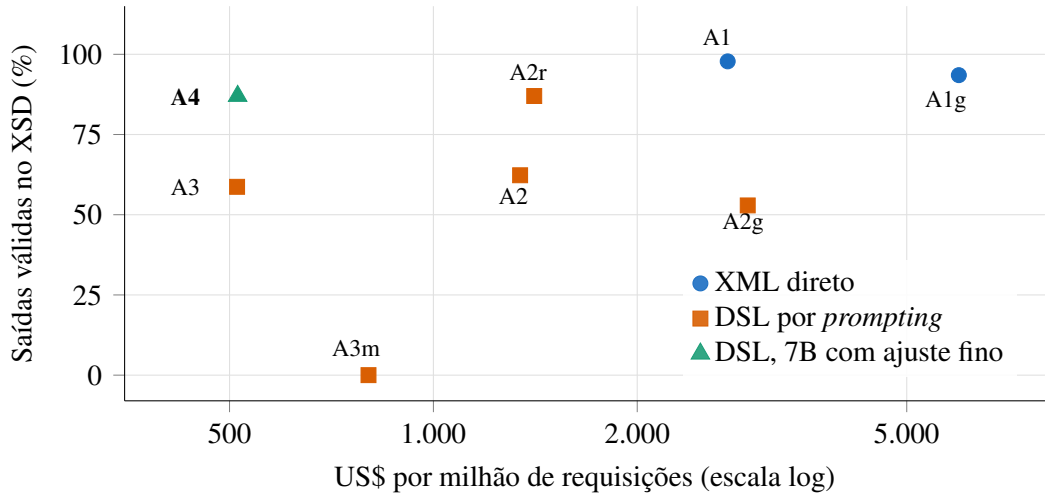
A taxa idêntica não indica um teto da notação. Se houvesse construção que a DSL não expressa, os dois braços falhariam nos mesmos itens; falham em itens quase disjuntos: 7 no A4, 10 no A2r, apenas 2 em comum. Falham também por motivos distintos. O A4 erra de modo sistemático, sempre nos mesmos itens nas três repetições, e quase só por referência a identificador não declarado (15 das 21 falhas), o que é coerente com um treino que só contém essa forma (Seção **??**). O A2r erra de modo disperso, por deslizes variados de sintaxe e por referências por rótulo a nós ainda não escritos (7 das 21). A parte que pertence à notação é a referência, presente nos dois, e algumas irregularidades de superfície, como o separador exclusivo do *gateway* paralelo.

Contrastes exploratórios

Os contrastes envolvendo A4 que não constam do plano confirmatório são reportados sem correção de múltiplas comparações e sem valor confirmatório. A4 supera A3 com efeito $r_{rb} = 0{,}405$ e $p = 0{,}013$; A4 supera A3m com efeito máximo ($r_{rb} = 1{,}0$), o que é trivial dado que A3m pontua zero em todos os itens.

O eixo econômico

Figura 4 – Custo por requisição contra validade sintática, por braço



Fonte: Elaborado pelo autor

Nota: Canto superior esquerdo é o desejável: alta validade a baixo custo. Custo = *tokens* médios de entrada e de saída × preço público por *token* no Together AI, consultado em 24/10/2026, sem cache de *prompt* (Tabela 4). Os braços do modelo pequeno usam o preço do Qwen2.5-7B-Instruct, e o A4, o cenário mais caro (adaptador com acréscimo de 50%); nenhum provedor consultado oferece hoje esse adaptador por *token*. O cenário com cache é discutido na Seção 5.6.7.

A Figura 4 posiciona os braços no plano entre custo por requisição e validade, que é a forma mais direta de expor o argumento central do trabalho. Sem cache e fora do horário de pico, o A4 custa cerca de US$ 506 por milhão de requisições no cenário mais caro, contra US$ 1.380 do A2r e US$ 2.626 do A1, com 86,8% de validade; o treinamento custou menos de um dólar. O cenário com cache e as ressalvas sobre o preço do modelo pequeno estão na Seção 5.6.7.

O A1 permanece à frente em validade (98,1%) e em fidelidade (0,1942), e o A2r, em fidelidade. A afirmação que os dados sustentam não é de superioridade absoluta, e sim de **posição favorável na fronteira entre custo e qualidade** — que é precisamente o enunciado delimitado na Seção **??**.

5.6.5 Verificações de Validade do Resultado Adverso

Um resultado contrário às hipóteses do autor exige o mesmo escrutínio que um resultado favorável, e preferencialmente antes de ser aceito. Quatro verificações foram executadas.

Simetria do casamento de rótulos. O DF-F1 identifica nós por rótulo, com alinhamento por Jaccard (Seção **??**). Se um formato induzisse rótulos sistematicamente mais longos ou mais curtos, o limiar penalizaria os formatos de modo desigual e contaminaria o contraste. Mediu-se o comprimento dos rótulos efetivamente emitidos: mediana de **3,0 palavras em todos os quatro braços**, com médias entre 3,02 e 3,46, contra 3,61 na referência. A penalidade é simétrica; o contraste não está contaminado por esse caminho.

Revalidação independente do XSD. A taxa de 98,1% do braço A1 foi reverificada submetendo-se as 53 saídas novamente ao esquema oficial, a partir do texto bruto armazenado. A concordância com o valor registrado foi total, sem saídas vazias. A validade do baseline é real, não artefato de contabilização.

Truncamento. Os braços de DSL não registraram truncamento algum; os de XML registraram 3 e 2 gerações truncadas em 159. O teto de *tokens* não é fator explicativo do resultado. Medição prévia sobre o conjunto de referência já havia estabelecido que o pior caso do XML lógico consome 4.232 dos 8.192 *tokens* disponíveis, e o pior caso da DSL, 520 dos 2.048.

Correção de defeito no tratamento de cercas. Durante a análise do braço A3m identificou-se que a função de remoção de cercas *markdown* exigia delimitador de fechamento, ausente por construção em saídas truncadas, deixando a abertura no texto e reprovando o candidato por defeito do instrumento. O viés não seria neutro: emitir cerca é hábito mais treinado em XML, e os braços de XML são os que mais se aproximam do teto. O defeito foi corrigido antes da execução dos braços A1 e A1g, com teste de regressão, e verificou-se que o braço A3m permanece inalterado — suas 53 saídas são XML e seguem sem aceitação pela gramática. Registra-se por integridade: a correção **favoreceu o baseline** contra o qual a hipótese do trabalho compete.

5.6.6 Emendas ao Protocolo Congelado

O pré-registro admite emendas mediante declaração explícita de data, motivo e de sua anterioridade ou posterioridade à observação dos resultados. Três emendas foram registradas, e sua divulgação integral é aqui cumprida. Elas diferem no ponto que mais importa: a primeira só podia prejudicar as hipóteses do autor; a segunda e a terceira só podiam favorecê-las.

E-1: glosa das palavras-chave no *prompt* de DSL

Após a execução do braço A3, constatou-se que o bloco de gramática do *prompt* listava as palavras-chave dos *gateways* sem vinculá-las aos nomes de conceito empregados no bloco de regras de modelagem — este último deliberadamente neutro quanto à notação, por ser compartilhado com o braço de XML. Adicionalmente, o *prompt* exibia duas formas distintas de sintaxe de ramificação sem advertir que uma não generaliza para a outra. O *prompt* de XML não requer glosa equivalente, pois a terminologia BPMN já integra o pré-treinamento dos modelos; a omissão penalizava, portanto, **apenas os braços de DSL**.

Ambos os defeitos são verificáveis pela leitura dos artefatos e pela submissão de construções ao *parser*, sem qualquer referência a pontuação obtida — critério adotado para distinguir emenda legítima de racionalização posterior. A emenda foi realizada **depois** de observados os resultados do A3, e é defensável apenas porque seu efeito possível era unicamente contrário às hipóteses do autor: elevar o A3 reduz o ganho aparente que o A4 poderá reivindicar.

Tabela 13 – Braço A3 antes e depois da emenda ao *prompt*

Métrica	Antes	Depois
Parsing aceito	27/53	31/53
XSD válido	26/53	31/53
DF-F1	0,0525	0,0666
Palavras-chave inventadas	9	7

Fonte**:** Elaborado pelo autor

Nota**:** As 159 gerações descartadas foram preservadas em arquivo e permanecem auditáveis. Contagem de palavras-chave inventadas sobre a primeira repetição.

O efeito da correção foi **pequeno**, e as palavras-chave inventadas não desapareceram. Conclui-se que o gargalo do braço A3 é a capacidade do modelo de 7 bilhões de parâmetros, não a redação do *prompt*. Esse desfecho é favorável à integridade do trabalho: caso a emenda tivesse elevado substancialmente o A3, boa parte do ganho que o ajuste fino viesse a demonstrar seria atribuível a um defeito introduzido pelo próprio autor, e não ao método.

E-2: correção do transpilador quanto à unicidade de identificadores

Em 25 de agosto de 2026, já observados todos os resultados, identificou-se defeito no transpilador: quando uma referência `#id` era redeclarada como declaração completa, emitia-se

um **segundo** elemento com o mesmo identificador. O XSD da BPMN tipa identificadores como `xs:ID`, cuja unicidade é requisito do documento; a saída era, portanto, inválida por construção.

O defeito é verificável sem qualquer referência a pontuação obtida — basta submeter ao esquema oficial uma DSL que redeclare uma referência. Dois testes de regressão foram acrescentados e **verificou-se que ambos falham sem a correção**, o que fixa a asserção em código e não em prosa.

A direção do efeito, contudo, inverte-se em relação à E-1, e isso exige rigor maior, não menor. Corrigir o transpilador só pode **elevar** a validade dos braços de DSL, que são os braços cuja superioridade o autor postulou. Uma correção favorável à própria hipótese, aplicada depois de vistos os resultados, é exatamente a categoria de decisão que o pré-registro existe para constranger. Três salvaguardas foram adotadas: a correção foi aplicada a **todos** os braços simultaneamente, por reprocessamento determinístico da saída bruta armazenada, sem nova chamada a modelo algum; nenhum braço foi reprocessado isoladamente; e o efeito é aqui reportado por inteiro.

O efeito foi **seis linhas em mil quinhentas e noventa**. Três no braço A2g (validade de 54,7% para 56,6%) e três no braço exploratório de curva de aprendizado com 25% dos dados (86,8% para 88,7%). Os demais braços não registraram alteração alguma — em particular, **o braço A4 não mudou**, de modo que o resultado central do trabalho não foi tocado pela correção que o favoreceria.

Nenhuma ordenação de tabela se alterou e nenhum desfecho de hipótese mudou. A hipótese H1g permanece refutada, com p_{Holm} passando de 0,005 para 0,006 e tamanho de efeito de $-0{,}463$ para $-0{,}429$: a correção moveu o resultado marginalmente na direção da hipótese do autor, e ainda assim a hipótese continua refutada. As 1.021 saídas do corpus de *augmentation* foram reprocessadas e permaneceram **idênticas byte a byte**, o que confirma que o defeito só se manifestava em DSL gerada por modelo, e não na produzida pelo pipeline determinístico.

Registre-se, por fim, que o defeito estava visível na própria tabela de resultados antes de ser procurado: o braço A2g exibia 56,6% de *parsing* contra 54,7% de validade XSD, ao passo que a nota da Figura 2 afirma — corretamente, como especificação do transpilador — que as duas taxas coincidem nos braços de DSL, pois a transpilação é determinística. A discrepância entre a nota e a tabela era a assinatura do defeito. Após a correção, a igualdade vale em todos os braços de DSL.

E-3: referência por rótulo na notação

Em 12 de outubro de 2026, já observados todos os resultados, a análise das 56 falhas de *parsing* do braço A2 mostrou que 41 delas (73%) eram de referência: 28 identificadores nunca declarados e 13 declarações tentadas depois do uso, fora do fluxo. É o mesmo mecanismo diagnosticado nos braços ajustados (Seção 5.6.12): marcar um nó com identificador exige saber, ao emiti-lo, que um ramo posterior voltará a ele. Em 21 das 28 referências não resolvidas, o nó-alvo já havia sido escrito sem identificador; nenhuma apontava para nó ainda não escrito.

A emenda acrescenta à notação uma segunda forma de referência, pelo rótulo, restrita a nós já emitidos (Seção 4.3), e um braço, A2r, que repete o A2 alterando o *prompt* apenas no bloco de referências. Antes da execução foram fixados a regra de correspondência (rótulo normalizado, igualdade exata), os desfechos (validade, DF-F1 e TCR, contra o A2) e o compromisso de reportar o braço qualquer que fosse o resultado. A forma por rótulo não altera resultado anterior algum: as 1.021 amostras do corpus produzem XML idêntico byte a byte, e as saídas já gravadas de todos os braços mantêm o mesmo desfecho.

Como a E-2, esta emenda só podia favorecer as hipóteses do autor, e por isso não substitui nada: H1 e H3 continuam decididas sobre o A2, e os contrastes com o A2r são reportados como exploratórios, sem correção de Holm (Seção 5.6.2). Uma decisão tomada antes da execução operou contra o braço novo: referências por rótulo a nós ainda não escritos não foram suportadas, porque nenhuma ocorria no A2; no A2r, 7 das 21 falhas são exatamente desse tipo.

Tabela 14 – Braço A2 contra A2r

Métrica	A2	A2r
XSD válido (por geração)	64,8%	**86,8%**
Itens com ao menos uma saída válida	40/53	**50/53**
DF-F1 (média das medianas por item)	0,1375	**0,1804**
DF-F1 médio das saídas válidas	0,217	0,214
TCR	7,03	6,91

Fonte**:** Elaborado pelo autor

Nota**:** Mesmo modelo (DeepSeek V4 Pro), mesmo teto de *tokens* e mesmo *prompt*, exceto o bloco que descreve as referências. Análise exploratória.

O efeito é grande e localizado. O modelo adotou a forma nova em 94 das 159 saídas, e a validade sobe 22 pontos percentuais: 20 itens melhoram e 3 pioram (Wilcoxon $p = 0{,}0045$, exploratório). A qualidade das saídas válidas não se altera (DF-F1 médio de 0,217 e 0,214), de

modo que o ganho é de forma, e não de modelagem. A troca custa 1,7% de compressão.

5.6.7 Eixo Econômico

A hipótese H4 estipulava TCR ≥ 2 nos braços com representação intermediária. A Tabela 15 apresenta o resultado.

Tabela 15 – Compressão e custo de saída por braço

Braço	Saída	*Tokens* (mediana)	TCR	Redução
A1	XML	631	—	—
A1g	XML	699	—	—
A2	DSL	138	**7,03**	85,8%
A2r	DSL	141	6,91	85,5%
A2g	DSL	149	6,70	85,1%
A3	DSL	159	6,70	85,1%
A4	DSL	**200**	**6,50**	**84,6%**

Fonte**:** Elaborado pelo autor

Nota**:** IC95% da TCR: A2 [6,88; 7,17], A2r [6,78; 7,04], A2g [6,57; 6,83], A3 [6,44; 6,94], A4 [6,38; 6,62]. Nos braços de XML direto não há representação intermediária e a razão não é definida; reportá-la como 1,0 apresentaria uma tautologia como resultado. O A4 emite mais *tokens* que os demais braços de DSL por produzir saída válida com mais frequência — as falhas de *parsing* dos outros braços são frequentemente truncadas ou degeneradas, e portanto curtas.

H4 é confirmada com folga: a razão observada situa-se em torno de 7, contra o limiar de 2. O braço A2 emite **138 *tokens* medianos contra 631 do A1** — uma redução de 4,6 vezes no custo de saída para a mesma tarefa. Registra-se que a TCR medida sobre as saídas dos braços (7,03) supera a medida sobre o corpus de treino (6,01, Seção 5.4), o que é coerente com a medição prévia sobre o conjunto de referência, que indicava razão de 8,84 para os itens do PMo especificamente. O A2r, com a referência por rótulo, emite 141 *tokens* medianos (TCR de 6,91): a forma nova custa 1,7% de compressão.

Custo por requisição

A TCR mede só a saída. O custo de uma requisição inclui a entrada, e nela está a principal diferença entre os braços de DSL: o A2r carrega a gramática no *prompt*, o A4 não. A Tabela 16 aplica a definição da Seção **??** aos três braços que sustentam o argumento.

Três leituras. Primeira: no mesmo modelo, emitir DSL em vez de XML reduz o

Tabela 16 – Custo por requisição

Braço	Entrada	Saída	Sem cache	Com cache	XSD
A1 (DeepSeek, XML)	1.306	891	2.626	1.896	98,1%
A2r (DeepSeek, DSL)	1.611	160	1.380	455	86,8%
A4 (7B, DSL)	912	212	337–506	120–179	86,8%

Fonte**:** Elaborado pelo autor

Nota**:** Custo em US$ por milhão de requisições. Entrada e saída: *tokens* médios por geração, com o tokenizador do modelo pequeno. Preços públicos consultados em 12/10/2026, fora do horário de pico (no pico, o modelo de fronteira custa o dobro): US$ 0,66 e 1,98 por milhão de *tokens* de entrada e de saída, e US$ 0,022 em cache. A4: preço de mercado de um modelo de 7 bilhões de parâmetros, US$ 0,30 por milhão, ou 0,45 com acréscimo de 50% pelo adaptador; em cache, a mesma proporção do modelo de fronteira (hipótese). Por saída válida, sem cache: A1 2.677, A2r 1.589, A4 388–583.

custo por requisição em 47% (US$ 1.380 contra 2.626 por milhão de requisições), porque a saída cai de 891 para 160 *tokens*. Segunda: no braço A2r a **entrada** domina o custo, pois o trecho fixo do *prompt*, que contém a gramática, ocupa 1.449 dos 1.611 *tokens* de entrada; o modelo especializado dispensa a gramática, e o ajuste fino economiza, assim, também na entrada. Terceira: o A4 sai de 2,7 a 4,1 vezes mais barato que o A2r sem cache, e de 2,5 a 3,8 vezes com cache.

O cenário com cache exige cuidado, porque muda a escala da comparação. O provedor do modelo de fronteira cobra o trecho repetido do *prompt* a um trigésimo do preço, e com isso o custo do A2r cai de US$ 1.380 para 455. Comparar esse valor com o A4 sem cache favoreceria o modelo de fronteira por construção, já que o *prompt* do A4 também se repete (750 de seus 912 *tokens* de entrada). Aplica-se, por isso, ao modelo pequeno a mesma proporção de desconto.

Duas ressalvas acompanham os valores do A4. Não foi encontrado provedor que sirva adaptador LoRA próprio sobre o modelo base cobrando por *token*: os principais oferecem adaptadores apenas em implantação dedicada, cobrada por hora. Os valores do A4 são, portanto, o preço de mercado de um modelo de 7 bilhões de parâmetros, com e sem acréscimo de 50% pelo adaptador, e não uma oferta verificada; no cenário com cache, a proporção de desconto é ela própria hipótese. Além disso, a contagem de *tokens* usa o tokenizador do modelo pequeno para todos os braços, o que aproxima os valores do modelo de fronteira.

A conclusão que os números sustentam é delimitada: a notação compacta reduz o custo de qualquer modelo que a emita, e o modelo pequeno especializado a emite com a validade do modelo de fronteira a um custo de duas a quatro vezes menor, sob a condição de ser servido a

preço de mercado. Em fidelidade topológica ele é inferior ao A2r (Seção 5.6.2), e é essa a troca que o modelo pequeno oferece.

5.6.8 Limitação Relevante da Métrica de Fidelidade

Os valores absolutos de DF-F1 são baixos em todos os braços, incluindo os de modelos de fronteira, e a interpretação desse fato exige cautela. Investigação sobre o braço A2 revelou que **apenas 40,5% dos rótulos da referência encontram par no candidato** sob o limiar de Jaccard adotado, com mediana de 12 rótulos na referência contra 9,5 no candidato — isto é, os modelos produzem processos da escala correta, porém **nomeiam as atividades de modo distinto**.

Como cada aresta do multiconjunto *direct-follows* depende do alinhamento de **dois** rótulos, uma taxa de alinhamento de 40,5% deprime o F1 muito abaixo desse patamar. Um item ilustrativo obteve DF-F1 nulo apesar de XSD válido: onde a referência registra *Clarify shipment method*, o candidato escreveu *Clarify shipping responsibility* — paráfrase cuja sobreposição de *tokens* normalizados fica abaixo do limiar.

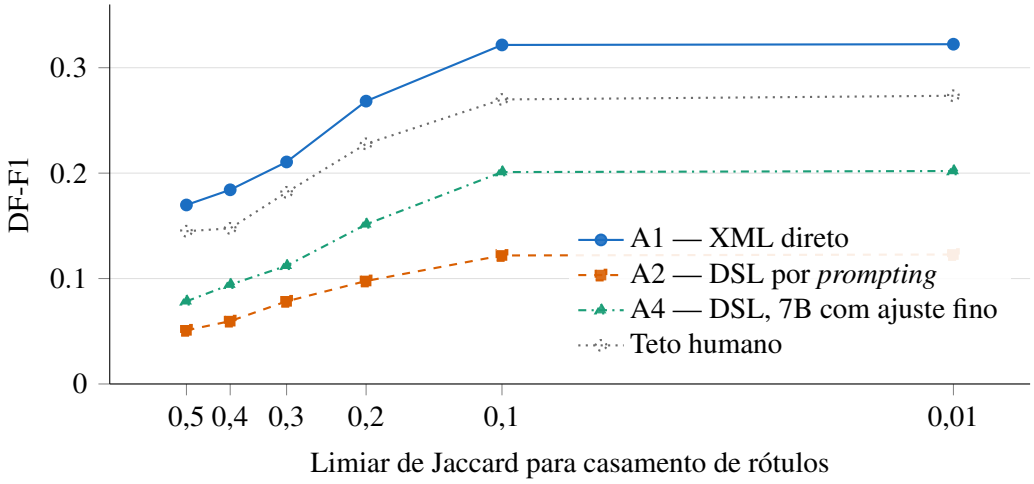
Decorrem daí duas consequências. A primeira é que **o DF-F1 absoluto não deve ser lido como percentual de acerto**; ele constitui um limite inferior severo, que penaliza paráfrase junto com erro estrutural sem distinguir as duas causas. A segunda é que **as comparações entre braços permanecem válidas**, pois todos são submetidos ao mesmo critério, com a simetria de comprimento de rótulo verificada na Seção 5.6.5.

A Figura 5 quantifica a afirmação. Afrouxando-se o limiar de 0,5 até 0,01 — ponto em que qualquer sobreposição de *tokens* basta para casar dois rótulos —, nenhuma série ultrapassa 0,33, e as curvas achatam-se antes mesmo do extremo. O que resta depois de neutralizada a divergência lexical é **divergência estrutural**: os modelos, humanos inclusive, discordam sobre quais arestas o processo possui. E o teto humano acompanha as curvas dos braços em toda a faixa — permanece abaixo do A1 e acima dos braços de DSL em todos os limiares —, o que significa que a saturação não é limitação dos métodos avaliados, e sim da tarefa sob esta métrica.

Itens estruturalmente inatingíveis

A heterogeneidade de nomenclatura do conjunto de referência produz um efeito mais severo do que a degradação gradual descrita acima. Em **8 dos 53 itens**, **todos os sete braços** obtêm DF-F1 exatamente zero — inclusive os conduzidos por modelos de fronteira. As

Figura 5 – Saturação do DF-F1 conforme o casamento de rótulos é afrouxado



Fonte**:** Elaborado pelo autor

Nota**:** Séries calculadas sobre os **24 itens com referência múltipla**, o recorte em que o teto humano é medido. O valor congelado no protocolo é 0,5; os demais pontos são análise de sensibilidade e não substituem a métrica primária. Mesmo com o casamento praticamente livre (0,01), nenhuma série passa de 0,33 — o resíduo é divergência estrutural, não lexical. O teto humano não contém saídas inválidas, por construção; os braços contam-nas como zero.

referências desses itens não são degeneradas: possuem de 4 a 73 arestas.

A causa é convenção de nomenclatura incompatível com a instrução dada aos modelos. As referências desses itens nomeiam atividades como **orações em terceira pessoa com o ator por sujeito**, ao passo que o bloco de regras de modelagem instrui explicitamente a forma imperativa sem ator. Três exemplos, extraídos da referência e do braço A4 no mesmo item:

IP checks the request of the INQ vs. `Check Request`

MPOO confirmes the dismissal vs. `Confirm Dismissal`

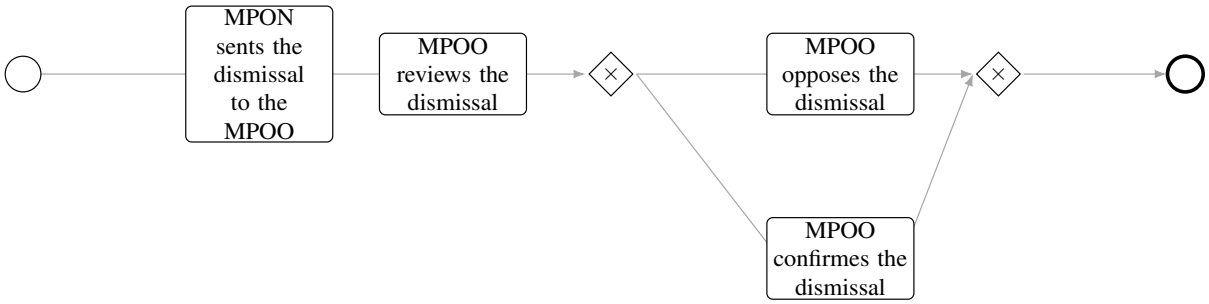
MPON sents the dismissal to the MPOO vs. `Send Dismissal`

Os rótulos desses oito itens têm **5,22 palavras** em média, contra 3,47 nos demais — e a diferença de comprimento, somada à ausência de radicalização morfológica no casamento (*checks* não casa com *check*), coloca a similaridade de Jaccard estruturalmente abaixo do limiar. Nenhum modelo que siga a instrução recebida pode pontuar nesses itens.

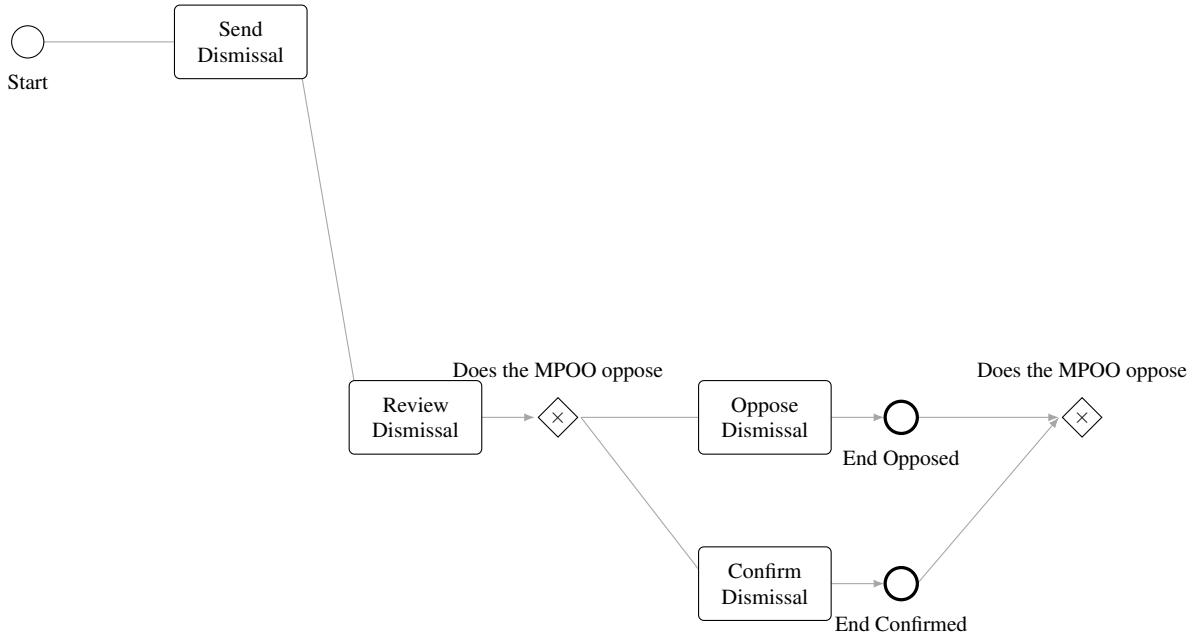
O efeito sobre os resultados é uniforme e não altera ordenação alguma: excluindo-os, A1 passa de 0,1942 para 0,2287, A2 de 0,1375 para 0,1619 e A4 de 0,1114 para 0,1312 — elevação de cerca de 18% em todos. Os valores reportados neste capítulo **incluem** os oito itens, conforme o protocolo congelado; a exclusão é apresentada apenas como quantificação do efeito.

Figura 6 – Divergência de nomenclatura sem divergência de estrutura (*pmo_52*)

(a) Referência de especialista



(b) Braço A4 — modelo de 7B com ajuste fino **DF-F1** $= 0{,}000$



Fonte**:** Elaborado pelo autor

Nota**:** Item selecionado pela regra, declarada antes da inspeção, de **menor número de nós na referência entre os itens em que o braço A4 produziu saída válida** — critério de legibilidade, independente de pontuação. Os diagramas usam a topologia e o leiaute automáticos do próprio *pipeline*; apenas o espaçamento vertical foi ampliado, porque os rótulos da referência ocupam quatro a cinco linhas e estouram a altura reservada ao nó pelo leiaute. A referência escreve *MPOO confirmes the dismissal*; o candidato, *Confirm Dismissal*. A sobreposição de *tokens* normalizados fica abaixo do limiar de casamento, e a aresta correspondente é contabilizada como erro estrutural.

A Figura 6 torna o fenômeno concreto. O braço A4 produziu, para o item *pmo_52*, um modelo de processo que qualquer leitor reconhece como descrição correta do mesmo fluxo da referência — mesma sequência, mesma decisão, mesmos dois desfechos — e obteve **DF-F1 igual a zero**. É a demonstração mais direta disponível de que o valor absoluto da métrica não deve ser lido como percentual de acerto.

O limiar não foi alterado. Diferentemente da emenda descrita na Seção 5.6.6, cujo efeito possível era exclusivamente contrário às hipóteses do autor, afrouxar o casamento de

rótulos após observar que a métrica produz valores baixos elevaria indistintamente todos os braços — movimento que o pré-registro existe para impedir. Recomenda-se, como trabalho futuro, análise de sensibilidade sobre múltiplos limiares, reportada como verificação de robustez, mantendo-se o valor congelado como número primário.

5.6.9 Não Avaliabilidade do Eixo de Fluxos de Mensagem

O Eixo 3 (Seção **??**) previa a medição de MF-F1 sobre os fluxos de mensagem entre participantes. Constatou-se que **apenas 2 dos 53 itens do conjunto de avaliação** — *pmo_23* e *pmo_38* — possuem `messageFlow` no modelo de referência. O eixo é, portanto, **não avaliável** neste conjunto, e os valores são reportados como descritivos, jamais como base de comparação entre braços.

A limitação é dupla. A primeira é de **potência**: seis linhas por braço (2 itens $\times$ 3 repetições) não sustentam inferência estatística de espécie alguma, e nenhum teste foi conduzido sobre elas. A segunda é de **construção da métrica**, e produz o efeito ilustrado na Tabela 17: quando referência e candidato não têm fluxo de mensagem, o F1 é definido como 1,0 por vacuidade. Em 125 das 159 gerações do braço A1 esse é o caso, de modo que a média sobre todas as linhas (0,786) mede predominantemente a ausência de mensagens, e não o acerto sobre elas.

Tabela 17 – MF-F1 restrito aos dois itens com fluxo de mensagem na referência

Braço	MF-F1	Gerações que emitiram `messageFlow`
A1	0,500	3/6
A1g	0,000	6/6
A2	0,167	0/6
A2g	0,333	0/6
A3	0,500	0/6

Fonte**:** Elaborado pelo autor

Nota**:** N = 6 linhas por braço (2 itens $\times$ 3 repetições). Valores descritivos; nenhum teste de hipótese foi conduzido sobre eles.

A tabela evidencia o problema de forma direta: o braço A1g emitiu `messageFlow` em todas as seis gerações e obteve MF-F1 nulo, enquanto o A3 não emitiu em nenhuma e obteve 0,500. Um número que ordena assim os braços não está medindo competência em modelar comunicação entre participantes — está medindo, sobretudo, coincidência de ausências.

Registra-se que essa fragilidade havia sido antecipada no protocolo, que já determi-

nava reportar o MF-F1 apenas sobre os itens cuja referência contém mensagens e jamais somá-lo ao DF-F1. A execução confirmou a previsão e acrescentou a magnitude: com 2 itens, a restrição prescrita pelo protocolo esvazia o eixo em vez de corrigi-lo.

A consequência prática é que **avaliar geração de colaborações BPMN exige um conjunto de avaliação construído para esse fim**. O PMo, concebido para processos únicos, não o oferece, e nenhuma correção de métrica supre ausência de dados. Fica registrado como trabalho futuro, e como critério para a seleção de conjuntos de avaliação em extensões deste trabalho.

5.6.10 Teto Humano da Métrica

A seção anterior estabelece que o DF-F1 penaliza divergência de nomenclatura como se fosse erro estrutural. Resta quantificar a magnitude dessa penalidade, e o conjunto de referências múltiplas permite fazê-lo diretamente: as 172 referências alternativas cobrem 24 itens com 4 a 11 modelos distintos do **mesmo** processo, todos aprovados por especialista. Comparar essas referências **entre si** mede o quanto dois modeladores humanos competentes concordam — isto é, o valor máximo que qualquer método pode razoavelmente aspirar.

A medição aplica aos especialistas exatamente o tratamento dado aos braços: cada referência é pontuada contra as demais sob a regra do máximo. Pares exatamente idênticos são descartados, pois em 17 dos 24 itens a referência primária coincide com uma das alternativas — ambas derivam da mesma fonte — e mantê-los mediria autocomparação.

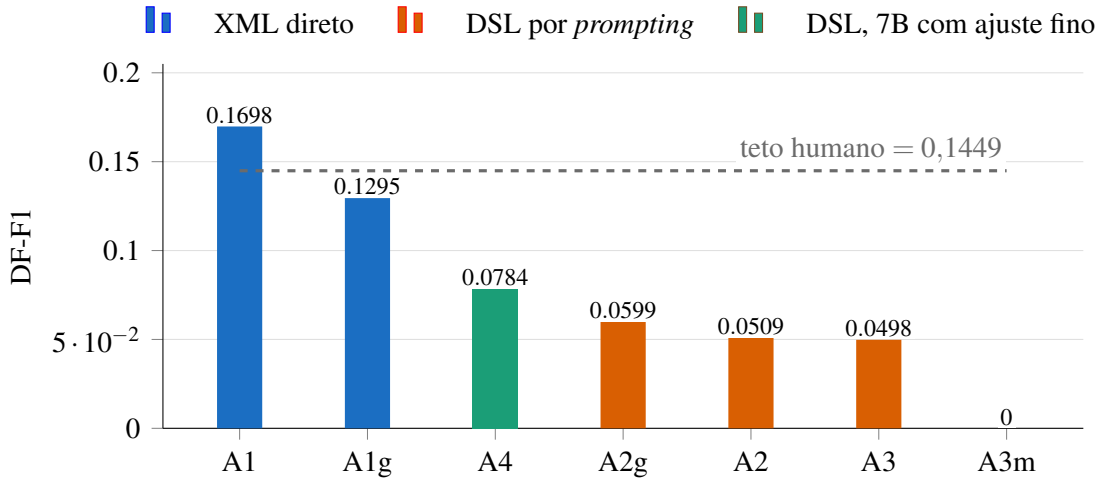
Tabela 18 – Desempenho relativo ao teto humano (24 itens com referência múltipla)

Origem do modelo	DF-F1	% do teto
A1 (DeepSeek → XML)	0,1698	**117%**
Teto humano (especialista vs. especialista)	**0,1449**	—
A1g (GLM → XML)	0,1295	89%
Pipeline de augmentation	0,1103	76%
A4 (Qwen 7B + SFT)	**0,0782**	**54%**
A2g (GLM → DSL)	0,0624	43%
A2 (DeepSeek → DSL)	0,0498	34%
A3 (Qwen 7B → DSL)	0,0473	33%
A3m (Qwen 7B, *prompt* mínimo)	0,0000	0%

Fonte**:** Elaborado pelo autor

Nota**:** Restrito aos 24 itens com referência múltipla, para que todas as linhas sejam comparáveis — inclusive a do teto, medida sobre esses mesmos itens. Os valores diferem da Tabela 9, calculada sobre os 53 itens, e a ordenação entre braços não é a mesma nos dois recortes. O teto aparece em posição ordenada, e não como cabeçalho, porque um dos braços o supera.

Figura 7 – Fidelidade topológica por braço, relativa à concordância entre especialistas



Fonte**:** Elaborado pelo autor

Nota**:** Média das medianas por item sobre os **24 itens com referência múltipla** — o mesmo recorte em que o teto é medido, para que barras e linha comparem a mesma coisa; os valores sobre os 53 itens estão na Tabela 9. O teto humano é a concordância média entre referências de especialista do mesmo processo, sob a mesma regra do máximo aplicada aos braços (Seção 5.6.10). Apenas o braço A1 o ultrapassa.

O teto humano situa-se em **0,1449**, e a Figura 7 o apresenta como linha de referência sobre os sete braços. A consequência é de primeira ordem para a leitura de todo este capítulo: **os valores de DF-F1 não devem ser comparados a 1,0**, que é inalcançável, mas a essa faixa. O braço A1 não obtém 19% de um máximo teórico — obtém **117% da concordância que dois especialistas humanos exibem entre si** sobre os mesmos processos.

O mecanismo é aritmético e coerente com a Seção 5.6.8. Mediu-se em 30,5% a taxa média com que dois especialistas concordam quanto aos rótulos. Como cada aresta do multiconjunto *direct-follows* exige o alinhamento de **dois** rótulos, a concordância esperada ao nível de aresta cai para a ordem de $0{,}305^2 \approx 0{,}09$, antes ainda de exigir que a aresta exista em ambos os modelos. Uma métrica de identidade lexical aplicada a uma tarefa com liberdade de denominação satura, portanto, muito abaixo da unidade.

Três consequências são registradas. A primeira é que **a refutação de H1 permanece válida**: o contraste A2 vs. A1 é pareado, aplicado às mesmas referências e ao mesmo critério, e a ordenação entre braços não depende da escala absoluta. A segunda é que **a magnitude do efeito deve ser lida contra o teto**, e não contra a unidade, sob pena de superestimar a distância que separa os métodos avaliados do desempenho humano. A terceira é que **o pipeline de augmentation opera a 76% do teto humano**, superando todos os braços que emitem DSL, o que reposiciona o oráculo discutido na seção seguinte.

Registra-se a limitação da própria estimativa: o teto é obtido sobre 24 itens, e não

sobre os 53, por serem os únicos com referência múltipla. Trata-se, ainda assim, da melhor estimativa disponível, e sua ausência levaria a interpretação sistematicamente pessimista de todos os resultados reportados. O recorte tem, além do tamanho, um efeito de ordenação que merece registro: nele o braço A4 (0,0782) fica **acima** dos dois braços de DSL conduzidos por modelos de fronteira, invertendo a ordem observada sobre os 53 itens da Tabela 9. Com 24 itens e diferenças dessa magnitude, a inversão é evidência de fragilidade da ordenação — não de superioridade do braço especializado.

5.6.11 Validação do Pipeline de Augmentation

A verificação do Eixo 2 (Seção 5.3), com 99,6% de equivalência exata, atesta a fidelidade da cadeia **determinística** JSON → DSL → XML. Ela nada afirma, contudo, sobre o passo **anterior** — a conversão de texto em prosa para o JSON canônico, executada por modelos de linguagem — que até a obtenção do conjunto de referência jamais fora confrontado com modelagem humana. O conjunto *gold* do PMo fecha esse ponto cego, e a medição correspondente é reportada aqui.

Construiu-se para isso um **oráculo**: a DSL produzida pelo próprio pipeline de augmentation para os 53 itens do PMo, transpilada e pontuada contra as referências de especialista pela mesma métrica aplicada aos braços. Esse valor estima o **teto** que o ajuste fino poderia alcançar, pois representa o desempenho de um modelo que reproduzisse os dados de treinamento com fidelidade perfeita.

Tabela 19 – Oráculo do pipeline de augmentation contra o *gold*

Origem do modelo	DF-F1	Rótulos alinhados	Arestas	*n*
Gold (referência)	—	—	18	53
A1 (DeepSeek → XML)	0,1942	40,1%	12	53
Pipeline de augmentation	0,1533	41,3%	14	53
A2 (DeepSeek → DSL)	0,1375	40,5%	13,5	40
A4 (Qwen 7B + SFT)	0,1114	38,2%	13	46

Fonte**:** Elaborado pelo autor

Nota**:** Arestas: mediana do multiconjunto *direct-follows*. Rótulos alinhados: proporção dos rótulos da referência com par no candidato sob o limiar de Jaccard adotado, excluídas as categorias de evento anônimo, que são tipo e não denominação. O DF-F1 segue a regra congelada, na qual geração inválida conta zero; as duas colunas de diagnóstico são calculadas apenas sobre as gerações válidas de cada origem (*n*), pois documento inválido não tem rótulo nem aresta a comparar — zerá-las faria a coluna medir validade, que é o que a primeira já mede.

O oráculo situa-se em **0,1533** sobre os 53 itens, e em 0,1103 no subconjunto de referência múltipla — **76% do teto humano** estabelecido na Seção 5.6.10, acima de todos os braços que emitem DSL e abaixo apenas dos braços de XML direto.

A leitura correta desse valor exige a moldura da seção anterior. Confrontado com a unidade, o oráculo sugeriria dado de treinamento gravemente defeituoso; confrontado com o teto, indica que **o pipeline de augmentation produz modelos cuja divergência em relação à referência é da ordem da divergência entre dois especialistas humanos**. O limite que ele impõe a H3 é, portanto, real mas moderado, e não o obstáculo intransponível que a comparação ingênua sugeriria.

A investigação das causas descartou três explicações que a inspeção superficial sugeria. A primeira é perda de paralelismo na conversão: o JSON canônico registra *gateways* paralelos em 68% dos itens do PMo e a DSL preserva 66%, com perda residual compatível com a da Seção 5.3.2. A segunda é afastamento do vocabulário de origem por efeito dos dois estágios de processamento por modelo de linguagem: mediu-se a proporção de palavras do rótulo presentes no texto-fonte e obteve-se 69,6% para o pipeline, contra 69,9% da própria referência de especialista — o pipeline é, portanto, **tão ancorado no texto original quanto o humano**, com diferença de três décimos de ponto. O braço A1 fica acima dos dois, em 76,1%: o modelo de fronteira reaproveita mais palavras da descrição do que o especialista, o que não recupera a hipótese descartada. A terceira é subdimensionamento estrutural: a contagem de arestas do pipeline (14) é a **mais próxima** da referência (18) entre todas as origens avaliadas.

O que resta como explicação é a **escolha lexical**: pipeline e especialista extraem denominações distintas do mesmo texto, ambas legítimas e ambas ancoradas na fonte, e o DF-F1 pontua tal divergência como erro estrutural. E aqui a Seção 5.6.10 fornece o parâmetro decisivo: a taxa de alinhamento de rótulos do pipeline com a referência é de **41,3%**, ao passo que dois especialistas humanos alinham entre si a **30,5%** — esta última medida sobre os 24 itens com referência múltipla, como o teto de DF-F1, e portanto comparável apenas em ordem de grandeza. O pipeline opera **acima da faixa de variação humana** quanto à denominação de atividades, e o mesmo vale para todas as demais origens da Tabela 19, que se distribuem entre 38% e 41%.

A consequência prática é que **não há defeito de nomenclatura a corrigir**. Tentar elevar o alinhamento acima desse patamar significaria ajustar o pipeline às escolhas lexicais idiossincráticas de um modelador específico — e, como todas as referências disponíveis pertencem à partição *holdout*, tal ajuste constituiria contaminação do conjunto de avaliação, não melhoria de método. Registra-se a decisão de não o fazer.

Registra-se ainda uma divergência de composição entre treino e avaliação, de efeito distinto: o pipeline atribui raias a **100%** das amostras, enquanto apenas **3 dos 53** modelos de referência as empregam. Como raias particionam elementos sem alterar relações de precedência, a divergência não afeta o DF-F1; ela é registrada por constituir viés de estilo herdável pelo ajuste fino, e por decorrer da predominância do *handbook* corporativo documentada na Seção 5.1.

A conclusão metodológica generaliza para além deste trabalho: **validar a porção determinística de um pipeline de geração de dados não valida o pipeline**. A etapa probabilística que a antecede requer confronto com referência independente, e a ausência desse confronto permaneceu invisível enquanto o único critério disponível foi a consistência interna entre representações.

5.6.12 Braços Exploratórios

Os braços descritos nesta seção **não integram o conjunto pré-registrado**. Foram definidos após a observação dos resultados confirmatórios, vivem em espaço de nomes próprio (prefixo `X-`) e nenhum deles entra nos contrastes submetidos à correção de Holm. A separação é sustentada por teste automatizado. Seus resultados são indicativos e orientam trabalho futuro; não sustentam afirmação confirmatória alguma. O braço A2r, embora pertença ao mesmo espaço de nomes, é reportado no corpo do capítulo, junto à emenda que o introduziu (Seção 5.6.6).

Curva de aprendizado: mais dados ajudariam?

A pergunta é de decisão prática — vale investir em coletar mais dados? — e admite resposta empírica sem coleta nova, treinando com **menos**. Treinaram-se dois modelos adicionais sobre subconjuntos do mesmo corpus, lendo-se a inclinação da curva na sua borda direita.

Duas decisões de amostragem tornam a curva interpretável. Primeira, a amostra é **por documento de origem, não por exemplo**: como 95,3% do treino provém de um único *handbook*, sortear exemplos soltos mediria o efeito de rotular mais seções do mesmo documento, que é outra pergunta. Segunda, as frações são **aninhadas** — a ordem dos documentos vem do *hash* do nome e cada fração é um prefixo dessa ordem, de modo que $25\% \subset 50\% \subset 100\%$ (verificado por asserção). Sem o aninhamento, a curva confundiria efeito de volume com efeito de composição do corpus. O conjunto de validação é **o mesmo nos três pontos**, sem sobreposição de documentos com o treino.

O resultado é uma **dissociação**. A *loss* de validação melhora de forma monótona

Tabela 20 – Curva de aprendizado sobre subconjuntos aninhados do treino

Braço	Documentos	Exemplos	*Loss* de val.	XSD-Val	DF-F1
X-lc25	51	167	0,4945	88,7%	0,1000
X-lc50	96	339	0,4488	86,8%	0,1141
A4	207	672	**0,4160**	86,8%	0,1114

Fonte**:** Elaborado pelo autor

Nota**:** O ponto de 100% é o próprio adaptador do braço A4, não um treino novo: regerá-lo produziria outro adaptador e invalidaria números já reportados sob protocolo congelado. *Loss* de validação é o melhor valor entre as três épocas, sobre os mesmos 78 exemplos de validação nos três pontos.

com o volume — 0,4945, 0,4488, 0,4160 —, exatamente como se espera. As métricas da tarefa, porém, **não acompanham**: a validade sintática vai de 88,7% a 86,8%, e o DF-F1 oscila entre 0,1000 e 0,1141 sem tendência. A diferença de validade entre o menor e o maior ponto corresponde a três gerações em 159, o que a coloca abaixo de qualquer limiar de relevância.

A leitura é que, **neste corpus**, o dado adicional compra verossimilhança e não capacidade: o modelo torna-se melhor em prever o próximo *token* da notação sem tornar-se melhor em produzir modelos válidos e fiéis. A explicação mais provável é a que já se registrou como ameaça à validade externa — quase todo o treino provém de uma única fonte, de modo que "mais dados"significou, aqui, mais do mesmo documento. A implicação prática é específica e não deve ser generalizada além dela: **coletar mais seções do mesmo *handbook* não é investimento produtivo**; coletar de fontes distintas permanece não testado, e é a pergunta que a curva não responde.

Registre-se ainda um sinal de convergência coerente com o volume: os dois pontos reduzidos ainda melhoravam na terceira época, ao passo que o ponto completo atingiu seu melhor valor na segunda e piorou na terceira. Menos dados, convergência mais tardia — o que indica que os pontos reduzidos não foram prejudicados por treino insuficiente.

Replicação em outras famílias de modelos

O braço A4 estabelece que o ajuste fino viabiliza a notação em **um** modelo. Se o resultado dependesse de particularidade do Qwen, a contribuição seria sobre esse modelo e não sobre o método. Treinaram-se, portanto, réplicas em outras famílias, sob protocolo idêntico — mesmo corpus, mesmos hiperparâmetros, mesma divisão, mesmo *prompt* — variando apenas o modelo base. **Registrou-se antes da execução o compromisso de reportar toda réplica treinada, replicasse ela ou não.**

Tabela 21 – Replicação do ajuste fino em três famílias

Braço	Modelo base	*Tokenizador*	XSD-Val	Itens	DF-F1
A4	Qwen2.5-Coder-7B	151.665	**86,8%**	46/53	0,1114
X-gr	Granite 4.1-8B	100.352	83,0%	44/53	0,0992
X-mi	MiMo-7B-RL	151.665	83,0%	44/53	0,1009
X-ds	DeepSeek-Coder-6.7B	—	**invalidado** — ver adiante		

Fonte**:** Elaborado pelo autor

Nota**:** Braços exploratórios, fora do conjunto pré-registrado. O X-mi emprega o **mesmo** tokenizador do A4 (`Qwen2Tokenizer`, 151.665 entradas); o X-gr emprega `GPT2Tokenizer` com 100.352. A comparação de *loss* entre vocabulários distintos não é lícita e não é feita.

O método replica. Duas famílias adicionais alcançam 83,0% de validade — rigorosamente o mesmo número, 132 gerações válidas em 159 e 44 itens em 53 — contra 86,8% do Qwen. A diferença de 3,8 pontos corresponde a seis gerações. Nenhuma das réplicas supera o braço original, e nenhuma fracassa: o ajuste fino sobre esta notação não é propriedade de um modelo.

Um controle não planejado tornou-se disponível. O MiMo compartilha com o Qwen **o tokenizador exato**, ao passo que o Granite usa outro, com dois terços do vocabulário. Se a tokenização governasse o comportamento, o MiMo deveria assemelhar-se ao Qwen. Não é o que se observa:

Tabela 22 – Uso da construção de referência por família

Braço	Itens em que emprega `#ref`	Falhas referenciais	Taxa condicional
A4 (Qwen)	45	5	**11,1%**
X-gr (Granite)	23	8	34,8%
X-mi (MiMo)	24	8	33,3%

Fonte**:** Elaborado pelo autor

Nota**:** O X-mi usa o mesmo tokenizador do A4 e comporta-se como o X-gr, que usa outro.

O MiMo comporta-se como o Granite, não como o Qwen. Segue-se que a divergência **não é artefato de tokenização**: é propriedade do pré-treinamento. E as duas estratégias são distintas diante da mesma dificuldade — o Qwen emprega a construção com liberdade e erra pouco; os outros dois a evitam, restringindo-a a cerca de metade dos itens, e erram três vezes mais quando a arriscam. Essa observação só se tornou possível porque ambas as réplicas foram executadas, e ilustra por que o compromisso de reportar réplicas independentemente do desfecho tem valor informativo, e não apenas ético.

Um braço invalidado, e por quê

O braço X-ds, sobre DeepSeek-Coder-6.7B, foi treinado e avaliado antes de constatar-se que seu tokenizador, sob a versão de biblioteca empregada, **não preserva espaços na ida e volta**: `decode(encode(t))` difere de `t`, fragmentando a notação. Treino e avaliação estavam corrompidos pela mesma causa, e por isso o braço é descartado em vez de reportado — seus 75,5% não medem o método. A verificação prévia que ele havia passado testava a coincidência dos identificadores de *token* entre *prompt* e alvo, invariante que se mantém quando ambos são corrompidos do mesmo modo; a verificação foi substituída pelo teste de ida e volta, que é o que de fato importa. O episódio é registrado por três razões: o braço consumiu recursos, sua ausência da tabela precisa de explicação, e a distinção entre "não replicou"e "não foi medido"é justamente o tipo de informação que a omissão destruiria.

Registre-se, por fim, que um quarto braço (X-ms, Mistral-7B) **não foi executado**, conforme regra fixada antes da execução: ele estava previsto apenas como substituto caso o MiMo falhasse em um teste de compatibilidade arquitetural. O MiMo passou, e o substituto não roda.

O resíduo de falhas é predominantemente referencial

Os braços com a notação nos pesos falham pouco e falham de modo **concentrado**. A Tabela 23 decompõe o resíduo.

Tabela 23 – Natureza das falhas de *parsing* por braço

Braço	Notação	Itens que falham	Taxa condicional	Erro dominante
A3	no *prompt*	22	—	léxico (66/66)
A4	nos pesos	7/45	15,6%	referência (5/7)
X-gr	nos pesos	9/23	39,1%	referência (8/9)
X-mi	nos pesos	9/24	37,5%	referência (8/9)
X-lc25	nos pesos	6/38	15,8%	referência (3/6)
X-lc50	nos pesos	7/49	14,3%	referência (7/7)

Fonte**:** Elaborado pelo autor

Nota**:** "Itens que falham"é contado sobre os itens em que o braço emitiu ao menos uma referência; a taxa condicional é o quociente. Nos braços ajustados, as falhas são determinísticas por item: as três repetições falham ou acertam em conjunto. O erro dominante "referência"corresponde a `Unresolved DSL ref`.

Duas leituras. A primeira é que o ajuste fino **elimina a falha léxica**: o braço A3, mesmo modelo base com a gramática no *prompt*, falha 66 vezes em 66 por caractere inesperado

e nenhuma por referência; os braços ajustados não registram esse erro de modo dominante em nenhum caso. Aprender a notação é, sobretudo, deixar de errar sua superfície.

A segunda é que o resíduo se concentra num único mecanismo: das 38 falhas de item somadas nos cinco braços ajustados, **31 são referências não resolvidas** — 82% do total. O modelo emite `#t07` sem jamais ter declarado `#t07`.

A taxa condicional separa-se com nitidez em dois regimes. Entre os braços construídos sobre o Qwen, ela é **estável em 14,3% a 15,8%** apesar de volumes de treino que variam por fator de quatro — o que exclui o volume como explicação. Entre as réplicas em outras famílias, ela sobe para 37,5% e 39,1%, mas sobre uma base muito menor de itens: Granite e MiMo empregam a construção em cerca de metade dos itens em que o Qwen a emprega. O que **não** varia é a natureza do resíduo — referencial em todos os cinco braços.

Diagnóstico do mecanismo: a notação exige antecipação

A causa da falha foi isolada, e não é capacidade do modelo. Na notação avaliada, um nó só pode ser referenciado se houver sido **marcado no momento de sua emissão** com um identificador explícito. Nos dados de treino essa disciplina é perfeita — os 690 exemplos declaram todas as referências que usam, sem uma única exceção — porque foram produzidos por transpilação determinística, que conhece o grafo inteiro antes de escrevê-lo. Um gerador autorregressivo não dispõe dessa informação: das 200 referências do treino, **151 apontam para trás**, a uma distância mediana de 334 caracteres. Para acertá-las, o modelo teria de saber, ao emitir um nó, que um ramo ainda não escrito voltaria a ele.

O mecanismo faz uma predição verificável: se a falha decorre de arestas de retorno, ela deve concentrar-se nos itens cujo modelo de referência contém **ciclo**. A predição confirma-se na direção esperada — todas as falhas referenciais dos três braços ajustados ocorrem em itens com ciclo (5/5 no A4, 8/8 no X-gr, 8/8 no X-mi), e nenhum dos 13 itens acíclicos falhou em braço algum. O teste, contudo, é **subdimensionado**: 40 dos 53 itens contêm ciclo, de modo que a concentração observada não atinge significância isoladamente ($p = 0{,}23$ no A4 e $p = 0{,}09$ no X-gr e no X-mi, teste exato de Fisher unilateral), e agregar os braços não é lícito, pois compartilham os mesmos itens. A observação vale como corroboração do mecanismo, não como estabelecimento estatístico da associação.

O que o modelo faz, diante disso, é notavelmente sistemático. Ele adota a convenção majoritária do treino — identificadores da forma `#tNN`, que aparecem 753 vezes — e a emprega

posicionalmente: `#t03` designa a terceira tarefa emitida. Interpretando as referências não resolvidas sob essa regra, e substituindo-as pelo *slug* do rótulo correspondente, obtêm-se documentos válidos em 12 das 15 falhas do A4 e em **24 das 24** tanto do X-gr quanto do X-mi. O modelo não alucina identificadores: ele mantém um esquema coerente que a notação não sabe ler.

Três observações delimitam o alcance dessa análise. Primeira, **a totalidade das falhas referenciais é reparável alterando apenas a forma da referência** — o corpo do documento está correto, e é só o endereçamento que falha. Segunda, o reparo eleva a validade a um teto de 96,2% no A4 e 98,1% no X-gr e no X-mi, mas esse número é um **limite superior** obtido com conhecimento do alvo, e não uma medição de desempenho. Terceira, e mais importante para a honestidade do argumento, o DF-F1 **não tem poder** para confirmar que a referência reparada aponta para o nó semanticamente pretendido: uma aresta de retorno é uma entre dezenas do multiconjunto, e sua realocação quase não move a métrica. De fato, no X-gr o reparo posicional (0,1251) e um reparo arbitrário (0,1247) são indistinguíveis. A evidência sustenta que o esquema do modelo é *sistemático*; não sustenta que seja *correto*.

A consequência de projeto é direta e o custo foi medido. O transpilador já resolve referências **por rótulo**: a resolução tenta o identificador declarado, depois o *slug* do rótulo, depois a declaração adiante. Referenciar os nós pelo rótulo que o próprio modelo acabou de emitir elimina inteiramente a exigência de antecipação, pois o rótulo é conteúdo que já está no contexto do gerador e não precisa ter sido planejado. Reescrevendo o corpus de treino nessa forma, o custo é de **2,31% em *tokens*** — 7,7 *tokens* por exemplo, o que levaria a TCR de aproximadamente 7,0 para 6,8. Contra os 85% de economia que a notação entrega, a troca é praticamente gratuita, e a tensão com o eixo econômico que se poderia supor não se materializa. A forma por rótulo foi depois incorporada à notação e testada no modelo de fronteira (emenda E-3, Seção 5.6.6): a validade do mesmo modelo subiu de 64,8% para 86,8%, ao custo de 1,7% de compressão nas saídas. No modelo especializado ela permanece **não testada** — exigiria retreinar sobre o corpus reescrito — e é o trabalho futuro mais bem fundamentado que esta avaliação produziu.

5.6.13 Síntese

A Tabela 24 consolida o estado das hipóteses.

O conjunto de evidências sustenta uma cadeia argumentativa distinta daquela originalmente antecipada, e mais informativa que ela:

Tabela 24 – Estado das hipóteses registradas

Hipótese	Enunciado	Desfecho
H1	A2 $\geq$ A1 em DF-F1	**Refutada** ($p_{Holm} = 0{,}039$)
H1g	A2g $\geq$ A1g em DF-F1	**Refutada** ($p_{Holm} = 0{,}006$)
H2	A2 $>$ A1 em XSD-Val	**Refutada** (64,8% vs 98,1%)
H3	A4 $\geq$ A2 em DF-F1	Não refutada, não demonstrada ($p_{Holm} = 0{,}25$)
H4	TCR ≥ 2 nos braços DSL	**Confirmada** (TCR ≈ 7)

Fonte**:** Elaborado pelo autor

1. Fornecer a notação **no contexto**, em sua primeira versão, foi inferior a permitir que o modelo emitisse o formato que já domina — H1, H1g e H2 refutadas, com replicação em duas famílias de modelos.
2. A causa **não era a novidade** da notação, e sim a forma de referência, que exige antecipação. Com a referência por rótulo (emenda E-3, exploratória), o mesmo modelo de fronteira passa de 64,8% a 86,8% de validade e empata com a geração direta de XML em fidelidade.
3. O ajuste fino remove a mesma barreira por outro caminho. A progressão 0% $\rightarrow$ 58,5% $\rightarrow$ 86,8%, sobre o mesmo modelo base, mede o ganho de mover a especificação do *prompt* para os pesos, e o modelo de 7 bilhões alcança a validade do modelo de fronteira sem gramática no contexto.
4. Em **fidelidade topológica** o modelo especializado empata com o A2 (H3 não refutada, nem demonstrada), mas é inferior ao A2r e não alcança a geração direta de XML.
5. A métrica de fidelidade **satura próximo ao ruído**: dois especialistas humanos concordam a 0,1449, e todos os braços operam nessa vizinhança. Comparações de fidelidade acima desse patamar não discriminam qualidade.
6. O ganho econômico é **substancial**: a notação reduz em cerca de 85% os *tokens* emitidos e em 47% o custo por requisição no mesmo modelo, e o modelo especializado custa de duas a quatro vezes menos que o de fronteira com a DSL, sob a hipótese de ser servido a preço de mercado.

A afirmação que o conjunto sustenta é, portanto, delimitada e verificável: **uma notação compacta, desenhada para geração da esquerda para a direita, reduz em cerca de 85% os *tokens* emitidos sem perda de fidelidade frente à geração direta de XML pelo mesmo modelo; e um modelo de 7 bilhões de parâmetros, especializado ao custo de menos de um dólar, emite essa notação com a mesma validade de um modelo de fronteira, com fidelidade menor, a uma fração do custo por requisição.** Não se afirma superioridade sobre a geração direta de XML por modelo de fronteira, nem que o modelo pequeno alcance a fidelidade

deste — os dados não a sustentam, e a Seção 5.6.10 indica que a métrica disponível dificilmente sustentaria tal afirmação para método algum.

Das cinco hipóteses registradas, três foram refutadas, uma ficou indeterminada e uma foi confirmada, e todas são reportadas como tais.

Fora do conjunto pré-registrado, e portanto sem força confirmatória, três achados exploratórios orientam o que vem depois. O primeiro, e de maior alcance, é o da emenda E-3: a forma de referência explicava a maior parte das falhas da notação, e corrigi-la elevou o modelo de fronteira à validade do modelo especializado. A curva de aprendizado (Seção 5.6.12) indica que **mais dados da mesma fonte não elevam as métricas da tarefa**, ainda que reduzam a *loss* de validação — o que desloca o esforço de coleta para fontes distintas, e não para mais volume. E o resíduo de falhas do modelo especializado é **predominantemente referencial**, o mesmo traço que a E-3 corrigiu no modelo de fronteira; retreiná-lo com a referência por rótulo é o passo seguinte. Nenhum dos três é resultado deste trabalho no sentido confirmatório; todos são hipóteses agora fundamentadas em medição.

6 CONCLUSÕES E TRABALHOS FUTUROS

O objetivo geral deste trabalho (Seção 1.2.1) foi investigar se a geração de uma representação intermediária comprimida, seguida de expansão determinística, produz modelos BPMN 2.0 válidos de forma mais confiável e mais econômica em *tokens* do que a geração direta de XML. A resposta obtida é **parcialmente afirmativa, e sua parte negativa é tão informativa quanto a positiva**.

Quanto à economia, a resposta é inequívoca: a representação proposta reduz em cerca de 85% o volume de *tokens* que o modelo precisa emitir, com razão de compressão em torno de 7 medida sobre as saídas efetivamente geradas. Quanto à confiabilidade, a resposta dependeu menos da novidade da notação do que de um traço de seu desenho. Na primeira versão, fornecida por *prompt*, a notação **piorou** o resultado: os braços que descreviam a gramática no contexto, com os modelos DeepSeek e GLM, obtiveram 64,8% e 56,6% de validade, respectivamente, contra 98,1% e 94,3% da geração direta de XML pelos mesmos modelos. A análise das falhas localizou a causa na forma de referência, que exigia declarar identificadores antes de saber que seriam usados; acrescentada a referência por rótulo, o mesmo modelo de fronteira passou a 86,8% de validade, com fidelidade estatisticamente indistinguível da geração direta de XML. Por outro caminho, o ajuste fino supervisionado levou um modelo de sete bilhões de parâmetros aos mesmos 86,8%, sem a gramática no contexto. Nenhuma das duas configurações alcança a validade da geração direta de XML.

A explicação organiza os achados do trabalho. O obstáculo não foi a novidade da notação, e sim a exigência de antecipação: um modelo autorregressivo gera da esquerda para a direita e não revisa o que já escreveu, de modo que uma notação que o obriga a marcar, ao emitir um nó, que um ramo futuro voltará a ele cria uma falha que nenhuma instrução remove. Removida essa exigência, a notação compacta torna-se emissível por instrução em contexto. O ajuste fino deixa, assim, de ser condição necessária da abordagem e passa a ser uma escolha de custo: ele dispensa a gramática no contexto e permite que um modelo pequeno substitua o de fronteira, ao preço de menor fidelidade.

6.1 CONTRIBUIÇÕES DO TRABALHO

Artefato técnico. Uma linguagem de domínio específico para descrição de processos, com gramática EBNF formalmente especificada, e um transpilador determinístico que a expande em XML BPMN 2.0. Sobre as 1.021 amostras ativas, a cadeia produz 100% de documentos

válidos contra o esquema oficial da OMG e preserva a equivalência topológica em 99,6% dos casos, com resíduo composto exclusivamente por arestas excedentes — isto é, o modo de falha remanescente nunca descarta lógica do processo de origem.

Evidência empírica sobre representações intermediárias. Três hipóteses foram refutadas com significância estatística e replicação em duas famílias de modelos: na primeira versão da notação, descrevê-la em *prompt* foi inferior a deixar o modelo emitir o formato que já domina, em fidelidade e em validade. A análise desse resultado negativo, registrada como emenda posterior à observação dos dados, mostrou que a inferioridade em fidelidade decorria quase inteiramente de falhas de forma, e desaparece com a correção da notação. O pré-registro do protocolo (Seção **??**) é o que permite relatar as duas coisas na ordem em que ocorreram.

Um princípio de desenho de notações para geração. Notações destinadas a serem emitidas por modelos autorregressivos não devem exigir que o gerador anuncie, ao escrever um elemento, que ele será referenciado adiante. A referência deve poder apontar para o que já está escrito, usando conteúdo presente no contexto do gerador, como o rótulo. No caso estudado, essa única alteração elevou a validade de um modelo de fronteira de 64,8% para 86,8%, ao custo de 1,7% de compressão. O princípio não depende da BPMN: aplica-se a qualquer notação com referências cruzadas, como identificadores em grafos, rótulos em linguagens de montagem ou âncoras em documentos.

Viabilidade econômica da especialização. A notação compacta reduz em 47% o custo por requisição do mesmo modelo de fronteira. O modelo ajustado emite a notação com a mesma validade desse modelo, sem a gramática no contexto, a um custo de duas a quatro vezes menor sob preço de mercado, com ou sem cache de *prompt*, e custou menos de um dólar para ser treinado; o patamar de validade foi replicado, em verificação exploratória, em duas famílias adicionais de modelos (Seção 5.6.12). Sua fidelidade topológica é indistinguível da obtida pelo modelo de fronteira com a primeira versão da notação, porém inferior à obtida com a versão corrigida. A afirmação sustentada pelos dados não é de superioridade, e sim de uma troca explícita: mesma validade e menor fidelidade, a uma fração do custo.

Contribuição metodológica. Mediu-se o **teto humano** da métrica de fidelidade adotada (Seção 5.6.10): duas referências de especialista para o mesmo processo concordam entre si em DF-F1 de apenas 0,1449, e em apenas 30,5% dos rótulos. Todos os métodos avaliados operam nessa vizinhança, e apenas um deles — a geração direta de XML pelo modelo de fronteira independente — a ultrapassa. Decorre daí que **métricas estruturais com identidade de nó por rótulo saturam próximo ao ruído** quando aplicadas a uma tarefa sem resposta única, e que

reportá-las contra um máximo teórico de 1,0 conduz a interpretação sistematicamente pessimista. Essa observação não depende da BPMN nem da linguagem aqui proposta, e é possivelmente a contribuição de maior alcance do trabalho.

6.2 LIMITAÇÕES

Validade externa do conjunto de treino. 95,3% das amostras de treinamento provêm de uma única fonte, o *handbook* corporativo da GitLab (Seção 5.1). O modelo especializado é, portanto, treinado predominantemente sobre o estilo redacional de uma organização e avaliado contra um conjunto de domínio distinto. Ampliar o volume só reduz esse risco se as amostras vierem de fontes novas.

Replicação do ajuste fino apenas exploratória. O patamar de validade do modelo especializado foi replicado em duas famílias adicionais de modelos — Granite e MiMo, com 83,0% de validade em ambas contra 86,8% do braço principal (Seção 5.6.12) —, de modo que a alegação não repousa sobre família única. As réplicas foram, contudo, executadas como braços exploratórios, fora do protocolo pré-registrado, e não carregam força confirmatória. O espaço de modelos tampouco se esgota nelas: o braço sobre uma quarta família foi invalidado por defeito de tokenização antes de qualquer medição, e o comportamento referencial divergiu entre as famílias — a taxa condicional de falha, estável entre 14% e 16% na família do modelo principal, sobe a 37–39% nas outras duas —, indício de que parte do resultado é propriedade do pré-treinamento, e não do método.

Teto imposto pelos dados de treinamento. A saída do próprio *pipeline* de geração de dados, pontuada contra as referências, alcança DF-F1 de 0,1533 (Seção 5.6.11). Um modelo que aprendesse o conjunto de treinamento com fidelidade perfeita não superaria esse valor, o que limita superiormente qualquer ganho atribuível ao ajuste fino sob os dados atuais.

Limitações da métrica primária. Além da saturação já discutida, oito dos cinquenta e três itens de avaliação produzem DF-F1 nulo em **todos** os braços, incluindo os de geração direta de XML. A causa é convenção de nomenclatura: essas referências nomeiam atividades como orações em terceira pessoa com o ator por sujeito, ao passo que o protocolo instrui a forma imperativa. Como o casamento de rótulos não aplica radicalização morfológica, a similaridade fica estruturalmente abaixo do limiar. O efeito é uniforme entre braços e não altera ordenação alguma, mas deprime todos os valores absolutos em cerca de 18%.

Eixo de fluxos de mensagem não avaliável. Apenas dois dos cinquenta e três itens

possuem `messageFlow` na referência (Seção 5.6.9), o que impede qualquer inferência sobre a capacidade de modelar comunicação entre participantes.

Dimensão do conjunto de avaliação. Com $n = 53$ itens e variância elevada, os contrastes têm potência estatística modesta. A ordenação entre braços chegou a inverter-se entre o conjunto completo e o subconjunto com referência múltipla, o que recomenda cautela na leitura de diferenças pequenas.

Correção da notação avaliada de forma exploratória e em um único modelo. A referência por rótulo foi introduzida depois de observados os resultados (emenda E-3), e seus contrastes não têm força confirmatória. Foi avaliada apenas com o modelo de fronteira independente; sua replicação no segundo modelo de fronteira, e no modelo especializado, que nunca observou essa forma em treino, não foi executada.

Custo do modelo especializado estimado, não observado. Não foi encontrado provedor que sirva adaptador LoRA próprio cobrando por *token*. O custo do modelo especializado é o preço de mercado de um modelo de mesmo porte, e, no cenário com cache de *prompt*, a proporção de desconto aplicada é hipótese. O tempo de inferência não foi comparado, pois os modelos foram executados em infraestruturas distintas.

6.3 TRABALHOS FUTUROS

Refinamento do casamento de rótulos. Radicalização morfológica e remoção de ator no início do rótulo endereçam diretamente a limitação mais severa identificada, e podem ser avaliadas como verificação de robustez sobre múltiplos limiares, preservando-se o valor congelado como número primário. Alterar o limiar após observar que a métrica produz valores baixos elevaria indistintamente todos os braços, motivo pelo qual não foi feito neste trabalho.

Referência por rótulo no modelo especializado. A forma de referência por rótulo, testada no modelo de fronteira (emenda E-3), não foi testada no modelo ajustado, cujo corpus contém apenas referências por identificador. É a extensão mais bem fundamentada que esta avaliação produziu: 15 das 21 falhas do modelo especializado são referências a identificadores não declarados, exatamente a classe que a forma por rótulo eliminou no modelo de fronteira. Reescrever o corpus nessa forma custa 2,31% em *tokens* e não exige dado novo, apenas retreino. Na mesma linha, cabe estender a forma por rótulo a nós ainda não escritos, que respondem por 7 das 21 falhas restantes do modelo de fronteira, e replicá-la no segundo modelo de fronteira.

Ampliação do corpus por fontes distintas. A curva de aprendizado executada

sobre frações aninhadas do conjunto (25%, 50% e 100%) mostrou que a perda de validação melhora monotonicamente com o volume, mas as métricas da tarefa não a acompanham — mais dados da mesma fonte compram verossimilhança, não capacidade (Seção 5.6.12). A questão que permanece em aberto é o efeito de **fontes novas**, que combinam volume com diversidade estilística, sobre um treino hoje concentrado em 95,3% num único *handbook* (Seção 5.1).

Aprendizado por reforço com recompensa verificável. A etapa prevista na Seção **??** permanece como extensão, com a ressalva ali registrada: a recompensa restrita a componentes verificáveis sem referência é explorável, pois premia a emissão da menor saída sintaticamente válida. Seu reparo exige um termo de ancoragem no texto de origem, cuja calibração constitui contribuição autônoma.

Decodificação restrita como linha de base concorrente. Garantir conformidade sintática durante a geração é alternativa direta ao que a correção da notação e o ajuste fino alcançaram aqui por outros caminhos, e o contraste entre as duas estratégias — uma que restringe o espaço de saída, outra que o internaliza — não foi avaliado.

Generalização para além da BPMN. A hipótese que motivou o trabalho é independente do domínio: aplica-se a qualquer esquema formal cuja serialização oficial seja verbosa. Avaliar o mesmo protocolo sobre outra linguagem de marcação testaria se os padrões observados — o efeito da forma de referência sobre a geração autorregressiva e o ganho de custo da especialização — são propriedades gerais da abordagem ou particularidades da BPMN.

REFERÊNCIAS

AA, H. van der *et al.* Challenges and opportunities of applying natural language processing in business process management. In: *Proceedings of the 27th International Conference on Computational Linguistics*. Santa Fe, New Mexico, USA: Association for Computational Linguistics, 2018. p. 2791–2801. Disponível em: <https://aclanthology.org/C18-1236/>.

Artificial Analysis. **Artificial Analysis Intelligence Index**. 2026. <https://artificialanalysis.ai/models>. Disponível em: <https://artificialanalysis.ai/models>. Acesso em: 24 out. 2026.

BELCAK, P.; HEINRICH, G.; DIAO, S.; FU, Y.; DONG, X.; MURALIDHARAN, S.; LIN, Y. C.; MOLCHANOV, P. Small language models are the future of agentic AI. **arXiv preprint arXiv:2506.02153**, 2025. Disponível em: <https://arxiv.org/abs/2506.02153>.

BELLAN, P.; AA, H. van der; DRAGONI, M.; GHIDINI, C.; PONZETTO, S. P. PET: An annotated dataset for process extraction from natural language text tasks. In: **Business Process Management Workshops: BPM 2022 International Workshops**. Cham: Springer, 2023. (Lecture Notes in Business Information Processing, v. 460), p. 315–321. Disponível em: <https://link.springer.com/chapter/10.1007/978-3-031-25383-6_23>.

BRISSARD, A.; CUPPENS, F.; ZOUAQ, A. **PMo Dataset**. Zenodo, 2025. Version 1.0.0. Disponível em: <https://zenodo.org/records/15857589>. Acesso em: 17 maio 2026.

BRISSARD, A.; CUPPENS, F.; ZOUAQ, A. What is the best process model representation? a comparative analysis for process modeling with large language models. In: **Proceedings of the AI4BPM Workshop at BPM 2025**. [S.l.: s.n.], 2025. Aceito para publicação; pré-print em arXiv:2507.11356.

BROWN, T. B.; MANN, B.; RYDER, N.; SUBBIAH, M. *et al.* Language models are few-shot learners. In: **Advances in Neural Information Processing Systems (NeurIPS)**. [s.n.], 2020. v. 33, p. 1877–1901. Disponível em: <https://proceedings.neurips.cc/paper/2020/hash/1457c0d6bfcb4967418bfb8ac142f64a-Abstract.html>.

CHEN, M.; TWOREK, J.; JUN, H.; YUAN, Q.; PINTO, H. Ponde de O. *et al.* Evaluating large language models trained on code. **arXiv preprint arXiv:2107.03374**, 2021. Disponível em: <https://arxiv.org/abs/2107.03374>.

COOTER, M. **Anthropic's AI services are too expensive, says Microsoft AI head**. 2026. CIO. Disponível em: <https://www.cio.com/article/4181777/anthropics-ai-services-are-too-expensive-says-microsoft-ai-head.html>. Acesso em: 6 set. 2026.

DETTMERS, T.; PAGNONI, A.; HOLTZMAN, A.; ZETTLEMOYER, L. QLoRA: Efficient finetuning of quantized LLMs. In: **Advances in Neural Information Processing Systems (NeurIPS)**. [s.n.], 2023. v. 36. Disponível em: <https://proceedings.neurips.cc/paper_files/paper/2023/hash/1feb87871436031bdc0f2beaa62a049b-Abstract.html>.

DUMAS, M.; ROSA, M. L.; MENDLING, J.; REIJERS, H. A. **Fundamentals of Business Process Management**. 2. ed. Berlin, Heidelberg: Springer, 2018. Disponível em: <https://link.springer.com/book/10.1007/978-3-662-56509-4>.

Fireworks AI. **Deploying Trained Models**. 2026. <https://docs.fireworks.ai/fine-tuning/deploying-loras>. Disponível em: <https://docs.fireworks.ai/fine-tuning/deploying-loras>. Acesso em: 24 out. 2026.

FOWLER, M. **Domain-Specific Languages**. 1. ed. Boston: Addison-Wesley Professional, 2010. ISBN 978-0-321-71294-3. Disponível em: <https://www.informit.com/store/domain-specific-languages-9780321712943>.

FRIEDRICH, F.; MENDLING, J.; PUHLMANN, F. Process model generation from natural language text. In: **Advanced Information Systems Engineering**. Berlin, Heidelberg: Springer, 2011. (Lecture Notes in Computer Science, v. 6741), p. 482–496. Disponível em: <https://link.springer.com/chapter/10.1007/978-3-642-21640-4_36>.

GAO, X.; XIAO, B.; TAO, D.; LI, X. A survey of graph edit distance. **Pattern Analysis and Applications**, v. 13, n. 1, p. 113–129, 2010. Disponível em: <https://link.springer.com/article/10.1007/s10044-008-0141-y>.

Headroom Labs. **Headroom: Compress Tool Outputs, Logs, Files, and RAG Chunks Before They Reach the LLM**. 2026. <https://github.com/headroomlabs-ai/headroom>. Versão 0.27.0. Software de código aberto, licença Apache-2.0. Disponível em: <https://github.com/headroomlabs-ai/headroom>. Acesso em: 8 ago. 2026.

HU, E. J.; SHEN, Y.; WALLIS, P.; ALLEN-ZHU, Z.; LI, Y.; WANG, S.; WANG, L.; CHEN, W. LoRA: Low-rank adaptation of large language models. In: **International Conference on Learning Representations (ICLR)**. [s.n.], 2022. Disponível em: <https://openreview.net/forum?id=nZeVKeeFYf9>.

HUI, B.; YANG, J.; CUI, Z.; YANG, J.; LIU, D.; ZHANG, L.; LIU, T.; ZHANG, J.; YU, B.; LU, K. *et al.* Qwen2.5-Coder technical report. **arXiv preprint arXiv:2409.12186**, 2024. Disponível em: <https://arxiv.org/abs/2409.12186>.

JIANG, H.; WU, Q.; LIN, C.-Y.; YANG, Y.; QIU, L. LLMLingua: Compressing prompts for accelerated inference of large language models. In: **Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing (EMNLP)**. Singapore: [s.n.], 2023. p. 13358–13376. Disponível em: <https://aclanthology.org/2023.emnlp-main.825/>.

KÖPKE, J.; SAFAN, A. Efficient LLM-based conversational process modeling. In: **Business Process Management Workshops (BPM 2024)**. Cham: Springer, 2025. (Lecture Notes in Business Information Processing, v. 534).

KOURANI, H.; BERTI, A.; SCHUSTER, D.; AALST, W. M. P. van der. ProMoAI: Process modeling with generative AI. In: **Proceedings of the Thirty-Third International Joint Conference on Artificial Intelligence (IJCAI-24), Demo Track**. International Joint Conferences on Artificial Intelligence Organization, 2024. p. 8708–8712. Disponível em: <https://www.ijcai.org/proceedings/2024/1014>.

MANGLER, J.; KLIEVTSOVA, N. **Textual Process Descriptions and Corresponding BPMN Models**. Zenodo, 2023. Version 1.0. Disponível em: <https://zenodo.org/records/7783492>. Acesso em: 17 maio 2026.

MERNIK, M.; HEERING, J.; SLOANE, A. M. When and how to develop domain-specific languages. **ACM Computing Surveys**, v. 37, n. 4, p. 316–344, 2005. Disponível em: <https://dl.acm.org/doi/10.1145/1118890.1118892>.

Object Management Group. **Business Process Model and Notation (BPMN), Version 2.0**. Needham, MA, USA, 2011. Documento OMG formal/2011-01-03. Disponível em: <https://www.omg.org/spec/BPMN/2.0/>.

OUYANG, L.; WU, J.; JIANG, X.; ALMEIDA, D.; WAINWRIGHT, C.; MISHKIN, P. *et al.* Training language models to follow instructions with human feedback. In: **Advances in Neural Information Processing Systems (NeurIPS)**. [s.n.], 2022. v. 35. Disponível em: <https://proceedings.neurips.cc/paper_files/paper/2022/hash/b1efde53be364a73914f58805a001731-Abstract.html>.

POESIA, G.; POLOZOV, A.; LE, V.; TIWARI, A.; SOARES, G.; MEEK, C.; GULWANI, S. Synchromesh: Reliable code generation from pre-trained language models. In: **International Conference on Learning Representations (ICLR)**. [s.n.], 2022. Disponível em: <https://openreview.net/forum?id=KmtVD97J43e>.

ROPEK, L. **Uber caps employee AI spending after blowing through budget in four months**. 2026. TechCrunch. Disponível em: <https://techcrunch.com/2026/06/02/uber-caps-employee-ai-spending-after-blowing-through-budget-in-four-months/>. Acesso em: 6 set. 2026.

SANFELIU, A.; FU, K.-S. A distance measure between attributed relational graphs for pattern recognition. **IEEE Transactions on Systems, Man, and Cybernetics**, SMC-13, n. 3, p. 353–362, 1983.

SENNRICH, R.; HADDOW, B.; BIRCH, A. Neural machine translation of rare words with subword units. In: **Proceedings of the 54th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)**. Berlin, Germany: Association for Computational Linguistics, 2016. p. 1715–1725. Disponível em: <https://aclanthology.org/P16-1162/>.

SHAO, Z.; WANG, P.; ZHU, Q.; XU, R.; SONG, J.; BI, X.; ZHANG, H.; ZHANG, M.; LI, Y. K.; WU, Y.; GUO, D. DeepSeekMath: Pushing the limits of mathematical reasoning in open language models. **arXiv preprint arXiv:2402.03300**, 2024. Disponível em: <https://arxiv.org/abs/2402.03300>.

SUGIYAMA, K.; TAGAWA, S.; TODA, M. Methods for visual understanding of hierarchical system structures. **IEEE Transactions on Systems, Man, and Cybernetics**, v. 11, n. 2, p. 109–125, 1981.

Together AI. **LoRA Inference**. 2026. <https://docs.together.ai/docs/lora-inference>. Disponível em: <https://docs.together.ai/docs/lora-inference>. Acesso em: 24 out. 2026.

Together AI. **Pricing**. 2026. <https://www.together.ai/pricing>. Disponível em: <https://www.together.ai/pricing>. Acesso em: 24 out. 2026.

VASWANI, A.; SHAZEER, N.; PARMAR, N.; USZKOREIT, J.; JONES, L.; GOMEZ, A. N.; KAISER, Ł.; POLOSUKHIN, I. Attention is all you need. In: **Advances in Neural Information Processing Systems (NeurIPS)**. [s.n.], 2017. v. 30. Disponível em: <https://papers.nips.cc/paper/7181-attention-is-all-you-need>.

VOELTER, M.; HADIAN, R.; KAMPIK, T.; BREITMAYER, M.; REICHERT, M. **Leveraging Generative AI for Extracting Process Models from Multimodal Documents**. 2024.

WESKE, M. **Business Process Management: Concepts, Languages, Architectures**. 3. ed. Berlin, Heidelberg: Springer, 2019. Disponível em: <https://link.springer.com/book/10.1007/978-3-662-59432-2>.

Apêndices

APÊNDICE A – Prompts dos braços experimentais

[A montar: regras comuns uma vez, depois a parte específica de cada braço, com o sha256 de cada prompt.]

APÊNDICE B – Prompts do juiz de fidelidade e da paráfrase

[A montar: rubrica completa, modelo da mensagem e prompt da paráfrase, com o *hash* da versão usada.]

APÊNDICE C – Piloto de escolha do modelo gerador

[A montar: tabela das três configurações e das três medidas.]

APÊNDICE D – Resultados das hipóteses originais

[A montar: H1 a H3 em DF-F1, como foram registradas.]